

Testi di riferimento

Argomento	Testo
Teoria della probabilità	Ernesto Conte, <i>Fenomeni aleatori</i> — molto didattico, richiede una guida (quella del corso)
Statistica inferenziale	Sheldon Ross, <i>Introduction to Probability and Statistics for Engineers and Scientists</i>

Esame

Modalità d'esame


- Prova scritta + colloquio orale
- 6 CFU, nessun progetto

Perché la Probabilità per l'Informatica?

Idea chiave del corso

Telecomunicazioni e informatica trattano entrambe lo stesso oggetto: **l'informazione**. Le telecomunicazioni la trasferiscono *nello spazio* (da un luogo a un altro); l'informatica la trasferisce *nel tempo* (memorizzazione, compressione, correzione degli errori).

Intrinseco nel concetto di informazione c'è **l'incertezza**: se non c'è incertezza su ciò che viene trasmesso, non c'è informazione da trasmettere.




La **probabilità** è lo strumento formale per modellare l'incertezza. Tutto ciò che va sotto il nome di *machine learning*, *statistical learning*, *deep learning*, reti neurali — è costruito su questa base.

 Citazione del prof

"Mettetevi in testa: se vi parlano di statistica dicendo che è un'altra cosa rispetto alla probabilità, vuol dire che non conoscono la probabilità. La probabilità è la base su cui si costruisce tutto il mondo della statistica."

Programma del Corso



Cherry picking

Essendo un corso da 6 CFU (vs 9 CFU del corso parallelo al 3° anno), alcuni argomenti come la compressione dati (Huffman, codifica aritmetica) e le passeggiate casuali su grafi non saranno trattati in dettaglio. Priorità: **meno argomenti, ma compresi bene.**

Statistica inferenziale vs descrittiva

Tipo	Cosa fa	Importanza
Descrittiva	Calcola statistiche globali su una popolazione data	Limitata ("giocare con Excel")
Inferenziale	Da un campione, inferisce le caratteristiche di tutti i campioni futuri statisticamente omogenei	Alta — base del machine learning

☰ Esempio di inferenza

Progettare un algoritmo di ML: non si vuole un sistema che funzioni solo sul campione di training, ma uno che generalizzi a qualunque campione con gli stessi parametri statistici.

Basi di Teoria della Probabilità

Il Discreto vs il Continuo

💡 Aforisma del prof

"Il discreto riempie la testa di idee; il continuo riempie la lavagna di formule. Se uno capisce bene le idee, le formule sono una conseguenza."

Definizioni Fondamentali

Esperimento

📋 Definizione

Un **esperimento** è un'operazione (o insieme di operazioni) che conduce a **uno tra tanti risultati possibili**.

Spazio dei Campioni Ω

📋 Definizione

Lo **spazio dei campioni** (o *sample space*) è l'insieme di **tutti i possibili risultati** di un esperimento. Si indica con Ω .

$$\Omega = \{\omega_1, \omega_2, \dots\}$$

Può essere:

- **Finito** → es. lancio di una moneta: $\Omega = \{T, C\}$
- **Numerabilmente infinito** → es. numero di pacchetti in coda: $\Omega = \mathbb{N}_0$
- **Non numerabile (continuo)** → es. tensione misurata ai capi di una resistenza (rumore termico): $\Omega = \mathbb{R}$

Discreto vs Continuo nella pratica

In realtà qualunque misura fisica è razionale (strumenti con cifre significative finite), ma quando i valori sono così tanti, si modella come continuo e poi si tronca. Il **tempo** viene solitamente schematizzato come continuo.

Evento

Definizione

Un **evento** è un **sottoinsieme** di Ω definito da una proposizione.
Un **evento elementare** è un singolo elemento di Ω .

La proposizione non è unica!

L'evento è univocamente determinato dagli elementi di Ω che lo compongono, ma la proposizione che lo descrive **non è univoca** (la ridondanza del linguaggio naturale lo permette).

Esempio: ho in tasca 1, 2, 3, 4 o 5 euro. L'evento $\{1, 3, 5\}$ può essere descritto come:

- "ho un numero dispari di euro"
- "non ho un numero pari di euro"
- "ho 1 o 3 o 5 euro"

→ Saper **reformulare** la proposizione in modo conveniente è spesso la chiave per risolvere un esercizio.

Nomenclatura degli eventi

Nome	Definizione	Notazione
Evento certo	Ω stesso — ogni volta che compie l'esperimento si ottiene un elemento di Ω	Ω
Evento impossibile	Insieme vuoto	$\emptyset$
Evento complementare	$A^c =$ elementi di Ω non in A	A^c o $\bar{A}$
Eventi incompatibili	$A \cap B = \emptyset$	—
A implica B	$A \subseteq B$ — il verificarsi di A implica il verificarsi di B (non viceversa)	$A \subseteq B$

☰ Esempio — dado

$A =$ "esce 2", $B =$ "esce un numero pari"

$\rightarrow A \subseteq B$: se esce 2, certamente è uscito un pari. Ma se esce un pari, non è detto che sia 2 (potrebbe essere 4 o 6).

Operazioni sugli Insiemi / Eventi

Riassunto operazioni

Operazione	Definizione
Unione	$A_1 \cup A_2 = \{\omega \in \Omega \mid \omega \in A_1 \text{ oppure } \omega \in A_2\}$
Intersezione	$A_1 \cap A_2 = \{\omega \in \Omega \mid \omega \in A_1 \text{ e } \omega \in A_2\}$
Complemento	$A_1^c = \{\omega \in \Omega \mid \omega \notin A_1\}$
Sottrazione	$A_1 \setminus A_2 = A_1 \cap A_2^c$

Proprietà utili

Proprietà	Formula
Doppio complemento	$(A^c)^c = A$
Complemento di Ω	$\Omega^c = \emptyset$
Unione con complementare	$A \cup A^c = \Omega$
De Morgan	$(A \cup B)^c = A^c \cap B^c$
De Morgan	$(A \cap B)^c = A^c \cup B^c$

Approccio Frequentistico alla Probabilità

Frequenza di successo

Definizione

Dati n esperimenti **indipendenti** (l'esito di uno non influenza gli altri), si definisce **frequenza di successo** dell'evento A su n prove:

$$f_n(A) = \frac{N_A}{n}$$

dove N_A è il numero di volte in cui si è verificato A .

Per un dado **onesto** (eventi elementari equiprobabili):

$$\lim_{n \rightarrow \infty} f_n(A) = \frac{|A|}{|\Omega|}$$

Il cane che si morde la coda

La definizione frequentistica usa implicitamente il concetto di **indipendenza** — che è esso stesso un concetto probabilistico. È una definizione un po' autoriflessiva: per questo il prof darà anche una definizione più rigorosa (assiomatica).

☰ Verifica dell'onestà di un dado

Lancio n volte, conto $N_1, N_2, \dots, N_6$. Il dado è (probabilmente) onesto se:

$$\frac{N_i}{n} \approx \frac{1}{6} \quad \forall i$$

Non è una condizione *sufficiente* (i singoli potrebbero compensarsi), ma è *necessaria*.

Analisi Combinatoria

📋 Perché?

Quando lo spazio dei campioni è **finito** e gli eventi sono **equiprobabili**:

$$P(A) = \frac{|A|}{|\Omega|}$$

Calcolare probabilità significa **saper contare** $|A|$ e $|\Omega|$ in modo efficiente.


Regola del Prodotto Cartesiano

Dati k insiemi $A_1, A_2, \dots, A_k$ con $|A_i| = n_i$:

$$|A_1 \times A_2 \times \dots \times A_k| = \prod_{i=1}^k n_i$$

Questa è la **formula base** da cui derivano tutti i risultati di analisi combinatoria.

k-uple ordinate da n elementi



Con ripetizione ammessa

Il primo elemento si sceglie in n modi, il secondo in n modi, ..., il k-esimo in n modi:

$$\text{k-uple ordinate con ripetizione} = n^k$$

≡ Sequenze binarie

Stringhe binarie di lunghezza n : 2^n

Senza ripetizione (disposizioni)

Il primo in n modi, il secondo in $n - 1$, ..., il k -esimo in $n - k + 1$:

$$D(n, k) = n \cdot (n - 1) \cdots (n - k + 1) = \frac{n!}{(n - k)!}$$

Permutazioni ($k = n$)

$$P(n) = n!$$

Le permutazioni di n elementi sono tutte le n -uple ordinate senza ripetizione degli n elementi stessi.

k -uple non ordinate (Combinazioni)

Due k -uple che differiscono **solo per l'ordine** degli elementi sono considerate la **stessa** combinazione.

Ragionamento chiave

Tra tutte le k -uple ordinate senza ripetizione, ogni gruppo di $k!$ di esse (tutte le permutazioni degli stessi elementi) collassa in **un'unica** k -upla non ordinata. Quindi:

$$C(n, k) = \binom{n}{k} = \frac{n!}{k!(n - k)!}$$

Questo è il **coefficiente binomiale**.

Riepilogo formule

Tipo	Formula	Nome
k-uple ordinate con ripetizione	n^k	—
k-uple ordinate senza ripetizione	$\frac{n!}{(n-k)!}$	Disposizioni semplici
k-uple ordinate, $k = n$, senza ripetizione	$n!$	Permutazioni
k-uple non ordinate senza ripetizione	$\binom{n}{k} = \frac{n!}{k!(n-k)!}$	Combinazioni / Coeff. binomiale

Trucco mnemonico

Partendo dalle disposizioni $\frac{n!}{(n-k)!}$:

- vuoi le **non ordinate**? dividi per $k!$ (le permutazioni interne alla k-upla)
- vuoi **con ripetizione**? ogni estrazione riparte da $n \rightarrow n^k$

Applicazione: Cardinalità dell'Insieme delle Parti

Teorema

Dato un insieme A con m elementi, l'**insieme delle parti** $P(A)$ (l'insieme di tutti i sottoinsiemi di A , inclusi $\emptyset$ e A stesso) ha cardinalità:

$$|P(A)| = 2^m$$

Dimostrazione combinatoria

I sottoinsiemi di A di cardinalità k sono esattamente le k -uple non ordinate senza ripetizione, cioè $\binom{m}{k}$. Sommando su tutti i possibili k :

$$|P(A)| = \sum_{k=0}^m \binom{m}{k} = \sum_{k=0}^m \binom{m}{k} 1^k \cdot 1^{m-k} = (1+1)^m = 2^m$$

L'ultima uguaglianza è il **Binomio di Newton**:

$$(a + b)^m = \sum_{k=0}^m \binom{m}{k} a^k b^{m-k}$$

Esempio guidato: Probabilità al poker

Mazzo francese da 52 carte, si estraggono 5 carte.

$$|\Omega| = \binom{52}{5} = \frac{52!}{5! \cdot 47!}$$

Probabilità di "colore" (flush): tutte e 5 le carte dello stesso seme (es. tutte cuori). Ci sono 13 carte per seme:

$$|A_{\text{colore}}| = 4 \cdot \binom{13}{5}$$

$$P(\text{colore}) = \frac{4 \cdot \binom{13}{5}}{\binom{52}{5}}$$

La prossima lezione

Faremo esercizi completi di analisi combinatoria (poker, blackjack, ecc.) prima di procedere alla definizione assiomatica formale della probabilità.

Curiosità: La Martingala

Perché i casinò hanno un limite di puntata?

La **Martingala** è una strategia alla roulette: raddoppia la puntata ad ogni perdita. Si può dimostrare che:

- Con **patrimonio infinito** e **nessun limite** di puntata → si vince sempre (con probabilità 1)
- Con qualunque limite di puntata, per quanto alto ma **finito** → si perde

Il limite di puntata esiste proprio per questo motivo.

Tags

#probabilità

#MSI

#spazio-campioni

#eventi

#analisi-combinatoria

#combinazioni

#permutazioni

#coefficiente-binomiale

? Argomenti trattati

- Fondamenti di calcolo combinatorio: disposizioni, combinazioni e relative formule
- Completamento esercizi di analisi combinatoria (cinquine da poker)
- Sequenze binarie con esattamente k uni: coefficiente multinomiale
- Definizione frequentistica di probabilità
- Critica e vantaggi dell'approccio frequentistico
- Proprietà della probabilità derivate dalla frequenza (senza assiomi)
- Evento complementare, subadditività, evento $A \setminus B$
- Probabilità condizionata: definizione e intuizione sul database
- Indipendenza stocastica

Fondamenti di Calcolo Combinatorio (Introdotta dopo)

Il calcolo combinatorio fornisce gli strumenti per **contare** gli elementi di insiemi finiti, fondamentale quando si calcola la probabilità di eventi sotto l'ipotesi che tutti gli esiti elementari siano equiprobabili.

Disposizioni con ripetizione

Il numero di **sequenze ordinate di lunghezza** k scelte da un alfabeto di n simboli, **con la possibilità di ripetere** lo stesso simbolo, è:

$$D_{n,k} = n^k$$

Ragionamento: per ogni delle k posizioni si sceglie uno dei n simboli indipendentemente. Totale: $n \times n \times \dots \times n$ (k volte) $= n^k$.

≡ Stringhe binarie

Stringhe di lunghezza 5 su alfabeto $\{0, 1\}$: $D_{2,5} = 2^5 = 32$.

Disposizioni semplici

Il numero di **sequenze ordinate di lunghezza** k scelte da un insieme di n elementi **senza ripetizione** (elementi distinti), è:

$$D_{n,k} = \frac{n!}{(n-k)!} = n(n-1)(n-2) \dots (n-k+1)$$

Ragionamento: per la prima posizione si sceglie uno dei n elementi; per la seconda, uno dei $n-1$ rimanenti; e così via fino alla k -esima posizione dove restano $n-k+1$ scelte.

≡ Codice di 3 cifre distinte da 0-9

$$D_{10,3} = \frac{10!}{7!} = 10 \times 9 \times 8 = 720.$$

Combinazioni semplici

Il numero di **sottoinsiemi non ordinati di dimensione** k scelti da un insieme di n elementi è:

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$

Ragionamento: le disposizioni semplici $D_{n,k}$ contano le sequenze ordinate. Se invece ordine non importa (sono sottoinsiemi), ogni sottoinsieme di k elementi corrisponde a $k!$ sequenze ordinate diverse (permutazioni degli elementi del sottoinsieme). Quindi:

$$\binom{n}{k} = \frac{D_{n,k}}{k!} = \frac{n!}{k!(n-k)!}$$

Questo coefficiente è detto anche **coefficiente binomiale**.

☰ Mani di poker

Mazzo da 52 carte, mano di 5 carte: $\binom{52}{5} = \frac{52!}{5! \cdot 47!} = 2.598.960$.

📌 Equivalenza: sequenze binarie con k uni

Il numero di sequenze binarie di lunghezza n con esattamente k uni (e $n - k$ zeri) è:

$$\binom{n}{k}$$

Questa interpretazione combinatoria del coefficiente binomiale è fondamentale per calcolare probabilità in esperimenti come "almeno k successi in n prove".

Esempi:

La mano nel Poker

Mazzo da poker francese: 32 carte (7, 8, 9, 10, J, Q, K, A in 4 semi = 8 valori $\times$ 4 semi).

Lo spazio dei campioni ha cardinalità:

$$|\Omega| = \binom{32}{5} = \frac{32!}{5! \cdot 27!} = 201.376$$

💡 L'ordinamento non conta nel poker

Una mano di poker è un sottoinsieme non ordinato: avere $A\spadesuit K\heartsuit Q\diamondsuit J\clubsuit 10\spadesuit$ o $K\heartsuit A\spadesuit Q\diamondsuit J\clubsuit 10\spadesuit$ è la stessa mano. Si usano sempre i coefficienti binomiali, non le disposizioni.

Cinquine con esattamente due assi

$$|C_2| = \underbrace{\binom{4}{2}}_{\text{scegli 2 assi tra 4}} \cdot \underbrace{\binom{28}{3}}_{\text{scegli 3 carte non-asso tra 28}} = 6 \cdot 3276 = 69.184$$

$$P(2 \text{ assi}) = \frac{69.184}{201.376} \approx 0,097 \approx 9,7\%$$

Nota: questo include doppie coppie e full (tre tra le altre carte uguali). Se si vuole solo la coppia d'assi come punteggio massimo:

$$|C_{\text{coppia assi}}| = \binom{4}{2} \cdot 28 \cdot \frac{24 \cdot 20}{3!} \Rightarrow P \approx 6,3\%$$

Almeno tre assi

$$|C_{\geq 3}| = \underbrace{\binom{4}{3} \cdot \binom{28}{2}}_{\text{tre assi}} + \underbrace{\binom{4}{4} \cdot 28}_{\text{quattro assi}} = 4 \cdot 378 + 28 = 1.540$$

$$P(\geq 3 \text{ assi}) = \frac{1.540}{201.376} \approx 0,76\%$$

Tris di un valore specifico (es. tre 7, senza full né poker)

$$|C_{3\text{sette}}| = \binom{4}{3} \cdot 28 \cdot \frac{24}{2} = 4 \cdot 28 \cdot 12 = 1.344$$

$$P(\text{tris qualsiasi}) = 8 \cdot \frac{1.344}{201.376} \approx 5,3\%$$

Colore di picche

$$|C_{\text{picche}}| = \binom{8}{5} = 56 \Rightarrow P(\text{colore picche}) = \frac{56}{201.376} \approx 0,11\%$$

$$P(\text{colore qualsiasi}) = 4 \cdot \frac{56}{201.376} \approx 0,44\%$$

Caso m-ario: Sequenze Binarie con Esattamente k Uni

Domanda:

Data una sequenza di n bit, quante sequenze hanno esattamente k uni?

Ragionamento senza formula:

Se tutti i bit fossero distinti, ci sarebbero $n!$ permutazioni. Ma nella nostra sequenza ci sono k uni (indistinguibili tra loro) e $n - k$ zeri (indistinguibili tra loro). Le $k!$ permutazioni degli uni tra di loro danno la stessa sequenza, e lo stesso vale per le $(n - k)!$ permutazioni degli zeri.

$$|\{x \in \{0, 1\}^n : |x|_1 = k\}| = \frac{n!}{k! \cdot (n - k)!} = \binom{n}{k}$$

Generalizzazione al caso m-ario:

Data una sequenza di lunghezza n su un alfabeto di m simboli, con n_i occorrenze del simbolo i (con $\sum_i n_i = n$), il numero di sequenze distinte è il **coefficiente multinomiale**:

$$\binom{n}{n_1, n_2, \dots, n_m} = \frac{n!}{n_1! \cdot n_2! \cdots n_m!}$$

Applicazione in teoria dell'informazione

Questi conteggi sono fondamentali per il codice universale a lunghezza fissa: determinare quanti messaggi di lunghezza n contengono esattamente k simboli di un certo tipo è la base per calcolare la capacità di un canale.

Definizione Frequentistica di Probabilità

Sia Ω uno spazio dei campioni *discreto* (finito o numerabile). Si eseguono n prove indipendenti dello stesso esperimento.

Definizione: Frequenza di successo (vista in precedenza)

$$f_n(A) = \frac{N_A}{n}$$

dove N_A è il numero di volte in cui l'evento A si verifica su n prove.

Definizione frequentistica: Probabilità

$$P(A) \stackrel{\text{def}}{=} \lim_{n \rightarrow \infty} f_n(A) = \lim_{n \rightarrow \infty} \frac{N_A}{n}$$

Perché questa definizione è intuitiva ma imprecisa

Questa definizione è matematicamente "zoppicante" per due motivi:

1. Il limite non esiste sempre — le prove devono essere **indipendenti** (o il processo deve essere ergodico) perché la sequenza $f_n(A)$ converga. Con prove indipendenti la convergenza è **forte** (quasi certamente e in media quadratica).
2. Non si specifica il tipo di convergenza. Verrà precisato nel seguito del corso.

Nonostante ciò, l'approccio frequentistico è preferito da questo docente per una ragione pratica: **rende le proprietà della probabilità intuitive**, derivandole direttamente dalle proprietà degli insiemi, senza bisogno di assiomi astratti da dimostrare separatamente.

💡 Parole del Professore

🔗 Quote

"Io do le carte napoletane, mi ha giocato a scopone, ho dieci carri per uno, poi la probabilità che gli do i sette carri... Con l'approccio teorico la gente cominciava a ragionare in percentuali assurde. Con quello frequentistico si ragiona automaticamente nel modo giusto."

La probabilità come misura

La probabilità è un **modo diverso di misurare gli elementi di un insieme**. Ordinariamente, in un insieme discreto, ogni elemento "pesa" $\frac{1}{|\Omega|}$. Con la probabilità, alcuni elementi possono pesare molto più di altri.

☰ L'ape e la pianta

Immagina un'aula di 50 m². Ogni metro quadro ha misura ordinaria $\frac{1}{50}$. Se metti una pianta fiorita su un metro quadro, l'ape sarà lì con probabilità $\approx 0,99$. Quel metro quadro ora pesa quasi 1 in termini di probabilità, anche se ha la stessa misura ordinaria degli altri 49.

Proprietà della Probabilità (derivate dalla frequenza)

Tutte le seguenti proprietà si derivano senza assiomi, solo dalle proprietà degli insiemi.

Limitazione

$$0 \leq P(A) \leq 1$$

Il numero di successi non può superare il numero di prove.

Evento complementare

$$P(A^c) = 1 - P(A)$$

Su n prove, se A si verifica N_A volte, allora A^c si verifica $n - N_A$ volte. Quindi $f_n(A^c) = 1 - f_n(A)$.

Subadditività (unione di eventi)

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Su n prove, il numero di volte in cui si verifica $A \cup B$ è $N_A + N_B - N_{A \cap B}$ (si somma, ma si sottrae l'intersezione contata due volte).

Caso speciale — eventi **disgiunti** ($A \cap B = \emptyset$):

$$P(A \cup B) = P(A) + P(B)$$

La probabilità è una misura

Proprio come la misura di due insiemi che si sovrappongono non è la somma delle misure (si conta due volte l'intersezione), la probabilità di $A \cup B$ non è la semplice somma. La probabilità è subadditiva esattamente come lo è qualsiasi misura.

Differenza di eventi

$$P(A \setminus B) = P(A) - P(A \cap B)$$

Il numero di volte in cui si verifica A ma non B è $N_A - N_{A \cap B}$.

Evento certo e impossibile

$$P(\Omega) = 1 \quad P(\emptyset) = 0$$

L'evento certo si verifica tutte le n volte; $f_n(\Omega) = n/n = 1$.

Probabilità nulla $\neq$ evento impossibile

Un evento con probabilità 0 può comunque verificarsi (infinite volte, ma con frequenza che tende a 0). Esempio: se un evento si verifica $\sqrt{n}$ volte su n prove, si verifica infinite volte, ma $P = \lim_{n \rightarrow \infty} \frac{\sqrt{n}}{n} = 0$.

Si dice allora che l'evento si verifica **quasi certamente** (quasi ovunque, nel linguaggio della teoria della misura).

Dado Truccato: Esempio di Probabilità Non Equiprobabili

Supponiamo che il dado sia truccato così: il risultato 1 esce 5 volte più spesso degli altri risultati (tra loro equiprobabili).

Sia $P(i) = x$ la probabilità associata a ciascun esito $i \in \{2, 3, 4, 5, 6\}$. Per ipotesi, si ha $P(1) = 5x$. Affinché la distribuzione sia valida, la somma delle probabilità su tutto lo spazio campionario Ω deve essere unitaria:

$$\sum_{i=1}^6 P(i) = 1 \implies 5x + 5x = 1 \implies 10x = 1$$

Si ricava $x = 1/10$. Di conseguenza, le probabilità elementari risultano:

- $P(1) = 5/10 = 1/2$
- $P(i) = 1/10$ per $i \in \{2, 3, 4, 5, 6\}$

☰ Esempio: Calcolo di probabilità per eventi composti

Calcoliamo la probabilità degli eventi E_{pari} ed E_{dispari} sotto questa nuova misura:

- $P(\text{pari}) = P(2) + P(4) + P(6) = \frac{1}{10} + \frac{1}{10} + \frac{1}{10} = 30\%$
- $P(\text{dispari}) = P(1) + P(3) + P(5) = \frac{1}{2} + \frac{1}{10} + \frac{1}{10} = 70\%$

⚠ Attenzione

Morale: **quando gli eventi elementari non sono equiprobabili**, calcolare la probabilità di un evento come rapporto di cardinalità **non ha senso**. Si deve usare la definizione frequentistica o la misura di probabilità corretta.

Probabilità Condizionata

Intuizione: il database

Immagina un database con tutti i residenti in Italia, con colonne altezza, peso, colore occhi.

$P(\text{peso} \geq 70 \text{ kg})$: conto quanti pesano almeno 70 kg, divido per il totale.

$P(\text{peso} \geq 70 \text{ kg} \mid \text{altezza} \geq 170 \text{ cm})$: **restringo il database** alle sole persone alte almeno 170 cm (elimino tutti gli altri), poi conto quanti di questi pesano almeno 70 kg, divido per la dimensione del database ristretto.

$$f_n(B \mid A) = \frac{N_{A \cap B}}{N_A} = \frac{N_{A \cap B} / n}{N_A / n} = \frac{f_n(A \cap B)}{f_n(A)}$$

Passando al limite:

📄 Definizione: Probabilità condizionata

$$P(B \mid A) = \frac{P(A \cap B)}{P(A)}, \quad P(A) > 0$$

"La probabilità che si verifichi B, dato che si è verificato A, è il rapporto tra la probabilità che si verifichino entrambi e la probabilità di A."

Il condizionamento cambia lo spazio dei campioni: da Ω si passa a A come nuovo universo di riferimento.

Da questa definizione si ricava:

$$P(A \cap B) = P(A) \cdot P(B \mid A) = P(B) \cdot P(A \mid B)$$

Probabilità a priori vs a posteriori

La **probabilità a priori** $P(\text{peso} \geq 70 \text{ kg})$ include tutti gli italiani (bambini, donne anziane, ...).

La **probabilità a posteriori** $P(\text{peso} \geq 70 \text{ kg} \mid \text{altezza} \geq 170 \text{ cm})$ è più alta: filtrando per altezza, si esclude una porzione di persone che mediamente pesano meno.

Indipendenza Stocastica

$P(\text{peso} \geq 70 \text{ kg} \mid \text{altezza} \geq 170 \text{ cm})$ è diversa da $P(\text{peso} \geq 70 \text{ kg})$: sapere l'altezza dà informazione sul peso.

Ma $P(\text{occhi chiari} \mid \text{altezza} \geq 170 \text{ cm}) = P(\text{occhi chiari})$: sapere l'altezza non dà alcuna informazione sul colore degli occhi.

Definizione: Indipendenza stocastica

Due eventi A e B sono **indipendenti** se e solo se:

$$P(B \mid A) = P(B) \quad \Longleftrightarrow \quad P(A \cap B) = P(A) \cdot P(B)$$

Il verificarsi di A non fornisce alcuna informazione sul verificarsi di B.

Dadi indipendenti

Se lancio due dadi onesti, il risultato del secondo non dipende dal primo. Quindi:

$$P(\text{primo} = 5 \text{ e secondo} = 2) = P(\text{primo} = 5) \cdot P(\text{secondo} = 2) = \frac{1}{6} \cdot \frac{1}{6} = \frac{1}{36}$$

Regola pratica: "Almeno uno" → pensare al complementare

Strategia: usare il complementare

Quando il problema chiede "almeno uno / almeno due / almeno k", conviene calcolare la probabilità del complementare ("nessuno / meno di k") e sottrarre da 1.

Esempio: probabilità di ottenere almeno un 6 lanciando un dado onesto 5 volte.

$$P(\text{almeno un 6}) = 1 - P(\text{nessun 6})$$

I lanci sono **indipendenti**, quindi:

$$P(\text{nessun 6 in 5 lanci}) = \left(\frac{5}{6}\right)^5 \approx 0,402$$

$$P(\text{almeno un 6}) = 1 - \left(\frac{5}{6}\right)^5 \approx 0,598 \approx 60\%$$

Esempio classico (paradosso del compleanno): probabilità che in una classe di 30 persone ci siano almeno due con lo stesso compleanno.

$$P(\text{almeno due stessi}) = 1 - P(\text{tutti diversi}) = 1 - \prod_{k=0}^{29} \frac{365 - k}{365}$$

Il risultato è circa 70% — molto più alto di quanto l'intuizione suggerisce.

Punti chiave della lezione

- Il coefficiente binomiale $\binom{n}{k}$ conta le sequenze binarie di lunghezza n con esattamente k uni: si deriva solo dal ragionamento sulle permutazioni degli indistinguibili.
- La probabilità frequentistica $P(A) = \lim_{n \rightarrow \infty} N_A/n$ è intuitiva e permette di derivare tutte le proprietà dalle operazioni sugli insiemi.
- Quando gli eventi elementari non sono equiprobabili, non si può usare il rapporto di cardinalità.
- La probabilità è una **misura**: subadditiva per l'unione, additiva per eventi disgiunti.
- La probabilità condizionata $P(B|A) = P(A \cap B)/P(A)$ corrisponde al restringimento dello spazio dei campioni ad A .
- Due eventi sono indipendenti se $P(A \cap B) = P(A) \cdot P(B)$.
- Per "almeno uno", usare il complementare è quasi sempre la strategia migliore.

#MSI

#probabilità

#frequenza

#probabilità-condizionata

#indipendenza

#misura

#combinatoria

#complementare

#Bayes

Argomenti trattati

- Riepilogo dell'analisi combinatoria (k -uple ordinate, non ordinate, con/senza ripetizione, coefficiente binomiale)
- Riepilogo della definizione frequentistica e delle proprietà derivate (complementare, unione, differenza)
- Riepilogo della probabilità condizionata e della frequenza condizionale
- Legge della probabilità composta e legge di Bayes (approccio frequentistico)
- Legge della probabilità totale (partizioni di Ω)
- Limiti dell'approccio frequentistico e necessità della teoria formale
- Algebra e σ -algebra di eventi: definizione e proprietà di chiusura
- Spazio di probabilità $(\Omega, \mathcal{E}, P)$ e assiomi di Kolmogorov
- Derivazione rigorosa delle proprietà della probabilità dagli assiomi
- Indipendenza stocastica: definizione, proprietà dei complementari, indipendenza di n eventi
- Indipendenza a coppie vs. indipendenza congiunta: controesempio del bit di parità
- Esercizio: probabilità con n eventi indipendenti (nessuno, almeno uno, esattamente uno)
- La probabilità condizionata come legge di probabilità (verifica degli assiomi)
- Esercizio: bussolotto con dado onesto e dado truccato (applicazione di Bayes)
- Introduzione alle variabili aleatorie discrete e alla PMF
- Cenno al valore atteso

Richiami :

Analisi Combinatoria

Sotto l'ipotesi di equiprobabilità degli eventi elementari, la probabilità di un evento si determina come rapporto tra la cardinalità dell'evento e quella dello spazio campionario. Il

problema si riduce dunque all'**enumerazione** degli elementi tramite gli strumenti dell'analisi combinatoria. Dato un insieme di n elementi, si definiscono:

- **k-uple ordinate con ripetizione:** n^k .
- **k-uple ordinate di elementi distinti (disposizioni semplici):** $D_{n,k} = \frac{n!}{(n-k)!}$.
- **k-uple non ordinate (combinazioni semplici):** $\binom{n}{k} = \frac{n!}{k!(n-k)!}$.

Il **coefficiente binomiale** $\binom{n}{k}$ esprime non solo il numero di sottoinsiemi di dimensione k , ma anche il numero di **sequenze binarie** di lunghezza n contenenti esattamente k uni, interpretazione fondamentale per la modellazione di processi a prove ripetute.

Proprietà Derivate dalla Definizione Frequentistica

Assumendo la probabilità come limite della frequenza relativa di successo, $P(A) = \lim_{n \rightarrow \infty} N_A/n$, è possibile derivare le proprietà fondamentali del calcolo probabilistico trattandolo come una **misura** (analogo all'area geometrica) definita sugli insiemi:

1. **Evento complementare:** Poiché su n prove il numero di insuccessi è $n - N_A$, si ha $P(A^c) = 1 - P(A)$.
2. **Unione (Subadditività):** Per due eventi A, B , il conteggio degli esiti favorevoli all'unione deve escludere la doppia computazione dell'intersezione:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B) \quad (2.1)$$

Nel caso di **eventi incompatibili** ($A \cap B = \emptyset$), la (2.1) si riduce alla somma delle probabilità.

3. **Differenza:** La probabilità dell'evento $A \setminus B$ (esiti in A che non appartengono a B) è pari a $P(A) - P(A \cap B)$.

Probabilità Condizionata e Teorema di Bayes

La **frequenza condizionale** $f_n(A | B)$ modella il restringimento dello spazio dei campioni ai soli esiti che soddisfano la condizione B . Nell'ambito di questo "nuovo universo", si valuta la quota di esiti che soddisfano simultaneamente A .

Definizione: Probabilità condizionata e Legge Composta

Dato $P(B) > 0$, la probabilità condizionata è:

$$P(A | B) = \frac{P(A \cap B)}{P(B)}$$

Da cui si deriva la **legge della probabilità composta**:

$$P(A \cap B) = P(A) \cdot P(B | A) = P(B) \cdot P(A | B) \quad (2.2)$$

Dalla (2.2), sfruttando la commutatività dell'intersezione, si ricava la **Legge di Bayes**, strumento cardine dell'inferenza statistica che permette di invertire la direzione del condizionamento:

Legge di Bayes

$$P(B|A) = \frac{P(A|B) \cdot P(B)}{P(A)}$$

Questa formulazione consente di aggiornare la conoscenza *a priori* di un fenomeno ($P(B)$) alla luce di nuove evidenze sperimentali (A), determinando la probabilità *a posteriori* ($P(B|A)$).

Legge della Probabilità Totale

Definizione: Partizione

Si definisce **partizione** di Ω una collezione di m sottoinsiemi $\{E_1, E_2, \dots, E_m\}$ tali che:

1. siano a due a due disgiunti: $E_i \cap E_j = \emptyset$ per $i \neq j$;
2. la loro unione sia l'intero spazio: $\bigcup_{i=1}^m E_i = \Omega$.

Esempio concreto: i lastroni dell'aula

I lastroni sul pavimento di un'aula sono una partizione della stanza: la loro unione copre tutta la stanza e due lastroni diversi non si sovrappongono (hanno intersezione nulla).

Derivazione. Dato un qualunque evento A :

$$A = A \cap \Omega = A \cap \left(\bigcup_{i=1}^m E_i \right) = \bigcup_{i=1}^m (A \cap E_i)$$

dove si è usata la proprietà distributiva dell'intersezione rispetto all'unione. Gli insiemi $A \cap E_i$ e $A \cap E_j$ (con $i \neq j$) sono **disgiunti**: $A \cap E_i$ contiene tutti e soli gli elementi che appartengono sia ad A che ad E_i , mentre $A \cap E_j$ contiene quelli che appartengono sia ad A che ad E_j ; ma E_i e E_j non hanno elementi comuni perchè formano una partizione. Quindi:

$$P(A) = \sum_{i=1}^m P(A \cap E_i)$$

Usando la definizione di probabilità condizionata, $P(A \cap E_i) = P(A|E_i) \cdot P(E_i)$:

Definizione: Legge della probabilità totale

$$P(A) = \sum_{i=1}^m P(A|E_i) \cdot P(E_i)$$

La probabilità di un evento A si può scomporre condizionando rispetto a una partizione dello spazio dei campioni.

Parole del Professore

Quote

"Questa legge, ragazzi, è importantissima. Si usa in tutti i calcoli probabilistici, in quasi tutti, perché a volte devo calcolare la probabilità di un evento ed è difficile, però se mi metto in certe condizioni la devo scomporre in calcoli più semplici. La useremo, la vedremo, ve la farò vedere negli esercizi."

Limiti dell'Approccio Frequentistico

Tutte le proprietà ricavate finora --- *complementare, unione, differenza, probabilità condizionata, legge di Bayes, legge della probabilità totale* --- derivano dalla definizione frequentistica (limite della frequenza di successo) e sono conseguenze delle proprietà delle operazioni tra insiemi.

Tuttavia questa impostazione presenta due problemi fondamentali:

1. **Convergenza non specificata:** non si è detto in che senso la frequenza di successo converge a un valore stabile; le prove devono essere indipendenti, ma l'indipendenza è essa stessa un concetto probabilistico (circolarità).
2. **Generalità non garantita:** non c'è a priori nessuna garanzia che le proprietà trovate sotto certe ipotesi valgano in generale.

Parole del Professore

Quote

"Io vi ho promesso che vi avrei definito in modo più rigoroso la probabilità. Tutto questo zoppica dal punto di vista non solo matematico, ma concettuale."

Teoria Formale: Algebra di Eventi

Algebra

Dato uno spazio dei campioni Ω , consideriamo una collezione E di sottoinsiemi di Ω .

Definizione: Algebra

Una collezione E di sottoinsiemi di Ω si chiama **algebra** se soddisfa due proprietà:

1. **Chiusura rispetto all'unione:** se $A_i \in E$ e $A_j \in E$, allora $A_i \cup A_j \in E$;
2. **Chiusura rispetto alla complementazione:** se $A_i \in E$, allora $A_i^c \in E$.

Chiusura rispetto all'intersezione (dimostrazione via De Morgan)

Il professore chiede alla classe se l'algebra contiene anche l'intersezione di due suoi elementi, e guida la dimostrazione usando le **leggi di De Morgan**.

La legge di De Morgan afferma:

$$(A \cup B)^c = A^c \cap B^c$$

Complementando entrambi i membri:

$$A \cap B = (A^c \cup B^c)^c$$

Allora, se $A \in E$ e $B \in E$:

1. $A^c \in E$ e $B^c \in E$ (chiusura per complementazione);
2. $A^c \cup B^c \in E$ (chiusura per unione);
3. $(A^c \cup B^c)^c \in E$ (chiusura per complementazione).

Quindi $A \cap B \in E$. L'algebra è **chiusa anche rispetto all'intersezione**.

Chiusura rispetto alla differenza

Analogamente, $A \setminus B = A \cap B^c$: poichè $B^c \in E$ (chiusura per complementazione) e l'intersezione è chiusa, si ha $A \setminus B \in E$.

Tutte le operazioni insiemistiche restano nell'algebra

Unione, intersezione, complementazione e differenza di elementi dell'algebra producono sempre elementi dell'algebra. Questo garantisce che la funzione di probabilità possa essere calcolata su qualunque combinazione di eventi: si resta sempre nel dominio di definizione.

Esercizio: La più piccola algebra contenente un evento

Esempio: dado e evento "risultato pari"

Sia $\Omega = \{1, 2, 3, 4, 5, 6\}$ e $A = \{2, 4, 6\}$ l'evento "risultato pari". La più piccola algebra che contiene A è:

$$E_{\min} = \{\emptyset, \Omega, A, A^c\}$$

Costruzione passo per passo:

- se c'è A , ci deve essere il suo complemento $A^c = \{1, 3, 5\}$;
- se ci sono A e A^c , la loro unione $A \cup A^c = \Omega$ deve appartenere;
- se c'è Ω , il suo complemento $\emptyset$ deve appartenere.

L'insieme delle parti 2^Ω è anch'esso un'algebra, ma è molto più grande del necessario. Più piccola di questi quattro elementi non è possibile.

Parole del Professore

Quote

"Non vi fate mai spaventare dai paroloni della matematica."

σ -Algebra

Definizione: σ -algebra

Un'algebra E si chiama σ -**algebra** se un'**unione numerabile** di suoi elementi è ancora un elemento dell'algebra:

$$A_1, A_2, A_3, \dots \in E \implies \bigcup_{i=1}^{\infty} A_i \in E$$

Algebra vs. σ -algebra

Un'algebra garantisce la chiusura per unioni **finite**. Una σ -algebra estende questa garanzia a unioni **numerabili** (infinite ma contabili). La distinzione è rilevante quando lo spazio dei campioni è numerabile.

Perché serve la σ -algebra

Siamo sull'autostrada e contiamo le macchine. Gli eventi elementari sono "non passa nessuna macchina", "passa una macchina", "passano due macchine", eccetera, fino potenzialmente a infinito. Per ogni insieme di questi eventi devo poter fare l'unione, anche all'infinito. Se Ω è finito, la σ -algebra non aggiunge nulla rispetto all'algebra, perché le unioni finite sono già sufficienti; la σ -algebra diventa necessaria quando Ω è numerabile.

Spazio di Probabilità e Assiomi di Kolmogorov

A questo punto si dispone di uno spazio dei campioni Ω e di una σ -algebra E dei sottoinsiemi di Ω .

Definizione: Legge di probabilità (Kolmogorov)

Dato uno spazio dei campioni Ω e una σ -algebra E , si definisce **legge di probabilità** una funzione

$$P : E \rightarrow [0, 1]$$

che soddisfa i seguenti **assiomi di Kolmogorov** ("tre assiomi e mezzo"):

- **Assioma 1 --- Non negatività:**

$$P(A) \geq 0 \quad \forall A \in E$$

- **Assioma 2 --- Normalizzazione:**

$$P(\Omega) = 1$$

- **Assioma 3 --- Additività (o subadditività):**

Se A e B sono eventi disgiunti ($A \cap B = \emptyset$):

$$P(A \cup B) = P(A) + P(B)$$

- **Assioma 3 $\frac{1}{2}$ --- σ -additività (estensione numerabile):**

Se $\{A_i\}_{i=1}^{\infty}$ è una successione di eventi a due a due disgiunti:

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

La terna (Ω, E, P) prende il nome di **spazio di probabilità**.

Perche la struttura della σ -algebra è necessaria

La σ -algebra garantisce che tutte le operazioni insiemistiche (unione, intersezione, complementazione, differenza) restino nel dominio di definizione della funzione P . Senza questa struttura, non si potrebbe essere certi di poter calcolare P su combinazioni arbitrarie di eventi.

Come dice il professore: "i matematici pensano: io resto nel dominio di definizione dell'algebra."

Parole del Professore

Quote

"Vedete che noi abbiamo fatto tutto questo ambaradan. Dice, ma e tutta questa cosa complicata? Tu metti le tue prove, fatti la frequenza di successo... Tutto quello che abbiamo ricavato, qua non c'è niente. Io ti faccio vedere che tutto quello che tu hai ricavato prima, usando quella definizione, se volete, un po' farlocca di probabilità, io te lo ricavo come unica conseguenza degli assiomi di Kolmogorov."

Derivazione delle Proprietà dagli Assiomi

Il professore mostra come le proprietà ricavate in modo "facile" dalla definizione frequentistica si dimostrino ora rigorosamente a partire dai **soli** assiomi di Kolmogorov.

Probabilità di $A \setminus B$

Si parte dall'identità insiemistica:

$$A = A \cap \Omega = A \cap (B \cup B^c) = (A \cap B) \cup (A \cap B^c)$$

dove si è usata la proprietà distributiva dell'intersezione rispetto all'unione. Ora si osserva che:

- $(A \cap B)$ contiene tutti e soli gli elementi che appartengono sia ad A che a B;
- $(A \cap B^c)$ contiene tutti e soli gli elementi che appartengono ad A ma **non** a B.

Questi due insiemi sono **disgiunti**. Per l'assioma 3 (σ -additività):

$$P(A) = P(A \cap B) + P(A \cap B^c)$$

Ma $A \cap B^c = A \setminus B$, quindi:

$$P(A \setminus B) = P(A) - P(A \cap B)$$



Osservazione

E la stessa formula trovata prima con la definizione frequentistica, ma ora è dimostrata rigorosamente a partire dagli assiomi.

Probabilità di $A \cup B$

Si scrive:

$$A \cup B = A \cup (B \cap A^c)$$

dove A e $B \cap A^c$ (gli elementi di B che non appartengono ad A) sono **disgiunti**. Quindi per l'assioma 3:

$$P(A \cup B) = P(A) + P(B \cap A^c)$$

Ma dalla proprietà appena dimostrata, $P(B \cap A^c) = P(B \setminus A) = P(B) - P(A \cap B)$ (si invertono i ruoli di A e B nella formula precedente):

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Probabilità dell'evento complementare

L'evento A e il suo complementare A^c soddisfano $A \cup A^c = \Omega$ e sono incompatibili ($A \cap A^c = \emptyset$). Per l'assioma 3 (additività) e l'assioma 2 (normalizzazione):

$$P(A) + P(A^c) = P(A \cup A^c) = P(\Omega) = 1$$

$$P(A^c) = 1 - P(A)$$

Probabilità dell'evento impossibile

L'insieme vuoto $\emptyset$ e il complemento di Ω :

$$P(\emptyset) = P(\Omega^c) = 1 - P(\Omega) = 1 - 1 = 0$$

Terminologia

L'insieme vuoto $\emptyset$ si chiama **evento impossibile**; lo spazio dei campioni Ω si chiama **evento certo**.

Parole del Professore

Quote

"Riprendo il giro per dirvi quanto è pesante questo. Abbiamo trovato le cose prima, le abbiamo trovate in modo facile. Ora dimostrarle diventa un giochino, perché già sappiamo il risultato che dobbiamo tirare."

Indipendenza Stocastica

Definizione: Indipendenza stocastica

Due eventi $A, B \in \mathcal{E}$ si dicono **statisticamente indipendenti** se:

$$P(A \cap B) = P(A) \cdot P(B)$$

Parole del Professore

Quote

"La nozione di indipendenza è fondamentale e moltissima statistica inferenziale si fonda su ipotesi di indipendenza, perché senza indipendenza una serie di convergenze [non valgono]. Voi avete dei grandi database, giocate quei file Excel per ricavarvi una serie di parametri globali. E ci sono delle ipotesi alla base: ipotesi di ergodicità, che a loro volta indicano ipotesi di indipendenza, per lo meno tra campioni sufficientemente lontani. Se no, la statistica descrittiva vale solo per quel campione di dati. Non è generalizzabile."

Indipendenza dei complementari

Teorema: Se A e B sono statisticamente indipendenti, allora anche A^c e B^c sono statisticamente indipendenti.

Dimostrazione. Per le leggi di De Morgan:

$$A^c \cap B^c = (A \cup B)^c$$

Quindi:

$$P(A^c \cap B^c) = P((A \cup B)^c) = 1 - P(A \cup B)$$

Sostituendo la formula dell'unione:

$$= 1 - P(A) - P(B) + P(A \cap B)$$

Poiché A e B sono indipendenti, $P(A \cap B) = P(A) \cdot P(B)$:

$$= 1 - P(A) - P(B) + P(A) \cdot P(B)$$

Raccogliendo:

$$= 1 - P(A) - P(B)(1 - P(A)) = (1 - P(A))(1 - P(B)) = P(A^c) \cdot P(B^c)$$

$$\boxed{P(A^c \cap B^c) = P(A^c) \cdot P(B^c) \quad \checkmark}$$

Indipendenza di n eventi

Definizione: Indipendenza di n eventi

Tre eventi A , B e C si dicono **indipendenti** se lo sono **a 2 a 2** e **a 3 a 3**:

$$P(A \cap B) = P(A) \cdot P(B), \quad P(A \cap C) = P(A) \cdot P(C), \quad P(B \cap C) = P(B) \cdot P(C)$$

$$P(A \cap B \cap C) = P(A) \cdot P(B) \cdot P(C)$$

In generale, una n -upla di eventi $A_1, A_2, \dots, A_n$ è una **n -upla indipendente** se per ogni sottoinsieme $\{i_1, i_2, \dots, i_k\} \subseteq \{1, \dots, n\}$:

$$P(A_{i_1} \cap A_{i_2} \cap \dots \cap A_{i_k}) = P(A_{i_1}) \cdot P(A_{i_2}) \cdot \dots \cdot P(A_{i_k})$$

L'indipendenza di ordine n implica quella di ordine inferiore (da $n - 1$ fino a 2), **ma non vale il viceversa**.

Indipendenza a coppie $\nRightarrow$ indipendenza congiunta

L'indipendenza a coppie **non** implica l'indipendenza della terna (o della n -upla). Un controesempio classico è il **bit di parità**.

Controesempio: il bit di parità

Il bit di parità

Siano X_1 e X_2 due bit equiprobabili e indipendenti, ciascuno con valore 0 o 1 con probabilità $\frac{1}{2}$. Si definisce il **bit di parità**:

$$X_3 = X_1 \oplus X_2$$

dove $\oplus$ denota la **somma modulo 2** (operazione XOR): $X_3 = 0$ se X_1 e X_2 sono uguali, $X_3 = 1$ se sono diversi, in modo che il numero di uni nella terna (X_1, X_2, X_3) sia sempre pari.

Risultato:

- X_1 e X_2 sono **indipendenti** (per ipotesi);
- X_1 e X_3 sono **indipendenti**;
- X_2 e X_3 sono **indipendenti**;
- ma la terna (X_1, X_2, X_3) **non** è indipendente.

Perché? Se si conoscono sia X_1 che X_2 , il valore di X_3 è **completamente determinato** ($X_3 = X_1 \oplus X_2$). La probabilità non si può fattorizzare:
 $P(X_1 = x_1, X_2 = x_2, X_3 = x_3) \neq P(X_1 = x_1) \cdot P(X_2 = x_2) \cdot P(X_3 = x_3)$.
Ma se si conosce **uno solo** dei due bit, non si può dedurre nulla sul terzo.

Esercizio: n Eventi Indipendenti

Siano $A_1, A_2, \dots, A_n$ eventi indipendenti, con $P(A_i) = p_i$. Si calcolino:

1. Probabilità che non se ne verifichi nessuno

L'evento "non si verifica nessuno" equivale a: non si verifica A_1 , e non si verifica A_2 , e ... e non si verifica A_n , cioè $A_1^c \cap A_2^c \cap \dots \cap A_n^c$.

Poiché gli A_i sono indipendenti, abbiamo dimostrato che anche i loro complementari sono indipendenti. Quindi la probabilità dell'intersezione è il prodotto:

$$P\left(\bigcap_{i=1}^n A_i^c\right) = \prod_{i=1}^n (1 - p_i)$$

2. Probabilità che se ne verifichi almeno uno

L'evento "almeno uno" è il **complementare** dell'evento "nessuno": se ne verifica almeno uno se non è vero che non se ne verifica nessuno.

$$P\left(\bigcup_{i=1}^n A_i\right) = 1 - \prod_{i=1}^n (1 - p_i)$$

3. Probabilità che se ne verifichi esattamente uno (non importa quale)

L'evento "esattamente uno" si traduce come: **o** si verifica A_1 ma non $A_2, A_3, \dots, A_n$; **oppure** non si verifica A_1 ma si verifica A_2 e non $A_3, \dots, A_n$; **oppure ... oppure** non si verificano $A_1, \dots, A_{n-1}$ ma si verifica A_n .

Formalmente:

$$(A_1 \cap A_2^c \cap \dots \cap A_n^c) \cup (A_1^c \cap A_2 \cap A_3^c \cap \dots \cap A_n^c) \cup \dots \cup (A_1^c \cap \dots \cap A_{n-1}^c \cap A_n)$$

Questi n eventi sono **disgiunti** (nel primo c'è A_1 , nel secondo c'è A_2 ma non A_1 , ecc.), quindi per la σ -additività e l'indipendenza:

$$P(\text{esattamente uno}) = \sum_{i=1}^n p_i \prod_{\substack{j=1 \\ j \neq i}}^n (1 - p_j)$$



Parole del Professore



Quote

"E solo logica, ragazzi, però vi dico anche che questa logica non la dovete dimenticare, perché poi quando andiamo sulle variabili aleatorie e un po' più numerica la cosa, però dovete sempre ricordarvi questa logica. Dovete formulare opportunamente le proposizioni."

La Probabilità Condizionata come Legge di Probabilità

Un risultato importante: **fissato** B con $P(B) > 0$, la funzione $P(\cdot | B)$ soddisfa gli assiomi di Kolmogorov ed è quindi una legge di probabilità a tutti gli effetti.

Verifica dei tre assiomi:

Assioma 1 (Non negatività): $P(A | B) = \frac{P(A \cap B)}{P(B)} \geq 0$, poiché rapporto di due quantità non negative.

Assioma 2 (Normalizzazione):

$$P(\Omega | B) = \frac{P(\Omega \cap B)}{P(B)} = \frac{P(B)}{P(B)} = 1 \quad \checkmark$$

Assioma 3 (σ -additività): Siano A e C eventi disgiunti ($A \cap C = \emptyset$):

$$P(A \cup C | B) = \frac{P((A \cup C) \cap B)}{P(B)} = \frac{P((A \cap B) \cup (C \cap B))}{P(B)}$$

Ma se $A \cap C = \emptyset$ allora $(A \cap B)$ e $(C \cap B)$ sono disgiunti: $A \cap B$ contiene tutti e soli gli elementi che appartengono a B e ad A , $C \cap B$ contiene quelli che appartengono a B e a C , ma A e C non hanno elementi comuni. Quindi:

$$= \frac{P(A \cap B) + P(C \cap B)}{P(B)} = \frac{P(A \cap B)}{P(B)} + \frac{P(C \cap B)}{P(B)} = P(A | B) + P(C | B) \quad \checkmark$$

Dunque $P(\cdot | B)$ è una legge di probabilità.

Conseguenza per l'indipendenza

Se A e B sono indipendenti:

$$P(A | B) = \frac{P(A \cap B)}{P(B)} = \frac{P(A) \cdot P(B)}{P(B)} = P(A)$$

Il verificarsi di B **non influisce minimamente** sulla probabilità di A: la probabilità condizionata coincide con quella incondizionata.

☰ Piove a Napoli, Portici e Kathmandu

Sia A = "piove a Napoli", B = "piove a Portici", C = "piove a Kathmandu".

- $P(A | B) \neq P(A)$: se piove a Portici, è più probabile che piovano anche a Napoli (eventi **dipendenti**).
- $P(A | C) \approx P(A)$: sapere che piove a Kathmandu non dà informazione utile sulla pioggia a Napoli (eventi approssimativamente **indipendenti**).

La probabilità a priori $P(A)$ si calcola guardando i record storici: quante volte ha piovuto a Napoli il 10 marzo, diviso il numero totale di anni registrati.

⚠ Spazio di probabilità e modellazione

Tutti gli spazi di probabilità sono **matematicamente equivalenti**. Per il lancio di una moneta:

- $P(\text{testa}) = 1$, $P(\text{croce}) = 0$ è legittimo (moneta con due teste);
- $P(\text{testa}) = P(\text{croce}) = \frac{1}{2}$ è legittimo (moneta onesta).

La scelta della legge di probabilità non è un problema matematico ma di **modellazione**: bisogna scegliere la legge che meglio descrive l'esperimento reale. Se si sbaglia la legge, non si sbaglia matematicamente, ma le predizioni non aderiscono alla realtà. Questo è il compito dell'**inferenza statistica**.

Esercizio: Bussolotto con Dado Onesto e Dado Truccato

☰ Enunciato

Un bussolotto contiene due dadi indistinguibili per colore e peso. Un dado è **onesto**, l'altro è **truccato** in modo che il 6 esca con probabilità $\frac{1}{2}$ e tutti gli altri risultati siano equiprobabili. Si estrae un dado e lo si lancia **due volte**, ottenendo la coppia (5, 5). Qual è la probabilità che il dado estratto sia quello truccato?

Modellazione del dado truccato

Per il **dado onesto** D_O , tutti i risultati sono equiprobabili:

$$P(X = i | D_O) = \frac{1}{6}, \quad i = 1, 2, \dots, 6$$

Per il **dado truccato** D_T , la probabilità che esca 6 è $\frac{1}{2}$ e gli altri risultati sono equiprobabili tra loro. Per trovare queste probabilità, si impone l'**assioma di normalizzazione** (la somma di tutte le probabilità deve valere 1):

$$P(\Omega) = P(X = 6) + \sum_{i=1}^5 P(X = i) = \frac{1}{2} + 5p = 1 \implies p = \frac{1}{10}$$

Quindi:

$$P(X = i | D_T) = \begin{cases} \frac{1}{2} & \text{se } i = 6 \\ \frac{1}{10} & \text{se } i \neq 6 \end{cases}$$

Impostazione con Bayes

Sia A = "il dado estratto è truccato" e B = "i due lanci danno (5, 5)". Si vuole calcolare $P(A | B)$.

Per la **legge di Bayes**:

$$P(A | B) = \frac{P(B | A) \cdot P(A)}{P(B)}$$

Calcolo di $P(B | A)$: probabilità di (5, 5) con il dado truccato

Dato che si è estratto il dado truccato, i due lanci sono **condizionalmente indipendenti** (lo stesso dado viene lanciato due volte):

$$P(5, 5 | D_T) = \frac{1}{10} \cdot \frac{1}{10} = \frac{1}{100}$$

Calcolo di $P(B | D_O)$: probabilità di (5, 5) con il dado onesto

$$P(5, 5 | D_O) = \frac{1}{6} \cdot \frac{1}{6} = \frac{1}{36}$$

Probabilità a priori

I dadi sono indistinguibili, quindi si estraggono con uguale probabilità:

$$P(D_T) = P(D_O) = \frac{1}{2}$$

Calcolo di P(B) con la legge della probabilità totale

La partizione è $\{D_O, D_T\}$ (i due eventi sono mutuamente esclusivi):

$$\begin{aligned}P(B) &= P(5, 5 | D_O) \cdot P(D_O) + P(5, 5 | D_T) \cdot P(D_T) = \frac{1}{36} \cdot \frac{1}{2} + \frac{1}{100} \cdot \frac{1}{2} \\&= \frac{1}{2} \left(\frac{1}{36} + \frac{1}{100} \right) = \frac{1}{2} \cdot \frac{100 + 36}{3600} = \frac{136}{7200} = \frac{17}{900}\end{aligned}$$

Risultato

$$P(D_T | 5, 5) = \frac{\frac{1}{100} \cdot \frac{1}{2}}{\frac{17}{900}} = \frac{\frac{1}{200}}{\frac{17}{900}} = \frac{900}{200 \cdot 17} = \frac{9}{34} \approx 0,265$$

Interpretazione

La probabilità a posteriori che il dado sia truccato ($\approx 26,5\%$) è **minore** della probabilità a priori (50%). Questo ha senso: il 5 esce più facilmente con il dado onesto ($\frac{1}{6} \approx 16,7\%$) che con il truccato ($\frac{1}{10} = 10\%$), quindi osservare due 5 rende più probabile che il dado sia quello onesto. Se fossero usciti due 6, il risultato sarebbe stato opposto.

Variante: reinserimento del dado

Il professore discute una variante proposta da uno studente: dopo il primo lancio si **rimette il dado nel bussolotto**, si mescola e si estrae nuovamente.

In questo caso i due lanci diventano **incondizionalmente indipendenti** (non solo condizionalmente), perché si ripristinano esattamente le stesse condizioni iniziali. La probabilità di ottenere 5 in un singolo lancio si calcola con la legge della probabilità totale:

$$P(X = 5) = P(5 | D_T) \cdot P(D_T) + P(5 | D_O) \cdot P(D_O) = \frac{1}{10} \cdot \frac{1}{2} + \frac{1}{6} \cdot \frac{1}{2} = \frac{1}{2} \left(\frac{1}{10} + \frac{1}{6} \right) = \frac{1}{2} \cdot \frac{4}{15} = \frac{2}{15}$$

E la probabilità della coppia (5, 5) è semplicemente il **quadrato**:

$$P(5, 5) = \left(\frac{2}{15} \right)^2 = \frac{4}{225}$$

Indipendenza condizionale vs. incondizionale

- **Stesso dado, due lanci:** i lanci sono **condizionalmente indipendenti** dato il tipo di dado (D_T o D_O), ma **non** incondizionalmente indipendenti. Si può scrivere $P(5, 5 | D_T) = P(5 | D_T)^2$, ma $P(5, 5) \neq P(5)^2$.
- **Reinserimento del dado:** ogni lancio è un esperimento completamente ripristinato, quindi i lanci sono **incondizionalmente indipendenti** e $P(5, 5) = P(5)^2$.

Introduzione alle Variabili Aleatorie

Motivazione: tre esperimenti, un unico trattamento

Il professore introduce le variabili aleatorie partendo da un'osservazione pratica. Tre esperimenti apparentemente diversi:

1. **Lancio di una moneta:** testa o croce;
2. **Sorgente binaria:** emette 0 o 1;
3. **Lancio di un dado:** risultato pari o dispari.

hanno tutti un esito **binario**. Codificando opportunamente (testa $\rightarrow$ 0, croce $\rightarrow$ 1; pari $\rightarrow$ 0, dispari $\rightarrow$ 1), si possono trattare in modo **unificato** attraverso un'applicazione che associa ad ogni esito dello spazio campione un valore numerico.



Definizione: Variabile aleatoria (caso discreto)

Dato uno spazio di probabilità $(\Omega, \mathcal{E}, P)$ discreto, una **variabile aleatoria** è un'applicazione

$$X : \Omega \rightarrow \mathbb{R}$$

dove $\mathbb{R}$ è un insieme numerico chiamato **alfabeto** della variabile aleatoria. La funzione X associa ad ogni esito $\omega \in \Omega$ un valore numerico $X(\omega) \in \mathbb{R}$.



Perché le variabili aleatorie sono utili

Consentono di trattare in modo unificato esperimenti diversi che hanno la stessa struttura probabilistica. Ogni insieme discreto non numerico si può sempre descrivere attraverso un insieme di numeri interi (ad esempio, puntatori a locazioni di memoria dove sono memorizzate le etichette). Quindi, quando lo spazio dei campioni è discreto, si possono indicizzare gli eventi elementari e la variabile aleatoria diventa semplicemente l'indice che denota quell'evento elementare.



Stringhe binarie di lunghezza k

Le stringhe binarie di lunghezza k sono 2^k . Ciascuna stringa può essere memorizzata in una locazione di memoria; la variabile aleatoria assume il valore i dove i è il puntatore alla locazione della i -esima configurazione. Si ottiene così una variabile aleatoria che assume 2^k possibili valori.

Cenno alla misurabilità

Il professore accenna al fatto che, per essere rigorosi, una variabile aleatoria deve essere un'**applicazione misurabile**: l'anti-immagine di ogni evento concernente X deve essere un elemento della σ -algebra. Questa condizione garantisce che si possa calcolare la probabilità che X assuma certi valori. Tuttavia, per il livello del corso, è sufficiente la definizione semplificata.

Parole del Professore

Quote

"Queste cose le ho studiate perché mi sono servite per la mia ricerca, e manco sono sicuro che mi siano servite veramente perché il mio advisor di dottorato era sadico e mi metteva in mano certi libri. Però se uno deve fare ricerca in questo campo, è bene che certe cose le faccia."

Evento elementare nello spazio della variabile aleatoria

L'evento elementare diventa $\{X(\omega) = x\}$, cioè l'insieme di tutti gli $\omega \in \Omega$ tali che $X(\omega) = x$:

$$P(X = x) = P(\{\omega \in \Omega : X(\omega) = x\})$$

La probabilità si "trasporta" dallo spazio di probabilità originario al nuovo spazio numerico.

Parità del lancio di un dado onesto

Sia $\Omega = \{1, 2, 3, 4, 5, 6\}$ e si definisca:

$$X(\omega) = \begin{cases} 0 & \text{se } \omega \in \{2, 4, 6\} \text{ (risultato pari)} \\ 1 & \text{se } \omega \in \{1, 3, 5\} \text{ (risultato dispari)} \end{cases}$$

Allora, poiché il dado è onesto e gli eventi $\{2\}, \{4\}, \{6\}$ sono incompatibili:

$$P(X = 0) = P(\{2, 4, 6\}) = \frac{1}{6} + \frac{1}{6} + \frac{1}{6} = \frac{1}{2}$$

$$P(X = 1) = 1 - P(X = 0) = \frac{1}{2}$$

Essendo la variabile binaria, una volta calcolata una probabilità non c'è bisogno di calcolare l'altra.

Doppio lancio di una moneta onesta

$\Omega = \{TT, TC, CT, CC\}$ (dove T = testa, C = croce). Si può definire una variabile aleatoria X che assume i valori $\{0, 1, 2, 3\}$ (oppure $\{1, 2, 3, 4\}$, la scelta è arbitraria), ciascuno con probabilità $\frac{1}{4}$ per una moneta onesta:

$$P = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}.$$

Probability Mass Function (PMF)

Definizione: PMF (funzione di massa di probabilità)

Data una variabile aleatoria discreta X con alfabeto $X = \{x_1, x_2, \dots, x_m\}$ (dove $m = |X|$ e la cardinalità dell'alfabeto), la **PMF** (Probability Mass Function) e la sequenza:

$$p_X(x_i) = P(X = x_i), \quad i = 1, 2, \dots, m$$

Una sequenza di m numeri è una PMF valida **se e solo se**:

1. $p_X(x_i) \geq 0$ per ogni i (non negatività --- Assioma 1 di Kolmogorov);
2. $\sum_{i=1}^m p_X(x_i) = 1$ (normalizzazione --- Assioma 2 di Kolmogorov).

Dalla normalizzazione e dalla non negatività segue automaticamente che $p_X(x_i) \leq 1$ per ogni i (la somma di numeri positivi è 1, quindi ogni singolo numero è al più 1).

Verifica di una PMF

La sequenza $(\frac{1}{2}, \frac{1}{4}, \frac{1}{8}, \frac{1}{8})$ è una PMF valida?

$$\frac{1}{2} + \frac{1}{4} + \frac{1}{8} + \frac{1}{8} = \frac{4}{8} + \frac{2}{8} + \frac{1}{8} + \frac{1}{8} = \frac{8}{8} = 1 \quad \checkmark$$

Tutti i termini sono non negativi e la somma è 1: **si**, è una PMF valida.

PMF del lancio singolo e del doppio lancio

- **Lancio singolo** di una moneta onesta: la PMF è $(\frac{1}{2}, \frac{1}{2})$, due valori (variabile binaria).
- **Doppio lancio** di una moneta onesta: la PMF è $(\frac{1}{4}, \frac{1}{4}, \frac{1}{4}, \frac{1}{4})$, quattro valori.

Cenno al Valore Atteso (Media)

Il professore anticipa brevemente il concetto di **valore atteso**. Per una variabile aleatoria binaria X con $P(X = 0) = P(X = 1) = \frac{1}{2}$, chiede alla classe: "Qual è la media di questa variabile aleatoria?"

La risposta è $\frac{1}{2}$, e il ragionamento frequentistico che porta a questa risposta è il seguente:

Se si fanno n prove e si osservano le realizzazioni $X(\omega_1), X(\omega_2), \dots, X(\omega_n)$, la **media aritmetica** è:

$$\bar{X}_n = \frac{1}{n} \sum_{k=1}^n X(\omega_k) = \frac{1}{n} (0 \cdot n_0 + 1 \cdot n_1) = \frac{n_1}{n}$$

dove n_0 è il numero di volte in cui esce 0 e $n_1 = n - n_0$ è il numero di volte in cui esce 1. Quando $n \rightarrow \infty$:

$$\bar{X}_n \xrightarrow{n \rightarrow \infty} 0 \cdot P(X = 0) + 1 \cdot P(X = 1) = \frac{1}{2} \stackrel{\text{def}}{=} E[X]$$

Parole del Professore

Quote

"Voi avete automaticamente detto, guarda, se io faccio n prove, la metà delle volte mi viene 0, la metà delle volte mi viene 1. Voi ragionate inevitabilmente sulla frequenza di successo."

Attenzione

Il risultato $E[X] = \frac{1}{2}$ vale perché la variabile è **equiprobabile**. Il fatto che la media aritmetica converga al valore atteso è un risultato profondo che sarà formalizzato nelle lezioni successive.

Punti chiave della lezione

- Le proprietà della probabilità derivate dalla frequenza di successo sono confermate dalla teoria assiomatica, dove diventano **teoremi** dimostrabili dai soli assiomi di Kolmogorov.
- Un'**algebra** è una collezione di sottoinsiemi chiusa rispetto a unione e complementazione; la chiusura rispetto a intersezione e differenza segue dalle leggi di De Morgan.
- Una σ -**algebra** estende la chiusura a unioni numerabili, ed è necessaria quando Ω è infinito numerabile.
- Lo **spazio di probabilità** $(\Omega, \mathcal{E}, P)$ è il fondamento rigoroso della probabilità: P deve soddisfare non negatività, normalizzazione e σ -additività.
- La **legge della probabilità composta** esprime $P(A \cap B)$ come $P(A) \cdot P(B | A)$ o $P(B) \cdot P(A | B)$.
- La **legge di Bayes** consente di invertire il condizionamento: da $P(A | B)$ a $P(B | A)$.
- La **legge della probabilità totale** permette di scomporre $P(A)$ condizionando rispetto a una partizione.
- L'**indipendenza stocastica** è definita da $P(A \cap B) = P(A) \cdot P(B)$; se due eventi sono indipendenti, lo sono anche i loro complementari.
- L'**indipendenza a coppie** non implica l'indipendenza congiunta (controesempio: bit di parità).
- La **probabilità condizionata** $P(\cdot | B)$ è essa stessa una legge di probabilità (soddisfa tutti gli assiomi di Kolmogorov).
- Una **variabile aleatoria** è un'applicazione da Ω a un insieme numerico; la **PMF** ne caratterizza completamente la distribuzione nel caso discreto.
- La **media aritmetica** delle osservazioni converge al valore atteso $E[X]$, concetto che sarà formalizzato nelle prossime lezioni.

? Argomenti trattati:

- Definizione del valore atteso (media statistica) e motivazione tramite legge dei grandi numeri
- Distribuzione di Bernoulli e distribuzione Binomiale: definizione, verifica PMF, media = np (derivazione completa)
- Connessione tra la Binomiale e i problemi di conteggio combinatorio
- Distribuzione Uniforme discreta: definizione, media = media aritmetica dell'alfabeto
- Formula di Gauss per la somma dei primi n interi
- Distribuzione di Poisson: definizione, verifica PMF tramite serie esponenziale, media = λ
- Applicazioni della Poisson: code di traffico, router, uffici postali
- Distribuzione Geometrica: tempo al primo successo, PMF, media = 1/p (derivazione con serie geometrica)
- Esercizio: 3 dadi (2 onesti, 1 truccato), applicazione del teorema di Bayes
- Introduzione alla PMF condizionata
- Cenni sugli outlier nell'analisi dei dati

Valore Atteso (Media Statistica)

Motivazione: dalla frequenza alla media

Nella lezione precedente abbiamo introdotto le variabili aleatorie discrete e la funzione massa di probabilità (PMF). Ora ci chiediamo: dato che una variabile aleatoria X può assumere diversi valori, esiste un singolo numero che ne "riassuma" il comportamento medio?

L'idea nasce dalla statistica descrittiva. Supponiamo di ripetere un esperimento n volte e di osservare i valori $x_1, x_2, \dots, x_n$. La **media campionaria** (la media aritmetica delle osservazioni) è:

$$\bar{x}_n = \frac{1}{n} \sum_{i=1}^n x_i$$

Sia $X = \{a_1, a_2, \dots, a_M\}$ l'**alfabeto** di X , cioè l'insieme dei valori che X può assumere. Se il valore a_k compare N_k volte nelle n prove (dove $\sum_{k=1}^M N_k = n$), possiamo riscrivere la media campionaria raggruppando i termini uguali:

$$\bar{x}_n = \frac{1}{n} \sum_{k=1}^M N_k \cdot a_k = \sum_{k=1}^M \frac{N_k}{n} \cdot a_k = \sum_{k=1}^M f_n(a_k) \cdot a_k$$

dove $f_n(a_k) = N_k/n$ è la **frequenza relativa** del valore a_k su n prove. Per la **legge dei grandi numeri**, quando il numero di prove n tende all'infinito, la frequenza relativa converge alla probabilità:

$$f_n(a_k) \xrightarrow{n \rightarrow \infty} P_X(a_k)$$

Quindi la media campionaria converge a un valore ben definito:

$$\bar{x}_n \xrightarrow{n \rightarrow \infty} \sum_{k=1}^M a_k \cdot P_X(a_k)$$

Questo limite è il **valore atteso** della variabile aleatoria.

Definizione: Valore atteso (media statistica)

Sia X una variabile aleatoria discreta con alfabeto $X = \{a_1, a_2, \dots, a_M\}$ (finito o numerabile) e PMF $P_X(x)$. Il **valore atteso** (o **media statistica**, o **speranza matematica**) di X è definito come:

$$E[X] = \mu_X = \sum_{k=1}^M a_k \cdot P_X(a_k)$$

dove a_k sono i valori nell'alfabeto e $P_X(a_k)$ le rispettive probabilità. Il simbolo $E[\cdot]$ si legge "valore atteso di" oppure "aspettazione di"; μ_X è la notazione alternativa con la lettera greca mu.

Media statistica vs media aritmetica

La media statistica **non** coincide in generale con la media aritmetica dei valori dell'alfabeto. La media aritmetica pesa tutti i valori allo stesso modo ($1/M$ ciascuno); la media statistica è una **media pesata** con pesi $P_X(a_k)$. Solo quando la distribuzione è uniforme (tutti i valori equiprobabili) le due medie coincidono.

Parole del Professore

Quote

"La media statistica è il baricentro della distribuzione di probabilità: se mettete dei pesi sulle posizioni dell'asse reale, il baricentro cade dove c'è più massa di probabilità. È il numero verso cui converge la media campionaria quando fate tante prove."

Distribuzione di Bernoulli

Definizione: Variabile aleatoria di Bernoulli

Una variabile aleatoria X segue una **distribuzione di Bernoulli** di parametro $p \in [0, 1]$, e si scrive $X \sim \text{Ber}(p)$, se:

- L'alfabeto è $X = \{0, 1\}$, dove 1 rappresenta il **successo** e 0 il **fallimento**
- La PMF è:

$$P_X(x) = \begin{cases} p & \text{se } x = 1 \\ 1 - p = q & \text{se } x = 0 \end{cases}$$

Il parametro p è la **probabilità di successo** e $q = 1 - p$ la probabilità di fallimento.

Scrittura compatta della PMF. La PMF di Bernoulli si può esprimere in forma chiusa, valida per entrambi i valori dell'alfabeto con un'unica espressione:

$$P_X(x) = p^x(1-p)^{1-x}, \quad x \in \{0, 1\}$$

Verifica: per $x = 1$ si ottiene $p^1(1-p)^0 = p$; per $x = 0$ si ottiene $p^0(1-p)^1 = 1-p = q$. Corretto.

Verifica della normalizzazione. La somma di tutte le probabilità deve dare 1:

$$\sum_{x \in \{0,1\}} P_X(x) = P_X(0) + P_X(1) = (1-p) + p = 1 \quad \checkmark$$

Media della Bernoulli

Il valore atteso di $X \sim \text{Ber}(p)$ si calcola direttamente dalla definizione, sommando su tutti i valori dell'alfabeto:

$$E[X] = \sum_{x \in \{0,1\}} x \cdot P_X(x) = 0 \cdot (1-p) + 1 \cdot p = p$$

$$\boxed{E[X] = p}$$

La media di una Bernoulli è semplicemente la probabilità di successo.

Esempio: lancio di una moneta

Una moneta onesta ha probabilità $p = 0,5$ di dare testa (codificata come $X = 1$). La media di X è $E[X] = 0,5$: se lancio la moneta un numero enorme di volte e faccio la media dei risultati (0 e 1), il valore converge a 0,5.

Distribuzione Binomiale

Definizione: Distribuzione Binomiale

Siano $X_1, X_2, \dots, X_n$ variabili aleatorie **i.i.d.** (indipendenti e identicamente distribuite), ciascuna con distribuzione $X_i \sim \text{Ber}(p)$. La variabile aleatoria:

$$S_n = X_1 + X_2 + \dots + X_n = \sum_{i=1}^n X_i$$

conta il **numero totale di successi** in n prove di Bernoulli indipendenti. Si dice che S_n segue una **distribuzione Binomiale** di parametri n (numero di prove) e p (probabilità di successo nella singola prova):

$$S_n \sim \text{Bin}(n, p)$$

L'alfabeto è $X = \{0, 1, 2, \dots, n\}$ e la PMF è:

$$P_{S_n}(k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n$$

dove $\binom{n}{k} = \frac{n!}{k!(n-k)!}$ è il **coefficiente binomiale**.

Interpretazione combinatoria (connessione con il conteggio)

La PMF binomiale ha una struttura che si spiega interamente con gli strumenti dell'analisi combinatoria visti nelle prime lezioni:

- Il fattore $p^k(1-p)^{n-k}$ è la probabilità di una **specificata sequenza** di n prove che contiene esattamente k successi e $n-k$ fallimenti. Per l'indipendenza delle prove, le probabilità si moltiplicano.
- Il fattore $\binom{n}{k}$ conta il **numero di sequenze distinte** di lunghezza n con esattamente k successi (e $n-k$ fallimenti). Questo è esattamente il conteggio delle sequenze binarie con k uni che avevamo derivato nella Lezione 2.

La PMF è quindi: (numero di sequenze favorevoli) $\times$ (probabilità di ciascuna sequenza).

Verifica della normalizzazione

La somma di tutte le probabilità deve dare 1. Applicando il Binomio di Newton con $a = p$ e $b = (1-p)$:

$$\sum_{k=0}^n P_{S_n}(k) = \sum_{k=0}^n \binom{n}{k} p^k (1-p)^{n-k} = (p + (1-p))^n = 1^n = 1 \quad \checkmark$$

Media della Binomiale: derivazione completa

- **Metodo 1 — Per linearità del valore atteso.** Poiché $S_n = X_1 + X_2 + \dots + X_n$ con $X_i \sim \text{Ber}(p)$ indipendenti, e poiché il valore atteso è un operatore **lineare** (la media di una somma è la somma delle medie):

$$E[S_n] = E\left[\sum_{i=1}^n X_i\right] = \sum_{i=1}^n E[X_i] = \sum_{i=1}^n p = np$$

$E[S_n] = np$

- **Metodo 2 — Calcolo diretto dalla definizione della PMF.** Si parte dalla definizione:

$$E[S_n] = \sum_{k=0}^n k \cdot \binom{n}{k} p^k (1-p)^{n-k}$$

Il termine con $k = 0$ è nullo, quindi la somma parte da $k = 1$:

$$= \sum_{k=1}^n k \cdot \frac{n!}{k!(n-k)!} p^k (1-p)^{n-k}$$

Semplifichiamo k con $k! = k \cdot (k-1)!$:

$$= \sum_{k=1}^n \frac{n!}{(k-1)!(n-k)!} p^k (1-p)^{n-k}$$

Raccogliamo il fattore np scrivendo $n! = n \cdot (n-1)!$ e $p^k = p \cdot p^{k-1}$:

$$= np \sum_{k=1}^n \frac{(n-1)!}{(k-1)!(n-1-(k-1))!} p^{k-1} (1-p)^{(n-1)-(k-1)}$$

Effettuiamo il cambio di indice $j = k-1$ e poniamo $m = n-1$:

$$= np \sum_{j=0}^m \binom{m}{j} p^j (1-p)^{m-j} = np \cdot (p + (1-p))^m = np \cdot 1 = np$$

I due metodi danno lo stesso risultato: $E[S_n] = np$.

☰ Esempio: vaccino

Un vaccino ha efficacia $p = 0,95$ (probabilità che un singolo vaccinato sviluppi l'immunità). Su $n = 1000$ vaccinati, il numero atteso di soggetti protetti è:

$$E[S_{1000}] = 1000 \cdot 0,95 = 950$$

☰ Esempio: roulette

Alla roulette europea, il rosso esce con probabilità $p = 18/37$ (ci sono 18 numeri rossi su 37 caselle totali). In $n = 37$ giri, il numero atteso di uscite del rosso è:

$$E[S_{37}] = 37 \cdot \frac{18}{37} = 18$$

Notiamo che la roulette non è un gioco equo: con 18 rossi, 18 neri e 1 zero verde, il banco ha un leggero vantaggio.

Distribuzione Uniforme Discreta

📄 Definizione: Distribuzione Uniforme Discreta

Una variabile aleatoria X segue una **distribuzione uniforme discreta** sull'alfabeto $X = \{a_1, a_2, \dots, a_M\}$ se tutti i valori sono equiprobabili:

$$P_X(a_k) = \frac{1}{M}, \quad k = 1, 2, \dots, M$$

dove $M = |X|$ è la **cardinalità** dell'alfabeto (il numero di valori possibili).

Verifica della normalizzazione:

$$\sum_{k=1}^M P_X(a_k) = \sum_{k=1}^M \frac{1}{M} = M \cdot \frac{1}{M} = 1 \quad \checkmark$$

Media della Uniforme Discreta

Il valore atteso si calcola applicando la definizione:

$$E[X] = \sum_{k=1}^M a_k \cdot \frac{1}{M} = \frac{1}{M} \sum_{k=1}^M a_k = \frac{a_1 + a_2 + \dots + a_M}{M}$$

⚠ La media della uniforme coincide con la media aritmetica dell'alfabeto

Nel caso uniforme — e **solo** nel caso uniforme — la media statistica coincide con la media aritmetica dei valori dell'alfabeto. Per qualunque altra distribuzione, i valori con probabilità maggiore "pesano" di più e spostano la media verso di sé.

Formula di Gauss

Quando l'alfabeto è $X = \{1, 2, \dots, M\}$ (i primi M interi positivi), per calcolare la somma $1 + 2 + \dots + M$ si usa la celebre **formula di Gauss**:

$$\sum_{k=1}^M k = \frac{M(M+1)}{2}$$

💡 Parole del Professore

🗉 Quote

"La scoprì Gauss a sei anni, quando il maestro gli chiese di sommare i numeri da 1 a 100 pensando di tenerlo occupato per un'ora. Gauss scrisse l'ultimo numero accanto al primo, il penultimo accanto al secondo... e si accorse che ogni coppia faceva 101. Cinquanta coppie: $50 \times 101 = 5050$. Il maestro rimase a bocca aperta."

Dimostrazione. Sia $S = 1 + 2 + \dots + M$. Scriviamo la somma due volte, una in ordine crescente e una in ordine decrescente:

$$S = 1 + 2 + \dots + (M-1) + M$$

$$S = M + (M-1) + \dots + 2 + 1$$

Sommando termine a termine, ogni coppia dà $(M+1)$, e le coppie sono M :

$$2S = \underbrace{(M+1) + (M+1) + \dots + (M+1)}_{M \text{ volte}} = M(M+1)$$

$$\text{Da cui } S = \frac{M(M+1)}{2}.$$

☰ Esempio: dado onesto

Un dado onesto a 6 facce ha $X = \{1, 2, 3, 4, 5, 6\}$ e distribuzione uniforme ($P_X(k) = 1/6$ per ogni faccia k). Il valore atteso è:

$$E[X] = \frac{1}{6} \sum_{k=1}^6 k = \frac{1}{6} \cdot \frac{6 \cdot 7}{2} = \frac{42}{12} = 3,5$$

Il valore 3,5 **non appartiene all'alfabeto**: la media è un indice sintetico che indica il baricentro della distribuzione, non necessariamente un valore che la variabile può assumere.

Formula generale. Per una variabile uniforme su $\{1, 2, \dots, M\}$, la media è:

$$E[X] = \frac{1}{M} \cdot \frac{M(M+1)}{2} = \frac{M+1}{2}$$

Distribuzione di Poisson

Definizione: Distribuzione di Poisson

Una variabile aleatoria X segue una **distribuzione di Poisson** di parametro $\lambda > 0$, e si scrive $X \sim \text{Poi}(\lambda)$, se:

- L'alfabeto è $X = \{0, 1, 2, 3, \dots\} = N_0$ (l'insieme dei naturali incluso lo zero, cioè **numerabilmente infinito**)
- La PMF è:

$$P_X(k) = \frac{\lambda^k}{k!} e^{-\lambda}, \quad k = 0, 1, 2, \dots$$

Il parametro λ (lettera greca lambda) rappresenta il **tasso medio** di occorrenze nell'intervallo di tempo (o spazio) considerato. Il simbolo $e \approx 2,718$ è il numero di Nepero, base del logaritmo naturale; $k!$ è il fattoriale di k (con la convenzione $0! = 1$).

Verifica della normalizzazione tramite serie esponenziale

La somma di tutte le probabilità deve dare 1. Per verificarlo, ricordiamo lo sviluppo in **serie di Taylor dell'esponenziale**:

$$e^\lambda = \sum_{k=0}^{\infty} \frac{\lambda^k}{k!}$$

Questa serie converge per ogni $\lambda \in \mathbb{R}$. Applicandola alla somma delle probabilità:

$$\sum_{k=0}^{\infty} P_X(k) = \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} e^{-\lambda} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = e^{-\lambda} \cdot e^\lambda = e^0 = 1 \quad \checkmark$$

Il fattore $e^{-\lambda}$ è proprio la costante di normalizzazione che rende la PMF una distribuzione di probabilità valida.

Media della Poisson: $E[X] = \lambda$ (derivazione completa)

Partiamo dalla definizione di valore atteso per una variabile con alfabeto infinito numerabile:

$$E[X] = \sum_{k=0}^{\infty} k \cdot \frac{\lambda^k}{k!} e^{-\lambda}$$

Il termine con $k = 0$ dà contributo nullo ($0 \cdot P_X(0) = 0$), quindi la somma parte da $k = 1$:

$$= e^{-\lambda} \sum_{k=1}^{\infty} k \cdot \frac{\lambda^k}{k!}$$

Semplifichiamo k con il fattoriale, usando $k! = k \cdot (k - 1)!$:

$$= e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^k}{(k-1)!}$$

Estraiamo un fattore λ dal numeratore, scrivendo $\lambda^k = \lambda \cdot \lambda^{k-1}$:

$$= \lambda e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!}$$

Effettuiamo il cambio di indice $j = k - 1$ (quando $k = 1$ si ha $j = 0$; quando $k \rightarrow \infty$ si ha $j \rightarrow \infty$):

$$= \lambda e^{-\lambda} \sum_{j=0}^{\infty} \frac{\lambda^j}{j!} = \lambda e^{-\lambda} \cdot e^{\lambda} = \lambda \cdot 1 = \lambda$$

$$\boxed{E[X] = \lambda}$$

La media della Poisson è esattamente il parametro λ : un risultato elegante che conferma l'interpretazione di λ come tasso medio.

Parole del Professore

Quote

"La Poisson è la distribuzione delle cose rare: eventi che singolarmente sono poco probabili, ma che vengono osservati su un numero enorme di occasioni. Quante macchine passano al casello in un minuto? Quanti pacchetti arrivano al router in un millisecondo? Quante persone entrano all'ufficio postale in un'ora? Tutte Poisson."

Applicazioni della distribuzione di Poisson

Esempio: code di traffico

Al casello autostradale, in media arrivano $\lambda = 4$ auto al minuto. Il numero di auto che arrivano in un dato minuto si modella come $X \sim \text{Poi}(4)$. La probabilità che in un minuto ne arrivino esattamente $k = 6$ è:

$$P(X = 6) = \frac{4^6}{6!} e^{-4} = \frac{4096}{720} \cdot e^{-4} \approx 5,689 \cdot 0,0183 \approx 0,104 \approx 10,4\%$$

☰ Esempio: pacchetti al router

Un router di rete riceve in media $\lambda = 100$ pacchetti al millisecondo. La variabile aleatoria "numero di pacchetti ricevuti in un millisecondo" segue una $\text{Poi}(100)$. Il valore atteso è $E[X] = 100$ pacchetti/ms. Questo modello di Poisson è fondamentale nel **dimensionamento delle code** nei sistemi di rete: permette di calcolare la probabilità che il buffer del router si saturi e inizi a perdere pacchetti.

☰ Esempio: ufficio postale

All'ufficio postale entrano in media $\lambda = 3$ clienti ogni 10 minuti. La probabilità che non entri **nessuno** in un intervallo di 10 minuti è:

$$P(X = 0) = \frac{3^0}{0!} e^{-3} = 1 \cdot e^{-3} \approx 0,050 = 5\%$$

Mentre la probabilità che ne entrino esattamente 3 (il valore medio) è:

$$P(X = 3) = \frac{3^3}{3!} e^{-3} = \frac{27}{6} \cdot e^{-3} \approx 4,5 \cdot 0,050 \approx 0,224 \approx 22,4\%$$

La Poisson come limite della Binomiale

⚠ Approssimazione di Poisson alla Binomiale

Quando n è molto grande e p è molto piccolo, con il prodotto $\lambda = np$ che resta finito, la distribuzione Binomiale $\text{Bin}(n, p)$ è ben approssimata dalla Poisson $\text{Poi}(\lambda)$:

$$\binom{n}{k} p^k (1-p)^{n-k} \approx \frac{\lambda^k}{k!} e^{-\lambda}, \quad \text{per } n \rightarrow \infty, p \rightarrow 0, np = \lambda$$

Questa approssimazione è molto utile nella pratica, perché evita di calcolare coefficienti binomiali con n enorme.

Distribuzione Geometrica

Definizione: Distribuzione Geometrica

Una variabile aleatoria X segue una **distribuzione Geometrica** di parametro $p \in (0, 1]$, e si scrive $X \sim \text{Geo}(p)$, se rappresenta il **numero di prove necessarie per ottenere il primo successo** in una sequenza di prove di Bernoulli indipendenti, ciascuna con probabilità di successo p .

- L'alfabeto è $X = \{1, 2, 3, \dots\}$ (numerabilmente infinito: il primo successo potrebbe teoricamente non arrivare mai)
- La PMF è:

$$P_X(k) = (1 - p)^{k-1} p, \quad k = 1, 2, 3, \dots$$

dove $(1 - p)^{k-1}$ è la probabilità di $k - 1$ fallimenti consecutivi e p è la probabilità del successo alla k -esima prova.

Interpretazione. Per ottenere il primo successo esattamente alla prova numero k , devono verificarsi:

- $k - 1$ fallimenti consecutivi, ciascuno con probabilità $q = 1 - p$
- Seguiti da 1 successo, con probabilità p

Per l'**indipendenza** delle prove, le probabilità si moltiplicano: $\underbrace{q \cdot q \cdots q}_{k-1} \cdot p = q^{k-1} p$.

Verifica della normalizzazione (serie geometrica)

Ricordiamo la formula della **serie geometrica**: per $|r| < 1$:

$$\sum_{k=0}^{\infty} r^k = \frac{1}{1 - r}$$

Sia $q = 1 - p$. Poiché $p \in (0, 1]$, si ha $q \in [0, 1)$ e quindi $|q| < 1$:

$$\sum_{k=1}^{\infty} P_X(k) = \sum_{k=1}^{\infty} q^{k-1} p = p \sum_{j=0}^{\infty} q^j = p \cdot \frac{1}{1 - q} = p \cdot \frac{1}{p} = 1 \quad \checkmark$$

dove nel secondo passaggio abbiamo posto $j = k - 1$.

Media della Geometrica: $E[X] = 1/p$ (derivazione completa)

Partiamo dalla definizione:

$$E[X] = \sum_{k=1}^{\infty} k \cdot q^{k-1} p = p \sum_{k=1}^{\infty} k \cdot q^{k-1}$$

Per calcolare la somma $\sum_{k=1}^{\infty} k \cdot q^{k-1}$, usiamo un trucco fondamentale: riconosciamo che è la **derivata** della serie geometrica rispetto a q .

Passo 1. Partiamo dalla serie geometrica:

$$\sum_{k=0}^{\infty} q^k = \frac{1}{1 - q}$$

Passo 2. Deriviamo entrambi i membri rispetto a q . A sinistra, la derivata di q^k è $k \cdot q^{k-1}$ (il termine $k = 0$ scompare perché la derivata di 1 è 0):

$$\frac{d}{dq} \sum_{k=0}^{\infty} q^k = \sum_{k=1}^{\infty} k \cdot q^{k-1}$$

A destra:

$$\frac{d}{dq} \left(\frac{1}{1-q} \right) = \frac{1}{(1-q)^2}$$

Passo 3. Quindi:

$$\sum_{k=1}^{\infty} k \cdot q^{k-1} = \frac{1}{(1-q)^2}$$

Passo 4. Sostituendo nella formula della media e ricordando che $1 - q = p$:

$$E[X] = p \cdot \frac{1}{(1-q)^2} = p \cdot \frac{1}{p^2} = \frac{1}{p}$$

$$E[X] = \frac{1}{p}$$

☰ Esempio: roulette — tempo alla prima vincita

Un giocatore scommette sul rosso alla roulette europea ($p = 18/37 \approx 0,486$). In media, quante giocate deve fare per vincere la prima volta?

$$E[X] = \frac{1}{18/37} = \frac{37}{18} \approx 2,06 \text{ giocate}$$

☰ Esempio: lancio di un dado — aspettare il 6

Qual è il numero medio di lanci di un dado onesto necessari per ottenere il primo 6? Qui $p = 1/6$:

$$E[X] = \frac{1}{1/6} = 6 \text{ lanci}$$

⚠ Proprietà di assenza di memoria (memoryless)

La distribuzione geometrica gode della **proprietà di assenza di memoria**: il fatto di aver già fallito n prove non cambia la distribuzione del tempo residuo al primo successo.

$$P(X > n + m \mid X > n) = P(X > m), \quad \forall n, m \geq 0$$

Intuitivamente: "le prove passate non influenzano il futuro". Se sto aspettando il primo 6 e ho già fatto 10 lanci senza successo, il numero medio di lanci rimanenti è ancora 6, non $6 - 10$. La geometrica è l'**unica** distribuzione discreta con questa proprietà.

Esercizio: Tre Dadi e il Teorema di Bayes

Testo del problema

Si dispone di 3 dadi: **2 onesti** (ciascuna faccia esce con probabilità $1/6$) e **1 truccato** (il 6 esce con probabilità $1/2$, le altre 5 facce escono con probabilità $1/10$ ciascuna). Si sceglie un dado a caso con uguale probabilità ($1/3$ per ciascun dado) e lo si lancia una volta. Esce il numero 6.

Domanda: qual è la probabilità che il dado utilizzato sia quello truccato?

Soluzione con il teorema di Bayes

Definizione degli eventi:

- T: il dado scelto è quello truccato
- O: il dado scelto è uno dei due onesti
- S: il risultato del lancio è 6 (il "sei")

Passo 1 — Probabilità a priori. Prima del lancio, non abbiamo alcuna informazione su quale dado sia stato scelto. La scelta è equiprobabile fra i 3 dadi:

$$P(T) = \frac{1}{3}, \quad P(O) = \frac{2}{3}$$

Passo 2 — Verosimiglianze (likelihood). La probabilità di osservare 6 dato il tipo di dado scelto:

$$P(S | T) = \frac{1}{2} \quad (\text{il dado truccato fa uscire il 6 con probabilità } 1/2)$$

$$P(S | O) = \frac{1}{6} \quad (\text{un dado onesto fa uscire il 6 con probabilità } 1/6)$$

Passo 3 — Probabilità totale. La probabilità complessiva di osservare 6 (indipendentemente dal dado) si calcola con il **teorema della probabilità totale**:

$$\begin{aligned} P(S) &= P(S | T) \cdot P(T) + P(S | O) \cdot P(O) = \frac{1}{2} \cdot \frac{1}{3} + \frac{1}{6} \cdot \frac{2}{3} \\ &= \frac{1}{6} + \frac{2}{18} = \frac{1}{6} + \frac{1}{9} = \frac{3}{18} + \frac{2}{18} = \frac{5}{18} \end{aligned}$$

Passo 4 — Applicazione del teorema di Bayes. La probabilità **a posteriori** che il dado sia truccato, dato che è uscito 6:

$$P(T | S) = \frac{P(S | T) \cdot P(T)}{P(S)} = \frac{\frac{1}{2} \cdot \frac{1}{3}}{\frac{5}{18}} = \frac{\frac{1}{6}}{\frac{5}{18}} = \frac{1}{6} \cdot \frac{18}{5} = \frac{18}{30} = \frac{3}{5}$$

$$P(T | S) = \frac{3}{5} = 60\%$$

Verifica di coerenza. Calcoliamo anche $P(O | S)$ per verificare che le probabilità a posteriori sommino a 1:

$$P(O | S) = \frac{P(S | O) \cdot P(O)}{P(S)} = \frac{\frac{1}{6} \cdot \frac{2}{3}}{\frac{5}{18}} = \frac{\frac{2}{18}}{\frac{5}{18}} = \frac{2}{5} = 40\%$$

$$P(T | S) + P(O | S) = \frac{3}{5} + \frac{2}{5} = 1 \quad \checkmark$$

L'aggiornamento bayesiano: a priori vs a posteriori

Prima del lancio, la probabilità che il dado fosse truccato era $P(T) = 1/3 \approx 33\%$. Dopo aver osservato l'uscita del 6, la probabilità è salita a $P(T|S) = 3/5 = 60\%$. L'osservazione ha **aggiornato** la nostra credenza: poiché il 6 è molto più probabile con il dado truccato ($1/2$ vs $1/6$), la sua uscita è un'evidenza a favore dell'ipotesi "dado truccato".

Parole del Professore

Quote

"Bayes è questo: prima di vedere i dati avete un'opinione — la probabilità a priori. Poi vedete i dati e aggiornate l'opinione — ottenete la probabilità a posteriori. Se i dati sono coerenti con la vostra ipotesi, la probabilità sale; se non lo sono, scende. Questo è il cuore dell'inferenza statistica."

PMF Condizionata

Definizione formale

Definizione: PMF condizionata

Sia X una variabile aleatoria discreta con alfabeto X e sia A un evento con $P(A) > 0$. La **PMF condizionata** di X dato l'evento A è:

$$P_{X|A}(x) = P(X = x | A) = \frac{P(\{X = x\} \cap A)}{P(A)}, \quad x \in X$$

dove $\{X = x\}$ è l'evento "la variabile aleatoria X assume il valore x ".

La PMF condizionata è essa stessa una PMF valida: è non-negativa e la somma su tutto l'alfabeto dà 1.

Interpretazione. Condizionare all'evento A equivale a **restringere** lo spazio dei campioni Ω al sottoinsieme A e ricalcolare le probabilità nel nuovo universo. I valori di X che sono incompatibili con A ricevono probabilità condizionata nulla; quelli compatibili vedono la loro probabilità aumentare proporzionalmente.

☰ Esempio: dado condizionato a "pari"

Sia X il risultato di un dado onesto. La PMF incondizionata è $P_X(k) = 1/6$ per $k = 1, 2, \dots, 6$.

Supponiamo di sapere che è uscito un numero **pari**: $A = \{2, 4, 6\}$, con $P(A) = 3/6 = 1/2$. La PMF condizionata è:

$$P_{X|A}(k) = \begin{cases} \frac{1/6}{1/2} = \frac{1}{3} & \text{se } k \in \{2, 4, 6\} \\ 0 & \text{se } k \in \{1, 3, 5\} \end{cases}$$

Lo spazio dei campioni si è ristretto da $\{1, 2, 3, 4, 5, 6\}$ a $\{2, 4, 6\}$: i tre valori pari diventano equiprobabili tra loro, con probabilità $1/3$ ciascuno.

Connessione con l'esercizio dei dadi e Bayes

Nell'esercizio con i 3 dadi, il passaggio dalla probabilità a priori alla probabilità a posteriori è esattamente un condizionamento:

- **PMF a priori** del tipo di dado: $P(T) = 1/3$, $P(O) = 2/3$
- **PMF a posteriori** (condizionata all'uscita del 6): $P(T | S) = 3/5$, $P(O | S) = 2/5$

Il teorema di Bayes fornisce il meccanismo per passare dalla PMF incondizionata alla PMF condizionata quando l'evento di condizionamento riguarda un'osservazione e si vuole aggiornare la distribuzione su un'ipotesi.

In generale, se $H_1, H_2, \dots, H_n$ sono ipotesi mutualmente esclusive ed esaustive (una partizione dello spazio), e D è un dato osservato:

$$P(H_i | D) = \frac{P(D | H_i) \cdot P(H_i)}{\sum_{j=1}^n P(D | H_j) \cdot P(H_j)}$$

Questa formula consente di passare dalla PMF a priori $\{P(H_i)\}$ alla PMF a posteriori $\{P(H_i | D)\}$.

Cenni sugli Outlier nell'Analisi dei Dati

⚠ Outlier e sensibilità della media

La media statistica è molto sensibile ai **valori anomali** (outlier). Un singolo valore estremo nella distribuzione (o nel campione) può spostare significativamente la media, rendendola un indicatore poco rappresentativo del "centro" della distribuzione. Nella pratica dell'analisi dei dati, questo è un problema serio.

☰ Esempio: stipendi in un'azienda

In un'azienda ci sono 9 dipendenti con stipendio annuo di 30.000 euro e 1 dirigente con stipendio di 300.000 euro. La media degli stipendi è:

$$\bar{x} = \frac{9 \cdot 30.000 + 300.000}{10} = \frac{270.000 + 300.000}{10} = \frac{570.000}{10} = 57.000 \text{ euro}$$

Ma 57.000 euro non rappresenta nessuno: il 90% dei dipendenti guadagna circa la metà della media, e il dirigente guadagna più di cinque volte la media. La **mediana** (30.000 euro, il valore che divide la distribuzione a metà) sarebbe in questo caso un indicatore molto più informativo.

Per questo motivo, nella pratica, accanto alla media si calcolano sempre altri indicatori:

- La **mediana**: il valore che divide la distribuzione a metà (il 50% dei dati sta sopra, il 50% sotto). È robusta rispetto agli outlier.
- La **varianza** (che vedremo nelle prossime lezioni): misura la dispersione dei dati attorno alla media. Se la varianza è alta, la media da sola è poco informativa.

💡 Parole del Professore

🗉 Quote

"Se uno mette la testa nel forno e i piedi nel congelatore, in media sta bene. Ecco perché la media da sola non basta: bisogna sempre guardare anche quanto i dati si disperdono attorno ad essa."

📋 Punti chiave della lezione

- Il **valore atteso** $E[X] = \sum_k a_k P_X(a_k)$ è il baricentro della distribuzione e il limite della media campionaria per la legge dei grandi numeri.
- **Bernoulli** $\text{Ber}(p)$: l'esperimento più semplice (successo/fallimento), con media $E[X] = p$.
- **Binomiale** $\text{Bin}(n, p)$: somma di n Bernoulli indipendenti, PMF $= \binom{n}{k} p^k (1-p)^{n-k}$, media $= np$.
- **Uniforme** discreta: tutti i valori equiprobabili, media = media aritmetica dell'alfabeto.
- **Poisson** $\text{Poi}(\lambda)$: distribuzione degli eventi rari, PMF $= \frac{\lambda^k}{k!} e^{-\lambda}$, media $= \lambda$. Si applica a code, traffico, reti.
- **Geometrica** $\text{Geo}(p)$: tempo al primo successo, PMF $= (1-p)^{k-1} p$, media $= 1/p$. Unica distribuzione discreta con assenza di memoria.
- Il **teorema di Bayes** permette di aggiornare la probabilità a priori di un'ipotesi dopo aver osservato dei dati, ottenendo la probabilità a posteriori.
- La **PMF condizionata** restringe lo spazio dei campioni e ridistribuisce le probabilità.
- La media è sensibile agli **outlier**: nella pratica va sempre affiancata da mediana e varianza.

? Argomenti trattati

- Ripasso variabili notevoli: Binomiale, Uniforme, Poissoniana, Geometrica
- PMF condizionata: ripasso e generalizzazione
- Media condizionale e legge della probabilità totale per le medie
- Funzioni di variabili aleatorie: $Y = g(X)$
 - Caso biiettivo: reflagging dell'alfabeto
 - Caso multi-a-uno: collasso delle probabilità
- Teorema fondamentale del calcolo della media: $E[g(X)] = \sum_x g(x)p_X(x)$
- Valore quadratico medio (RMS) e valore efficace
- Varianza e deviazione standard
- Relazione varianza-valore quadratico medio
- Esercizi: dado truccato (3 dadi), vaccinazione (Binomiale), carte napoletane (non-geometrica)

Ripasso: Variabili Notevoli

Variabile	Alfabeto	PMF $p_X(k)$	Media $E[X]$
Binomiale $B(n, p)$	$\{0, \dots, n\}$	$\binom{n}{k} p^k (1-p)^{n-k}$	np
Uniforme su m valori	$\{x_1, \dots, x_m\}$	$1/m$	media aritmetica
Poissoniana $P(\lambda)$	N_0	$\lambda^k e^{-\lambda} / k!$	λ
Geometrica $G(p)$	$\{1, 2, 3, \dots\}$	$(1-p)^{k-1} p$	$1/p$

PMF Condizionata: Ripasso e Media Condizionale

PMF condizionata a un evento

Data una condizione C con $P(C) > 0$:

$$p_{X|C}(k) = \frac{P(X = k, C)}{P(C)} = \begin{cases} \frac{p_X(k)}{P(C)} & \text{se } k \in C \\ 0 & \text{altrimenti} \end{cases}$$

Questa è ancora una PMF valida. Applicazione in data analysis: **potatura degli outlier** (si escludono valori anomali imponendo una maschera di ammissibilità sul dominio).

Media condizionale e scomposizione della media

Dato un evento C , la **media condizionale** di X dato C è:

$$E[X | C] = \sum_{x \in X} x \cdot p_{X|C}(x)$$

Data una partizione $\{E_1, E_2, \dots, E_m\}$ di Ω (eventi disgiunti la cui unione è Ω), la media totale si scompone come:

$$E[X] = \sum_{i=1}^m P(E_i) \cdot E[X | E_i]$$

Derivazione: si applica la legge della probabilità totale alla PMF di X , moltiplicando per x e sommando su tutti gli x .

☰ **Esempio con Binomiale** $B(16, 1/3)$

Partizione: $E_1 = \{X \leq 4\}$, $E_2 = \{X > 4\}$.

$$E[X] = P(X \leq 4) \cdot E[X | X \leq 4] + P(X > 4) \cdot E[X | X > 4]$$

Funzioni di Variabili Aleatorie: $Y = g(X)$

Se X è una variabile aleatoria e g è una funzione definita sull'alfabeto di X , allora $Y = g(X)$ è anch'essa una variabile aleatoria.

Caso 1: Corrispondenza biiettiva ($|Y| = |X|$)

Se g è una biiezione (ogni valore di X mappa in un valore distinto di Y), allora:

$$p_Y(g(x_i)) = p_X(x_i)$$

Si tratta di un semplice **reflagging dell'alfabeto**: le probabilità sono invariate, cambiano solo le etichette dei valori.

☰ $Y = 4X$, con $X \in \{-2, -1, 1, 2\}$ e $p_X = \{1/8, 1/4, 1/4, 3/8\}$

L'alfabeto di Y è $\{-8, -4, 4, 8\}$ con le stesse probabilità.

Caso 2: Corrispondenza multi-a-uno ($|Y| < |X|$)

Più valori di X collassano in uno stesso valore di Y . Le probabilità corrispondenti si sommano:

$$p_Y(y_k) = \sum_{\{x: g(x)=y_k\}} p_X(x)$$

$\Xi Y = |X|$, con $X \in \{-2, -1, 1, 2\}$

$Y \in \{1, 2\}$.

$$p_Y(1) = p_X(-1) + p_X(1) = 1/4 + 1/4 = 1/2$$

$$p_Y(2) = p_X(-2) + p_X(2) = 1/8 + 3/8 = 1/2$$

$$\text{Media: } E[Y] = 1 \cdot 1/2 + 2 \cdot 1/2 = 3/2$$

Teorema Fondamentale del Calcolo della Media

Teorema

Data una variabile aleatoria X con PMF p_X e una funzione g , la media di $Y = g(X)$ è:

$$E[g(X)] = \sum_{x \in \mathcal{X}} g(x) \cdot p_X(x)$$

indipendentemente dal fatto che g sia biiettiva o multi-a-uno.

Questo teorema è fondamentale perché permette di calcolare $E[g(X)]$ **senza costruire esplicitamente la PMF di Y** : si lavora direttamente con la PMF di X .

Dimostrazione (caso multi-a-uno): i valori che collasano nello stesso punto di Y hanno tutti lo stesso $g(x)$; la somma su x è quindi equivalente alla somma su y (le probabilità si sommano automaticamente).

Valore Quadratico Medio (RMS)

Definizione

Il **valore quadratico medio** di X è:

$$E[X^2] = \sum_{x \in \mathcal{X}} x^2 \cdot p_X(x)$$

Il **valore efficace** (root mean square) è:

$$x_{\text{rms}} = \sqrt{E[X^2]}$$

Terminologia RMS

Il termine inglese "root mean square" indica che si prende la **radice** del valor medio del **quadrato**. La notazione $x_{\text{rms}}^2 = E[X^2]$ (il quadrato del valore efficace = valore quadratico medio) può essere fonte di confusione.

☰ Corrente alternata e valore efficace

La corrente sinusoidale ha **media nulla** (le semionde positive e negative si cancellano). La corrente efficace $I_{\text{rms}} = I_0 / \sqrt{2}$ è quella che determina la potenza dissipata: $P = I_{\text{rms}}^2 \cdot R$. Una presa con corrente media zero può essere letale se il valore efficace è diverso da zero.

Machine Learning: minimizzazione dell'errore quadratico medio

L'errore quadratico medio (MSE) è la funzione costo standard nel ML:

$$\text{MSE} = E[(X - \hat{X})^2]$$

Vantaggi: è **convessa** (forma a coppa con un unico minimo globale), derivabile e trattabile analiticamente. I problemi di ottimizzazione convessa convergono a soluzioni ottimali globali, a differenza di quelli concavi che hanno massimi unici ma sono usati quando si massimizza una figura di merito.

Varianza e Deviazione Standard

Definizione

La **variabile centrata** $X - \mu_X$ ha media nulla per costruzione. La sua "dimensione" è misurata dalla **varianza**:

$$\sigma_X^2 = E[(X - \mu_X)^2] = \sum_x (x - \mu_X)^2 \cdot p_X(x) \geq 0$$

La **deviazione standard** è $\sigma_X = \sqrt{\sigma_X^2}$.

Relazione con il valore quadratico medio

$$\sigma_X^2 = E[X^2] - \mu_X^2$$

Dimostrazione:

$$E[(X - \mu_X)^2] = E[X^2 - 2\mu_X X + \mu_X^2] = E[X^2] - 2\mu_X^2 + \mu_X^2 = E[X^2] - \mu_X^2$$

Interpretazione fisica: media e varianza come coppia

La coppia (μ_X, σ_X) caratterizza globalmente la variabile aleatoria:

- $\sigma_X \ll \mu_X$: la variabile è concentrata intorno alla media → la media è un buon predittore
- $\sigma_X \gg \mu_X$: la variabile è dispersa → la media non descrive bene il comportamento tipico

Il rapporto μ_X / σ_X (inverso del coefficiente di variazione) misura il "segnale rispetto al rumore" della variabile aleatoria.

☰ Confronto

Sia X una variabile con media 100€ e deviazione standard 1 centesimo: praticamente deterministica, la media descrive la situazione quasi perfettamente. Se invece $\sigma_X = 40$ €: alta aleatorietà, la situazione economica "istantanea" può essere molto diversa dalla media.

Esercizi Svolti

Esercizio 1: Tre Dadi — Probabilità di Ottenere 12

Setup: urna con 3 dadi: D_0 (onesto), D_1 ($P(1) = u$, altri equiprobabili), D_6 ($P(6) = u$, altri equiprobabili). Si estraggono **2 dadi** e si lanciano.

Per D_1 : $P(i \neq 1) = (1 - u)/5$. Per D_6 : $P(i \neq 6) = (1 - u)/5$.

Le coppie estratte (D_0D_1 , D_0D_6 , D_1D_6) sono equiprobabili con prob. $1/3$ ciascuna. Per la legge della probabilità totale:

$$P(12) = \frac{1}{3} \left[\frac{1}{6} \cdot \frac{1-u}{5} + \frac{1}{6} \cdot u + \frac{1-u}{5} \cdot u \right] = \frac{1 + 10u - 6u^2}{90}$$

Domanda 2: $P(12) = 2/36 = 1/18 \rightarrow$ risolve $6u^2 - 10u + 4 = 0 \rightarrow u_1 = 1, u_2 = 2/3$.

Domanda 3: massimizzare $P(12)$. La funzione è concava, il massimo è in $u^* = 10/12 = 5/6$, con $P(12)_{\max} \approx 0,0584$.

Esercizio 2: Vaccinazione — Variabile Binomiale $B(10, 0,9)$

10 bambini vaccinati, vaccino efficace nel 90% dei casi, indipendentemente. X = numero di bambini immunizzati.

a) Tutti immunizzati:

$$P(X = 10) = 0,9^{10} \approx 0,349$$

b) Almeno 8 immunizzati:

$$P(X \geq 8) = \binom{10}{8} (0,9)^8 (0,1)^2 + \binom{10}{9} (0,9)^9 (0,1) + (0,9)^{10}$$

c) Numero medio: $E[X] = 10 \cdot 0,9 = 9$.

Esercizio 3: Carte Napoletane — Distribuzione Non-Standard

Setup: mazzo da 40 carte napoletane (10 denari + 30 altre). Due giocatori estraggono **senza reinserire**. Vince chi per primo estrae un denaro. X = numero di estrazioni.

Alfabeto: $X = \{1, 2, \dots, 31\}$.

 Non è una geometrica!

La geometrica richiede prove indipendenti. Qui le estrazioni sono **dipendenti**: ogni carta estratta riduce il mazzo e cambia le probabilità per le estrazioni successive.

Calcolo di $P(X = 4)$ con la probabilità composta:

$$P(X = 4) = \frac{30}{40} \cdot \frac{29}{39} \cdot \frac{28}{38} \cdot \frac{10}{37}$$

Chi vince il primo giocatore? Vince se X è dispari (estrae alle posizioni 1, 3, 5, ...):

$$P(\text{vince il 1° giocatore}) = \sum_{\substack{i \text{ dispari} \\ 1 \leq i \leq 31}} p_X(i)$$

 Argomenti trattati

- Varianza come misura dell'aleatorietà: interpretazione fisica e geometrica
- Disuguaglianza di Markov e disuguaglianza di Chebyshev
- Relazione varianza-media: quando la media è un buon indicatore
- Proprietà algebriche di media e varianza (linearità, covarianza per scala, invarianza per traslazione)
- Giustificazione matematica della definizione frequentistica di probabilità
- Convergenza in media quadratica e in probabilità della frequenza di successo
- Legge dei grandi numeri: versione forte e debole
- Esercizio: strategia di gioco con puntata costante (geometrica) e martingala
- Annuncio: prossima lezione su coppie di variabili aleatorie

Varianza come Misura dell'Aleatorietà

Interpretazione

La media statistica μ_X è il baricentro della distribuzione. La **varianza** σ_X^2 misura quanto i valori di X si discostano mediamente da quel baricentro.

 Definizione: Varianza e Deviazione Standard

Data una variabile aleatoria X con media μ_X , si definisce:

$$\sigma_X^2 = E[(X - \mu_X)^2] = \sum_{x \in X} (x - \mu_X)^2 \cdot p_X(x)$$

La **deviazione standard** è $\sigma_X = \sqrt{\sigma_X^2}$. Per costruzione, $\sigma_X^2 \geq 0$.

La coppia (μ_X, σ_X) caratterizza globalmente una variabile aleatoria:

- Se $\sigma_X \ll \mu_X$: la variabile è **poco aleatoria**, concentrata intorno alla media. La media è un buon indicatore.
- Se σ_X è comparabile o superiore a μ_X : la variabile è **molto aleatoria**. Osservare valori molto lontani dalla media è probabile. La media da sola non descrive bene il

comportamento tipico.

☰ Esempio con deviazione standard 1€ vs 10€

Se il professore ha mediamente 100€ in tasca:

- Con $\sigma_X = 1€$: con probabilità 99% trovo tra 90 e 110€. La media è quasi deterministica.
- Con $\sigma_X = 10€$: con probabilità 90% trovo tra 90 e 110€. Alta incertezza.

La quantità rilevante è il **rapporto** μ_X / σ_X (inverso del coefficiente di variazione): più è grande, meno è aleatoria la variabile.

Disuguaglianza di Chebyshev

Disuguaglianza di Markov (prerequisito)

Per ogni variabile aleatoria **non negativa** Y e ogni $\delta > 0$:

$$P(Y \geq \delta) \leq \frac{E[Y]}{\delta}$$

Disuguaglianza di Chebyshev

Applicando la disuguaglianza di Markov alla variabile non negativa $Y = (X - \mu_X)^2$ con $\delta = (k\sigma_X)^2$:

📋 Disuguaglianza di Chebyshev

Per ogni variabile aleatoria X di media μ_X e deviazione standard σ_X , e per ogni $k > 0$:

$$P(|X - \mu_X| \geq k\sigma_X) \leq \frac{1}{k^2}$$

Equivalentemente:

$$P(|X - \mu_X| < k\sigma_X) \geq 1 - \frac{1}{k^2}$$

Interpretazione: la probabilità di trovare X a una distanza superiore a k deviazioni standard dalla media è al più $1/k^2$, indipendentemente dalla forma specifica della distribuzione.

☰ Applicazione numerica

Con $k = 10$: $P(|X - \mu_X| \geq 10\sigma_X) \leq 1\%$. Qualunque sia la distribuzione di X , osservare un valore a più di 10 deviazioni standard dalla media ha probabilità inferiore all'1%.

Proprietà Algebriche di Media e Varianza

Proprietà operative di Media e Varianza

Per costanti reali a e b :

$$E[aX + b] = a \cdot E[X] + b$$

Dimostrazione: b è deterministica (non aleatoria), quindi esce fuori dall'operatore E . Anche a è deterministica e fattorizza:

$$E[aX + b] = E[aX] + E[b] = a E[X] + b$$

Comportamento della varianza

$$\sigma_{aX+b}^2 = a^2 \sigma_X^2$$

Due proprietà distinte:

1. **Invarianza per traslazione:** la varianza di $aX + b$ è uguale a quella di aX . Un termine additivo b sposta la distribuzione ma non la allarga né la restringe.
2. **Covarianza quadratica per scala:** un fattore moltiplicativo a scala la deviazione standard di $|a|$ e la varianza di a^2 .

Dimostrazione:

$$\sigma_{aX+b}^2 = E[(aX + b - (a\mu_X + b))^2] = E[(a(X - \mu_X))^2] = a^2 E[(X - \mu_X)^2] = a^2 \sigma_X^2$$

Conseguenza importante

Se $\sigma_X^2 = 0$, la variabile aleatoria è quasi certamente uguale alla sua media: per la disuguaglianza di Chebyshev, per ogni $\varepsilon > 0$, $P(|X - \mu_X| > \varepsilon) \rightarrow 0$.

Covarianza e Correlazione (Introdotta dopo)

Covarianza

Definizione: Covarianza

Date due variabili aleatorie X e Y , la **covarianza** è:

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)] = E[XY] - E[X]E[Y]$$

dove $\mu_X = E[X]$ e $\mu_Y = E[Y]$.

La covarianza misura il grado di **co-variazione** tra due variabili:

- **Positiva:** le deviazioni dalla media di X e Y tendono a essere dello stesso segno (se X è sopra la media, anche Y lo è).
- **Negativa:** le deviazioni tendono a essere di segno opposto (se X è sopra la media, Y tende ad essere sotto).
- **Zero:** non esiste una tendenza lineare di co-variazione.

Indipendenza implica incorrelazione

Se X e Y sono indipendenti, allora $\text{Cov}(X, Y) = 0$:

$$E[XY] = E[X]E[Y] \Rightarrow \text{Cov}(X, Y) = 0$$

Però l'implicazione non vale al contrario: variabili non correlate (covarianza nulla) **non sono necessariamente indipendenti**.

Variabili dipendenti ma incorrelate

Sia $U \sim \text{Uniforme}(-1, 1)$ (simmetrica attorno a 0). Poniamo $Y = U^2$. Chiaramente Y dipende da U , ma:

$$\text{Cov}(U, U^2) = E[U \cdot U^2] - E[U] \cdot E[U^2] = E[U^3] - 0 = 0$$

perché U^3 è una funzione dispari di U (simmetrico attorno allo zero).

Coefficiente di correlazione

Definizione: Coefficiente di correlazione

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

dove $\sigma_X = \sqrt{\text{Var}(X)}$ e $\sigma_Y = \sqrt{\text{Var}(Y)}$ sono le deviazioni standard.

Questo coefficiente **normalizza** la covarianza rispetto alle scale delle due variabili, rendendola adimensionale.

Proprietà fondamentale:

$$\boxed{-1 \leq \rho_{XY} \leq 1}$$

Dimostrazione (Cauchy-Schwarz): consideriamo le variabili centrate $X' = X - \mu_X$ e $Y' = Y - \mu_Y$. L'insieme delle variabili aleatorie con varianza finita forma uno **spazio vettoriale** con prodotto scalare $\langle X', Y' \rangle = \text{Cov}(X, Y)$ e norma $\|X'\| = \sigma_X$. La disuguaglianza di Cauchy-Schwarz afferma:

$$|\langle X', Y' \rangle| \leq \|X'\| \cdot \|Y'\| \Rightarrow |\text{Cov}(X, Y)| \leq \sigma_X \sigma_Y \Rightarrow |\rho_{XY}| \leq 1$$

Interpretazione dei valori estremi:

- $\rho_{XY} = 1$: relazione lineare perfetta crescente; $Y = a + bX$ con $b > 0$.
- $\rho_{XY} = -1$: relazione lineare perfetta decrescente; $Y = a + bX$ con $b < 0$.
- $\rho_{XY} = 0$: assenza di relazione lineare (incorrelazione).

$$\boxed{\text{Incorrelazione} \Leftrightarrow \rho_{XY} = 0}$$

$$\boxed{\text{Indipendenza} \Rightarrow \text{Incorrelazione}} \text{ (implicazione unidirezionale, salvo caso gaussiano)}$$

Correlazione $\neq$ Causalità

Una correlazione elevata tra X e Y non implica che X cause Y o viceversa. Potrebbero essere entrambe causate da una terza variabile (confondimento).

La frequenza di successo come variabile aleatoria

Il professore mostra rigorosamente perché la definizione frequentistica di probabilità è matematicamente fondata. Si effettuano n prove indipendenti di un esperimento e si conta quante volte l'evento A si verifica.

La frequenza di successo è essa stessa una variabile aleatoria:

$$F_n(A) = \frac{N_A(\omega)}{n}$$

dove $N_A(\omega)$ è il numero di occorrenze di A in n prove. Ogni volta che si ripete il blocco di n prove, N_A può assumere un valore diverso.

N_A è un conteggio Binomiale:

Se le prove sono indipendenti, $N_A \sim B(n, P(A))$, perché contiamo il numero di successi (verificarsi di A) in n prove indipendenti, ciascuna con probabilità $P(A)$.

Di conseguenza:

$$E[N_A] = n \cdot P(A) \quad \Rightarrow \quad E[F_n(A)] = \frac{E[N_A]}{n} = P(A)$$

$$\text{Var}(N_A) = n \cdot P(A) \cdot (1 - P(A)) \quad \Rightarrow \quad \text{Var}(F_n(A)) = \frac{P(A)(1 - P(A))}{n}$$

Convergenza al crescere di n

$$\lim_{n \rightarrow \infty} \text{Var}(F_n(A)) = \lim_{n \rightarrow \infty} \frac{P(A)(1 - P(A))}{n} = 0$$

Quando la varianza tende a zero, la variabile aleatoria si concentra attorno alla sua media. Quindi $F_n(A) \rightarrow P(A)$ in due sensi precisi:


Legge dei Grandi Numeri (forme)

Convergenza in media quadratica: $E[(F_n(A) - P(A))^2] \rightarrow 0$ quando $n \rightarrow \infty$, perché coincide con la varianza di $F_n(A)$.

Convergenza in probabilità (da Chebyshev): per ogni $\epsilon > 0$:

$$P(|F_n(A) - P(A)| > \epsilon) \leq \frac{\text{Var}(F_n(A))}{\epsilon^2} = \frac{P(A)(1 - P(A))}{n\epsilon^2} \rightarrow 0$$

Convergenza con probabilità 1 (Legge forte dei grandi numeri, non dimostrata): l'evento che $F_n(A) \rightarrow P(A)$ ha probabilità esattamente 1.



Le frecce indicano implicazioni. Convergenza con prob. 1 e convergenza in media quadratica sono entrambe **forti**, ma non si implicano a vicenda. Entrambe implicano la convergenza in probabilità (la più debole).

💡 Parole del Professore

🗉 Quote

"La probabilità è definita come il limite della frequenza di successo. Questo ha senso matematico rigoroso: la frequenza converge alla probabilità in media quadratica e in probabilità. La nostra definizione era corretta fin dall'inizio."

Nota sul problema circolare

La definizione frequentistica richiede che le prove siano **indipendenti** — ma l'indipendenza è essa stessa un concetto probabilistico. L'approccio formale (assiomi di Kolmogorov) risolve questo problema: si definisce prima la probabilità assiomaticamente, poi si dimostra che la frequenza converge a essa.

💡 Parole del Professore

🔖 Quote

"Il professore Conte me lo contesta sempre: per definire la probabilità usi la frequenza, ma per dire che è una frequenza hai bisogno dell'indipendenza, che è un concetto probabilistico. È il cane che si morde la coda. In realtà non serve strettamente l'indipendenza: basta un'asintotica indipendenza."

Esercizio: Strategie di Gioco al Casinò

Setup

Un giocatore ha una somma S e adotta diverse strategie in un gioco dove la probabilità di vincita è a e, in caso di vittoria, riceve b volte la posta puntata.

Strategia A: Punta costante (1€ per volta)

Variabile aleatoria: X = numero di puntate effettuate.

Alfabeto: $X = \{1, 2, \dots, S\}$.

PMF:

- Per $k < S$: $P(X = k) = (1 - a)^{k-1} \cdot a$ (vince alla k -esima puntata dopo $k - 1$ fallimenti)
- Per $k = S$: il giocatore fa l'ultima puntata comunque, sia che vinca che perda. Quindi $P(X = S) = (1 - a)^{S-1}$ (equivalente a: perde le prime $S - 1$ puntate, poi gioca la S -esima indipendentemente dall'esito).

💡 Semplificazione per $k = S$

Non importa se l'ultima puntata viene vinta o persa: il giocatore si alza in entrambi i casi. Quindi l'evento $\{X = S\}$ coincide con "perde le prime $S - 1$ puntate", con probabilità $(1 - a)^{S-1}$.

Questa distribuzione è **quasi geometrica** (la coda è troncata a S).

Guadagno: Se vince alla k -esima puntata, il guadagno è $b - k$ (riceve b euro, ne ha spesi k). Se $X = S$ senza vincere l'ultima, il guadagno è $-S$.

Strategia B: Martingala (raddoppio dopo ogni perdita)

Alla k -esima puntata si punta 2^{k-1} euro. La somma totale puntata fino alla puntata k -esima è:

$$\sum_{i=1}^k 2^{i-1} = 2^k - 1$$

Il numero massimo di puntate intere prima di esaurire la somma S è:

$$x_{\max} = \lfloor \log_2(S + 1) \rfloor$$

Guadagno se vince alla k -esima puntata:

$$g(k) = b \cdot 2^{k-1} - (2^k - 1) = (b - 2) \cdot 2^{k-1} + 1$$

Per la roulette ($b = 36$, $a = 18/37$): $g(k) = 34 \cdot 2^{k-1} + 1$.

Paradosso della martingala

Se il limite di puntata $S \rightarrow \infty$ (patrimonio infinito, nessun limite), la martingala garantisce di vincere con probabilità 1 — ed è per questo che i casinò impongono un **limite massimo di puntata**. Con un qualunque limite finito S , il guadagno medio è negativo per il giocatore (il banco ha sempre un vantaggio statistico).

Parole del Professore

Quote

"Il guadagno medio per $S \rightarrow \infty$ diverge. Ma attenzione: fare il limite di S al denominatore non è lo stesso che calcolare il guadagno con S infinito. La convergenza è in probabilità, non puntuale. Questo è un esempio di convergenza in probabilità che non implica nulla sul limite dei valori attesi."

Punti chiave della lezione

- La **varianza** misura l'aleatorietà: σ_X^2 piccolo significa variabile concentrata intorno alla media. La coppia (μ_X, σ_X) caratterizza globalmente X .
- La **disuguaglianza di Chebyshev** quantifica quanto raramente una variabile si discosta dalla media: $P(|X - \mu_X| \geq k\sigma_X) \leq 1/k^2$.
- **Media** è lineare: $E[aX + b] = aE[X] + b$. **Varianza** è invariante per traslazione e covariante per scala: $\text{Var}(aX + b) = a^2\text{Var}(X)$.
- La **frequenza di successo** $F_n(A)$ è una variabile aleatoria con $E[F_n(A)] = P(A)$ e $\text{Var}(F_n(A)) = P(A)(1 - P(A))/n \rightarrow 0$. Quindi $F_n(A) \rightarrow P(A)$ in media quadratica e in probabilità (legge dei grandi numeri).
- La convergenza in media quadratica e quella con probabilità 1 sono entrambe forti e implicano quella in probabilità, ma non si implicano a vicenda.

#MSI

#varianza

#deviazione-standard

#Chebyshev

#convergenza

#frequenza

#martingala

#legge-grandi-numeri

? Argomenti trattati

- Riepilogo: caratterizzazione di una singola variabile aleatoria
- Coppia di variabili aleatorie: definizione e PMF congiunta
- Proprietà di marginalizzazione
- Indipendenza statistica tra variabili aleatorie
- Estensione a terne e n-uple di variabili aleatorie
- PMF condizionale per coppie
- Esempio: terne di bit (sorgente senza memoria vs. bit di parità)

Riepilogo: singola variabile aleatoria

Una singola variabile aleatoria discreta X è completamente caratterizzata dalla sua **PMF** (Probability Mass Function) $p_X(x)$, che assegna a ogni valore x dell'alfabeto la probabilità $P(X = x)$.

Dalla PMF si derivano:

- **Media** (valore atteso): $E[X] = \sum_x x \cdot p_X(x)$
- **Teorema fondamentale per il calcolo della media**: $E[g(X)] = \sum_x g(x) \cdot p_X(x)$
- **Momenti**: $E[X^m]$ (momento di ordine m), $E[(X - E[X])^m]$ (momento centrale)
- **Varianza**: $\text{Var}(X) = E[(X - E[X])^2] = E[X^2] - (E[X])^2$
- **Disuguaglianza di Chebyshev**: $P(|X - E[X]| \geq k\sigma) \leq \frac{1}{k^2}$, dove σ è la deviazione standard

Trasformazione di Densità (Introdotta dopo)

Questa sezione introduce il concetto cruciale per passare a variabili aleatorie continue. Se X è una variabile aleatoria continua con densità $f_X(x)$ e $Y = g(X)$ dove g è una trasformazione monotona e differenziabile, la densità di Y si calcola come segue:

Se g è **strettamente monotona** (crescente o decrescente), esiste una funzione inversa unica $x = g^{-1}(y)$. Per la regola della catena nel calcolo delle probabilità:

📄 Teorema Fondamentale della Trasformazione di Densità

$$f_Y(y) = f_X(g^{-1}(y)) \cdot \left| \frac{d}{dy} g^{-1}(y) \right| = \frac{f_X(x)}{|g'(x)|} \Big|_{x=g^{-1}(y)}$$

dove il termine $|g'(x)|^{-1}$ è il **fattore jacobiano** che tiene conto della dilatazione/compressione della trasformazione.

Intuizione: quando g dilata lo spazio (aumenta le distanze), la concentrazione di probabilità diminuisce, quindi la densità deve diminuire. Il fattore jacobiano compensa questa variazione.

☰ Trasformazione $Y = aX + b$

Se $X \sim N(\mu, \sigma^2)$ e $Y = aX + b$ con $a > 0$:

$$x = \frac{y - b}{a}, \quad \frac{dx}{dy} = \frac{1}{a}$$

$$f_Y(y) = f_X\left(\frac{y - b}{a}\right) \cdot \frac{1}{|a|} = \frac{1}{\sigma\sqrt{2\pi}|a|} \exp\left(-\frac{1}{2\sigma^2}\left(\frac{y - b}{a} - \mu\right)^2\right)$$

che si riconosce come una gaussiana con media $a\mu + b$ e deviazione standard $|a|\sigma$.

Entropia di Shannon (Introdotta dopo)

Informazione contenuta in un evento

L'**entropia** è un concetto fondamentale nella teoria dell'informazione, introdotto da Claude Shannon nel 1948. Misura il grado di **incertezza** o **contenuto informativo** di una fonte di dati.

Dato un evento A di probabilità $P(A)$, la quantità di informazione ricevuta dal verificarsi di A è misurata dalla funzione:

$$I(A) = \log_2 \frac{1}{P(A)} = -\log_2 P(A)$$

Questa funzione soddisfa tre proprietà naturali:

1. **Non negativa:** $I(A) \geq 0$ (evento impossibile o certo raramente porta informazione).
2. **Decrescente nella probabilità:** più rare l'evento, più informazione contiene. Un evento frequente ("il Sole sorgerà domani") porta poca informazione.
3. **Additiva per eventi indipendenti:** $I(A \cap B) = I(A) + I(B)$ se A e B sono indipendenti.

La base 2 del logaritmo rende l'unità di misura il **bit** (binary digit): un evento certo e uno impossibile corrispondono rispettivamente a 0 e $+\infty$ bit.

☰ Esempi interpretativi

- Evento certo ($P(A) = 1$): $I(A) = -\log_2 1 = 0$ bit (informazione nulla: non apprendiamo nulla di nuovo).
- Moneta equilibrata ($P(A) = 1/2$): $I(A) = -\log_2(1/2) = 1$ bit (informazione massima per un evento binario).
- Evento molto raro ($P(A) = 1/1024 = 2^{-10}$): $I(A) = 10$ bit (informazione molto alta).

Entropia di una variabile aleatoria discreta

Poiché $I(X = x) = -\log_2 p_X(x)$ è essa stessa una variabile aleatoria (dipende dal valore assunto da X), l'**entropia** è definita come la sua **media statistica**:

Definizione: Entropia di Shannon

L'entropia di una variabile aleatoria discreta X con PMF $p_X(x)$ è:

$$H(X) = - \sum_{x \in \mathcal{X}} p_X(x) \log_2 p_X(x)$$

Alternativamente: $H(X) = E[-\log_2 p_X(X)]$.
Si misura in **bit** (con logaritmo in base 2).

L'entropia risponde alla domanda: **quanti bit in media** serve trasferire (o memorizzare) per codificare il valore di X ?

Proprietà fondamentali:

- **Non negativa:** $H(X) \geq 0$, con $H(X) = 0$ se e solo se X è deterministica (assume un valore con probabilità 1).
- **Massimizzata dall'uniforme:** data un alfabeto di cardinalità n , l'entropia è massima quando $p_X(x) = 1/n$ per ogni x , e vale $H_{\max} = \log_2 n$.
- **Sotto-additività per variabili indipendenti:** $H(X, Y) \leq H(X) + H(Y)$, con uguaglianza se X e Y sono indipendenti.

Entropia di variabili comuni

Variabile	Alfabeto	PMF	Entropia massima
Bernoulliana	$\{0, 1\}$	$p, 1 - p$	$H_{\max} = 1$ bit a $p = 1/2$
Uniforme su n valori	$\{1, \dots, n\}$	$1/n$	$H_{\max} = \log_2 n$ bit
Poissoniana $P(\lambda)$	N_0	$\lambda^k e^{-\lambda} / k!$	Infinito (alfabeto infinito)

Entropia di una Bernoulliana

Per $X \in \{0, 1\}$ con $P(X = 1) = p$:

$$H(X) = -p \log_2 p - (1 - p) \log_2 (1 - p)$$

A $p = 1/2$ (equiprobabile): $H(1/2, 1/2) = -\frac{1}{2} \log_2 (1/2) - \frac{1}{2} \log_2 (1/2) = 1$ bit.

A $p = 0.9$ (molto asimmetrica): $H(0.9, 0.1) \approx 0.47$ bit.

A $p = 1$ (deterministica): $H(1, 0) = 0$ bit.

Implicazione nella compressione di dati

Un **file compresso ideale** è una sequenza binaria in cui ogni bit è ugualmente probabile di essere 0 o 1 (**equiprobabile**) e i bit sono statisticamente indipendenti. In questo caso, ogni bit trasferisce 1 bit di informazione nel senso di Shannon, e non è possibile comprimere ulteriormente.

Se il file ha caratteri con frequenze diverse (es. lettera 'e' più frequente), l'entropia è inferiore a 1 bit per carattere, e la **compressione** (es. **Huffman coding**) può ridurre la media di bit utilizzati.

Motivazione

In molte applicazioni si osservano più grandezze contemporaneamente sullo stesso esperimento. Per esempio, su un database di persone, ogni estrazione casuale restituisce sia l'altezza X che il peso Y : si ha un'applicazione dallo spazio dei campioni a una coppia ordinata $(X(\omega), Y(\omega))$.

Definizione: Coppia di variabili aleatorie

Dato uno spazio di probabilità $(\Omega, \mathcal{F}, P)$, una **coppia di variabili aleatorie** (X, Y) è un'applicazione:

$$\omega \mapsto (X(\omega), Y(\omega)) \in X \times Y$$

dove X e Y sono gli alfabeti (insiemi di valori possibili) di X e Y rispettivamente.

PMF congiunta

Definizione: PMF congiunta

La **PMF congiunta** di (X, Y) è la tabella:

$$p_{XY}(x, y) = P(X = x, Y = y), \quad \forall x \in X, y \in Y$$

Questa tabella ha $|X| \times |Y|$ entrate, tutte non negative, la cui somma è 1:

$$\sum_{x \in X} \sum_{y \in Y} p_{XY}(x, y) = 1$$

Esempio: due variabili binarie

$X_1, X_2 \in \{0, 1\}$. La tabella seguente è una PMF congiunta valida:

	$X_2 = 0$	$X_2 = 1$
$X_1 = 0$	1/4	1/8
$X_1 = 1$	1/8	1/2

Verifica: $1/4 + 1/8 + 1/8 + 1/2 = 1$. ✓

Marginalizzazione

Dalla PMF congiunta si ricavano le PMF delle singole variabili, dette **PMF marginali**:

$$p_X(x) = \sum_{y \in Y} p_{XY}(x, y), \quad p_Y(y) = \sum_{x \in X} p_{XY}(x, y)$$

Dimostrazione: L'evento $\{X = x\}$ è l'unione disgiunta degli eventi $\{X = x, Y = y\}$ al variare di y . Per l'assioma di additività di Kolmogorov: $P(X = x) = \sum_y P(X = x, Y = y)$.

Asimmetria congiunta ↔ marginali

- Congiunta **implica** marginali: data la PMF congiunta, le marginali sono univocamente determinate (per somma).
- Marginali **non implicano** congiunta: date le due PMF marginali, esistono in generale molte congiunte compatibili con esse.

L'unica eccezione è il caso di indipendenza statistica (vedi §4).

Indipendenza statistica

Definizione: Indipendenza statistica

Due variabili aleatorie X e Y sono **statisticamente indipendenti** se e solo se la loro PMF congiunta si fattorizza nel prodotto delle marginali:

$$p_{XY}(x, y) = p_X(x) \cdot p_Y(y), \quad \forall x \in X, y \in Y$$

Equivalentemente: conoscere il valore assunto da X non modifica la distribuzione di probabilità di Y e viceversa.

Altezza e peso: variabili dipendenti

Altezza e peso non sono indipendenti: se so che una persona è alta 1,70 m, la distribuzione del peso condizionata è diversa dalla distribuzione marginale del peso. La probabilità congiunta che una persona sia alta 1,70 m e pesi 40 kg non è il prodotto delle probabilità marginali.

Verifica sull'esempio binario

Dalle marginali: $p_{X_1}(0) = 1/4 + 1/8 = 3/8$, $p_{X_2}(0) = 1/4 + 1/8 = 3/8$.

Se fossero indipendenti: $p_{X_1 X_2}(0, 0) = 3/8 \cdot 3/8 = 9/64 \neq 1/4$.

Quindi X_1 e X_2 non sono indipendenti in questo esempio.

PMF condizionale

Definizione: PMF condizionale

La **PMF condizionale di X dato Y** è:

$$p_{X|Y}(x|y) = P(X = x | Y = y) = \frac{p_{XY}(x, y)}{p_Y(y)}, \quad \text{per ogni } y \text{ con } p_Y(y) > 0$$

Proprietà: Per ogni y fissato, $\sum_{x \in \mathcal{X}} p_{X|Y}(x|y) = 1$ (è una legge di probabilità). La somma su tutti i valori di y non è necessariamente 1.

Organizzazione della tabella condizionale

Nella tabella $p_{X|Y}(x|y)$: la **somma per colonne** (condizionamento fisso) fa 1. La **somma per righe** (condizionamento varia) non fa 1.

PMF condizionale sull'esempio binario

$$p_{X_2}(0) = 3/8, p_{X_2}(1) = 5/8.$$

	$X_2 = 0$	$X_2 = 1$
p_{X_1}	$X_2\{0$	$\cdot\}$
p_{X_1}	$X_2\{1$	$\cdot\}$

Colonne: $2/3 + 1/3 = 1 \checkmark$, $1/5 + 4/5 = 1 \checkmark$. Righe: $2/3 + 1/5 = 13/15 \neq 1$.

Relazione con l'indipendenza: Se X e Y sono indipendenti, allora $p_{X|Y}(x|y) = p_X(x)$: conoscere Y non modifica la distribuzione di X .

Estensione a n-uple di variabili aleatorie

Il caso di due variabili si generalizza naturalmente.

Definizione: PMF congiunta di ordine n

Date n variabili aleatorie $X_1, X_2, \dots, X_n$ con alfabeti $\mathcal{X}_1, \dots, \mathcal{X}_n$, la PMF congiunta è:

$$p_{X_1 \dots X_n}(x_1, \dots, x_n) = P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n)$$

È una tabella di $|\mathcal{X}_1| \times \dots \times |\mathcal{X}_n|$ numeri non negativi che si sommano a 1.

Marginalizzazione gerarchica: Una PMF di ordine n implica tutte le PMF di ordine inferiore. Sommando su tutti i valori di X_k , si ottiene la PMF congiunta delle restanti $n - 1$ variabili.

La gerarchia va solo verso il basso

La conoscenza di ordine n implica la conoscenza di ordine $n - 1$, $n - 2$, ..., fino a 1. Non vale il contrario: le marginali di ordine inferiore non determinano quella di ordine superiore (salvo indipendenza).

Esempio: terne di bit

Due leggi di probabilità per terne binarie

Si considerano tre variabili aleatorie binarie $X_1, X_2, X_3 \in \{0, 1\}$, con $p \in (0, 1)$.

Prima legge (sorgente senza memoria):

$$p_{X_1 X_2 X_3}(x_1, x_2, x_3) = p^k (1 - p)^{3-k}$$

dove k è il numero di 1 nella terna. In questa legge i tre bit sono **indipendenti**: la probabilità di ogni terna è il prodotto delle probabilità dei singoli bit (p per 1, $1 - p$ per 0).

Seconda legge (bit di parità):

Le terne con numero dispari di 1 hanno probabilità 0. Le terne con numero pari di 1 hanno probabilità $p^k (1 - p)^{2-k}$ (per $k = 0, 2$).

In questa seconda legge, X_3 è il **bit di parità** dei primi due: è deterministicamente uguale a $X_1 \oplus X_2$. I bit X_1 e X_2 sono indipendenti, ma X_3 è dipendente dagli altri due.

Entrambe le leggi hanno le stesse marginali: $p_{X_i}(0) = 1 - p$, $p_{X_i}(1) = p$ per $i = 1, 2, 3$. Eppure modellano fenomeni radicalmente diversi.

Questo esempio mostra concretamente che scegliere una legge di probabilità congiunta significa **modellare un fenomeno fisico** specifico. Leggi diverse con le stesse marginali corrispondono a fenomeni diversi.

Regola della catena e marginalizzazione come media

Regola della catena

Per tre variabili aleatorie:

$$p_{XYZ}(x, y, z) = p_Z(z) \cdot p_{Y|Z}(y|z) \cdot p_{X|YZ}(x|y, z)$$

e analogamente per ogni permutazione degli indici. La regola si generalizza a n variabili.

Marginalizzazione come media statistica

Si può riscrivere la marginalizzazione come:

$$p_X(x) = \sum_{y \in \mathcal{Y}} p_{X|Y}(x|y) \cdot p_Y(y) = E_Y[p_{X|Y}(x|Y)]$$

Cioè, la PMF marginale di X è la **media rispetto a Y** della PMF condizionale di X dato Y . Questo punto di vista ha applicazioni importanti nella teoria delle code e nei processi di

Punti chiave della lezione

- Una coppia di variabili aleatorie è caratterizzata dalla PMF congiunta: una tabella di $|X| \times |Y|$ numeri non negativi che sommano a 1.
- Dalla congiunta si ricavano le marginali per somma (marginalizzazione). Il viceversa non vale in generale.
- Due variabili sono indipendenti se e solo se la congiunta si fattorizza nel prodotto delle marginali.
- La PMF condizionale $p_{X|Y}(x|y)$ è una legge di probabilità per Y fisso, non per tutte le coppie (x, y) .
- Una PMF di ordine n implica tutte le PMF di ordine inferiore; una caratterizzazione di ordine superiore implica quelle di ordine inferiore.

#MSP

#PMF-congiunta

#marginalizzazione

#indipendenza

#variabili-multiple

#probabilità

Argomenti trattati

- Canale binario simmetrico: modello, probabilità di errore, legge di Bayes
- Caso peggiore del canale: $\epsilon = 1/2$
- Introduzione all'entropia e al concetto di informazione (Claude Shannon)
- PMF condizionale e proprietà di marginalizzazione come media
- Regola della catena per tre variabili aleatorie
- Indipendenza condizionale e catene di Markov (cenni)
- Esercizi: urna con due estrazioni, dado onesto e dado truccato

1. Canale binario simmetrico (BSC)


Modello

Un **canale di comunicazione** trasferisce un bit X (input) a una destinazione come bit Y (output). Il canale introduce errori con probabilità ϵ : con probabilità $1 - \epsilon$ il bit è ricevuto correttamente, con probabilità ϵ è invertito.

Il canale è detto **simmetrico** perché il comportamento è identico per $X = 0$ e $X = 1$:

$$p_{Y|X}(0|0) = p_{Y|X}(1|1) = 1 - \epsilon$$

$$p_{Y|X}(1|0) = p_{Y|X}(0|1) = \epsilon$$



Probabilità di errore

Sia $P(X = 1) = p$, quindi $P(X = 0) = 1 - p$.

Per la legge della probabilità totale:

$$\begin{aligned} P(\text{errore}) &= P(Y \neq X) = P(Y \neq X | X = 0) \cdot P(X = 0) + P(Y \neq X | X = 1) \cdot P(X = 1) \\ &= \varepsilon(1 - p) + \varepsilon p = \varepsilon \end{aligned}$$

Risultato: probabilità di errore nel BSC

In un canale binario simmetrico, la probabilità di errore è esattamente ε , indipendentemente dalla distribuzione dell'input. Il parametro ε è la **frazione di bit trasferiti incorrettamente**.

Inferenza: qual è il bit trasmesso?

Data $Y = 0$, qual è la probabilità che $X = 0$? (Legge di Bayes)

$$P(X = 0 | Y = 0) = \frac{P(Y = 0 | X = 0) \cdot P(X = 0)}{P(Y = 0)}$$

Il denominatore si calcola con la legge della probabilità totale:

$$P(Y = 0) = P(Y = 0 | X = 0) \cdot P(X = 0) + P(Y = 0 | X = 1) \cdot P(X = 1) = (1 - \varepsilon)(1 - p) + \varepsilon p$$

Quindi:

$$P(X = 0 | Y = 0) = \frac{(1 - \varepsilon)(1 - p)}{(1 - \varepsilon)(1 - p) + \varepsilon p}$$

Il caso peggiore: $\varepsilon = 1/2$

Potrebbe sembrare che il caso peggiore sia $\varepsilon = 1$ (tutti i bit invertiti). Ma se $\varepsilon = 1$, il canale è ancora deterministico: basta invertire il bit ricevuto.

Il caso peggiore è quando **osservare l'uscita non dà informazioni sull'ingresso**, cioè quando la probabilità a posteriori è uguale a quella a priori:

$$P(X = 0 | Y = 0) = P(X = 0)$$

Questo accade quando $\varepsilon = 1/2$: il canale produce rumore puro, e Y è completamente indipendente da X .

Definizione: caso peggiore del BSC

Il caso peggiore per il canale binario simmetrico è $\varepsilon = 1/2$: osservare l'uscita non fornisce alcuna informazione sull'ingresso.

Entropia e informazione (introduzione)

Misura dell'informazione

L'informazione ricevuta quando si osserva un evento A di probabilità $P(A)$ deve soddisfare tre proprietà di senso comune:

1. **Non negativa:** $I(A) \geq 0$ (non si mente).
2. **Decrescente nella probabilità:** più raro l'evento, più informazione porta.
3. **Additiva per eventi indipendenti:** $I(A \cap B) = I(A) + I(B)$ se $A \perp B$.

L'unica funzione che soddisfa tutte e tre è:

$$I(A) = \log_2 \frac{1}{P(A)} = -\log_2 P(A)$$

La base 2 fa sì che l'unità sia il **bit** (unità di misura dell'informazione).

Casi limite

- Evento certo ($P(A) = 1$): $I(A) = \log_2 1 = 0$ (nessuna informazione: "il Sole sorgerà domani").
- Evento impossibile ($P(A) = 0$): $I(A) \rightarrow \infty$ (informazione infinita: "il Sole non sorgerà domani").

Entropia di una variabile aleatoria

Dato che la quantità di informazione $I(X = x) = \log_2 \frac{1}{p_X(x)}$ è essa stessa una variabile aleatoria, si definisce l'**entropia** come la sua media statistica:

Definizione: Entropia

L'entropia di una variabile aleatoria discreta X con PMF p_X è:

$$H(X) = E \left[\log_2 \frac{1}{p_X(X)} \right] = \sum_{x \in \mathcal{X}} p_X(x) \log_2 \frac{1}{p_X(x)}$$

Si misura in **bit**.

Entropia di una variabile Bernoulliana

Per $X \in \{0, 1\}$ con $P(X = 1) = p$:

$$H(X) = p \log_2 \frac{1}{p} + (1 - p) \log_2 \frac{1}{1 - p}$$

Proprietà: $0 \leq H(X) \leq 1$, con $H(X) = 1$ se e solo se $p = 1/2$.

Implicazione per i file compressi

Una variabile Bernoulliana porta al più 1 bit di informazione, e esattamente 1 bit solo quando $p = 1/2$ (i due valori sono equiprobabili). Un file compresso idealmente è una sequenza binaria in cui 0 e 1 sono equiprobabili e statisticamente indipendenti: questa è la condizione di massima complessità informazionale.

Entropia di una variabile quaternaria uniforme

Per $X \in \{1, 2, 3, 4\}$ con $p_X(x) = 1/4$ per ogni x :

$$H(X) = 4 \cdot \frac{1}{4} \log_2 4 = \log_2 4 = 2 \text{ bit}$$

Una variabile quaternaria equiprobabile porta 2 bit di informazione, coerentemente con il fatto che 4 valori si codificano con 2 bit binari.

Parole del Professore

Quote

"Una variabile bistabile trasporta una quantità di informazione che è al più un bit."

PMF condizionale e marginalizzazione come media

Ricapitolo

La PMF condizionale di X dato Y è:

$$p_{X|Y}(x|y) = \frac{p_{XY}(x, y)}{p_Y(y)}$$

Per ogni y fissato, è una legge di probabilità su X .

Marginalizzazione come media

Riscrivendo la proprietà di marginalizzazione:

$$p_X(x) = \sum_y p_{XY}(x, y) = \sum_y p_{X|Y}(x|y) \cdot p_Y(y) = E_Y[p_{X|Y}(x|Y)]$$

Cioè: **la PMF marginale di X è la media (rispetto a Y) della PMF condizionale di X dato Y** . Questo offre un modo alternativo di calcolare le marginali, utile quando la struttura condizionale è più facile da specificare rispetto a quella congiunta.

Regola della catena

Per tre variabili aleatorie X, Y, Z :

$$p_{XYZ}(x, y, z) = p_Z(z) \cdot p_{Y|Z}(y|z) \cdot p_{X|YZ}(x|y, z)$$

e tutte le permutazioni degli indici sono valide.

☰ Uso nell'esercizio del dado

Nell'esercizio con dado onesto e dado truccato si è usata la legge della catena:

$$P(X_1 = 6, X_2 = 6 | \text{onesto}) = P(X_1 = 6 | \text{onesto}) \cdot P(X_2 = 6 | X_1 = 6, \text{onesto})$$

Dove il secondo fattore vale $1/6$ (stesso dado, $X_1 = 6$ è pari $\rightarrow$ non si cambia dado).

Proprietà di Markov (Introdotta dopo)

Definizione: Proprietà di Markov

Una sequenza di variabili aleatorie $X_1, X_2, \dots, X_n, X_{n+1}$ soddisfa la **proprietà di Markov** (o proprietà "senza memoria") se:

📄 Proprietà di Markov

$$P(X_{n+1} | X_n, X_{n-1}, \dots, X_1) = P(X_{n+1} | X_n)$$

Il valore futuro X_{n+1} dipende dal passato **solo attraverso il presente** X_n , non direttamente da stati precedenti.

In altre parole, conoscere X_n rende **condizionalmente indipendente** la distribuzione futura dal resto della storia.

Interpretazione: "Assenza di memoria"

La proprietà dice che la probabilità di un evento futuro, dato lo stato presente, non cambia se si conosce la storia precedente. Questo è il concetto fondamentale dietro i **processi di Markov**, utilizzati in teoria delle code, teoria dei circuiti, biologia (catene evolutive), finanza (modelli di prezzo delle azioni), ecc.

☰ Passeggero in una stazione

Date le stazioni visitate fino ad ora $(X_1, X_2, \dots, X_n)$, la probabilità di trovare treni per la prossima destinazione (numero di treni, ritardi) **dipende solo dalla stazione attuale** X_n , non dai percorsi storici presi per arrivarci.

☰ Coda in banca

Se X_n è il numero di clienti in coda al tempo n , e gli arrivi seguono un processo di Poisson, allora il numero di clienti al tempo $n + 1$ dipende solo da X_n (numero attuale) e non da come il sistema è arrivato a quella situazione.

Catena di Markov omogenea

Se la probabilità di transizione **non dipende da n** (il tempo):

$$P(X_{n+1} = j | X_n = i) = P_{ij} \quad (\text{costante per ogni } n)$$

allora la catena è detta **omogenea nel tempo** o **stazionaria**. Questa è l'ipotesi che semplifica enormemente l'analisi e permette di usare la teoria delle matrici stocastiche.

Indipendenza Condizionale nelle Catene

📄 Definizione: Indipendenza condizionale

X_1 e X_3 sono **condizionalmente indipendenti dato X_2** se:

$$p_{X_1 X_3 | X_2}(x_1, x_3 | x_2) = p_{X_1 | X_2}(x_1 | x_2) \cdot p_{X_3 | X_2}(x_3 | x_2)$$

Questo è diverso dall'indipendenza (marginale): X_1 e X_3 possono essere dipendenti, ma diventano indipendenti una volta noto X_2 .

☰ Mosse del re su una scacchiera

La posizione del re alla mossa 1 (X_1) e alla mossa 3 (X_3) sono dipendenti: se il re è in un angolo al tempo 1, non può essere lontano al tempo 3. Tuttavia, nota la posizione al tempo 2 (X_2), la posizione al tempo 3 dipende solo da X_2 e non più da X_1 . Quindi X_1 e X_3 sono condizionalmente indipendenti dato X_2 .

Quando vale questa proprietà, la terna (X_1, X_2, X_3) è detta **catena di Markov**. Questa struttura è alla base della teoria delle code e dei processi stocastici in generale.

Esercizi:

1. urna con due estrazioni senza reinserimento

Setup: urna con 6 palline — 1 marcata "1", 2 marcate "2", 3 marcate "3". Due estrazioni senza reinserimento. X_1 = risultato prima estrazione, X_2 = risultato seconda estrazione.

PMF marginale di X_1

$$p_{X_1}(1) = \frac{1}{6}, \quad p_{X_1}(2) = \frac{2}{6} = \frac{1}{3}, \quad p_{X_1}(3) = \frac{3}{6} = \frac{1}{2}$$

PMF congiunta

Si usa la regola della probabilità composta: $p_{X_1, X_2}(x_1, x_2) = p_{X_1}(x_1) \cdot p_{X_2|X_1}(x_2|x_1)$.

Le probabilità condizionali $p_{X_2|X_1}(x_2|x_1)$ si calcolano ricordando che si lavora **senza reinserimento**: estratta x_1 , rimangono 5 palline.

	$X_2 = 1$	$X_2 = 2$	$X_2 = 3$
$X_1 = 1$	0	$\frac{1}{6} \cdot \frac{2}{5} = \frac{1}{15}$	$\frac{1}{6} \cdot \frac{3}{5} = \frac{1}{10}$
$X_1 = 2$	$\frac{1}{3} \cdot \frac{1}{5} = \frac{1}{15}$	$\frac{1}{3} \cdot \frac{1}{5} = \frac{1}{15}$	$\frac{1}{3} \cdot \frac{3}{5} = \frac{1}{5}$
$X_1 = 3$	$\frac{1}{2} \cdot \frac{1}{5} = \frac{1}{10}$	$\frac{1}{2} \cdot \frac{2}{5} = \frac{1}{5}$	$\frac{1}{2} \cdot \frac{2}{5} = \frac{1}{5}$

☰ Verifica della somma

$$0 + \frac{1}{15} + \frac{1}{10} + \frac{1}{15} + \frac{1}{15} + \frac{1}{5} + \frac{1}{10} + \frac{1}{5} + \frac{1}{5} = 1 \quad \checkmark$$

PMF condizionale $p_{X_2|X_1}$

Organizzata per righe (condizionamento = valore di X_1):

	$X_2 = 1$	$X_2 = 2$	$X_2 = 3$	Somma
$X_1 = 1$	0	$2/5$	$3/5$	1 ✓
$X_1 = 2$	$1/5$	$1/5$	$3/5$	1 ✓
$X_1 = 3$	$1/5$	$2/5$	$2/5$	1 ✓

⚠ Attenzione alla costruzione della tabella condizionale

Il condizionamento è X_1 : le righe sommano a 1, le colonne no. Non confondere le righe con le colonne quando si costruisce la tabella.

2. dado onesto e dado truccato

Setup: bussolotto con un dado onesto e uno truccato ($P(6|\text{truccato}) = 1/2$, $P(i|\text{truccato}) = 1/10$ per $i \neq 6$). Si estrae un dado casualmente (prob. $1/2$ ciascuno), si lancia, se il risultato è pari si rilancia lo stesso dado, se dispari si cambia dado.

Distribuzione del dado truccato

$$P(6|\text{truccato}) = 5 \cdot P(i|\text{truccato}) = 5p. \text{ Normalizzazione: } 5p + 5p = 1 \Rightarrow p = 1/10.$$

$$P(i|\text{truccato}) = \begin{cases} 1/2 & i = 6 \\ 1/10 & i \in \{1, 2, 3, 4, 5\} \end{cases}$$

Calcolo di $P(X_1 = 6, X_2 = 6)$

Per la legge della probabilità totale (condizionando sul dado estratto):

$$P(X_1 = 6, X_2 = 6) = \frac{1}{2}P(X_1 = 6, X_2 = 6|\text{onesto}) + \frac{1}{2}P(X_1 = 6, X_2 = 6|\text{truccato})$$

- Dado onesto: $P(X_1 = 6|\text{onesto}) = 1/6$. Dato $X_1 = 6$ (pari), si rilancia lo stesso dado:
 $P(X_2 = 6|X_1 = 6, \text{onesto}) = 1/6$. Contributo: $1/6 \cdot 1/6 = 1/36$.
- Dado truccato: $P(X_1 = 6|\text{truccato}) = 1/2$. Dato $X_1 = 6$ (pari), si rilancia lo stesso dado:
 $P(X_2 = 6|X_1 = 6, \text{truccato}) = 1/2$. Contributo: $1/2 \cdot 1/2 = 1/4$.

$$P(6, 6) = \frac{1}{2} \cdot \frac{1}{36} + \frac{1}{2} \cdot \frac{1}{4} = \frac{1}{72} + \frac{1}{8} = \frac{1+9}{72} = \frac{10}{72} = \frac{5}{36}$$

Calcolo di $P(X_1 = 6, X_2 = 5)$

- Dado onesto: $P(X_1 = 6|\text{onesto}) = 1/6$. Dato $X_1 = 6$ (pari), si rilancia lo stesso dado:
 $P(X_2 = 5|X_1 = 6, \text{onesto}) = 1/6$. Contributo: $1/36$.
- Dado truccato: $P(X_1 = 6|\text{truccato}) = 1/2$. Dato $X_1 = 6$ (pari), si rilancia il dado truccato: $P(X_2 = 5|X_1 = 6, \text{truccato}) = 1/10$. Contributo: $1/2 \cdot 1/10 = 1/20$.

$$P(6, 5) = \frac{1}{2} \cdot \frac{1}{36} + \frac{1}{2} \cdot \frac{1}{20} = \frac{1}{72} + \frac{1}{40}$$

Confronto: $P(6, 5)$ vs. $P(5, 6)$

Asimmetria della coppia (6, 5) vs (5, 6)

Per il calcolo di $P(X_1 = 5, X_2 = 6)$: dato $X_1 = 5$ (dispari), si **cambia dado**. Quindi, se il primo dado era onesto, il secondo è truccato (e viceversa). Questo cambia radicalmente le probabilità:

- Dado onesto primo: $P(X_1 = 5|\text{onesto}) = 1/6$. Dato $X_1 = 5$ (dispari), si usa il dado truccato: $P(X_2 = 6|\text{truccato}) = 1/2$. Contributo: $1/6 \cdot 1/2 = 1/12$.
- Dado truccato primo: $P(X_1 = 5|\text{truccato}) = 1/10$. Dato $X_1 = 5$ (dispari), si usa il dado onesto: $P(X_2 = 6|\text{onesto}) = 1/6$. Contributo: $1/10 \cdot 1/6 = 1/60$.

$$P(5, 6) = \frac{1}{2} \cdot \frac{1}{12} + \frac{1}{2} \cdot \frac{1}{60} \neq P(6, 5)$$

La PMF congiunta **non è simmetrica**: $P(6, 5) \neq P(5, 6)$. La regola "pari $\rightarrow$ stesso dado, dispari $\rightarrow$ cambia dado" rompe la simmetria.

Punti chiave della lezione

- Nel canale binario simmetrico la probabilità di errore è ϵ indipendentemente dall'input; il caso peggiore è $\epsilon = 1/2$ (l'uscita non dà informazioni sull'ingresso).
- L'entropia $H(X) = E[\log_2(1/p_X(X))]$ misura la quantità media di informazione in bit; per una variabile Bernoulliana vale al più 1 bit, raggiunto con $p = 1/2$.
- La PMF marginale è la media della PMF condizionale rispetto alla variabile condizionante.
- L'indipendenza condizionale (e le catene di Markov) è un concetto distinto dall'indipendenza marginale.
- Negli esercizi probabilistici complessi, condizionare su un evento ausiliario (legge della probabilità totale) e applicare la regola della catena sistematicamente porta alla soluzione.

#MSP

#canale-binario

#entropia

#informazione

#PMF-condizionale

#Bayes

#esercizi

Argomenti trattati

- Passaggio da variabili discrete a variabili continue
- Caratterizzazione mediante misura di probabilità su intervalli
- Definizione formale di CDF e PDF per variabili continue
- Relazione tra CDF e PDF: integrazione e derivazione
- Distribuzioni continue notevoli: uniforme, esponenziale
- Valore atteso per variabili continue
- Introduzione alla PDF condizionata

1. Variabili continue: definizione

Variabile aleatoria continua

Una variabile aleatoria X è **continua** se gli eventi elementari corrispondono all'appartenenza di X a un **intervallo**, non a un valore puntuale.

Caratteristica: $P(X = x) = 0$ per ogni $x \in \mathbb{R}$ — gli eventi puntuali hanno probabilità nulla.

Conseguenza: le probabilità si assegnano a **intervalli** $[a, b]$, non a singoli punti.

2. Funzione di distribuzione cumulativa (CDF)

CDF (Cumulative Distribution Function)

La **funzione di distribuzione cumulativa** di X è:

$$F_X(x) = P(X \leq x) \quad \forall x \in \mathbb{R}$$

Definita per **qualsiasi** variabile aleatoria, discreta o continua.

Proprietà della CDF

1. **Valori agli estremi:** $F_X(-\infty) = 0$, $F_X(+\infty) = 1$
2. **Monotonia crescente:** se $x_1 < x_2$, allora $F_X(x_1) \leq F_X(x_2)$
3. **Continuità a destra:** per variabili continue, la CDF è continua ovunque
4. **Probabilità di intervalli:**

$$P(a < X \leq b) = F_X(b) - F_X(a)$$

3. Densità di probabilità (PDF)

PDF (Probability Density Function)

La **funzione di densità di probabilità** è la derivata della CDF:

$$f_X(x) = \frac{d}{dx} F_X(x)$$

Relazione inversa (integrazione):

$$F_X(x) = \int_{-\infty}^x f_X(t) dt$$

Proprietà della PDF

1. **Non negatività:** $f_X(x) \geq 0$ per ogni x (la CDF è monotona)
2. **Normalizzazione:**

$$\int_{-\infty}^{+\infty} f_X(x) dx = 1$$

3. **Probabilità di intervalli:**

$$P(a \leq X \leq b) = \int_a^b f_X(x) dx$$

⚠ **Errore comune: "La PDF è una probabilità"**

FALSO! La PDF può valere più di 1 (es. $f_X(0) = 5$). È una **densità**, non una probabilità. La probabilità è l'**area** sotto la curva su un intervallo.

4. Variabile uniforme $U(a, b)$

📌 Distribuzione uniforme

Una variabile X è **uniforme** sull'intervallo $[a, b]$ se la probabilità è distribuita **uniformemente**:

$$f_X(x) = \begin{cases} \frac{1}{b-a} & a \leq x \leq b \\ 0 & \text{altrove} \end{cases}$$

Verifica di normalizzazione:

$$\int_a^b \frac{1}{b-a} dx = 1 \quad \checkmark$$

CDF della uniforme

$$F_X(x) = \begin{cases} 0 & x < a \\ \frac{x-a}{b-a} & a \leq x \leq b \\ 1 & x > b \end{cases}$$

La CDF è una **rampa lineare** da 0 a 1.

Valore atteso

$$E[X] = \int_a^b x \cdot \frac{1}{b-a} dx = \frac{a+b}{2}$$

💡 Ricordare per l'esame

Media della uniforme = punto medio dell'intervallo — intuitivo e facile da verificare

5. Variabile esponenziale $\text{Exp}(\lambda)$

Distribuzione esponenziale

Una variabile X è **esponenziale** di parametro $\lambda > 0$ se:

$$f_X(x) = \begin{cases} \lambda e^{-\lambda x} & x \geq 0 \\ 0 & x < 0 \end{cases}$$

Interpretazione: modella il tempo di attesa di un evento raro in un processo senza memoria (es. tempo fino al prossimo arrivo in una coda Poissoniana).

CDF della esponenziale

$$F_X(x) = \begin{cases} 0 & x < 0 \\ 1 - e^{-\lambda x} & x \geq 0 \end{cases}$$

Derivazione:

$$F_X(x) = \int_0^x \lambda e^{-\lambda t} dt = [-e^{-\lambda t}]_0^x = 1 - e^{-\lambda x}$$

Valore atteso

$$E[X] = \int_0^{+\infty} x \cdot \lambda e^{-\lambda x} dx = \frac{1}{\lambda}$$

Regola: parametro e media

Se λ è grande, la media $1/\lambda$ è **piccola** (decadimento veloce). Se λ è piccolo, la media è grande (decadimento lento).

Errore comune: confondere PDF e probabilità

$f_X(0) = \lambda$, che può essere > 1 se $\lambda > 1$. **La PDF non è una probabilità!**

6. Valore atteso: derivazione dalla quantizzazione

Giustificazione di $E[X] = \int x f_X(x) dx$

Dividiamo il supporto di X in intervalli di ampiezza δ , e approssimiamo con una variabile discreta X_δ .

Per la variabile discreta:

$$E[X_\delta] = \sum_i x_i \cdot P(X_\delta = x_i) = \sum_i x_i \cdot f_X(c_i) \cdot \delta$$

Questa è la **somma di Riemann** dell'integrale $\int x f_X(x) dx$. Quando $\delta \rightarrow 0$:

$$E[X] = \int_{-\infty}^{+\infty} x f_X(x) dx$$

 Applicazione: quantizzazione vettoriale

Shannon (1948): per digitalizzare dati analogici è **ottimale quantizzare blocchi di dati simultaneamente**, non campione per campione. La quantizzazione vettoriale è asintoticamente molto più efficiente e fonda i moderni sistemi di compressione (JPEG, MP3, ecc.).

7. PDF e CDF condizionate

 Probabilità e PDF condizionate

Data un evento A :

$$F_{X|A}(x) = P(X \leq x|A) = \frac{P(X \leq x \cap A)}{P(A)}$$

PDF condizionate: derivando la CDF

$$f_{X|A}(x) = \frac{d}{dx} F_{X|A}(x)$$

Esempio: PDF condizionata di una uniforme

Sia $X \sim U(0, 10)$ e $A = \{X > 3\}$.

$$P(A) = 1 - F_X(3) = 0.7$$

Per $x \in (3, 10)$:

$$f_{X|A}(x) = \frac{1}{7} \quad (\text{uniforme su intervallo ridotto})$$

 Interpretazione

La PDF condizionata è una **uniforme su** $(3, 10)$ — ridimensionata perché la larghezza è 7, non 10.

Riepilogo: Punti Chiave

1. **CDF:** $F_X(x) = P(X \leq x)$ — definita per variabili continue e discrete
2. **PDF:** $f_X(x) = F'_X(x)$ — densità, non probabilità
3. **Uniforme:** PDF costante, media = $\frac{a+b}{2}$, CDF lineare
4. **Esponenziale:** media = $\frac{1}{\lambda}$, modella tempi di attesa
5. **Valore atteso:** giustificato da quantizzazione e somme di Riemann
6. **PDF condizionata:** definita tramite CDF condizionata

Domande d'esame frequenti

- Dimostrare che l'integrale di una PDF è 1
- Calcolare CDF e media per una distribuzione uniforme
- Confrontare PDF e PMF (massa vs densità)
- Interpretare il significato di $PDF > 1$

Esercizi suggeriti

- ☐ Dimostrare che $E[\text{Exp}(\lambda)] = 1/\lambda$
- ☐ Calcolare PDF condizionata di esponenziale su intervallo $[0, T]$
- ☐ Generare variabili uniformi e esponenziali in Python/R

#MSI

#variabili-continue

#CDF

#PDF

#distribuzione-uniforme

#distribuzione-esponenziale

10. Ineguaglianze di Probabilità e Distribuzioni Continue Notevoli

10.1 Ineguaglianza di Markov

Consideriamo una variabile aleatoria X a valori non negativi con media finita $\mu_X = E[X]$. L'ineguaglianza di Markov fornisce un limite superiore alla probabilità che X ecceda una soglia $\delta > 0$:

$$P(X \geq \delta) \leq \frac{E[X]}{\delta}$$

Dimostrazione

Per ogni $\delta > 0$, definiamo l'evento $A = \{X \geq \delta\}$. Allora:

$$E[X] = \int_0^{\infty} x f_X(x) dx \geq \int_{\delta}^{\infty} x f_X(x) dx \geq \delta \int_{\delta}^{\infty} f_X(x) dx = \delta \cdot P(X \geq \delta)$$

Dividendo per δ si ottiene il risultato. La dimostrazione nel caso discreto è analoga, sostituendo l'integrale con una sommatoria.

Osservazione sulla generalizzazione

L'ineguaglianza di Markov si generalizza a qualsiasi funzione monotona crescente $g: \mathbb{R}_{\geq 0} \rightarrow \mathbb{R}_{\geq 0}$:

$$P(X \geq \delta) = P(g(X) \geq g(\delta)) \leq \frac{E[g(X)]}{g(\delta)}$$

Questo è il motivo per cui l'ineguaglianza di Chebyshev, che considereremo di seguito, rappresenta una specializzazione della formula di Markov al caso $g(x) = (x - \mu_X)^2$.

10.2 Ineguaglianza di Chebyshev

Sia X una variabile aleatoria con media μ_X e varianza σ_X^2 finita. L'ineguaglianza di Chebyshev limita la probabilità che X devia dalla sua media di più di k volte la deviazione standard:

$$P(|X - \mu_X| \geq k\sigma_X) \leq \frac{1}{k^2}$$

equivalentemente,

$$P(|X - \mu_X| \geq \delta) \leq \frac{\sigma_X^2}{\delta^2}$$

Derivazione

Applichiamo l'ineguaglianza di Markov alla variabile aleatoria $Y = (X - \mu_X)^2$, che è non negativa:

$$P(Y \geq \delta^2) \leq \frac{E[Y]}{\delta^2} = \frac{\text{Var}(X)}{\delta^2}$$

Poiché $Y \geq \delta^2$ è equivalente a $|X - \mu_X| \geq \delta$, si ottiene il risultato.

Universalità dell'ineguaglianza di Chebyshev

A differenza di ineguaglianze specifiche per distribuzioni particolari (come la gaussiana), l'ineguaglianza di Chebyshev vale per qualsiasi distribuzione con varianza finita. Il prezzo è che il limite è spesso molto conservativo.

Limiti pratici

Nel caso continuo la dimostrazione è identica a quella nel caso discreto: basta sostituire la sommatoria con l'integrale. Per questo motivo, la coppia (μ_X, σ_X) fornisce una caratterizzazione globale di qualsiasi variabile aleatoria, discreta o continua, indipendentemente dalla distribuzione specifica.

10.3 Distribuzione Uniforme Continua

La distribuzione uniforme su un intervallo $[a, b]$ ha densità costante:

$$f_X(x) = \begin{cases} \frac{1}{b-a} & a \leq x \leq b \\ 0 & \text{altrove} \end{cases}$$

Media: $E[X] = \frac{a+b}{2}$ (il punto medio dell'intervallo).

Varianza: $\text{Var}(X) = \frac{(b-a)^2}{12}$.

Applicazione: Quantizzazione uniforme

Nella rappresentazione numerica di segnali analogici, un quantizzatore uniforme divide un intervallo $[a, b]$ in $M = 2^R$ livelli di ampiezza $\Delta = \frac{b-a}{M}$. L'errore di quantizzazione (differenza tra il valore continuo e il suo rappresentante quantizzato) può essere modellato come uniformemente distribuito su $[-\frac{\Delta}{2}, \frac{\Delta}{2}]$.

L'errore quadratico medio (distorsione) risulta:

$$\text{Distorsione} = \text{Var}(\text{errore}) = \frac{\Delta^2}{12}$$

Questo risultato è fondamentale nella teoria della codifica. Se le statistiche dei dati non sono uniformi, un quantizzatore non uniforme (quantizzazione adattativa) può ridurre significativamente la distorsione. Tecniche moderne di compressione utilizzano quantizzatori vettoriali, che operano su blocchi di dati invece che su singoli campioni, ottenendo prestazioni teoricamente ottimali.



Osservazione su quantizzazione uniforme vs. adattativa

La quantizzazione uniforme è appropriata solo quando i dati seguono una distribuzione uniforme, una situazione rara nella pratica. Se i dati hanno una distribuzione nota (ad esempio gaussiana), è ottimo concentrare i livelli di quantizzazione dove la densità di probabilità è maggiore. Se la distribuzione è sconosciuta, un algoritmo di apprendimento statistico (ad es. k-means clustering) può stimare i livelli di quantizzazione adattativi in modo automatico durante l'addestramento.

10.4 Distribuzione di Laplace (Doppia Esponenziale)

La distribuzione di Laplace con parametro $\lambda > 0$ ha densità:

$$f_X(x) = \frac{\lambda}{2} e^{-\lambda|x|}$$

CDF:

$$F_X(x) = \begin{cases} \frac{1}{2} e^{\lambda x} & x < 0 \\ 1 - \frac{1}{2} e^{-\lambda x} & x \geq 0 \end{cases}$$

Media: $E[X] = 0$ (per simmetria).

Varianza: $\text{Var}(X) = \frac{2}{\lambda^2}$.

La distribuzione di Laplace modella fenomeni con code più pesanti dell'esponenziale (asimmetrico), come il rumore impulsivo (ad es. atmosferico) nei sistemi di telecomunicazione. In contrasto, la distribuzione gaussiana (che vedremo in seguito) è più lieve nelle code ed è appropriata per il rumore termico.

Distribuzioni con varianza infinita

La distribuzione di Cauchy, definita da $f_X(x) = \frac{1}{\pi(1+x^2)}$, è un esempio notevole di variabile aleatoria continua senza varianza finita. Le sue code decadono così lentamente che $E[X^2] = \infty$. Fenomeni fisici modellati da Cauchy (come il rumore atmosferico da fulmine) hanno potenza infinita e non ammettono caratterizzazione tramite i momenti ordinari.

10.5 PDF Condizionata

Data una variabile aleatoria X con PDF $f_X(x)$ e un evento A con $P(A) > 0$, la **PDF condizionata** è:

$$f_{X|A}(x) = \begin{cases} \frac{f_X(x)}{P(A)} & x \in A \\ 0 & x \notin A \end{cases}$$

In altri termini, la PDF condizionata è proporzionale alla PDF originale, confinata al supporto di A e riscalata affinché l'integrale faccia 1.

Esempio: Distribuzione triangolare condizionata

Consideriamo una variabile aleatoria X con supporto $[-3, -1] \cup [1, 3]$, con densità costante $\frac{1}{4}$ su $[-3, -1]$ e triangolare su $[1, 3]$. Calcoliamo la PDF condizionata all'evento $A = \{X \leq 0\}$.

$$P(A) = P(X \in [-3, -1]) = \frac{1}{4} \cdot 2 = \frac{1}{2}$$

Per $x \in [-3, -1]$:

$$f_{X|A}(x) = \frac{1/4}{1/2} = \frac{1}{2}$$

La PDF condizionata è uniforme su $[-3, -1]$ con densità doppia rispetto all'originale, poiché le osservazioni negative rappresentano la metà della probabilità totale. Per $x > 0$, invece, $f_{X|A}(x) = 0$.

La media condizionata è:

$$E[X|A] = \int_{-3}^{-1} x \cdot \frac{1}{2} dx = \frac{1}{2} \cdot \frac{x^2}{2} \Big|_{-3}^{-1} = \frac{1}{2} \cdot \frac{9-1}{2} = 2$$

Per simmetria, $E[X|X > 0] = 2$ e $E[X] = E[X|A]P(A) + E[X|A^c]P(A^c) = (-2) \cdot \frac{1}{2} + 2 \cdot \frac{1}{2} = 0$.

#MSI

#ineguaglianza-markov

#ineguaglianza-chebyshev

#distribuzione-uniforme

#distribuzione-laplace

#quantizzazione

#PDF-condizionata

10. Ineguaglianze di Probabilità e Distribuzioni Continue Notevoli

10.1 Ineguaglianza di Markov

Consideriamo una variabile aleatoria X a valori non negativi con media finita $\mu_X = E[X]$. L'ineguaglianza di Markov fornisce un limite superiore alla probabilità che X ecceda una soglia $\delta > 0$:

$$P(X \geq \delta) \leq \frac{E[X]}{\delta}$$

Dimostrazione

Per ogni $\delta > 0$, definiamo l'evento $A = \{X \geq \delta\}$. Allora:

$$E[X] = \int_0^{\infty} x f_X(x) dx \geq \int_{\delta}^{\infty} x f_X(x) dx \geq \delta \int_{\delta}^{\infty} f_X(x) dx = \delta \cdot P(X \geq \delta)$$

Dividendo per δ si ottiene il risultato. La dimostrazione nel caso discreto è analoga, sostituendo l'integrale con una sommatoria.

Osservazione sulla generalizzazione

L'ineguaglianza di Markov si generalizza a qualsiasi funzione monotona crescente $g: \mathbb{R}_{\geq 0} \rightarrow \mathbb{R}_{\geq 0}$:

$$P(X \geq \delta) = P(g(X) \geq g(\delta)) \leq \frac{E[g(X)]}{g(\delta)}$$

Questo è il motivo per cui l'ineguaglianza di Chebyshev, che considereremo di seguito, rappresenta una specializzazione della formula di Markov al caso $g(x) = (x - \mu_X)^2$.

10.2 Ineguaglianza di Chebyshev

Sia X una variabile aleatoria con media μ_X e varianza σ_X^2 finita. L'ineguaglianza di Chebyshev limita la probabilità che X devia dalla sua media di più di k volte la deviazione standard:

$$P(|X - \mu_X| \geq k\sigma_X) \leq \frac{1}{k^2}$$

equivalentemente,

$$P(|X - \mu_X| \geq \delta) \leq \frac{\sigma_X^2}{\delta^2}$$

Derivazione

Applichiamo l'ineguaglianza di Markov alla variabile aleatoria $Y = (X - \mu_X)^2$, che è non negativa:

$$P(Y \geq \delta^2) \leq \frac{E[Y]}{\delta^2} = \frac{\text{Var}(X)}{\delta^2}$$

Poiché $Y \geq \delta^2$ è equivalente a $|X - \mu_X| \geq \delta$, si ottiene il risultato.

Universalità dell'ineguaglianza di Chebyshev

A differenza di ineguaglianze specifiche per distribuzioni particolari (come la gaussiana), l'ineguaglianza di Chebyshev vale per qualsiasi distribuzione con varianza finita. Il prezzo è che il limite è spesso molto conservativo.

Limiti pratici

Nel caso continuo la dimostrazione è identica a quella nel caso discreto: basta sostituire la sommatoria con l'integrale. Per questo motivo, la coppia (μ_X, σ_X) fornisce una caratterizzazione globale di qualsiasi variabile aleatoria, discreta o continua, indipendentemente dalla distribuzione specifica.

10.3 Distribuzione Uniforme Continua

La distribuzione uniforme su un intervallo $[a, b]$ ha densità costante:

$$f_X(x) = \begin{cases} \frac{1}{b-a} & a \leq x \leq b \\ 0 & \text{altrove} \end{cases}$$

Media: $E[X] = \frac{a+b}{2}$ (il punto medio dell'intervallo).

Varianza: $\text{Var}(X) = \frac{(b-a)^2}{12}$.

Applicazione: Quantizzazione uniforme

Nella rappresentazione numerica di segnali analogici, un quantizzatore uniforme divide un intervallo $[a, b]$ in $M = 2^R$ livelli di ampiezza $\Delta = \frac{b-a}{M}$. L'errore di quantizzazione (differenza tra il valore continuo e il suo rappresentante quantizzato) può essere modellato come uniformemente distribuito su $[-\frac{\Delta}{2}, \frac{\Delta}{2}]$.

L'errore quadratico medio (distorzione) risulta:

$$\text{Distorzione} = \text{Var}(\text{errore}) = \frac{\Delta^2}{12}$$

Questo risultato è fondamentale nella teoria della codifica. Se le statistiche dei dati non sono uniformi, un quantizzatore non uniforme (quantizzazione adattativa) può ridurre significativamente la distorsione. Tecniche moderne di compressione utilizzano quantizzatori vettoriali, che operano su blocchi di dati invece che su singoli campioni, ottenendo prestazioni teoricamente ottimali.

Osservazione su quantizzazione uniforme vs. adattativa

La quantizzazione uniforme è appropriata solo quando i dati seguono una distribuzione uniforme, una situazione rara nella pratica. Se i dati hanno una distribuzione nota (ad esempio gaussiana), è ottimo concentrare i livelli di quantizzazione dove la densità di probabilità è maggiore. Se la distribuzione è sconosciuta, un algoritmo di apprendimento statistico (ad es. k-means clustering) può stimare i livelli di quantizzazione adattativi in modo automatico durante l'addestramento.

10.4 Distribuzione di Laplace (Doppia Esponenziale)

La distribuzione di Laplace con parametro $\lambda > 0$ ha densità:

$$f_X(x) = \frac{\lambda}{2} e^{-\lambda|x|}$$

CDF:

$$F_X(x) = \begin{cases} \frac{1}{2} e^{\lambda x} & x < 0 \\ 1 - \frac{1}{2} e^{-\lambda x} & x \geq 0 \end{cases}$$

Media: $E[X] = 0$ (per simmetria).

Varianza: $\text{Var}(X) = \frac{2}{\lambda^2}$.

La distribuzione di Laplace modella fenomeni con code più pesanti dell'esponenziale (asimmetrico), come il rumore impulsivo (ad es. atmosferico) nei sistemi di telecomunicazione. In contrasto, la distribuzione gaussiana (che vedremo in seguito) è più lieve nelle code ed è appropriata per il rumore termico.

Distribuzioni con varianza infinita

La distribuzione di Cauchy, definita da $f_X(x) = \frac{1}{\pi(1+x^2)}$, è un esempio notevole di variabile aleatoria continua senza varianza finita. Le sue code decadono così lentamente che $E[X^2] = \infty$. Fenomeni fisici modellati da Cauchy (come il rumore atmosferico da fulmine) hanno potenza infinita e non ammettono caratterizzazione tramite i momenti ordinari.

10.5 PDF Condizionata

Data una variabile aleatoria X con PDF $f_X(x)$ e un evento A con $P(A) > 0$, la **PDF condizionata** è:

$$f_{X|A}(x) = \begin{cases} \frac{f_X(x)}{P(A)} & x \in A \\ 0 & x \notin A \end{cases}$$

In altri termini, la PDF condizionata è proporzionale alla PDF originale, confinata al supporto di A e riscalata affinché l'integrale faccia 1.

Esempio: Distribuzione triangolare condizionata

Consideriamo una variabile aleatoria X con supporto $[-3, -1] \cup [1, 3]$, con densità costante $\frac{1}{4}$ su $[-3, -1]$ e triangolare su $[1, 3]$. Calcoliamo la PDF condizionata all'evento $A = \{X \leq 0\}$.

$$P(A) = P(X \in [-3, -1]) = \frac{1}{4} \cdot 2 = \frac{1}{2}$$

Per $x \in [-3, -1]$:

$$f_{X|A}(x) = \frac{1/4}{1/2} = \frac{1}{2}$$

La PDF condizionata è uniforme su $[-3, -1]$ con densità doppia rispetto all'originale, poiché le osservazioni negative rappresentano la metà della probabilità totale. Per $x > 0$, invece,

$$f_{X|A}(x) = 0.$$

La media condizionata è:

$$E[X|A] = \int_{-3}^{-1} x \cdot \frac{1}{2} dx = \frac{1}{2} \cdot \frac{x^2}{2} \Big|_{-3}^{-1} = \frac{1}{2} \cdot \frac{9-1}{2} = 2$$

Per simmetria, $E[X|X > 0] = 2$ e $E[X] = E[X|A]P(A) + E[X|A^c]P(A^c) = (-2) \cdot \frac{1}{2} + 2 \cdot \frac{1}{2} = 0$.

#MSI

#ineguaglianza-markov

#ineguaglianza-chebyshev

#distribuzione-uniforme

#distribuzione-laplace

#quantizzazione

#PDF-condizionata

11. Esercizi su Variabili Aleatorie Continue

11.1 Costruzione di una PDF triangolare

Consideriamo la seguente densità di probabilità definita su due intervalli disgiunti:

Nel supporto $[-3, -1]$ la densità è costante, mentre su $[1, 3]$ è triangolare. Descriviamo formalmente questa PDF.

Su $[-3, -1]$: $f_X(x) = \frac{1}{4}$ (costante).

Su $[1, 3]$: La densità ha forma triangolare con apice nel punto $x = 2$ e valore massimo $\frac{1}{2}$.

Analiticamente, per $x \in [1, 3]$:

$$f_X(x) = \begin{cases} \frac{x-1}{2} & 1 \leq x \leq 2 \\ \frac{3-x}{2} & 2 < x \leq 3 \end{cases}$$

Verifica di normalizzazione

L'integrale totale della PDF deve fare 1:

$$\begin{aligned} \int_{-3}^{-1} \frac{1}{4} dx + \int_1^3 f_X(x) dx &= \frac{1}{4} \cdot 2 + \int_1^2 \frac{x-1}{2} dx + \int_2^3 \frac{3-x}{2} dx \\ &= \frac{1}{2} + \frac{1}{2} \left[\frac{(x-1)^2}{2} \right]_1^2 + \frac{1}{2} \left[(3x - \frac{x^2}{2}) \right]_2^3 = \frac{1}{2} + \frac{1}{2} + 0 = 1 \quad \checkmark \end{aligned}$$

11.2 Calcolo della CDF

La funzione di distribuzione cumulativa è:

$$F_X(x) = \begin{cases} 0 & x < -3 \\ \frac{x+3}{4} & -3 \leq x \leq -1 \\ \frac{1}{2} & -1 < x < 1 \\ \frac{1}{2} + \int_1^x f_X(t) dt & 1 \leq x \leq 3 \\ 1 & x > 3 \end{cases}$$

Per la regione $[1, 3]$, calcoliamo l'integrale della parte triangolare. Per $x \in [1, 2]$:

$$\int_1^x \frac{t-1}{2} dt = \frac{1}{2} \cdot \frac{(x-1)^2}{2} = \frac{(x-1)^2}{4}$$

Per $x \in [2, 3]$:

$$\int_1^2 \frac{t-1}{2} dt + \int_2^x \frac{3-t}{2} dt = \frac{1}{4} + \frac{1}{2} \left(3(x-2) - \frac{(x-2)^2}{2} \right) = \frac{1}{4} + \frac{3(x-2)}{2} - \frac{(x-2)^2}{4}$$

Semplificando: $F_X(x) = \frac{1}{2} + \frac{1}{4} + \frac{3(x-2)}{2} - \frac{(x-2)^2}{4}$ per $x \in [2, 3]$.

Proprietà dell'alfabeto

L'alfabeto di X è l'insieme dei valori in cui la PDF è diversa da zero: $\text{supp}(f_X) = [-3, -1] \cup [1, 3]$. Due variabili aleatorie con alfabeti che differiscono per insiemi di probabilità nulla (ad es., due intervalli disgiunti vs. uno solo) sono considerate equivalenti in senso probabilistico.

11.3 Media e Condizionamento

Calcolo della media

Una strategia efficace è usare il **teorema della media condizionata**, evitando integrali complessi.

Definiamo l'evento $A = \{X \leq 0\}$. Allora:

$$E[X] = E[X|A]P(A) + E[X|A^c]P(A^c)$$

Calcolo di $P(A)$: $P(A) = P(X \in [-3, -1]) = \int_{-3}^{-1} \frac{1}{4} dx = \frac{1}{2}$.

Calcolo di $E[X|A]$: Condizionato a $X \in [-3, -1]$, la densità diventa:

$$f_{X|A}(x) = \frac{f_X(x)}{P(A)} = \frac{1/4}{1/2} = \frac{1}{2} \quad \text{per } x \in [-3, -1]$$

Questa è uniforme su $[-3, -1]$, quindi:

$$E[X|A] = \int_{-3}^{-1} x \cdot \frac{1}{2} dx = \frac{1}{2} \cdot \frac{(-1)^2 - (-3)^2}{2} = \frac{1}{2} \cdot \frac{1-9}{2} = -2$$

Per simmetria: La regione $[1, 3]$ è simmetrica a $[-3, -1]$ rispetto all'origine, quindi $E[X|A^c] = 2$.

Risultato finale: $E[X] = (-2) \cdot \frac{1}{2} + 2 \cdot \frac{1}{2} = 0$.

Strategie di calcolo

Quando una PDF è non uniforme o complessa, il **riconoscimento di strutture simmetriche** e l'uso del **condizionamento** riducono drasticamente il lavoro computazionale rispetto all'integrazione diretta. La dimestichezza con proprietà come la linearità della media è essenziale.

11.4 Probabilità Condizionata Composta

Calcoliamo $P(X > 2|X > -2)$.

Per definizione di probabilità condizionata:

$$P(X > 2|X > -2) = \frac{P(X > 2 \text{ e } X > -2)}{P(X > -2)} = \frac{P(X > 2)}{P(X > -2)}$$

Calcolo di $P(X > 2)$:

$$P(X > 2) = \int_2^3 \frac{3-x}{2} dx = \frac{1}{2} \left[3x - \frac{x^2}{2} \right]_2^3 = \frac{1}{2} \left(9 - \frac{9}{2} - 6 + 2 \right) = \frac{1}{4}$$

Calcolo di $P(X > -2)$:

$$P(X > -2) = P(X \in (-2, -1]) + P(X \in [1, 3]) = \int_{-2}^{-1} \frac{1}{4} dx + \frac{1}{2} = \frac{1}{4} + \frac{1}{2} = \frac{3}{4}$$

Risultato: $P(X > 2|X > -2) = \frac{1/4}{3/4} = \frac{1}{3}$.

11.5 Integrazione nella Densità Congiunta

Per variabili aleatorie bidimensionali (X, Y) con densità congiunta $f_{X,Y}(x, y)$:

- L'integrale doppio su tutto lo spazio fornisce 1: $\iint_{\mathbb{R}^2} f_{X,Y}(x, y) dx dy = 1$.
- L'integrale su una regione rettangolare $[x_1, x_2] \times [y_1, y_2]$ fornisce la probabilità congiunta:

$$P(x_1 \leq X \leq x_2, y_1 \leq Y \leq y_2) = \int_{x_1}^{x_2} \int_{y_1}^{y_2} f_{X,Y}(x, y) dy dx$$

- **Marginalizzazione:** integrare su una variabile fornisce la densità dell'altra:

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dy, \quad f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dx$$

Avvertenza sugli integrali multipli

Gli integrali multipli (doppi, tripli, n-pi) sono rari nella pratica della probabilità applicata. Ogni volta che si incontra un integrale n-plo con $n > 2$, è bene verificare se esiste un approccio alternativo (scomposizione, simmetria, cambio di variabili) che eviti il calcolo diretto. Nella ricerca e nell'industria, problemi con dati n-dimensionali ($n \gg 2$) si risolvono con metodi di apprendimento statistico, non con integrazione numerica.

#MSI

#esercizi

#distribuzione-triangolare

#PDF

#CDF

#densità-condizionata

#media-condizionata

#integrale-doppio

12. Variabili Aleatorie Continue Bivariate

12.1 Densità di Probabilità Congiunta

Analogamente al caso monodimensionale, una coppia di variabili aleatorie continue (X, Y) è caratterizzata da una **densità di probabilità congiunta** (PDF congiunta):

$$f_{X,Y}(x, y) \geq 0, \quad \iint_{\mathbb{R}^2} f_{X,Y}(x, y) dx dy = 1$$

Interpretazione geometrica

La densità di probabilità congiunta rappresenta la "densità di massa" su un piano: il valore $f_{X,Y}(x, y)$ indica la concentrazione di probabilità in un intorno del punto (x, y) . La probabilità che la coppia cada in una regione $C \subset \mathbb{R}^2$ è:

$$P((X, Y) \in C) = \iint_C f_{X,Y}(x, y) dx dy$$

Geometricamente, questa è il volume sotto la "superficie" $z = f_{X,Y}(x, y)$ sulla regione C .

Analogy con la fisica

La nozione di densità congiunta in probabilità è esattamente analoga alla densità di massa in fisica. Come la densità di massa (o densità di un materiale non uniforme) rappresenta il rapporto tra massa e volume in un intorno di un punto, la densità di probabilità rappresenta il rapporto tra probabilità e "volume ordinario" (area nel caso bidimensionale, volume nel caso tridimensionale, ecc.).

12.2 Funzione di Distribuzione Cumulativa Congiunta

La **CDF congiunta** è:

$$F_{X,Y}(x, y) = P(X \leq x, Y \leq y) = \int_{-\infty}^x \int_{-\infty}^y f_{X,Y}(u, v) dv du$$

Proprietà:

- $F_{X,Y}(-\infty, y) = 0$ e $F_{X,Y}(x, -\infty) = 0$ (eventi impossibili).
- $F_{X,Y}(+\infty, +\infty) = 1$ (evento certo).
- $F_{X,Y}(+\infty, y) = F_Y(y)$ e $F_{X,Y}(x, +\infty) = F_X(x)$ (marginalizzazione).

La PDF congiunta si recupera dalla CDF mediante derivata parziale mista:

$$f_{X,Y}(x, y) = \frac{\partial^2 F_{X,Y}(x, y)}{\partial x \partial y}$$

12.3 Distribuzioni Marginali

Marginalizzando rispetto a una variabile, si ottengono le densità univariate:

$$f_X(x) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y) dy, \quad f_Y(y) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y) dx$$

Queste sono esattamente gli analoghi continui delle marginalizzazioni nel caso discreto (dove la somma su y fornisce la PMF marginale di X).

12.4 Indipendenza

Due variabili aleatorie X e Y sono **indipendenti** se e solo se:

$$F_{X,Y}(x,y) = F_X(x) \cdot F_Y(y)$$

equivalentemente,

$$f_{X,Y}(x,y) = f_X(x) \cdot f_Y(y)$$

L'indipendenza significa che la conoscenza del valore di X non fornisce informazione sul valore di Y , e viceversa.

☰ Test di indipendenza

Se una PDF congiunta si fattorizza come $f_{X,Y}(x,y) = g(x) \cdot h(y)$ per opportune funzioni $g, h \geq 0$, allora X e Y sono indipendenti. Basta normalizzare: $\int g(x)dx = c_1$ e $\int h(y)dy = c_2$ con $c_1 \cdot c_2 = 1$, quindi $f_X(x) = \frac{g(x)}{c_1}$ e $f_Y(y) = \frac{h(y)}{c_2}$.

12.5 Densità Condizionale

Data la PDF congiunta $f_{X,Y}(x,y)$ e un valore y_0 di Y , la **densità di probabilità condizionale di X dato $Y = y_0$** è:

$$f_{X|Y}(x|y_0) = \frac{f_{X,Y}(x, y_0)}{f_Y(y_0)}$$

(per $f_Y(y_0) > 0$).

Interpretazione

La densità condizionale è la "restrizione" della densità congiunta al "filo" di ordinata costante $y = y_0$, riscalata affinché integri a 1. Se integriamo sulla variabile x :

$$\int_{-\infty}^{+\infty} f_{X|Y}(x|y_0) dx = \frac{\int_{-\infty}^{+\infty} f_{X,Y}(x, y_0) dx}{f_Y(y_0)} = \frac{f_Y(y_0)}{f_Y(y_0)} = 1 \quad \checkmark$$

Analogia con il caso discreto

L'espressione $f_{X|Y}(x|y) = \frac{f_{X,Y}(x,y)}{f_Y(y)}$ è formalmente identica a $P(X = x|Y = y) = \frac{P(X=x, Y=y)}{P(Y=y)}$ nel caso discreto. L'unica differenza è che nel caso continuo $P(Y = y) = 0$, quindi la definizione è in senso limite (come descritto nella lezione 11).

12.6 Derivate Parziali e Cambio di Variabili

Derivata parziale

Se $g(x,y) = \sin^2(xy) + x^3y^4$, le derivate parziali sono:

$$\frac{\partial g}{\partial x} = 2 \sin(xy) \cos(xy) \cdot y + 3x^2y^4 = y \sin(2xy) + 3x^2y^4$$

$$\frac{\partial^2 g}{\partial x \partial y} = \sin(2xy) + 2xy \cos(2xy) + 12x^2y^3$$

La regola è semplice: si deriva rispetto a una variabile trattenendo le altre come costanti.

Theorem di Schwarz

Per funzioni sufficientemente regolari, l'ordine di derivazione non conta:

$$\frac{\partial^2 g}{\partial x \partial y} = \frac{\partial^2 g}{\partial y \partial x}$$

Questa proprietà è sfruttata nel ricavare la PDF congiunta dalla CDF congiunta.

12.7 Caso di Variabili Indipendenti Gaussiane

Se $X \sim N(\mu_X, \sigma_X^2)$ e $Y \sim N(\mu_Y, \sigma_Y^2)$ sono indipendenti, allora:

$$f_{X,Y}(x,y) = f_X(x) \cdot f_Y(y) = \frac{1}{2\pi\sigma_X\sigma_Y} \exp\left(-\frac{(x-\mu_X)^2}{2\sigma_X^2} - \frac{(y-\mu_Y)^2}{2\sigma_Y^2}\right)$$

Questa è la PDF di una distribuzione **gaussiana bivariata** con covarianza nulla.

#MSI

#PDF-congiunta

#indipendenza

#marginalizzazione

#densità-condizionale

#CDF-congiunta

#derivata-parziale

13. Processi Stocastici e Processi Aleatori

13.1 Definizione e Nomenclatura

Un **processo aleatorio** (o **processo stocastico**) è un'estensione delle variabili aleatorie al dominio temporale. Mentre una variabile aleatoria assegna un numero a ogni elemento ω dello spazio campionario, un processo aleatorio assegna una **sequenza** di numeri.

Definizione formale

Dato uno spazio di probabilità $(\Omega, \mathcal{F}, P)$, un **processo stocastico** è una famiglia di variabili aleatorie indicizzate dal tempo:

$$\{X(t) : t \in T\}$$

dove T è un insieme di indici (tipicamente $\mathbb{N}$ per tempo discreto, $\mathbb{R}$ per tempo continuo) e ogni $X(t)$ è una variabile aleatoria.

Per ogni $\omega \in \Omega$ fissato, la funzione $t \mapsto X(t, \omega)$ è una **realizzazione** (o **traiettoria**) del processo. Le realizzazioni sono sequenze numeriche (nel caso discreto) o funzioni del tempo (nel caso continuo), non numeri singoli.

13.2 Dipendenza dalle Due Variabili

Un processo aleatorio dipende da due variabili:

1. **L'indice temporale** t : determina quando osserviamo il processo.
2. **L'elemento dello spazio campionario** ω : rappresenta l'incertezza.

Fissando t e variando ω , si ottiene una variabile aleatoria $X(t, \cdot)$. Fissando ω e variando t , si ottiene una realizzazione particolare $X(\cdot, \omega)$.

Notazione abbreviata

Per brevità, scriviamo X_t (tempo discreto) o $X(t)$ (tempo continuo) intendendo $X(t, \omega)$, dove il contesto rende chiaro se stiamo parlando di una variabile aleatoria (fissato t) o di una realizzazione (fissato ω).

13.3 Processi in Tempo Discreto vs. Continuo

Tempo discreto ($T = \mathbb{Z}$ o $\mathbb{N}$)

La sequenza di variabili aleatorie è $\{X_1, X_2, X_3, \dots\}$ o $\{X_0, X_1, X_2, \dots\}$. Una realizzazione è una sequenza numerica:

$$(x_1, x_2, x_3, \dots)$$

Esempi: prezzi azionari giornalieri, campioni di un segnale audio digitalizzato, numero di clienti in una coda ad ogni istante di campionamento.

Tempo continuo ($T = [0, T]$ o $\mathbb{R}_{\geq 0}$)

Una realizzazione è una funzione continua del tempo:

$$t \mapsto X(t, \omega)$$

Esempi: voltaggio di rumore termico in un circuito, posizione di una particella soggetta a moto browniano, intensità di una sorgente luminosa nel tempo.

13.4 Caratterizzazione Statistica

Per caratterizzare un processo aleatorio sono necessari:

1. **Medie al primo ordine:** per ogni t , la media $\mu_X(t) = E[X(t)]$ e la varianza $\sigma_X^2(t) = \text{Var}(X(t))$.
2. **Medie al secondo ordine:** per ogni coppia di tempi t_1, t_2 , la covarianza $\text{Cov}(X(t_1), X(t_2)) = E[(X(t_1) - \mu_X(t_1))(X(t_2) - \mu_X(t_2))]$.
3. **Densità congiunte:** le PDF (o PMF) congiunte $f_{X(t_1), X(t_2), \dots, X(t_n)}$ per qualsiasi n e qualsiasi scelta di tempi $t_1, \dots, t_n$.

Una caratterizzazione completa (descrizione probabilistica totale) richiede tutte le densità congiunte finite-dimensionali.

13.5 Proprietà di Stazionarietà

Un processo è **stazionario** (in senso stretto) se le proprietà statistiche sono invarianti nel tempo. Formalmente:

$$P(X(t_1) \leq x_1, \dots, X(t_n) \leq x_n) = P(X(t_1 + \tau) \leq x_1, \dots, X(t_n + \tau) \leq x_n)$$

per ogni scelta di tempi e ritardo τ .

Un processo è **stazionario in senso lato** se:

- $E[X(t)]$ è costante nel tempo.
- $\text{Var}(X(t))$ è costante nel tempo.
- $\text{Cov}(X(t_1), X(t_2))$ dipende solo dalla differenza $t_1 - t_2$.

La stazionarietà semplifica l'analisi: molti processi reali (almeno su scale temporali limitate) possono essere approssimati come stazionari.

13.6 Esempio: Processo di Poisson

Il **processo di Poisson** con intensità λ è un processo in tempo continuo fondamentale che conta il numero di eventi (arrivi, click, decadimenti) in intervalli di tempo. Se $N(t)$ è il numero di eventi fino al tempo t , allora:

$$P(N(t) = k) = \frac{(\lambda t)^k}{k!} e^{-\lambda t}$$

Proprietà caratteristiche:

- **Incrementi indipendenti:** il numero di eventi in intervalli disgiunti sono variabili aleatorie indipendenti.
- **Incrementi stazionari:** la distribuzione del numero di eventi in $[t, t + s]$ dipende solo da s , non da t .
- **Assenza di memoria:** la probabilità di un prossimo evento non dipende dal passato.

Il processo di Poisson modella code (numero di clienti), affidabilità (numero di guasti), e comunicazioni (numero di pacchetti).

13.7 Processi Gaussiani

Se ogni marginale $X(t)$ è gaussiana e ogni densità congiunta è gaussiana multivariata, il processo si dice **gaussiano**. I processi gaussiani:

- Sono completamente caratterizzati dalle loro medie $\mu_X(t)$ e funzione di autocovarianza $\gamma(t_1, t_2) = \text{Cov}(X(t_1), X(t_2))$.
- Generalizzano il concetto di distribuzione normale alle funzioni del tempo.
- Sono importanti nella teoria del filtraggio (Kalman filter) e nell'apprendimento supervisionato (Gaussian Process regression).

#MSI

#processi-aleatori

#processi-stocastici

#tempo-discreto

#tempo-continuo

#realizzazione

#stazionarietà

#processo-poisson

14. Vettori Aleatori e Proprietà Multidimensionali

14.1 Vettori Aleatori Bidimensionali

Una coppia di variabili aleatorie può essere rappresentata come un **vettore aleatorio** $X = (X_1, X_2)^T$. Il vettore delle medie è:

$$\mu = E[X] = \begin{pmatrix} E[X_1] \\ E[X_2] \end{pmatrix} = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}$$

La **matrice di covarianza** è una matrice 2×2 che racchiude tutte le informazioni sulla variabilità e la co-variabilità:

$$K = \text{Cov}(X) = E[(X - \mu)(X - \mu)^T] = \begin{pmatrix} \sigma_1^2 & \text{Cov}(X_1, X_2) \\ \text{Cov}(X_1, X_2) & \sigma_2^2 \end{pmatrix}$$

dove $\text{Cov}(X_1, X_2) = E[(X_1 - \mu_1)(X_2 - \mu_2)]$ è la covarianza fra le due variabili, e $\sigma_i^2 = \text{Var}(X_i)$.

14.2 Coefficient di Correlazione

La **correlazione normalizzata** fra X_1 e X_2 è:

$$\rho_{12} = \frac{\text{Cov}(X_1, X_2)}{\sigma_1 \sigma_2}$$

Proprietà:

- $|\rho_{12}| \leq 1$ per la disuguaglianza di Cauchy-Schwarz.
- $\rho_{12} = 1$ se e solo se $X_2 = aX_1 + b$ con $a > 0$ (relazione lineare diretta).
- $\rho_{12} = -1$ se e solo se $X_2 = aX_1 + b$ con $a < 0$ (relazione lineare inversa).
- $\rho_{12} = 0$ se le variabili sono incorrelate (ma non necessariamente indipendenti).

Correlazione vs. Indipendenza

L'indipendenza implica correlazione nulla, ma il viceversa non è vero. Due variabili possono avere $\rho = 0$ (zero covarianza) pur essendo fortemente dipendenti tramite una relazione non lineare. L'unica eccezione è il caso gaussiano, dove incorrelazione equivale a indipendenza.

14.3 Generalizzazione a Vettori n-dimensionali

Per un vettore aleatorio $X = (X_1, \dots, X_n)^T$, la matrice di covarianza è $n \times n$:

$$K_{ij} = \text{Cov}(X_i, X_j)$$

Proprietà della matrice di covarianza:

- **Simmetria:** $K = K^T$ (poiché $\text{Cov}(X_i, X_j) = \text{Cov}(X_j, X_i)$).
- **Semidefinitezza positiva:** per ogni vettore a , si ha $a^T K a \geq 0$. Questo garantisce che la matrice sia sempre invertibile (se non singolare).
- **Diagonale:** i termini sulla diagonale sono le varianze $K_{ii} = \sigma_i^2 \geq 0$.

La matrice di covarianza è fondamentale in **analisi dei componenti principali (PCA)**, **filtraggio ottimale (Kalman filter)**, e **stima MMSE** (Minimum Mean Square Error).

14.4 Operazione di Convoluzione

Definizione

Date due funzioni integrabili f e g , il **prodotto di convoluzione** è:

$$(f * g)(t) = \int_{-\infty}^{+\infty} f(\tau) \cdot g(t - \tau) d\tau = \int_{-\infty}^{+\infty} f(t - \tau) \cdot g(\tau) d\tau$$

La convoluzione è **commutativa**, **associativa** e **distributiva** rispetto alla somma.

Motivazione probabilistica

Se X e Y sono variabili aleatorie continue indipendenti con densità f_X e f_Y , la densità della somma $Z = X + Y$ è la convoluzione:

$$f_Z(z) = (f_X * f_Y)(z) = \int_{-\infty}^{+\infty} f_X(x) \cdot f_Y(z - x) dx$$

La convoluzione cattura come la "combinazione" di due fenomeni aleatori indipendenti si riflette nella distribuzione della loro somma.

Applicazioni

- **Sistemi lineari tempo-invarianti (LTI):** la relazione ingresso-uscita di un sistema LTI è descritta dalla convoluzione dell'ingresso con la risposta all'impulso del sistema.
- **Processamento di segnali:** filtraggio di immagini, audio e dati è implementato via convoluzione.
- **Reti neurali convoluzionali (CNN):** gli strati convoluzionali eseguono prodotti di convoluzione discreti.

14.5 Trasformata di Laplace e Funzioni di Trasferimento

La **trasformata di Laplace** di una funzione $f(t)$ è:

$$F(s) = \mathcal{L}\{f\}(s) = \int_0^{\infty} f(t)e^{-st} dt$$

Proprietà fondamentale: la convoluzione nel dominio del tempo diventa **moltiplicazione** nel dominio di Laplace:

$$\mathcal{L}\{f * g\} = \mathcal{L}\{f\} \cdot \mathcal{L}\{g\}$$

Questa proprietà è cruciale per risolvere equazioni differenziali lineari a coefficienti costanti, trasformandole in equazioni algebriche nel dominio di Laplace.

14.6 Teorema Centrale del Limite

Teorema Centrale del Limite (TCL)

Siano $X_1, X_2, \dots, X_n$ variabili aleatorie **indipendenti e identicamente distribuite** (i.i.d.) con media finita μ e varianza finita σ^2 . Allora, per $n \rightarrow \infty$, la somma (risalata e centrata)

$$Z_n = \frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}$$

converge in distribuzione a una **gaussiana standard** $N(0, 1)$.

Significato pratico

Il TCL spiega perché la distribuzione gaussiana è ubiquitaria in natura: ogniqualvolta un fenomeno è la sovrapposizione di molti fenomeni elementari indipendenti (ad es., rumore termico come somma di migliaia di eventi di scattering), il risultato è approssimativamente gaussiano, indipendentemente dalle distribuzioni individuali dei componenti.

Applicazioni:

- **Teoria degli errori:** errori di misura frequentist sono generalmente gaussiani.
- **Control di qualità:** il TCL permette di stimare distribuzioni di media campionaria senza conoscere la distribuzione esatta dei dati.
- **Propagazione dell'incertezza:** quando si combinano misure indipendenti, l'incertezza risultante tende alla gaussiana.

Velocità di convergenza

La convergenza è più rapida se le distribuzioni individuali sono già simmetriche. Se le X_i hanno distribuzioni "pesanti" (con code molto pronunciate), servono più termini per la convergenza.

14.7 Cenno a Estensioni

Variabili continue multivariate

L'intero framework (CDF congiunta, PDF congiunta, marginalizzazione, condizionamento, covarianza) si estende a n variabili qualsiasi. Gli integrali diventano n -pli, ma la logica rimane identica.

Convergenze e limiti

Oltre al TCL, esistono teoremi di limite più generali:

- **Legge dei grandi numeri:** la media campionaria converge alla media teorica quando $n \rightarrow \infty$.
- **Teorema di Slutsky:** regole per combinare limiti di sequenze di variabili aleatorie.
- **Convergenza in distribuzione, probabilità, e quasi-certamente:** diversi modi di formalizzare cosa significhi "convergere" per variabili aleatorie.

#MSI

#vettore-aleatorio

#matrice-covarianza

#correlazione

#convoluzione

#teorema-limite-centrale

#sistemi-lineari

#trasformata-laplace

Lezione 16 — Fondamenti di Statistica Inferenziale, Convergenza e Decisione Bayesiana

1. Introduzione alla Statistica Inferenziale

Essenza

La **statistica inferenziale** è il processo bottom-up che utilizza l'analisi dei dati per inferire le proprietà di una distribuzione di probabilità sottostante (popolazione), a differenza della **statistica descrittiva** (o "statistica Excel") che si limita a descrivere le proprietà dei soli dati osservati senza assumere che essi provengano da una popolazione più grande.

Immaginiamo che un dataset x^n (vettore n -dimensionale) sia una realizzazione di un vettore aleatorio X^n . Collezionando un altro dataset x'^n , otterremo valori diversi, ma che condividono le stesse caratteristiche globali della popolazione originaria.

Obiettivi Fondamentali della Statistica Inferenziale

1. **Test di Ipotesi:** decidere se la natura si trova in uno stato discreto tra una serie di scenari incompatibili.
2. **Stima Parametrica:** determinare il valore di uno o più parametri continui nascosti nei dati.

2. Successioni di Variabili Aleatorie e Convergenza

Una variabile aleatoria non è un singolo numero, ma una funzione $Y(\omega)$ definita sullo spazio campionario. Pertanto, la convergenza di una successione di variabili aleatorie $Y_n(\omega)$ richiede definizioni specifiche.

2.1 Convergenza in Distribuzione

Definizione

La successione Y_n converge in distribuzione a Y ($Y_n \xrightarrow{d} Y$) se la legge di probabilità (CDF) di Y_n converge alla CDF di Y in tutti i punti di continuità.

Esempio classico: Il **Teorema Centrale del Limite (TCL)**. Se X_i sono i.i.d. con media 0 e varianza σ^2 , allora:

$$Y_n = \frac{1}{\sqrt{n}} \sum_{i=1}^n X_i \xrightarrow{d} N(0, \sigma^2)$$

2.2 Convergenza in Probabilità

Definizione

La successione Y_n converge in probabilità a Y ($Y_n \xrightarrow{p} Y$) se, per ogni $\epsilon > 0$:

$$\lim_{n \rightarrow \infty} P(|Y_n - Y| > \epsilon) = 0$$

2.3 Convergenza in Media Quadratica (MS)

Definizione

La successione Y_n converge in media quadratica a Y ($Y_n \xrightarrow{m.q.} Y$) se:

$$\lim_{n \rightarrow \infty} E[(Y_n - Y)^2] = 0$$

Relazione tra convergenze

La convergenza in media quadratica **implica** la convergenza in probabilità, ma il viceversa non è sempre vero.

2.4 Legge Debole dei Grandi Numeri: Dimostrazione

Consideriamo una successione X_i di variabili aleatorie discrete i.i.d., appartenenti all'alfabeto $\{a_1, \dots, a_m\}$ con $P(X_i = a_j) = p_j$.
Vogliamo analizzare la media campionaria:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

Possiamo riordinare la somma raggruppando i termini uguali:

$$\bar{X}_n = \sum_{j=1}^m a_j \frac{N_j}{n}$$

dove N_j è la variabile aleatoria (binomiale) che conta quante volte compare il simbolo a_j su n campioni.

La variabile N_j ha:

- Media: $E[N_j] = np_j$
- Varianza: $\text{Var}(N_j) = np_j(1 - p_j)$

Considerando la frequenza relativa N_j/n :

- Media: $E\left[\frac{N_j}{n}\right] = p_j$
- Varianza: $\text{Var}\left[\frac{N_j}{n}\right] = \frac{p_j(1-p_j)}{n}$

Applicando la **Disuguaglianza di Chebyshev** per una generica soglia $\delta > 0$:

$$P\left(\left|\frac{N_j}{n} - p_j\right| > \delta\right) \leq \frac{\text{Var}(N_j/n)}{\delta^2} = \frac{p_j(1-p_j)}{n\delta^2}$$

Prendendo il limite per $n \rightarrow \infty$:

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{N_j}{n} - p_j\right| > \delta\right) = 0$$

Dunque, la frequenza relativa N_j/n converge in probabilità (e in media quadratica, poiché la varianza va a zero) a p_j .

Di conseguenza, la media campionaria $\bar{X}_n$ converge alla media statistica:

$$\bar{X}_n \xrightarrow{P} E[X] = \sum_{j=1}^m a_j p_j$$

Questa è la **Legge Debole dei Grandi Numeri**.

Legge Forte dei Grandi Numeri

Se la convergenza avviene con probabilità 1 (quasi certamente), si parla di Legge Forte. Una condizione sufficiente per la convergenza quasi certa è fornita dal **Lemma di Borel-Cantelli**: se la serie $\sum_{n=1}^{\infty} P(|Y_n - Y| > \epsilon)$ è sommabile (finita), allora $Y_n \rightarrow Y$ con probabilità 1.

3. Classificazione e Decisione Bayesiana

3.1 Formulazione del Problema

- **Osservabili:** $x^n \in X^n$, realizzazione del vettore aleatorio X^n .
- **Stati della natura (Ipotesi):** la natura può trovarsi in uno tra M stati mutualmente esclusivi, descritti dalle ipotesi $H_1, H_2, \dots, H_M$.
- **Distribuzioni condizionate:** se è vera H_i , i dati seguono la legge condizionale $P(x^n|H_i)$ (caso discreto, PMF) o $f(x^n|H_i)$ (caso continuo, PDF).

- **Probabilità a priori:** $P(H_i) = \pi_i$, con $\sum_{i=1}^M \pi_i = 1$.

3.2 Regola di Decisione e Rischio di Bayes

Una regola di decisione è una mappa $d(x^n)$ che associa a ciascun dataset osservato una decisione $i \in \{1, \dots, M\}$, partizionando lo spazio degli osservabili in M regioni disgiunte $\Omega_1, \dots, \Omega_M$.

Definiamo una **matrice dei costi** $C \in \mathbb{R}^{M \times M}$, in cui c_{ij} rappresenta il costo associato alla scelta dell'ipotesi H_i quando lo stato reale della natura è H_j .

Il costo effettivo pagato è una variabile aleatoria $C(X^n)$. Il **Rischio Medio Bayesiano** è definito come il valore atteso del costo:

$$R_B = \sum_{i=1}^M \sum_{j=1}^M c_{ij} P(d(X^n) = i, H_j)$$

Una regola di decisione è **Bayes-ottima** se minimizza R_B .

3.3 Minimizzazione della Probabilità di Errore (P_e)

Se impostiamo i costi in modo da non penalizzare le decisioni corrette e penalizzare equamente tutti gli errori:

$$c_{ii} = 0, \quad c_{ij} = 1 \quad (\forall i \neq j)$$

Il rischio medio bayesiano coincide esattamente con la **probabilità di errore** P_e :

$$R_B = P_e = \sum_{i \neq j} P(d(X^n) = i, H_j)$$

Minimizzare P_e equivale a massimizzare la probabilità di decisione corretta $P_c = 1 - P_e$.

Caso Binario ($M = 2$)

La probabilità di corretta decisione è:

$$P_c = P(H_1)P(d(X^n) = 1|H_1) + P(H_2)P(d(X^n) = 2|H_2)$$

Definendo Ω_1 e Ω_2 come le partizioni dello spazio campionario:

$$P_c = \sum_{x^n \in \Omega_1} \pi_1 P(x^n|H_1) + \sum_{x^n \in \Omega_2} \pi_2 P(x^n|H_2)$$

Per massimizzare questa somma, per ogni stringa osservata x^n , la assegniamo alla regione che fornisce il contributo maggiore. Dunque la regola ottima (a minima probabilità di errore) è:

$$\text{Decidi } H_1 \iff \pi_1 P(x^n|H_1) > \pi_2 P(x^n|H_2)$$

Applicando il Teorema di Bayes, dividendo entrambi i membri per la probabilità totale $P(x^n)$, otteniamo la regola **MAP (Maximum A Posteriori)**:

$$\text{Decidi } H_1 \iff P(H_1|x^n) > P(H_2|x^n)$$

Regola MAP vs ML

- **MAP (Maximum A Posteriori):** Sceglie l'ipotesi che massimizza la probabilità a posteriori del parametro date le osservazioni.
- **ML (Maximum Likelihood / Massima Verosimiglianza):** Se le ipotesi sono a priori equiprobabili ($\pi_1 = \pi_2$), la regola MAP si semplifica nel confronto diretto delle verosimiglianze (Likelihood):

$$\text{Decidi } H_1 \iff P(x^n|H_1) > P(x^n|H_2)$$

4. Esempio Pratico: Classificazione di Sorgenti Binarie I.I.D.

Setup

- Gli osservabili sono stringhe binarie $x^n \in \{0, 1\}^n$.
- Le ipotesi sono equiprobabili ($\pi_1 = \pi_2 = 1/2$), perciò MAP coincide con ML.
- Sotto H_1 : la sorgente è i.i.d. e genera 1 con probabilità p_1 .
- Sotto H_2 : la sorgente è i.i.d. e genera 1 con probabilità p_2 .
- Si assume $p_1 > p_2$.

Sviluppo del Test

La PMF condizionata sotto l'ipotesi H_j per una stringa indipendente è:

$$P(x^n|H_j) = p_j^{w(x^n)}(1 - p_j)^{n - w(x^n)}$$

dove $w(x^n) = \sum_{i=1}^n x_i$ è il **peso di Hamming** (il numero di 1 nella stringa).

La regola di massima verosimiglianza impone:

$$\frac{P(x^n|H_1)}{P(x^n|H_2)} > 1 \implies \frac{p_1^{w(x^n)}(1 - p_1)^{n - w(x^n)}}{p_2^{w(x^n)}(1 - p_2)^{n - w(x^n)}} > 1$$

Prendendo il logaritmo naturale (funzione monotona crescente):

$$w(x^n) \ln\left(\frac{p_1}{p_2}\right) + [n - w(x^n)] \ln\left(\frac{1 - p_1}{1 - p_2}\right) > 0$$

Raggruppando i termini per il peso di Hamming $w(x^n)$:

$$w(x^n) \left[\ln\left(\frac{p_1}{p_2}\right) - \ln\left(\frac{1 - p_1}{1 - p_2}\right) \right] > n \ln\left(\frac{1 - p_2}{1 - p_1}\right)$$

Poiché $p_1 > p_2$, il coefficiente tra parentesi quadre è strettamente positivo. Possiamo dividere isolando il peso di Hamming:

$$w(x^n) \underset{H_2}{\overset{H_1}{>}} \eta_1$$

dove la soglia ottima η_1 è data da:

$$\eta_1 = n \frac{\ln \left(\frac{1-p_2}{1-p_1} \right)}{\ln \left(\frac{p_1(1-p_2)}{p_2(1-p_1)} \right)}$$

Interpretazione Geometrica

Il test ottimo si riduce semplicemente a **contare il numero di 1** nella sequenza ricevuta e a confrontarlo con la soglia η_1 .

Calcolo della Probabilità di Errore (P_e)

L'errore si commette se superiamo la soglia sotto H_2 , o se non la superiamo sotto H_1 :

$$P_e = \frac{1}{2} P(w(X^n) > \eta_1 | H_2) + \frac{1}{2} P(w(X^n) \leq \eta_1 | H_1)$$

Sotto l'ipotesi H_j , il peso di Hamming $w(X^n)$ è una variabile aleatoria binomiale di parametri n e p_j :

$$P_e = \frac{1}{2} \sum_{k=\lfloor \eta_1 \rfloor + 1}^n \binom{n}{k} p_2^k (1-p_2)^{n-k} + \frac{1}{2} \sum_{k=0}^{\lfloor \eta_1 \rfloor} \binom{n}{k} p_1^k (1-p_1)^{n-k}$$

Lezione 17 — Test Continuo, Statistiche Sufficienti e Criterio di Neyman-Pearson

1. Estensione del Test di Ipotesi al Caso Continuo

Essenza

Nel caso continuo, le sommatorie della probabilità di decisione corretta si trasformano in integrali multivariati sullo spazio delle osservazioni $\mathbb{R}^n$.

La probabilità di decisione corretta P_c con M ipotesi è:

$$P_c = \sum_{i=1}^M \pi_i \int_{\Omega_i} f(x^n | H_i) dx^n$$

Per massimizzare P_c (riducendo al minimo la probabilità di errore P_e), ciascun vettore osservato x^n deve essere assegnato alla regione Ω_k in cui l'integrando $\pi_k f(x^n | H_k)$ è massimo.

La regola Bayesiana a minima probabilità di errore (MAP) per osservabili continui diventa:

$$\text{Decidi } H_k \iff k = \arg \max_i \pi_i f(x^n | H_i)$$

Se le ipotesi sono a priori equiprobabili ($\pi_i = 1/M$), la regola si riduce alla massimizzazione della densità di verosimiglianza (Maximum Likelihood):

$$\text{Decidi } H_k \iff k = \arg \max_i f(x^n | H_i)$$

2. Esempi Notevoli di Test di Ipotesi I.I.D. (Caso Binario)

2.1 Esempio 1: Test sulla Media di Gaussiane I.I.D. con Varianza Nota

Consideriamo osservazioni gaussiane i.i.d. sotto due ipotesi equiprobabili ($\pi_1 = \pi_2 = 1/2$):

- $H_1 : X_i \sim N(\mu_1, \sigma^2)$
 - $H_2 : X_i \sim N(\mu_2, \sigma^2)$
- Assumiamo $\mu_1 > \mu_2$.

Derivazione della Regola di Decisione (LRT)

Le PDF condizionate congiunte sono:

$$f(x^n|H_j) = \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right)^n \exp \left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu_j)^2 \right)$$

Il rapporto di verosimiglianza (Likelihood Ratio Test) impone:

$$\frac{f(x^n|H_1)}{f(x^n|H_2)} \underset{H_2}{\overset{H_1}{\geq}} 1$$

Prendendo il logaritmo naturale:

$$\ln \left(\frac{f(x^n|H_1)}{f(x^n|H_2)} \right) = -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu_1)^2 + \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu_2)^2 \underset{H_2}{\overset{H_1}{\geq}} 0$$

Espandendo i quadrati all'interno delle sommatorie:

$$\begin{aligned} \sum_{i=1}^n (x_i - \mu_1)^2 &= \sum_{i=1}^n x_i^2 - 2\mu_1 \sum_{i=1}^n x_i + n\mu_1^2 \\ \sum_{i=1}^n (x_i - \mu_2)^2 &= \sum_{i=1}^n x_i^2 - 2\mu_2 \sum_{i=1}^n x_i + n\mu_2^2 \end{aligned}$$

Sostituendo e semplificando il termine comune $\sum x_i^2$:

$$\frac{1}{2\sigma^2} [2(\mu_1 - \mu_2) \sum_{i=1}^n x_i - n(\mu_1^2 - \mu_2^2)] \underset{H_2}{\overset{H_1}{\geq}} 0$$

Moltiplicando per $\frac{2\sigma^2}{n}$:

$$\frac{2(\mu_1 - \mu_2)}{n} \sum_{i=1}^n x_i - (\mu_1^2 - \mu_2^2) \underset{H_2}{\overset{H_1}{\geq}} 0$$

Sapendo che $\mu_1^2 - \mu_2^2 = (\mu_1 - \mu_2)(\mu_1 + \mu_2)$ e che per ipotesi $\mu_1 > \mu_2$ (dunque $\mu_1 - \mu_2 > 0$), possiamo dividere per $2(\mu_1 - \mu_2)$ isolando la media campionaria $\bar{X}_n$:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n x_i \underset{H_2}{\overset{H_1}{\geq}} \frac{\mu_1 + \mu_2}{2}$$

Concetto di Statistica Sufficiente

Non è necessario conoscere ogni singola componente del vettore x^n per decidere in modo ottimo. Tutta l'informazione rilevante per il test è racchiusa nella sola **media campionaria** $\bar{X}_n$. Qualsiasi altra statistica (es. varianza campionaria o i singoli ordinamenti dei dati) rappresenta rumore irrilevante ai fini della decisione.

Calcolo della Probabilità di Errore (P_e)

La statistica sufficiente $\bar{X}_n$ è una combinazione lineare di gaussiane indipendenti, quindi è anch'essa gaussiana:

- Sotto H_1 : $\bar{X}_n \sim N(\mu_1, \frac{\sigma^2}{n})$
- Sotto H_2 : $\bar{X}_n \sim N(\mu_2, \frac{\sigma^2}{n})$

Dato che la soglia ottima è $\eta = \frac{\mu_1 + \mu_2}{2}$, l'errore sotto H_1 (decidere H_2) è:

$$P(d(X^n) = 2|H_1) = P(\bar{X}_n < \frac{\mu_1 + \mu_2}{2} | H_1)$$

Normalizzando la variabile ponendo $Z = \frac{\bar{X}_n - \mu_1}{\sigma/\sqrt{n}} \sim N(0, 1)$:

$$P(Z < \frac{\frac{\mu_1 + \mu_2}{2} - \mu_1}{\sigma/\sqrt{n}}) = P(Z < -\frac{\mu_1 - \mu_2}{2\sigma/\sqrt{n}}) = \Phi(-\frac{\sqrt{n}(\mu_1 - \mu_2)}{2\sigma}) = Q(\frac{\sqrt{n}(\mu_1 - \mu_2)}{2\sigma})$$

dove $Q(x) = \frac{1}{\sqrt{2\pi}} \int_x^\infty e^{-t^2/2} dt$ è la funzione Q-Gaussiana.

Per simmetria, $P(d(X^n) = 1|H_2)$ fornisce lo stesso risultato. Essendo le ipotesi equiprobabili:

$$P_e = Q(\frac{\sqrt{n}(\mu_1 - \mu_2)}{2\sigma})$$

Dinamica dell'Errore

All'aumentare del numero di campioni n , la probabilità di errore decresce in modo **esponenziale**. Ciò è coerente con la legge dei grandi numeri: la varianza della media campionaria collapsa a zero, separando nettamente le distribuzioni delle due ipotesi.

2.2 Esempio 2: Test su Variabili di Poisson I.I.D.

- $H_1 : X_i \sim \text{Poisson}(\lambda_1)$
 - $H_2 : X_i \sim \text{Poisson}(\lambda_2)$
- Assumiamo $\lambda_1 > \lambda_2$ e ipotesi equiprobabili ($\pi_1 = \pi_2 = 1/2$).

Derivazione del Test

La PMF di una singola osservazione poissoniana è:

$$P(X_i = x_i | H_j) = \frac{\lambda_j^{x_i}}{x_i!} e^{-\lambda_j}$$

La PMF congiunta di n campioni indipendenti è:

$$P(x^n | H_j) = \prod_{i=1}^n \frac{\lambda_j^{x_i}}{x_i!} e^{-\lambda_j} = e^{-n\lambda_j} \frac{\lambda_j^{\sum x_i}}{\prod x_i!}$$

Il rapporto di verosimiglianza ML esclude i denominatori comuni $\prod x_i!$:

$$\frac{e^{-n\lambda_1} \lambda_1^{\sum x_i}}{e^{-n\lambda_2} \lambda_2^{\sum x_i}} \underset{H_2}{\overset{H_1}{>}} 1$$

Prendendo il logaritmo naturale:

$$-n(\lambda_1 - \lambda_2) + \left(\sum_{i=1}^n x_i \right) \ln \left(\frac{\lambda_1}{\lambda_2} \right) \underset{H_2}{\overset{H_1}{>}} 0$$

Essendo $\lambda_1 > \lambda_2$, abbiamo $\ln(\lambda_1/\lambda_2) > 0$. Dividendo:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n x_i \underset{H_2}{\overset{H_1}{>}} \frac{\lambda_1 - \lambda_2}{\ln(\lambda_1/\lambda_2)}$$

Somma di Poissoniane Indipendenti

Teorema

Se $X_1 \sim \text{Poisson}(\lambda_1)$ e $X_2 \sim \text{Poisson}(\lambda_2)$ sono indipendenti, la loro somma $Z = X_1 + X_2$ è poissoniana con parametro $\lambda_1 + \lambda_2$.

Dimostrazione:

$$P(Z = m) = \sum_{l=0}^m P(X_1 = m-l) P(X_2 = l) = \sum_{l=0}^m \frac{\lambda_1^{m-l}}{(m-l)!} e^{-\lambda_1} \frac{\lambda_2^l}{l!} e^{-\lambda_2}$$

Moltiplicando e dividendo per $m!$:

$$P(Z = m) = \frac{e^{-(\lambda_1 + \lambda_2)}}{m!} \sum_{l=0}^m \frac{m!}{l!(m-l)!} \lambda_2^l \lambda_1^{m-l} = \frac{(\lambda_1 + \lambda_2)^m}{m!} e^{-(\lambda_1 + \lambda_2)}$$

Pertanto, la somma totale $Y = \sum_{i=1}^n X_i$ è distribuita come:

- Sotto H_1 : $Y \sim \text{Poisson}(n\lambda_1)$
- Sotto H_2 : $Y \sim \text{Poisson}(n\lambda_2)$

Definendo la soglia intera per la somma come $K_{\text{soglia}} = \lfloor n \frac{\lambda_1 - \lambda_2}{\ln(\lambda_1/\lambda_2)} \rfloor$, la probabilità di errore è:

$$P_e = \frac{1}{2} \sum_{k=0}^{K_{\text{soglia}}} \frac{(n\lambda_1)^k}{k!} e^{-n\lambda_1} + \frac{1}{2} \sum_{k=K_{\text{soglia}}+1}^{\infty} \frac{(n\lambda_2)^k}{k!} e^{-n\lambda_2}$$

2.3 Esempio 3: Test sulla Varianza di Gaussiane a Media Nulla

- $H_1: X_i \sim N(0, \sigma_1^2)$

- $H_2 : X_i \sim N(0, \sigma_2^2)$
Assumiamo $\sigma_1^2 > \sigma_2^2$ e ipotesi equiprobabili.

Le verosimiglianze sono:

$$f(x^n | H_j) = \left(\frac{1}{\sqrt{2\pi\sigma_j^2}} \right)^n \exp \left(-\frac{1}{2\sigma_j^2} \sum_{i=1}^n x_i^2 \right)$$

Applicando il log-LRT:

$$-n \ln(\sigma_1) - \frac{1}{2\sigma_1^2} \sum_{i=1}^n x_i^2 \underset{H_2}{\overset{H_1}{>}} -n \ln(\sigma_2) - \frac{1}{2\sigma_2^2} \sum_{i=1}^n x_i^2$$

Isolando la somma dei quadrati:

$$\left(\frac{1}{2\sigma_2^2} - \frac{1}{2\sigma_1^2} \right) \sum_{i=1}^n x_i^2 \underset{H_2}{\overset{H_1}{>}} n \ln \left(\frac{\sigma_1}{\sigma_2} \right)$$

Essendo $\sigma_1 > \sigma_2$, la parentesi a sinistra è strettamente positiva. Dividendo per essa e per n:

$$\frac{1}{n} \sum_{i=1}^n x_i^2 \underset{H_2}{\overset{H_1}{>}} \frac{2 \ln(\sigma_1 / \sigma_2)}{\frac{1}{\sigma_2^2} - \frac{1}{\sigma_1^2}}$$

Interpretazione

La statistica sufficiente è il **momento secondo campionario** $\frac{1}{n} \sum X_i^2$. La sua distribuzione sotto le due ipotesi è una riscaturatura di una variabile aleatoria Chi-Quadro (χ^2) con n gradi di libertà.

3. Il Criterio di Neyman-Pearson

Contesto

Nei casi reali (es. radar militare o rilevamento epidemie), spesso **non conosciamo le probabilità a priori delle ipotesi** π_j né disponiamo di una **matrice dei costi definita**.

In tali scenari si introduce l'ipotesi nulla H_0 ("stato di quiete/assenza di segnale") e l'ipotesi alternativa H_1 ("anomalia/presenza di segnale").

3.1 Classificazione degli Errori

Assegnando lo spazio campionario alle regioni Ω_0 (si decide per H_0) e Ω_1 (si decide per H_1):

- **Errore di I Specie (Falso Allarme):** decidere H_1 quando è vera H_0 .

$$P_{FA} = \alpha = \int_{\Omega_1} f(x^n | H_0) dx^n$$

- **Errore di II Specie (Mancata Rivelazione / Miss):** decidere H_0 quando è vera H_1 .

$$P_M = \beta = \int_{\Omega_0} f(x^n|H_1)dx^n$$

- **Potenza del Test (Probabilità di Rivelazione / Detection):** decidere H_1 quando è vera H_1 .

$$P_D = 1 - \beta = \int_{\Omega_1} f(x^n|H_1)dx^n$$

⚡ Trappola da evitare

Non è possibile minimizzare contemporaneamente sia α che β . Ad esempio, decidendo sempre H_1 si ottiene $\beta = 0$ (massima potenza $P_D = 1$) ma al costo di generare un falso allarme costante $\alpha = 1$.

3.2 Formulazione del Criterio

Il criterio di Neyman-Pearson risolve questo trade-off vincolando la probabilità di falso allarme a non superare un livello di significatività massimo tollerabile α_0 , e massimizzando la potenza del test sotto tale vincolo:

$$\max_{\Omega_1} P_D \quad \text{s.t.} \quad P_{FA} \leq \alpha_0$$

3.3 Il Lemma di Neyman-Pearson

🔥 Teorema

Il test che massimizza la probabilità di rivelazione P_D sotto il vincolo $P_{FA} \leq \alpha_0$ è il **Rapporto di Verosimiglianza (LRT)**:

$$L(x^n) = \frac{f(x^n|H_1)}{f(x^n|H_0)} \underset{H_0}{\overset{H_1}{>}} \eta$$

dove la soglia η deve essere scelta in modo da soddisfare strettamente l'uguaglianza sul bordo del vincolo:

$$P(L(X^n) > \eta | H_0) = \alpha_0$$

🧠 Lezione 18 — Esercizi di Decisione e Introduzione alla Stima Bayesiana (MMSE)

1. Analisi di Test di Ipotesi Notevoli

1.1 Esempio 1: Test di Neyman-Pearson con Variabili Esponenziali

Siano $X_1, \dots, X_n$ osservazioni i.i.d. distribuite secondo leggi esponenziali sotto due ipotesi:

- Under H_0 : $X_i \sim \text{Exp}(\lambda_0) \implies f(x_i|H_0) = \lambda_0 e^{-\lambda_0 x_i} u(x_i)$

- Under H_1 : $X_i \sim \text{Exp}(\lambda_1) \implies f(x_i|H_1) = \lambda_1 e^{-\lambda_1 x_i} u(x_i)$
Assumiamo che $\lambda_0 > \lambda_1$ (il che significa che la media sotto H_1 , pari a $1/\lambda_1$, è maggiore della media sotto H_0 , pari a $1/\lambda_0$).

Calcolo del Rapporto di Verosimiglianza

Le PDF condizionate congiunte sono:

$$f(x^n|H_j) = \lambda_j^n \exp\left(-\lambda_j \sum_{i=1}^n x_i\right) \quad (\forall x_i \geq 0)$$

Il rapporto di verosimiglianza è:

$$L(x^n) = \frac{f(x^n|H_1)}{f(x^n|H_0)} = \left(\frac{\lambda_1}{\lambda_0}\right)^n \exp\left((\lambda_0 - \lambda_1) \sum_{i=1}^n x_i\right) \underset{H_0}{\overset{H_1}{\geq}} \eta$$

Prendendo il logaritmo naturale:

$$n \ln\left(\frac{\lambda_1}{\lambda_0}\right) + (\lambda_0 - \lambda_1) \sum_{i=1}^n x_i \underset{H_0}{\overset{H_1}{\geq}} \ln \eta$$

Poiché $\lambda_0 > \lambda_1$, si ha $(\lambda_0 - \lambda_1) > 0$. Risolvendo per la somma delle osservazioni:

$$\sum_{i=1}^n x_i \underset{H_0}{\overset{H_1}{\geq}} \frac{\ln \eta - n \ln(\lambda_1/\lambda_0)}{\lambda_0 - \lambda_1} = \eta'$$

Caso a Singolo Campione ($n = 1$)

Il test si riduce a:

$$x \underset{H_0}{\overset{H_1}{\geq}} \eta'$$

Dato il vincolo sulla probabilità di Falso Allarme $P_{FA} = \alpha$, determiniamo la soglia η' sotto H_0 :

$$P(X > \eta'|H_0) = \int_{\eta'}^{\infty} \lambda_0 e^{-\lambda_0 x} dx = e^{-\lambda_0 \eta'} = \alpha$$

Risolvendo per η' :

$$\eta' = -\frac{1}{\lambda_0} \ln \alpha$$

La potenza del test $P_D = 1 - \beta$ (probabilità di rivelazione sotto H_1) è:

$$P_D = P(X > \eta'|H_1) = \int_{\eta'}^{\infty} \lambda_1 e^{-\lambda_1 x} dx = e^{-\lambda_1 \eta'}$$

Sostituendo η' :

$$P_D = e^{-\lambda_1 \left(-\frac{1}{\lambda_0} \ln \alpha\right)} = e^{\frac{\lambda_1}{\lambda_0} \ln \alpha} = \alpha^{\frac{\lambda_1}{\lambda_0}}$$

Considerazione sulla Potenza

Essendo $\lambda_1 < \lambda_0$, l'esponente $\frac{\lambda_1}{\lambda_0}$ è strettamente minore di 1. Per piccoli valori di Falso Allarme α (es. 10^{-3}), la potenza del test risulta significativamente superiore al valore del falso allarme (es. se $\lambda_1/\lambda_0 = 0.5$, allora $P_D = \sqrt{0.001} \approx 0.0316 \gg 0.001$).

1.2 Esempio 2: Rumore Laplaciano e Transizione della Decisione

Consideriamo un singolo campione osservato Z .

- Under H_0 : $Z = N$, dove N è un rumore laplaciano a media nulla.

$$f_Z(z|H_0) = \frac{1}{2}e^{-|z|}$$

- Under H_1 : $Z = N + 4$, ovvero c'è un segnale costante aggiunto pari a 4.

$$f_Z(z|H_1) = \frac{1}{2}e^{-|z-4|}$$

Rapporto di Verosimiglianza Logaritmico

$$\Lambda(z) = \ln \left(\frac{f_Z(z|H_1)}{f_Z(z|H_0)} \right) = |z| - |z-4|$$

Analizziamo l'andamento della funzione $\Lambda(z)$ suddividendo l'asse reale in tre regioni:

1. Per $z < 0$:

$$|z| = -z, \quad |z-4| = -(z-4) = 4-z \implies \Lambda(z) = -z - (4-z) = -4$$

2. Per $z > 4$:


$$|z| = z, \quad |z-4| = z-4 \implies \Lambda(z) = z - (z-4) = 4$$

3. Per $0 \leq z \leq 4$:

$$|z| = z, \quad |z-4| = 4-z \implies \Lambda(z) = z - (4-z) = 2z-4$$

Rappresentazione analitica della statistica di test $\Lambda(z)$:

$$\Lambda(z) = \begin{cases} -4 & z < 0 \\ 2z-4 & 0 \leq z \leq 4 \\ 4 & z > 4 \end{cases}$$



La decisione ottima Bayesiana confronta $\Lambda(z)$ con la soglia $\eta = \ln\left(\frac{\pi_0}{\pi_1}\right)$.

Analisi dei Regimi della Soglia

- **Soglia Elevata ($\eta > 4$):**
Poiché il valore massimo di $\Lambda(z)$ è 4, se la soglia η è maggiore di 4, la condizione $\Lambda(z) > \eta$ non può mai essere soddisfatta. Decideremo **sempre** H_0 .
Ciò si verifica quando:

$$\ln\left(\frac{\pi_0}{\pi_1}\right) > 4 \implies \frac{1 - \pi_1}{\pi_1} > e^4 \implies \pi_1 < \frac{1}{1 + e^4} \approx 0.018$$

Trappola da evitare

Se la probabilità a priori del segnale è estremamente bassa ($\pi_1 < 1.8\%$), il sistema rigetterà sempre la presenza del segnale, ritenendo qualsiasi osservazione (anche superiore a 4) come una fluttuazione anomala del rumore laplaciano sotto H_0 .

- **Ipotesi Equiprobabili ($\pi_0 = \pi_1 = 1/2 \implies \eta = 0$):**
Il test si riduce a:

$$\Lambda(z) \underset{H_0}{\overset{H_1}{>}} 0 \implies 2z - 4 \underset{H_0}{\overset{H_1}{>}} 0 \implies z \underset{H_0}{\overset{H_1}{>}} 2$$

La soglia ottima è il punto medio geometrico $z = 2$.

- **Caso di Soglia Asimmetrica ($z_{\text{soglia}} = 1$):**
Se volessimo impostare la soglia di decisione a $z = 1$, all'interno dell'intervallo lineare $[0, 4]$:

$$\Lambda(z) > \eta \implies 2z - 4 > \eta \implies z > \frac{\eta + 4}{2}$$

Uguagliando la soglia a 1:

$$\frac{\eta + 4}{2} = 1 \implies \eta = -2 \implies \ln\left(\frac{\pi_0}{1 - \pi_0}\right) = -2 \implies \pi_0 = \frac{1}{1 + e^2} \approx 0.12$$

Dunque, la soglia ottima si sposta a $z = 1$ solo se la probabilità a priori dello stato di quiete H_0 è molto bassa ($\approx 12\%$), rendendo a priori molto probabile lo stato di perturbazione H_1 .

2. Introduzione alla Teoria della Stima Bayesiana

Essenza

Nella **stima parametrica**, lo stato della natura è descritto da una variabile continua $\theta \in \Theta$.

L'obiettivo è costruire una funzione delle sole osservazioni, detta **stimatore** $\hat{\theta}(x^n)$, che approssimi il valore reale di θ .

Nell'**approccio Bayesiano**, il parametro ignoto θ è modellato come una **variabile aleatoria continua** dotata di una densità di probabilità a priori nota $f_{\theta}(\theta)$.

2.1 Teorema di Bayes e Densità A Posteriori

Dato il vettore di osservazioni x^n , la verosimiglianza dei dati è descritta dalla PDF condizionata $f(x^n|\theta)$.

La densità di probabilità a posteriori del parametro θ date le osservazioni è:

$$f(\theta|x^n) = \frac{f(x^n|\theta)f_{\theta}(\theta)}{f(x^n)} = \frac{f(x^n|\theta)f_{\theta}(\theta)}{\int_{-\infty}^{\infty} f(x^n|\theta)f_{\theta}(\theta)d\theta}$$

2.2 Stimatore MMSE (Minimum Mean Square Error)

Lo stimatore a minimo errore quadratico medio (MMSE) punta a minimizzare il **Rischio Medio Bayesiano** calcolato rispetto a una funzione di costo quadratica:

$$C(\theta - \hat{\theta}) = (\theta - \hat{\theta})^2 \implies R_B = E[(\theta - \hat{\theta}(X^n))^2]$$

Derivazione dell'Ottimalità dello Stimatore MMSE

Esprimiamo il valore atteso sdoppiandolo mediante la proprietà del valore atteso condizionato:

$$E[(\theta - \hat{\theta}(X^n))^2] = E_X[E_{\theta|X}[(\theta - \hat{\theta}(X^n))^2|X^n]]$$

Poiché la PDF esterna $f(x^n)$ è non-negativa, per minimizzare l'intero valore atteso è sufficiente minimizzare l'integrale interno (rispetto a θ) per ogni singola realizzazione osservata x^n :

$$g(\hat{\theta}) = E_{\theta|X}[(\theta - \hat{\theta})^2|x^n] = E[\theta^2|x^n] - 2\hat{\theta}E[\theta|x^n] + \hat{\theta}^2$$

Derivando la funzione rispetto alla decisione $\hat{\theta}$ e ponendo la derivata pari a zero:

$$\frac{dg(\hat{\theta})}{d\hat{\theta}} = -2E[\theta|x^n] + 2\hat{\theta} = 0 \implies \hat{\theta}_{MMSE}(x^n) = E[\theta|X^n = x^n]$$

Teorema Fondamentale

Lo stimatore a minimo errore quadratico medio (MMSE) coincide sempre con la **media condizionata** della distribuzione a posteriori del parametro date le osservazioni.

Geometricamente rappresenta la proiezione ortogonale (regressione) di θ sullo spazio generato dalle osservazioni.

Lezione 19 — Stimatore MAP, Esempio Completo (Sorgente Binaria) e Proprietà degli Stimatori

1. Stimatore MAP (Maximum A Posteriori) per Variabili Continue

Essenza

Nello stimare un parametro continuo θ , non possiamo definire la probabilità di commettere un errore esatto $P(\hat{\theta} \neq \theta)$, poiché essa è sempre pari a 1. Possiamo invece definire una funzione di costo uniforme "hit-or-miss" su una tolleranza $\epsilon \rightarrow 0$:

$$C(\theta - \hat{\theta}) = \begin{cases} 0 & |\theta - \hat{\theta}| \leq \epsilon/2 \\ 1 & |\theta - \hat{\theta}| > \epsilon/2 \end{cases}$$

Il rischio Bayesiano associato è la probabilità che lo stimatore disti da θ più di $\epsilon/2$:

$$R_B = P(|\theta - \hat{\theta}(X^n)| > \frac{\epsilon}{2}) = 1 - \int_{\theta - \epsilon/2}^{\theta + \epsilon/2} f(\theta|x^n) d\theta$$

Per massimizzare l'integrale a destra quando la tolleranza $\epsilon \rightarrow 0$, dobbiamo posizionare l'intervallo attorno al punto di massimo (la moda) della densità a posteriori:

$$\hat{\theta}_{MAP}(x^n) = \arg \max_{\theta} f(\theta|x^n)$$

Applicando il Teorema di Bayes e ignorando il denominatore $f(x^n)$ (che non dipende da θ):

$$\hat{\theta}_{MAP}(x^n) = \arg \max_{\theta} [f(x^n|\theta)f_{\theta}(\theta)]$$

Spesso si preferisce massimizzare la funzione di log-verosimiglianza a posteriori (monotona):

$$\hat{\theta}_{MAP}(x^n) = \arg \max_{\theta} [\ln f(x^n|\theta) + \ln f_{\theta}(\theta)]$$

2. Caso di Studio: Stima del Parametro di una Sorgente Binaria I.I.D.

Setup del Problema

- **Osservazioni:** stringa binaria x^n con peso di Hamming w_H (numero di 1 su n bit).
- **Parametro ignoto:** $\theta \in [0, 1]$, la probabilità che la sorgente generi 1.
- **Prior:** distribuzione uniforme sul dominio del parametro:

$$f_{\theta}(\theta) = 1 \cdot u(\theta)u(1 - \theta)$$

- **Verosimiglianza (Bernoulli I.I.D.):**

$$P(x^n|\theta) = \theta^{w_H} (1 - \theta)^{n - w_H}$$

2.1 Calcolo della Densità A Posteriori

La densità condizionata a posteriori è:

$$f(\theta|x^n) = \frac{P(x^n|\theta)f_{\theta}(\theta)}{\int_0^1 P(x^n|\theta)f_{\theta}(\theta)d\theta} = \frac{\theta^{w_H}(1 - \theta)^{n - w_H}}{\int_0^1 \theta^{w_H}(1 - \theta)^{n - w_H}d\theta}$$

Per risolvere l'integrale a denominatore, utilizziamo la **funzione speciale Beta**:

$$B(a, b) = \int_0^1 t^{a-1} (1-t)^{b-1} dt = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)}$$

Nel nostro caso poniamo $a - 1 = w_H \implies a = w_H + 1$, e $b - 1 = n - w_H \implies b = n - w_H + 1$. Poiché gli argomenti sono interi, possiamo esprimere la funzione Gamma tramite i fattoriali ($\Gamma(k) = (k-1)!$):

$$\int_0^1 \theta^{w_H} (1-\theta)^{n-w_H} d\theta = \frac{w_H! (n-w_H)!}{(n+1)!} = \frac{1}{(n+1) \binom{n}{w_H}}$$

La PDF a posteriori risulta quindi essere una densità Beta di parametri $(w_H + 1, n - w_H + 1)$:

$$f(\theta|x^n) = (n+1) \binom{n}{w_H} \theta^{w_H} (1-\theta)^{n-w_H} \quad (\forall \theta \in [0, 1])$$

2.2 Derivazione dello Stimatore MMSE

Lo stimatore MMSE è la media condizionata a posteriori:

$$\hat{\theta}_{\text{MMSE}}(x^n) = E[\theta|x^n] = \int_0^1 \theta f(\theta|x^n) d\theta$$

$$E[\theta|x^n] = (n+1) \binom{n}{w_H} \int_0^1 \theta^{w_H+1} (1-\theta)^{n-w_H} d\theta$$

Risolvendo il nuovo integrale Beta con parametri $a = w_H + 2$ e $b = n - w_H + 1$:

$$\int_0^1 \theta^{w_H+1} (1-\theta)^{n-w_H} d\theta = \frac{(w_H+1)!(n-w_H)!}{(n+2)!}$$

Sostituendo e semplificando i fattoriali:

$$\hat{\theta}_{\text{MMSE}}(x^n) = \frac{(n+1)!}{w_H! (n-w_H)!} \cdot \frac{(w_H+1)!(n-w_H)!}{(n+2)!} = \frac{w_H+1}{n+2}$$

Regola di Successione di Laplace

Lo stimatore MMSE aggiunge un'operazione di regolarizzazione (o "smoothing") virtuale, sommando fittiziamente un successo e un fallimento alle osservazioni. Evita stime estreme (0 o 1) in presenza di campioni ridotti.

2.3 Derivazione dello Stimatore MAP

Dobbiamo massimizzare la verosimiglianza a posteriori (essendo il prior uniforme):

$$\hat{\theta}_{\text{MAP}}(x^n) = \arg \max_{\theta} [\theta^{w_H} (1-\theta)^{n-w_H}]$$

Prendendo il logaritmo:

$$g(\theta) = w_H \ln \theta + (n - w_H) \ln(1 - \theta)$$

Derivando rispetto a θ e uguagliando a zero:

$$\frac{dg(\theta)}{d\theta} = \frac{w_H}{\theta} - \frac{n - w_H}{1 - \theta} = 0 \implies w_H(1 - \theta) = (n - w_H)\theta \implies \hat{\theta}_{\text{MAP}}(x^n) = \frac{w_H}{n}$$

Risultato

Lo stimatore MAP coincide esattamente con la **frequenza relativa** (la proporzione empirica di successi osservati).

3. Proprietà delle Prestazioni degli Stimatori

Per valutare la bontà di uno stimatore, analizziamo il comportamento statistico dell'errore $\hat{\theta}(X^n) - \theta$ al variare delle realizzazioni dei dati per un dato parametro reale θ (analisi condizionata a θ).

3.1 Polarizzazione (Bias)

Definizione

La **polarizzazione (o bias)** di uno stimatore indica lo scostamento sistematico del valore atteso dello stimatore dal valore reale del parametro:

$$B(\theta) = E[\hat{\theta}(X^n)|\theta] - \theta$$

- Se $B(\theta) = 0$ per ogni θ , lo stimatore si dice **non polarizzato** (o corretto / unbiased).
- Se $\lim_{n \rightarrow \infty} B(\theta) = 0$, lo stimatore si dice **asintoticamente non polarizzato**.

Sotto il vero parametro θ , il peso di Hamming w_H è una variabile binomiale di parametri n e θ , per cui il suo valore atteso è $E[w_H|\theta] = n\theta$.

Verifica del Bias per MAP

$$E[\hat{\theta}_{\text{MAP}}|\theta] = E\left[\frac{w_H}{n}|\theta\right] = \frac{n\theta}{n} = \theta$$

Lo stimatore MAP è **non polarizzato** (unbiased).

Verifica del Bias per MMSE

$$E[\hat{\theta}_{\text{MMSE}}|\theta] = E\left[\frac{w_H + 1}{n + 2}|\theta\right] = \frac{n\theta + 1}{n + 2} \neq \theta$$

Lo stimatore MMSE è **polarizzato** (biased). Tuttavia:

$$\lim_{n \rightarrow \infty} E[\hat{\theta}_{\text{MMSE}}|\theta] = \lim_{n \rightarrow \infty} \frac{n\theta + 1}{n + 2} = \theta$$

Lo stimatore MMSE è **asintoticamente non polarizzato**.

3.2 Consistenza

Definizione

Uno stimatore si dice **consistente in media quadratica** se l'errore quadratico medio (MSE) tende a zero al tendere all'infinito del numero di osservazioni:

$$\lim_{n \rightarrow \infty} E[(\hat{\theta}_n - \theta)^2 | \theta] = 0$$

Per la disuguaglianza di Chebyshev, la consistenza in media quadratica implica la **consistenza in probabilità** (consistenza debole):

$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| > \epsilon | \theta) = 0$$

Calcolo delle prestazioni medie (Errore Quadratico Medio)

Calcoliamo l'MSE medio integrando rispetto alla distribuzione uniforme del parametro $\theta \sim U[0, 1]$:

- **Per lo stimatore MAP:**

$$E[(\hat{\theta}_{\text{MAP}} - \theta)^2 | \theta] = \text{Var}\left(\frac{w_H}{n} \middle| \theta\right) = \frac{\theta(1 - \theta)}{n}$$

Calcolando l'MSE medio globale integrando sul prior:

$$E[(\hat{\theta}_{\text{MAP}} - \theta)^2] = \int_0^1 \frac{\theta(1 - \theta)}{n} d\theta = \frac{1}{n} \left[\frac{\theta^2}{2} - \frac{\theta^3}{3} \right]_0^1 = \frac{1}{6n}$$

- **Per lo stimatore MMSE:**

$$E[(\hat{\theta}_{\text{MMSE}} - \theta)^2] = \frac{1}{6(n + 2)}$$

Confronto e Ottimalità

Poiché lo stimatore MMSE è progettato per minimizzare l'errore quadratico medio calcolato sulla PDF congiunta, si ha:

$$E[(\hat{\theta}_{\text{MMSE}} - \theta)^2] = \frac{1}{6(n + 2)} < \frac{1}{6n} = E[(\hat{\theta}_{\text{MAP}} - \theta)^2]$$

Per ogni valore finito di n , lo stimatore MMSE garantisce sempre un errore quadratico medio inferiore rispetto allo stimatore MAP. Entrambi gli stimatori sono comunque **consistenti**, poiché l'errore decade a zero come $O(1/n)$.