Metodi Statistici dell' Informazione

00 - Obsidian Notes/2° Anno/2° Semestre/Metodi Statistici dell' Informazione/Lezione 0.md
00 - Obsidian Notes/2° Anno/2° Semestre/Metodi Statistici dell' Informazione/Lezione 1.md
00 - Obsidian Notes/2° Anno/2° Semestre/Metodi Statistici dell' Informazione/Lezione 3.md
00 - Obsidian Notes/2° Anno/2° Semestre/Metodi Statistici dell' Informazione/Lezione 4.md
00 - Obsidian Notes/2° Anno/2° Semestre/Metodi Statistici dell' Informazione/Lezione 5.md
00 - Obsidian Notes/2° Anno/2° Semestre/Metodi Statistici dell' Informazione/Lezione 2.md
00 - Obsidian Notes/2° Anno/2° Semestre/Metodi Statistici dell' Informazione/Lezione 6.md
00 - Obsidian Notes/2° Anno/2° Semestre/Metodi Statistici dell' Informazione/Lezione 7.md

00 - Obsidian Notes/2° Anno/2° Semestre/Metodi Statistici dell' Informazione/Lezione 0.md

MSI — Lezione 0: Introduzione, Spazio dei Campioni e Analisi Combinatoria

Docente: Prof. Marco Lops (Telecomunicazioni) | **CFU:** 6 | **Corso:** Metodi Statistici per l'Informazione

Orario

- **Martedì** 14:00–16:00
- **Giovedì** 8:45–10:45
- Ricevimento: orari ufficiali + disponibile su Teams per appuntamenti di gruppo
- Materiale (slide + lavagne PDF) sul canale **Teams** del corso

Nota logistica

Nella prima settimana di maggio il prof sarà all'estero per ricerca → lezione da remoto o recupero.

📚 Testi di riferimento

Argomento	Testo
Teoria della probabilità	Ernesto Conte, *Fenomeni aleatori* — molto didattico, richiede una guida (quella del corso)

Argomento	Testo
Statistica inferenziale	Sheldon Ross, *Introduction to Probability and Statistics for Engineers and Scientists*

📝 Esame

Modalità d'esame

- **Prova scritta + colloquio orale**
- 6 CFU, nessun progetto

Perché la Probabilità per l'Informatica?

Idea chiave del corso

Telecomunicazioni e informatica trattano entrambe lo stesso oggetto: l'**informazione**. Le telecomunicazioni la trasferiscono *nello spazio* (da un luogo a un altro); l'informatica la trasferisce *nel tempo* (memorizzazione, compressione, correzione degli errori).

Intrinseco nel concetto di informazione c'è l'**incertezza**: se non c'è incertezza su ciò che viene trasmesso, non c'è informazione da trasmettere.

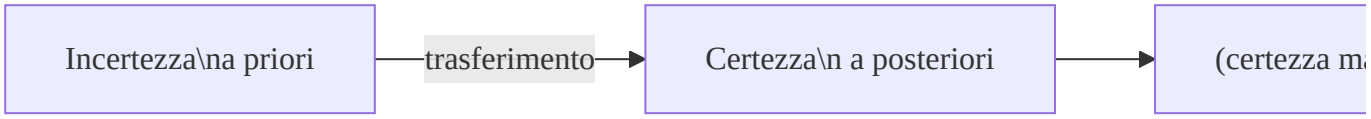

La **probabilità** è lo strumento formale per modellare l'incertezza. Tutto ciò che va sotto il nome di *machine learning*, *statistical learning*, *deep learning*, reti neurali — è costruito su questa base.

Citazione del prof

"Mettetevi in testa: se vi parlano di statistica dicendo che è un'altra cosa rispetto alla probabilità, vuol dire che non conoscono la probabilità. La probabilità è la base su cui si costruisce tutto il mondo della statistica."

Programma del Corso

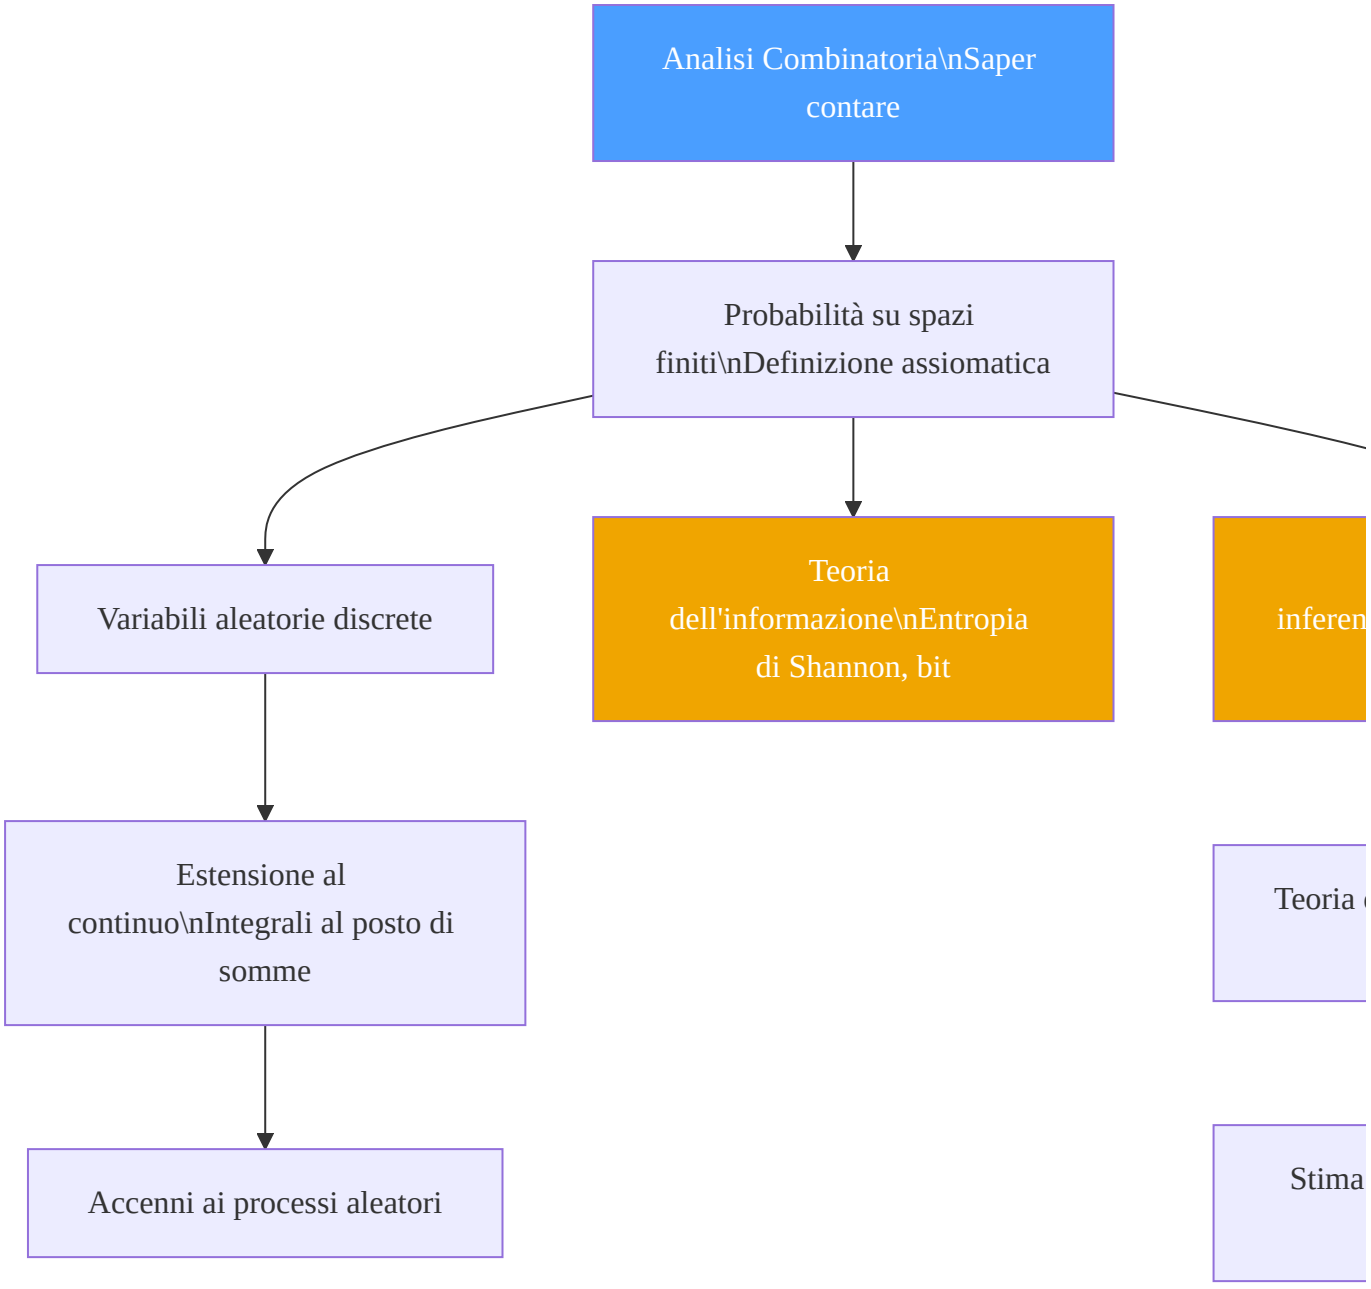

Cherry picking

Essendo un corso da 6 CFU (vs 9 CFU del corso parallelo al 3° anno), alcuni argomenti come la compressione dati (Huffman, codifica aritmetica) e le passeggiate casuali su grafi non saranno trattati in dettaglio. Priorità: **meno argomenti, ma compresi bene**.

Statistica inferenziale vs descrittiva

Tipo	Cosa fa	Importanza
Descrittiva	Calcola statistiche globali su una popolazione data	Limitata ("giocare con Excel")
Inferenziale	Da un campione, inferisce le caratteristiche di tutti i campioni futuri statisticamente omogenei	Alta — base del machine learning

Esempio di inferenza

Progettare un algoritmo di ML: non si vuole un sistema che funzioni solo sul campione di training, ma uno che generalizzi a qualunque campione con gli stessi parametri statistici.

Basi di Teoria della Probabilità

Il Discreto vs il Continuo

Aforisma del prof

"Il discreto riempie la testa di idee; il continuo riempie la lavagna di formule. Se uno capisce bene le idee, le formule sono una conseguenza."

Definizioni Fondamentali

Esperimento

Definizione

Un **esperimento** è un'operazione (o insieme di operazioni) che conduce a **uno tra tanti risultati possibili**.

Spazio dei Campioni Ω

Definizione

Lo **spazio dei campioni** (o *sample space*) è l'insieme di **tutti i possibili risultati** di un esperimento. Si indica con Ω.

$$\Omega = \{\omega_1, \omega_2, \dots\}$$

Può essere:

- **Finito** $\rightarrow$ es. lancio di una moneta: $\Omega = \{T, C\}$
- **Numerabilmente infinito** $\rightarrow$ es. numero di pacchetti in coda: $\Omega = N_0$
- **Non numerabile (continuo)** $\rightarrow$ es. tensione misurata ai capi di una resistenza (rumore termico): $\Omega = R$

Discreto vs Continuo nella pratica

In realtà qualunque misura fisica è razionale (strumenti con cifre significative finite), ma quando i valori sono così tanti, si modella come continuo e poi si tronca. Il **tempo** viene solitamente schematizzato come continuo.

Evento

Definizione

Un **evento** è un **sottoinsieme** di Ω definito da una proposizione.
Un **evento elementare** è un singolo elemento di Ω.

La proposizione non è unica!

L'evento è univocamente determinato dagli elementi di Ω che lo compongono, ma la proposizione che lo descrive **non è univoca** (la ridondanza del linguaggio naturale lo permette).

Esempio: ho in tasca 1, 2, 3, 4 o 5 euro. L'evento $\{1, 3, 5\}$ può essere descritto come:

- "ho un numero dispari di euro"
- "non ho un numero pari di euro"

$$> -"\text{ho1o3o5euro}"$$

→ Saper **riformulare** la proposizione in modo conveniente è spesso la chiave per risolvere un esercizio.

Nomenclatura degli eventi

Nome	Definizione	Notazione
Evento certo	Ω stesso — ogni volta che compie l'esperimento si ottiene un elemento di Ω	Ω
Evento impossibile	Insieme vuoto	$\varnothing$
Evento complementare	A^c = elementi di Ω non in A	A^c o $\bar{A}$
Eventi incompatibili	$A \cap B = \varnothing$	—
A **implica** B	$A \subseteq B$ — il verificarsi di A implica il verificarsi di B (non viceversa)	$A \subseteq B$

Esempio — dado

A = "esce 2", B = "esce un numero pari"
$\rightarrow$ $A \subseteq B$: se esce 2, certamente è uscito un pari. Ma se esce un pari, non è detto che sia 2 (potrebbe essere 4 o 6).

Operazioni sugli Insiemi / Eventi

Riassunto operazioni

$$A_1 \cup A_2 = \{\omega \in \Omega \mid \omega \in A_1 \text{ oppure } \omega \in A_2\}$$

$$A_1 \cap A_2 = \{\omega \in \Omega \mid \omega \in A_1 \text{ e } \omega \in A_2\}$$

$$A_1^c = \{\omega \in \Omega \mid \omega \notin A_1\}$$

$$A_1 \setminus A_2 = A_1 \cap A_2^c$$

Proprietà utili

Proprietà	Formula
Doppio complemento	$(A\text{^}c)^c = A$
Complemento di Ω	$\Omega^c = \varnothing$
Unione con complementare	$A \cup \$A^c = \backslash Omega\$$
De Morgan	$(A \cup B)^c = A^c \cap B^c$
De Morgan	$(A \cap B)^c = A^c \cup B^c$

Approccio Frequentistico alla Probabilità

Frequenza di successo

Definizione

Dati n esperimenti **indipendenti** (l'esito di uno non influenza gli altri), si definisce **frequenza di successo** dell'evento A su n prove:

$$f_n(A) = \frac{N_A}{n}$$

dove N_A è il numero di volte in cui si è verificato A.

Per un dado **onesto** (eventi elementari equiprobabili):

$$\lim_{n \to \infty} f_n(A) = \frac{|A|}{|\Omega|}$$

⚠ Il cane che si morde la coda

La definizione frequentistica usa implicitamente il concetto di **indipendenza** — che è esso stesso un concetto probabilistico. È una definizione un po' autoriflessiva: per questo il prof darà anche una definizione più rigorosa (assiomatica).

Verifica dell'onestà di un dado

Lancio n volte, conto N_1, N_2, \ldots, N_6. $Ildadoè(probabilmente)onestose: \frac{N_i}{n} \approx \frac{1}{6} \quad \forall i$
Non è una condizione *sufficiente* (i singoli potrebbero compensarsi), ma è *necessaria*.

Analisi Combinatoria

Perché?

Quando lo spazio dei campioni è **finito** e gli eventi sono **equiprobabili**:

$$P(A) = \frac{|A|}{|\Omega|}$$

Calcolare probabilità significa **saper contare** $|A|$ e $|\Omega|$ in modo efficiente.

Regola del Prodotto Cartesiano

Dati k insiemi A_1, A_2, \ldots, A*k$ con* $|A_i| = n_i$:
*$$|A_1 \times A_2 \times \cdots \times A_k| = \prod*{i=1}^{k} n_i$$
Questa è la **formula base** da cui derivano tutti i risultati di analisi combinatoria.

---

k-uple ordinate da n elementi

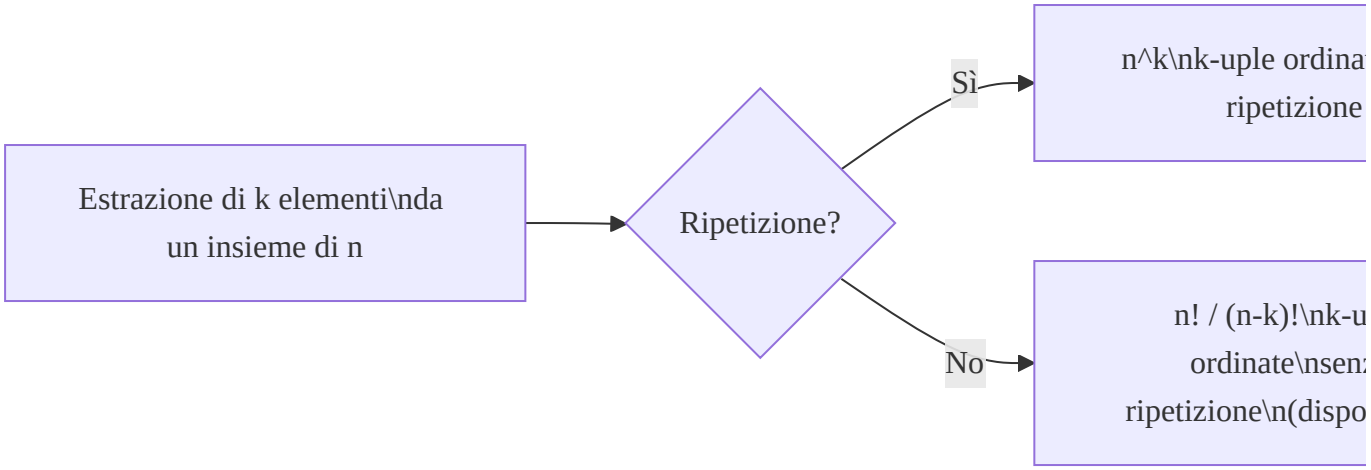

Con ripetizione ammessa

Il primo elemento si sceglie in n modi, il secondo in n modi, ..., il k-esimo in n modi:

$$\text{k-uple ordinate con ripetizione} = n^k$$

Sequenze binarie

Stringhe binarie di lunghezza n: 2^n

Senza ripetizione (disposizioni)

Il primo in n modi, il secondo in $n - 1$, ..., il k-esimo in $n - k + 1$:

$$D(n, k) = n \cdot (n - 1) \cdots (n - k + 1) = \frac{n!}{(n - k)!}$$

Permutazioni ($k = n$)

$$P(n) = n!$$

Le permutazioni di n elementi sono tutte le n-uple ordinate senza ripetizione degli n elementi stessi.

---

k-uple non ordinate (Combinazioni)

Due k-uple che differiscono **solo per l'ordine** degli elementi sono considerate la **stessa** combinazione.

Ragionamento chiave

Tra tutte le k-uple ordinate senza ripetizione, ogni gruppo di $k!$ di esse (tutte le permutazioni degli stessi elementi) collassa in **un'unica** k-upla non ordinata. Quindi:

$$C(n,k) = \binom{n}{k} = \frac{n!}{k!(n-k)!}$$

Questo è il **coefficiente binomiale**.

Riepilogo formule

Tipo	Formula	Nome
k-uple ordinate **con** ripetizione	n^k	—
k-uple ordinate **senza** ripetizione	$\frac{n!}{(n-k)!}$	Disposizioni semplici
k-uple ordinate, $k = n$, senza ripetizione	$n!$	Permutazioni
k-uple **non** ordinate senza ripetizione	$\binom{n}{k} = \frac{n!}{k!(n-k)!}$	Combinazioni / Coeff. binomiale

Trucco mnemonico

Partendo dalle disposizioni $\frac{n!}{(n-k)!}$:

- vuoi le **non ordinate**? dividi per $k!$ (le permutazioni interne alla k-upla)
- vuoi **con ripetizione**? ogni estrazione riparte da $n \to n^k$

Applicazione: Cardinalità dell'Insieme delle Parti

Teorema

Dato un insieme A con m elementi, l'**insieme delle parti** $P(A)$ (l'insieme di tutti i sottoinsiemi di A, inclusi $\emptyset$ e A stesso) ha cardinalità:

$$|P(A)| = 2^m$$

Dimostrazione combinatoria:

I sottoinsiemi di A di cardinalità k sono esattamente le k-uple non ordinate senza ripetizione, cioè $\binom{m}{k}$. Sommando su tutti i possibili k:

$$|P(A)| = \sum_{k=0}^{m} \binom{m}{k} = \sum_{k=0}^{m} \binom{m}{k} 1^k \cdot 1^{m-k} = (1+1)^m = 2^m$$

L'ultima uguaglianza è il **Binomio di Newton**:

$$\boxed{(a+b)^m = \sum_{k=0}^{m} \binom{m}{k} a^k b^{m-k}}$$

Esempio guidato: Probabilità al poker

Mazzo francese da 52 carte, si estraggono 5 carte.

$$|\Omega| = \binom{52}{5} = \frac{52!}{5! \cdot 47!}$$

Probabilità di "colore" (flush): tutte e 5 le carte dello stesso seme (es. tutte cuori). Ci sono 13 carte per seme:

$$|A_{\text{colore}}| = 4 \cdot \binom{13}{5}$$

$$P(\text{colore}) = \frac{4 \cdot \binom{13}{5}}{\binom{52}{5}}$$

La prossima lezione

Faremo esercizi completi di analisi combinatoria (poker, blackjack, ecc.) prima di procedere alla definizione assiomatica formale della probabilità.

Curiosità: La Martingala

Perché i casinò hanno un limite di puntata?

La **Martingala** è una strategia alla roulette: raddoppia la puntata ad ogni perdita. Si può dimostrare che:

- Con **patrimonio infinito** e **nessun limite** di puntata → si vince sempre (con probabilità 1)
- Con qualunque limite di puntata, per quanto alto ma **finito** → si perde

Il limite di puntata esiste proprio per questo motivo.

Prossimi argomenti

- [ ] Ripasso completo analisi combinatoria con esercizi
- [ ] Definizione assiomatica (Kolmogorov) della probabilità

- [ ] Probabilità condizionata e indipendenza
- [ ] Variabili aleatorie discrete

Tags

#probabilità #MSI #spazio-campioni #eventi #analisi-combinatoria #combinazioni #permutazioni #coefficiente-binomiale

00 - Obsidian Notes/2° Anno/2° Semestre/Metodi Statistici dell' Informazione/Lezione 1.md

MSI — Lezione 1: Probabilità Frequentistica e Proprietà Fondamentali

Docente: Prof. Marco Lops | **Corso:** Metodi Statistici per l'Informazione | **CFU:** 6

Argomenti trattati

- Completamento esercizi di analisi combinatoria (cinquine da poker)
- Sequenze binarie con esattamente k uni: coefficiente multinomiale
- Definizione frequentistica di probabilità
- Critica e vantaggi dell'approccio frequentistico
- Proprietà della probabilità derivate dalla frequenza (senza assiomi)
- Evento complementare, subadditività, evento $A \setminus B$
- Probabilità condizionata: definizione e intuizione sul database
- Indipendenza stocastica

Completamento: Analisi Combinatoria sul Poker

Mazzo da poker francese: 32 carte (7, 8, 9, 10, J, Q, K, A in 4 semi = 8 valori × 4 semi).

Lo spazio dei campioni ha cardinalità:

$$|\Omega| = \binom{32}{5} = \frac{32!}{5! \cdot 27!} = 201.376$$

L'ordinamento non conta nel poker

Una mano di poker è un sottoinsieme non ordinato: avere A♠ K♥ Q♦ J♣ 10♠ o K♥ A♠ Q♦ J♣ 10♠ è la stessa mano. Si usano sempre i coefficienti binomiali, non le disposizioni.

Cinquine con esattamente due assi

$$|C_2| = \underbrace{\binom{4}{2}}_{\text{scegli 2 assi tra 4}} \cdot \underbrace{\binom{28}{3}}_{\text{scegli 3 carte non-asso tra 28}} = 6 \cdot 3276 = 69.184$$

$$P(2 \text{ assi}) = \frac{69.184}{201.376} \approx 0{,}097 \approx 9{,}7\%$$

Nota: questo include doppie coppie e full (tre tra le altre carte uguali). Se si vuole solo la coppia d'assi come punteggio massimo:

$$|C_{\text{coppia assi}}| = \binom{4}{2} \cdot 28 \cdot \frac{24 \cdot 20}{3!} \quad \Rightarrow \quad P \approx 6{,}3\%$$

Almeno tre assi

$$|C_{\geq 3}| = \underbrace{\binom{4}{3} \cdot \binom{28}{2}}_{\text{tre assi}} + \underbrace{\binom{4}{4} \cdot 28}_{\text{quattro assi}} = 4 \cdot 378 + 28 = 1.540$$

$$P(\geq 3 \text{ assi}) = \frac{1.540}{201.376} \approx 0{,}76\%$$

Tris di un valore specifico (es. tre 7, senza full né poker)

$$|C_{3\text{sette}}| = \binom{4}{3} \cdot 28 \cdot \frac{24}{2} = 4 \cdot 28 \cdot 12 = 1.344$$

$$P(\text{tris qualsiasi}) = 8 \cdot \frac{1.344}{201.376} \approx 5{,}3\%$$

Colore di picche

$$|C_{\text{picche}}| = \binom{8}{5} = 56 \quad \Rightarrow \quad P(\text{colore picche}) = \frac{56}{201.376} \approx 0{,}11\%$$

$$P(\text{colore qualsiasi}) = 4 \cdot \frac{56}{201.376} \approx 0{,}44\%$$

Sequenze Binarie con Esattamente k Uni

Domanda: data una sequenza di n bit, quante sequenze hanno esattamente k uni?

Ragionamento senza formula:

Se tutti i bit fossero distinti, ci sarebbero $n!$ permutazioni. Ma nella nostra sequenza ci sono k uni (indistinguibili tra loro) e $n - k$ zeri (indistinguibili tra loro). Le $k!$ permutazioni degli uni tra di loro danno la stessa sequenza, e lo stesso vale per le $(n - k)!$ permutazioni degli zeri.

$$\boxed{|\{x \in \{0,1\}^n : |x|_1 = k\}| = \frac{n!}{k! \cdot (n-k)!} = \binom{n}{k}}$$

Generalizzazione al caso m**-ario:** data una sequenza di lunghezza n su un alfabeto di m simboli, con n_i occorrenze del simbolo i (con $\sum_i n_i = n$), il numero di sequenze distinte è il **coefficiente multinomiale**:

$$\binom{n}{n_1, n_2, \dots, n_m} = \frac{n!}{n_1! \cdot n_2! \cdots n_m!}$$

Applicazione in teoria dell'informazione

Questi conteggi sono fondamentali per il codice universale a lunghezza fissa: determinare quanti messaggi di lunghezza n contengono esattamente k simboli di un certo tipo è la base per calcolare la capacità di un canale.

Definizione Frequentistica di Probabilità

Sia Ω uno spazio dei campioni discreto (finito o numerabile). Si eseguono n prove indipendenti dello stesso esperimento.

Definizione: Frequenza di successo

$$f_n(A) = \frac{N_A}{n}$$

dove N_A è il numero di volte in cui l'evento A si verifica su n prove.

Definizione frequentistica: Probabilità

$$P(A) \overset{\text{def}}{=} \lim_{n \to \infty} f_n(A) = \lim_{n \to \infty} \frac{N_A}{n}$$

Perché questa definizione è intuitiva ma imprecisa

Questa definizione è matematicamente "zoppicante" per due motivi:

1. Il limite non esiste sempre — le prove devono essere **indipendenti** (o il processo deve essere ergodico) perché la sequenza $f_n(A)$ converga. Con prove indipendenti la convergenza è **forte** (quasi certamente e in media quadratica).

2. Non si specifica il tipo di convergenza. Verrà precisato nel seguito del corso.

Nonostante ciò, l'approccio frequentistico è preferito da questo docente per una ragione pratica: **rende le proprietà della probabilità intuitive**, derivandole direttamente dalle proprietà degli insiemi, senza bisogno di assiomi astratti da dimostrare separatamente.

> **Quote**
>
> "Io do le carte napoletane, mi ha giocato a scopone, ho dieci carri per uno, poi la probabilità che gli do i sette carri... Con l'approccio teorico la gente cominciava a ragionare in percentuali assurde. Con quello frequentistico si ragiona automaticamente nel modo giusto."

La probabilità come misura

La probabilità è un **modo diverso di misurare gli elementi di un insieme**. Ordinariamente, in un insieme discreto, ogni elemento "pesa" $\frac{1}{|\Omega|}$. Con la probabilità, alcuni elementi possono pesare molto più di altri.

> **L'ape e la pianta**
>
> Immagina un'aula di 50 m². Ogni metro quadro ha misura ordinaria $\frac{1}{50}$. Se metti una pianta fiorita su un metro quadro, l'ape sarà lì con probabilità $\approx$ 0,99. Quel metro quadro ora pesa quasi 1 in termini di probabilità, anche se ha la stessa misura ordinaria degli altri 49.

Proprietà della Probabilità (derivate dalla frequenza)

Tutte le seguenti proprietà si derivano senza assiomi, solo dalle proprietà degli insiemi.

Limitazione

$$0 \leq P(A) \leq 1$$

Il numero di successi non può superare il numero di prove.

Evento complementare

$$P(A^c) = 1 - P(A)$$

Su n prove, se A si verifica N_A volte, allora A^c si verifica $n - N_A$ volte. Quindi $f_n(A^c) = 1 - f_n(A)$.

Subadditività (unione di eventi)

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Su n prove, il numero di volte in cui si verifica $A \cup B$ è $N_A + N_B - N_{A \cap B}$ (si somma, ma si sottrae l'intersezione contata due volte).

Caso speciale — eventi **disgiunti** ($A \cap B = \emptyset$):

$$P(A \cup B) = P(A) + P(B)$$

La probabilità è una misura

Proprio come la misura di due insiemi che si sovrappongono non è la somma delle misure (si conta due volte l'intersezione), la probabilità di $A \cup B$ non è la semplice somma. La probabilità è subadditiva esattamente come lo è qualsiasi misura.

Differenza di eventi

$$P(A \setminus B) = P(A) - P(A \cap B)$$

Il numero di volte in cui si verifica A ma non B è $N_A - N_{A \cap B}$.

Evento certo e impossibile

$$P(\Omega) = 1 \qquad P(\emptyset) = 0$$

L'evento certo si verifica tutte le n volte; $f_n(\Omega) = n/n = 1$.

Probabilità nulla ≠ evento impossibile

Un evento con probabilità 0 può comunque verificarsi (infinite volte, ma con frequenza che tende a 0). Esempio: se un evento si verifica $\sqrt{n}$ volte su n prove, si verifica infinite volte, ma $P = \lim_{n \to \infty} \frac{\sqrt{n}}{n} = 0$.

Si dice allora che l'evento si verifica **quasi certamente** (quasi ovunque, nel linguaggio della teoria della misura).

Dado Truccato: Esempio di Probabilità Non Equiprobabili

Supponiamo che il dado sia truccato così: il risultato 1 esce 5 volte più spesso degli altri risultati (tra loro equiprobabili).

Allora: $N_1 = 5 \cdot (N_2 + N_3 + N_4 + N_5 + N_6)/5$, da cui:

$$P(1) = \frac{5}{10} = \frac{5}{6}^{\star} \qquad P(i) = \frac{1}{30} \text{ per } i = 2, \dots, 6$$

Correzione: ricalcolo esatto

Con il dado truccato dove $N_1 = 5 \cdot N_i$ per ogni $i \neq 1$, e $\sum P = 1$:

$$5x + 5x = 1 \Rightarrow x = \frac{1}{10}, \quad P(1) = \frac{5}{10} = \frac{1}{2}, \quad P(i) = \frac{1}{10} \text{ per } i \neq 1$$

Quindi: $P(\text{pari}) = P(2) + P(4) + P(6) = 3 \cdot \frac{1}{10} = 30\%$, mentre
$P(\text{dispari}) = P(1) + P(3) + P(5) = \frac{1}{2} + \frac{1}{10} + \frac{1}{10} = 70\%$.

Morale: **quando gli eventi elementari non sono equiprobabili**, calcolare la probabilità di un evento come rapporto di cardinalità **non ha senso**. Si deve usare la definizione frequentistica o la misura di probabilità corretta.

Probabilità Condizionata

Intuizione: il database

Immagina un database con tutti i residenti in Italia, con colonne altezza, peso, colore occhi.

$P(\text{peso} \geq 70 \text{ kg})$: conto quanti pesano almeno 70 kg, divido per il totale.

$P(\text{peso} \geq 70 \text{ kg} \mid \text{altezza} \geq 170 \text{ cm})$: **restringo il database** alle sole persone alte almeno 170 cm (elimino tutti gli altri), poi conto quanti di questi pesano almeno 70 kg, divido per la dimensione del database ristretto.

$$f_n(B \mid A) = \frac{N_{A \cap B}}{N_A} = \frac{N_{A \cap B}/n}{N_A/n} = \frac{f_n(A \cap B)}{f_n(A)}$$

Passando al limite:

Definizione: Probabilità condizionata

$$P(B \mid A) = \frac{P(A \cap B)}{P(A)}, \qquad P(A) > 0$$

"La probabilità che si verifichi B, dato che si è verificato A, è il rapporto tra la probabilità che si verifichino entrambi e la probabilità di A."

Il condizionamento cambia lo spazio dei campioni: da Ω si passa a A come nuovo universo di riferimento.

Da questa definizione si ricava:

$$P(A \cap B) = P(A) \cdot P(B \mid A) = P(B) \cdot P(A \mid B)$$

Probabilità a priori vs a posteriori

La **probabilità a priori** $P(\text{peso} \geq 70 \text{ kg})$ include tutti gli italiani (bambini, donne anziane, ...). La **probabilità a posteriori** $P(\text{peso} \geq 70 \text{ kg} \mid \text{altezza} \geq 170 \text{ cm})$ è più alta: filtrando per altezza, si esclude una porzione di persone che mediamente pesano meno.

Indipendenza Stocastica

$P(\text{peso} \geq 70 \text{ kg} \mid \text{altezza} \geq 170 \text{ cm})$ è diversa da $P(\text{peso} \geq 70 \text{ kg})$: sapere l'altezza dà informazione sul peso.

Ma $P(\text{occhi chiari} \mid \text{altezza} \geq 170 \text{ cm}) = P(\text{occhi chiari})$: sapere l'altezza non dà alcuna informazione sul colore degli occhi.

Definizione: Indipendenza stocastica

Due eventi A e B sono **indipendenti** se e solo se:

$$P(B \mid A) = P(B) \quad \Longleftrightarrow \quad P(A \cap B) = P(A) \cdot P(B)$$

Il verificarsi di A non fornisce alcuna informazione sul verificarsi di B.

Dadi indipendenti

Se lancio due dadi onesti, il risultato del secondo non dipende dal primo. Quindi:

$$P(\text{primo} = 5 \text{ e secondo} = 2) = P(\text{primo} = 5) \cdot P(\text{secondo} = 2) = \frac{1}{6} \cdot \frac{1}{6} = \frac{1}{36}$$

Regola pratica: "Almeno uno" → pensare al complementare

Strategia: usare il complementare

Quando il problema chiede "almeno uno / almeno due / almeno k", conviene calcolare la probabilità del complementare ("nessuno / meno di k") e sottrarre da 1.

Esempio: probabilità di ottenere almeno un 6 lanciando un dado onesto 5 volte.

$P(\text{almeno un } 6) = 1 - P(\text{nessun } 6)$

I lanci sono **indipendenti**, quindi:

$$P(\text{nessun 6 in 5 lanci}) = \left(\frac{5}{6}\right)^5 \approx 0{,}402$$

$$P(\text{almeno un } 6) = 1 - \left(\frac{5}{6}\right)^5 \approx 0{,}598 \approx 60\%$$

Esempio classico (paradosso del compleanno): probabilità che in una classe di 30 persone ci siano almeno due con lo stesso compleanno.

$$P(\text{almeno due stessi}) = 1 - P(\text{tutti diversi}) = 1 - \prod_{k=0}^{29} \frac{365 - k}{365}$$

Il risultato è circa 70% — molto più alto di quanto l'intuizione suggerisce.

Punti chiave della lezione

- Il coefficiente binomiale $\binom{n}{k}$ conta le sequenze binarie di lunghezza n con esattamente k uni: si deriva solo dal ragionamento sulle permutazioni degli indistinguibili.
- La probabilità frequentistica $P(A) = \lim_{n \to \infty} N_A / n$ è intuitiva e permette di derivare tutte le proprietà dalle operazioni sugli insiemi.
- Quando gli eventi elementari non sono equiprobabili, non si può usare il rapporto di cardinalità.
- La probabilità è una **misura**: subadditiva per l'unione, additiva per eventi disgiunti.
- La probabilità condizionata $P(B \mid A) = P(A \cap B) / P(A)$ corrisponde al restringimento dello spazio dei campioni ad A.
- Due eventi sono indipendenti se $P(A \cap B) = P(A) \cdot P(B)$.
- Per "almeno uno", usare il complementare è quasi sempre la strategia migliore.

Prossimi argomenti

- [ ] Teorema della probabilità totale
- [ ] Teorema di Bayes
- [ ] Variabili aleatorie discrete
- [ ] Esercizi su probabilità condizionata, indipendenza e Bayes

---

#MSI #probabilità #frequenza #probabilità-condizionata #indipendenza #misura #combinatoria #complementare #Bayes

00 - Obsidian Notes/2° Anno/2° Semestre/Metodi Statistici dell' Informazione/Lezione 3.md

MSI — Lezione 3: Valore Atteso e Distribuzioni Notevoli

Docente: Prof. Marco Lops | **Corso:** Metodi Statistici per l'Informazione | **CFU:** 6

Argomenti trattati

- Definizione del valore atteso (media statistica) e motivazione tramite legge dei grandi numeri
- Distribuzione di Bernoulli e distribuzione Binomiale: definizione, verifica PMF, media = np (derivazione completa)
- Connessione tra la Binomiale e i problemi di conteggio combinatorio
- Distribuzione Uniforme discreta: definizione, media = media aritmetica dell'alfabeto
- Formula di Gauss per la somma dei primi n interi
- Distribuzione di Poisson: definizione, verifica PMF tramite serie esponenziale, media = λ
- Applicazioni della Poisson: code di traffico, router, uffici postali
- Distribuzione Geometrica: tempo al primo successo, PMF, media = $1/p$ (derivazione con serie geometrica)
- Esercizio: 3 dadi (2 onesti, 1 truccato), applicazione del teorema di Bayes
- Introduzione alla PMF condizionata
- Cenni sugli outlier nell'analisi dei dati

Valore Atteso (Media Statistica)

Motivazione: dalla frequenza alla media

Nella lezione precedente abbiamo introdotto le variabili aleatorie discrete e la funzione massa di probabilità (PMF). Ora ci chiediamo: dato che una variabile aleatoria X può assumere diversi valori, esiste un singolo numero che ne "riassuma" il comportamento medio?

L'idea nasce dalla statistica descrittiva. Supponiamo di ripetere un esperimento n volte e di osservare i valori $x_1, x_2, \dots, x_n$. La **media campionaria** (la media aritmetica delle osservazioni) è:

$$\bar{x}_n = \frac{1}{n} \sum_{i=1}^{n} x_i$$

Sia $X = \{a_1, a_2, \dots, a_M\}$ l'**alfabeto** di X, cioè l'insieme dei valori che X può assumere. Se il valore a_k compare N_k volte nelle n prove (dove $\sum_{k=1}^{M} N_k = n$), possiamo riscrivere la media campionaria raggruppando i termini uguali:

$$\bar{x}_n = \frac{1}{n} \sum_{k=1}^{M} N_k \cdot a_k = \sum_{k=1}^{M} \frac{N_k}{n} \cdot a_k = \sum_{k=1}^{M} f_n(a_k) \cdot a_k$$

dove $f_n(a_k) = N_k/n$ è la **frequenza relativa** del valore a_k su n prove. Per la **legge dei grandi numeri**, quando il numero di prove n tende all'infinito, la frequenza relativa converge alla probabilità:

$$f_n(a_k) \xrightarrow{n \to \infty} P_X(a_k)$$

Quindi la media campionaria converge a un valore ben definito:

$$\overline{x}_n \xrightarrow{n \to \infty} \sum_{k=1}^{M} a_k \cdot P_X(a_k)$$

Questo limite è il **valore atteso** della variabile aleatoria.

Definizione: Valore atteso (media statistica)

Sia X una variabile aleatoria discreta con alfabeto $\mathcal{X} = \{a_1, a_2, \dots, a_M\}$ (finito o numerabile) e PMF $P_X(x)$. Il **valore atteso** (o **media statistica**, o **speranza matematica**) di X è definito come:

$$E[X] = \mu_X = \sum_{k=1}^{M} a_k \cdot P_X(a_k)$$

dove a_k sono i valori nell'alfabeto e $P_X(a_k)$ le rispettive probabilità. Il simbolo $E[\cdot]$ si legge "valore atteso di" oppure "aspettazione di"; μ_X è la notazione alternativa con la lettera greca mu.

Media statistica vs media aritmetica

La media statistica **non** coincide in generale con la media aritmetica dei valori dell'alfabeto. La media aritmetica pesa tutti i valori allo stesso modo ($1/M$ ciascuno); la media statistica è una **media pesata** con pesi $P_X(a_k)$. Solo quando la distribuzione è uniforme (tutti i valori equiprobabili) le due medie coincidono.

Quote

"La media statistica è il baricentro della distribuzione di probabilità: se mettete dei pesi sulle posizioni dell'asse reale, il baricentro cade dove c'è più massa di probabilità. È il numero verso cui converge la media campionaria quando fate tante prove."

Distribuzione di Bernoulli

Definizione: Variabile aleatoria di Bernoulli

Una variabile aleatoria X segue una **distribuzione di Bernoulli** di parametro $p \in [0, 1]$, e si scrive $X \sim \mathrm{Ber}(p)$, se:

- L'alfabeto è $\mathcal{X} = \{0, 1\}$, dove 1 rappresenta il **successo** e 0 il **fallimento**
- La PMF è:

$$P_X(x) = \begin{cases} p & \text{se } x = 1 \\ 1 - p = q & \text{se } x = 0 \end{cases}$$

Il parametro p è la **probabilità di successo** e $q = 1 - p$ la probabilità di fallimento.

Scrittura compatta della PMF. La PMF di Bernoulli si può esprimere in forma chiusa, valida per entrambi i valori dell'alfabeto con un'unica espressione:

$$P_X(x) = p^x(1-p)^{1-x}, \qquad x \in \{0, 1\}$$

Verifica: per $x = 1$ si ottiene $p^1(1-p)^0 = p$; per $x = 0$ si ottiene $p^0(1-p)^1 = 1 - p = q$. Corretto.

Verifica della normalizzazione. La somma di tutte le probabilità deve dare 1:

$$\sum_{x \in \{0,1\}} P_X(x) = P_X(0) + P_X(1) = (1-p) + p = 1 \quad \checkmark$$

Media della Bernoulli

Il valore atteso di $X \sim \text{Ber}(p)$ si calcola direttamente dalla definizione, sommando su tutti i valori dell'alfabeto:

$$E[X] = \sum_{x \in \{0,1\}} x \cdot P_X(x) = 0 \cdot (1-p) + 1 \cdot p = p$$

$$\boxed{E[X] = p}$$

La media di una Bernoulli è semplicemente la probabilità di successo.

Esempio: lancio di una moneta

Una moneta onesta ha probabilità $p = 0{,}5$ di dare testa (codificata come $X = 1$). La media di X è $E[X] = 0{,}5$: se lancio la moneta un numero enorme di volte e faccio la media dei risultati (0 e 1), il valore converge a 0,5.

Distribuzione Binomiale

Definizione: Distribuzione Binomiale

Siano $X_1, X_2, \dots, X_n$ variabili aleatorie **i.i.d.** (indipendenti e identicamente distribuite), ciascuna con distribuzione $X_i \sim \text{Ber}(p)$. La variabile aleatoria:

$$S_n = X_1 + X_2 + \cdots + X_n = \sum_{i=1}^{n} X_i$$

conta il **numero totale di successi** in n prove di Bernoulli indipendenti. Si dice che S_n segue

una **distribuzione Binomiale** di parametri n (numero di prove) e p (probabilità di successo nella singola prova):

$$S_n \sim \mathrm{Bin}(n, p)$$

L'alfabeto è $X = \{0, 1, 2, \dots, n\}$ e la PMF è:

$$P_{S_n}(k) = \binom{n}{k} p^k (1-p)^{n-k}, \qquad k = 0, 1, \dots, n$$

dove $\binom{n}{k} = \frac{n!}{k!(n-k)!}$ è il **coefficiente binomiale**.

Interpretazione combinatoria (connessione con il conteggio)

La PMF binomiale ha una struttura che si spiega interamente con gli strumenti dell'analisi combinatoria visti nelle prime lezioni:

- Il fattore $p^k(1-p)^{n-k}$ è la probabilità di una **specifica sequenza** di n prove che contiene esattamente k successi e $n-k$ fallimenti. Per l'indipendenza delle prove, le probabilità si moltiplicano.
- Il fattore $\binom{n}{k}$ conta il **numero di sequenze distinte** di lunghezza n con esattamente k successi (e $n-k$ fallimenti). Questo è esattamente il conteggio delle sequenze binarie con k uni che avevamo derivato nella Lezione 2.

La PMF è quindi: (numero di sequenze favorevoli) $\times$ (probabilità di ciascuna sequenza).

Verifica della normalizzazione

La somma di tutte le probabilità deve dare 1. Applicando il Binomio di Newton con $a = p$ e $b = (1-p)$:

$$\sum_{k=0}^{n} P_{S_n}(k) = \sum_{k=0}^{n} \binom{n}{k} p^k (1-p)^{n-k} = (p + (1-p))^n = 1^n = 1 \quad \checkmark$$

Media della Binomiale: derivazione completa

Metodo 1 — Per linearità del valore atteso. Poiché $S_n = X_1 + X_2 + \cdots + X_n$ con $X_i \sim \mathrm{Ber}(p)$ indipendenti, e poiché il valore atteso è un operatore **lineare** (la media di una somma è la somma delle medie):

$$E[S_n] = E\left[\sum_{i=1}^{n} X_i\right] = \sum_{i=1}^{n} E[X_i] = \sum_{i=1}^{n} p = np$$

$$\boxed{E[S_n] = np}$$

Metodo 2 — Calcolo diretto dalla definizione della PMF. Si parte dalla definizione:

$$E[S_n] = \sum_{k=0}^{n} k \cdot \binom{n}{k} p^k (1-p)^{n-k}$$

Il termine con $k = 0$ è nullo, quindi la somma parte da $k = 1$:

$$= \sum_{k=1}^{n} k \cdot \frac{n!}{k!(n-k)!} p^k (1-p)^{n-k}$$

Semplifichiamo k con $k! = k \cdot (k-1)!$:

$$= \sum_{k=1}^{n} \frac{n!}{(k-1)!(n-k)!} p^k (1-p)^{n-k}$$

Raccogliamo il fattore np scrivendo $n! = n \cdot (n-1)!$ e $p^k = p \cdot p^{k-1}$:

$$= np \sum_{k=1}^{n} \frac{(n-1)!}{(k-1)!((n-1)-(k-1))!} p^{k-1} (1-p)^{(n-1)-(k-1)}$$

Effettuiamo il cambio di indice $j = k - 1$ e poniamo $m = n - 1$:

$$= np \sum_{j=0}^{m} \binom{m}{j} p^j (1-p)^{m-j} = np \cdot (p + (1-p))^m = np \cdot 1 = np$$

I due metodi danno lo stesso risultato: $E[S_n] = np$.

Esempio: vaccino

Un vaccino ha efficacia $p = 0{,}95$ (probabilità che un singolo vaccinato sviluppi l'immunità). Su $n = 1000$ vaccinati, il numero atteso di soggetti protetti è:

$$E[S_{1000}] = 1000 \cdot 0{,}95 = 950$$

Esempio: roulette

Alla roulette europea, il rosso esce con probabilità $p = 18/37$ (ci sono 18 numeri rossi su 37 caselle totali). In $n = 37$ giri, il numero atteso di uscite del rosso è:

$$E[S_{37}] = 37 \cdot \frac{18}{37} = 18$$

Notiamo che la roulette non è un gioco equo: con 18 rossi, 18 neri e 1 zero verde, il banco ha un leggero vantaggio.

Distribuzione Uniforme Discreta

Definizione: Distribuzione Uniforme Discreta

Una variabile aleatoria X segue una **distribuzione uniforme discreta** sull'alfabeto $\mathcal{X} = \{a_1, a_2, \dots, a_M\}$ se tutti i valori sono equiprobabili:

$$P_X(a_k) = \frac{1}{M}, \qquad k = 1, 2, \dots, M$$

dove $M = |\mathcal{X}|$ è la **cardinalità** dell'alfabeto (il numero di valori possibili).

Verifica della normalizzazione:

$$\sum_{k=1}^{M} P_X(a_k) = \sum_{k=1}^{M} \frac{1}{M} = M \cdot \frac{1}{M} = 1 \quad \checkmark$$

Media della Uniforme Discreta

Il valore atteso si calcola applicando la definizione:

$$E[X] = \sum_{k=1}^{M} a_k \cdot \frac{1}{M} = \frac{1}{M} \sum_{k=1}^{M} a_k = \frac{a_1 + a_2 + \cdots + a_M}{M}$$

La media della uniforme coincide con la media aritmetica dell'alfabeto

Nel caso uniforme — e **solo** nel caso uniforme — la media statistica coincide con la media aritmetica dei valori dell'alfabeto. Per qualunque altra distribuzione, i valori con probabilità maggiore "pesano" di più e spostano la media verso di sé.

Formula di Gauss

Quando l'alfabeto è $\mathcal{X} = \{1, 2, \dots, M\}$ (i primi M interi positivi), per calcolare la somma $1 + 2 + \cdots + M$ si usa la celebre **formula di Gauss**:

$$\sum_{k=1}^{M} k = \frac{M(M+1)}{2}$$

Quote

"La scoprì Gauss a sei anni, quando il maestro gli chiese di sommare i numeri da 1 a 100 pensando di tenerlo occupato per un'ora. Gauss scrisse l'ultimo numero accanto al primo, il penultimo accanto al secondo... e si accorse che ogni coppia faceva 101. Cinquanta coppie: $50 \times 101 = 5050$. Il maestro rimase a bocca aperta."

Dimostrazione. Sia $S = 1 + 2 + \cdots + M$. Scriviamo la somma due volte, una in ordine crescente e una in ordine decrescente:

$$S = 1 + 2 + \cdots + (M - 1) + M$$

$$S = M + (M - 1) + \cdots + 2 + 1$$

Sommando termine a termine, ogni coppia dà $(M + 1)$, e le coppie sono M:

$$2S = \underbrace{(M + 1) + (M + 1) + \cdots + (M + 1)}_{M \text{ volte}} = M(M + 1)$$

Da cui $S = \frac{M(M+1)}{2}$.

Esempio: dado onesto

Un dado onesto a 6 facce ha $X = \{1, 2, 3, 4, 5, 6\}$ e distribuzione uniforme ($P_X(k) = 1/6$ per ogni faccia k). Il valore atteso è:

$$E[X] = \frac{1}{6} \sum_{k=1}^{6} k = \frac{1}{6} \cdot \frac{6 \cdot 7}{2} = \frac{42}{12} = 3{,}5$$

Il valore 3,5 **non appartiene all'alfabeto**: la media è un indice sintetico che indica il baricentro della distribuzione, non necessariamente un valore che la variabile può assumere.

Formula generale. Per una variabile uniforme su $\{1, 2, \ldots, M\}$, la media è:

$$E[X] = \frac{1}{M} \cdot \frac{M(M + 1)}{2} = \frac{M + 1}{2}$$

Distribuzione di Poisson

Definizione: Distribuzione di Poisson

Una variabile aleatoria X segue una **distribuzione di Poisson** di parametro $\lambda > 0$, e si scrive $X \sim \mathrm{Poi}(\lambda)$, se:

- L'alfabeto è $X = \{0, 1, 2, 3, \ldots\} = \mathbb{N}_0$ (l'insieme dei naturali incluso lo zero, cioè **numerabilmente infinito**)
- La PMF è:

$$P_X(k) = \frac{\lambda^k}{k!} e^{-\lambda}, \qquad k = 0, 1, 2, \ldots$$

  Il parametro λ (lettera greca lambda) rappresenta il **tasso medio** di occorrenze

nell'intervallo di tempo (o spazio) considerato. Il simbolo $e \approx 2{,}718$ è il numero di Nepero, base del logaritmo naturale; $k!$ è il fattoriale di k (con la convenzione $0! = 1$).

Verifica della normalizzazione tramite serie esponenziale

La somma di tutte le probabilità deve dare 1. Per verificarlo, ricordiamo lo sviluppo in **serie di Taylor dell'esponenziale**:

$$e^{\lambda} = \sum_{k=0}^{\infty} \frac{\lambda^k}{k!}$$

Questa serie converge per ogni $\lambda \in \mathbb{R}$. Applicandola alla somma delle probabilità:

$$\sum_{k=0}^{\infty} P_X(k) = \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} e^{-\lambda} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = e^{-\lambda} \cdot e^{\lambda} = e^0 = 1 \quad \checkmark$$

Il fattore $e^{-\lambda}$ è proprio la costante di normalizzazione che rende la PMF una distribuzione di probabilità valida.

Media della Poisson: $E[X] = \lambda$ (derivazione completa)

Partiamo dalla definizione di valore atteso per una variabile con alfabeto infinito numerabile:

$$E[X] = \sum_{k=0}^{\infty} k \cdot \frac{\lambda^k}{k!} e^{-\lambda}$$

Il termine con $k = 0$ dà contributo nullo ($0 \cdot P_X(0) = 0$), quindi la somma parte da $k = 1$:

$$= e^{-\lambda} \sum_{k=1}^{\infty} k \cdot \frac{\lambda^k}{k!}$$

Semplifichiamo k con il fattoriale, usando $k! = k \cdot (k-1)!$:

$$= e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^k}{(k-1)!}$$

Estraiamo un fattore λ dal numeratore, scrivendo $\lambda^k = \lambda \cdot \lambda^{k-1}$:

$$= \lambda e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!}$$

Effettuiamo il cambio di indice $j = k - 1$ (quando $k = 1$ si ha $j = 0$; quando $k \to \infty$ si ha $j \to \infty$):

$$= \lambda e^{-\lambda} \sum_{j=0}^{\infty} \frac{\lambda^j}{j!} = \lambda e^{-\lambda} \cdot e^{\lambda} = \lambda \cdot 1 = \lambda$$

$$\boxed{E[X] = \lambda}$$

La media della Poisson è esattamente il parametro λ: un risultato elegante che conferma l'interpretazione di λ come tasso medio.

Quote

"La Poisson è la distribuzione delle cose rare: eventi che singolarmente sono poco probabili, ma che vengono osservati su un numero enorme di occasioni. Quante macchine passano al casello in un minuto? Quanti pacchetti arrivano al router in un millisecondo? Quante persone entrano all'ufficio postale in un'ora? Tutte Poisson."

Applicazioni della distribuzione di Poisson

Esempio: code di traffico

Al casello autostradale, in media arrivano $\lambda = 4$ auto al minuto. Il numero di auto che arrivano in un dato minuto si modella come $X \sim \mathrm{Poi}(4)$. La probabilità che in un minuto ne arrivino esattamente $k = 6$ è:

$$P(X = 6) = \frac{4^6}{6!} e^{-4} = \frac{4096}{720} \cdot e^{-4} \approx 5{,}689 \cdot 0{,}0183 \approx 0{,}104 \approx 10{,}4\%$$

Esempio: pacchetti al router

Un router di rete riceve in media $\lambda = 100$ pacchetti al millisecondo. La variabile aleatoria "numero di pacchetti ricevuti in un millisecondo" segue una $\mathrm{Poi}(100)$. Il valore atteso è $E[X] = 100$ pacchetti/ms. Questo modello di Poisson è fondamentale nel **dimensionamento delle code** nei sistemi di rete: permette di calcolare la probabilità che il buffer del router si saturi e inizi a perdere pacchetti.

Esempio: ufficio postale

All'ufficio postale entrano in media $\lambda = 3$ clienti ogni 10 minuti. La probabilità che non entri **nessuno** in un intervallo di 10 minuti è:

$$P(X = 0) = \frac{3^0}{0!} e^{-3} = 1 \cdot e^{-3} \approx 0{,}050 = 5\%$$

Mentre la probabilità che ne entrino esattamente 3 (il valore medio) è:

$$P(X = 3) = \frac{3^3}{3!} e^{-3} = \frac{27}{6} \cdot e^{-3} \approx 4{,}5 \cdot 0{,}050 \approx 0{,}224 \approx 22{,}4\%$$

La Poisson come limite della Binomiale

⚠ Approssimazione di Poisson alla Binomiale

Quando n è molto grande e p è molto piccolo, con il prodotto $\lambda = np$ che resta finito, la distribuzione Binomiale $\mathrm{Bin}(n, p)$ è ben approssimata dalla Poisson $\mathrm{Poi}(\lambda)$:

$$\binom{n}{k} p^k (1-p)^{n-k} \approx \frac{\lambda^k}{k!} e^{-\lambda}, \qquad \text{per } n \to \infty,\ p \to 0,\ np = \lambda$$

Questa approssimazione è molto utile nella pratica, perché evita di calcolare coefficienti binomiali con n enorme.

Distribuzione Geometrica

Definizione: Distribuzione Geometrica

Una variabile aleatoria X segue una **distribuzione Geometrica** di parametro $p \in (0, 1]$, e si scrive $X \sim \mathrm{Geo}(p)$, se rappresenta il **numero di prove necessarie per ottenere il primo successo** in una sequenza di prove di Bernoulli indipendenti, ciascuna con probabilità di successo p.

- L'alfabeto è $X = \{1, 2, 3, \dots\}$ (numerabilmente infinito: il primo successo potrebbe teoricamente non arrivare mai)
- La PMF è:

$$P_X(k) = (1-p)^{k-1} p, \qquad k = 1, 2, 3, \dots$$

  dove $(1-p)^{k-1}$ è la probabilità di $k-1$ fallimenti consecutivi e p è la probabilità del successo alla k-esima prova.

Interpretazione. Per ottenere il primo successo esattamente alla prova numero k, devono verificarsi:

- $k-1$ fallimenti consecutivi, ciascuno con probabilità $q = 1-p$
- Seguiti da 1 successo, con probabilità p

Per l'**indipendenza** delle prove, le probabilità si moltiplicano: $\underbrace{q \cdot q \cdots q}_{k-1} \cdot p = q^{k-1} p$.

Verifica della normalizzazione (serie geometrica)

Ricordiamo la formula della **serie geometrica**: per $|r| < 1$:

$$\sum_{k=0}^{\infty} r^k = \frac{1}{1-r}$$

Sia $q = 1 - p$. Poiché $p \in (0, 1]$, si ha $q \in [0, 1)$ e quindi $|q| < 1$:

$$\sum_{k=1}^{\infty} P_X(k) = \sum_{k=1}^{\infty} q^{k-1} p = p \sum_{j=0}^{\infty} q^j = p \cdot \frac{1}{1-q} = p \cdot \frac{1}{p} = 1 \quad \checkmark$$

dove nel secondo passaggio abbiamo posto $j = k - 1$.

Media della Geometrica: $E[X] = 1/p$ (derivazione completa)

Partiamo dalla definizione:

$$E[X] = \sum_{k=1}^{\infty} k \cdot q^{k-1} p = p \sum_{k=1}^{\infty} k \cdot q^{k-1}$$

Per calcolare la somma $\sum_{k=1}^{\infty} k \cdot q^{k-1}$, usiamo un trucco fondamentale: riconosciamo che è la **derivata** della serie geometrica rispetto a q.

Passo 1. Partiamo dalla serie geometrica:

$$\sum_{k=0}^{\infty} q^k = \frac{1}{1-q}$$

Passo 2. Deriviamo entrambi i membri rispetto a q. A sinistra, la derivata di q^k è $k \cdot q^{k-1}$ (il termine $k = 0$ scompare perché la derivata di 1 è 0):

$$\frac{d}{dq} \sum_{k=0}^{\infty} q^k = \sum_{k=1}^{\infty} k \cdot q^{k-1}$$

A destra:

$$\frac{d}{dq}\left(\frac{1}{1-q}\right) = \frac{1}{(1-q)^2}$$

Passo 3. Quindi:

$$\sum_{k=1}^{\infty} k \cdot q^{k-1} = \frac{1}{(1-q)^2}$$

Passo 4. Sostituendo nella formula della media e ricordando che $1 - q = p$:

$$E[X] = p \cdot \frac{1}{(1-q)^2} = p \cdot \frac{1}{p^2} = \frac{1}{p}$$

$$\boxed{E[X] = \frac{1}{p}}$$

Esempio: roulette — tempo alla prima vincita

Un giocatore scommette sul rosso alla roulette europea ($p = 18/37 \approx 0{,}486$). In media, quante giocate deve fare per vincere la prima volta?

$$E[X] = \frac{1}{18/37} = \frac{37}{18} \approx 2{,}06 \text{ giocate}$$

Esempio: lancio di un dado — aspettare il 6

Qual è il numero medio di lanci di un dado onesto necessari per ottenere il primo 6? Qui $p = 1/6$:

$$E[X] = \frac{1}{1/6} = 6 \text{ lanci}$$

Proprietà di assenza di memoria (memoryless)

La distribuzione geometrica gode della **proprietà di assenza di memoria**: il fatto di aver già fallito n prove non cambia la distribuzione del tempo residuo al primo successo.

$$P(X > n + m \mid X > n) = P(X > m), \qquad \forall n, m \geq 0$$

Intuitivamente: "le prove passate non influenzano il futuro". Se sto aspettando il primo 6 e ho già fatto 10 lanci senza successo, il numero medio di lanci rimanenti è ancora 6, non $6 - 10$. La geometrica è l'**unica** distribuzione discreta con questa proprietà.

Esercizio: Tre Dadi e il Teorema di Bayes

Testo del problema

Si dispone di 3 dadi: **2 onesti** (ciascuna faccia esce con probabilità $1/6$) e **1 truccato** (il 6 esce con probabilità $1/2$, le altre 5 facce escono con probabilità $1/10$ ciascuna). Si sceglie un dado a caso con uguale probabilità ($1/3$ per ciascun dado) e lo si lancia una volta. Esce il numero 6.

Domanda: qual è la probabilità che il dado utilizzato sia quello truccato?

Soluzione con il teorema di Bayes

Definizione degli eventi:

- T: il dado scelto è quello truccato
- O: il dado scelto è uno dei due onesti
- S: il risultato del lancio è 6 (il "sei")

Passo 1 — Probabilità a priori. Prima del lancio, non abbiamo alcuna informazione su quale dado sia stato scelto. La scelta è equiprobabile fra i 3 dadi:

$$P(T) = \frac{1}{3}, \qquad P(O) = \frac{2}{3}$$

Passo 2 — Verosimiglianze (likelihood). La probabilità di osservare 6 dato il tipo di dado scelto:

$$P(S \mid T) = \frac{1}{2} \qquad \text{(il dado truccato fa uscire il 6 con probabilità } 1/2\text{)}$$

$$P(S \mid O) = \frac{1}{6} \qquad \text{(un dado onesto fa uscire il 6 con probabilità } 1/6\text{)}$$

Passo 3 — Probabilità totale. La probabilità complessiva di osservare 6 (indipendentemente dal dado) si calcola con il **teorema della probabilità totale**:

$$P(S) = P(S \mid T) \cdot P(T) + P(S \mid O) \cdot P(O) = \frac{1}{2} \cdot \frac{1}{3} + \frac{1}{6} \cdot \frac{2}{3}$$

$$= \frac{1}{6} + \frac{2}{18} = \frac{1}{6} + \frac{1}{9} = \frac{3}{18} + \frac{2}{18} = \frac{5}{18}$$

Passo 4 — Applicazione del teorema di Bayes. La probabilità **a posteriori** che il dado sia truccato, dato che è uscito 6:

$$P(T \mid S) = \frac{P(S \mid T) \cdot P(T)}{P(S)} = \frac{\frac{1}{2} \cdot \frac{1}{3}}{\frac{5}{18}} = \frac{\frac{1}{6}}{\frac{5}{18}} = \frac{1}{6} \cdot \frac{18}{5} = \frac{18}{30} = \frac{3}{5}$$

$$\boxed{P(T \mid S) = \frac{3}{5} = 60\%}$$

Verifica di coerenza. Calcoliamo anche $P(O \mid S)$ per verificare che le probabilità a posteriori sommino a 1:

$$P(O \mid S) = \frac{P(S \mid O) \cdot P(O)}{P(S)} = \frac{\frac{1}{6} \cdot \frac{2}{3}}{\frac{5}{18}} = \frac{\frac{2}{18}}{\frac{5}{18}} = \frac{2}{5} = 40\%$$

$$P(T \mid S) + P(O \mid S) = \frac{3}{5} + \frac{2}{5} = 1 \quad \checkmark$$

⚠ L'aggiornamento bayesiano: a priori vs a posteriori

Prima del lancio, la probabilità che il dado fosse truccato era $P(T) = 1/3 \approx 33\%$. Dopo aver osservato l'uscita del 6, la probabilità è salita a $P(T \mid S) = 3/5 = 60\%$. L'osservazione ha **aggiornato** la nostra credenza: poiché il 6 è molto più probabile con il dado truccato ($1/2$ vs $1/6$), la sua uscita è un'evidenza a favore dell'ipotesi "dado truccato".

Quote

"Bayes è questo: prima di vedere i dati avete un'opinione — la probabilità a priori. Poi vedete i dati e aggiornate l'opinione — ottenete la probabilità a posteriori. Se i dati sono coerenti con la vostra ipotesi, la probabilità sale; se non lo sono, scende. Questo è il cuore dell'inferenza statistica."

PMF Condizionata

Definizione formale

Definizione: PMF condizionata

Sia X una variabile aleatoria discreta con alfabeto $\mathcal{X}$ e sia A un evento con $P(A) > 0$. La **PMF condizionata** di X dato l'evento A è:

$$P_{X|A}(x) = P(X = x \mid A) = \frac{P(\{X = x\} \cap A)}{P(A)}, \qquad x \in \mathcal{X}$$

dove $\{X = x\}$ è l'evento "la variabile aleatoria X assume il valore x".

La PMF condizionata è essa stessa una PMF valida: è non-negativa e la somma su tutto l'alfabeto dà 1.

Interpretazione. Condizionare all'evento A equivale a **restringere** lo spazio dei campioni Ω al sottoinsieme A e ricalcolare le probabilità nel nuovo universo. I valori di X che sono incompatibili con A ricevono probabilità condizionata nulla; quelli compatibili vedono la loro probabilità aumentare proporzionalmente.

Esempio: dado condizionato a "pari"

Sia X il risultato di un dado onesto. La PMF incondizionata è $P_X(k) = 1/6$ per $k = 1, 2, \dots, 6$.

Supponiamo di sapere che è uscito un numero **pari**: $A = \{2, 4, 6\}$, con $P(A) = 3/6 = 1/2$. La PMF condizionata è:

$$P_{X|A}(k) = \begin{cases} \dfrac{1/6}{1/2} = \dfrac{1}{3} & \text{se } k \in \{2, 4, 6\} \\ 0 & \text{se } k \in \{1, 3, 5\} \end{cases}$$

Lo spazio dei campioni si è ristretto da $\{1, 2, 3, 4, 5, 6\}$ a $\{2, 4, 6\}$: i tre valori pari diventano equiprobabili tra loro, con probabilità $1/3$ ciascuno.

Connessione con l'esercizio dei dadi e Bayes

Nell'esercizio con i 3 dadi, il passaggio dalla probabilità a priori alla probabilità a posteriori è esattamente un condizionamento:

- **PMF a priori** del tipo di dado: $P(T) = 1/3$, $P(O) = 2/3$
- **PMF a posteriori** (condizionata all'uscita del 6): $P(T \mid S) = 3/5$, $P(O \mid S) = 2/5$

Il teorema di Bayes fornisce il meccanismo per passare dalla PMF incondizionata alla PMF condizionata quando l'evento di condizionamento riguarda un'osservazione e si vuole aggiornare la distribuzione su un'ipotesi.

In generale, se $H_1, H_2, \ldots, H_n$ sono ipotesi mutualmente esclusive ed esaustive (una partizione dello spazio), e D è un dato osservato:

$$P(H_i \mid D) = \frac{P(D \mid H_i) \cdot P(H_i)}{\sum_{j=1}^{n} P(D \mid H_j) \cdot P(H_j)}$$

Questa formula consente di passare dalla PMF a priori $\{P(H_i)\}$ alla PMF a posteriori $\{P(H_i \mid D)\}$.

Cenni sugli Outlier nell'Analisi dei Dati

⚠ Outlier e sensibilità della media

La media statistica è molto sensibile ai **valori anomali** (outlier). Un singolo valore estremo nella distribuzione (o nel campione) può spostare significativamente la media, rendendola un indicatore poco rappresentativo del "centro" della distribuzione. Nella pratica dell'analisi dei dati, questo è un problema serio.

☰ Esempio: stipendi in un'azienda

In un'azienda ci sono 9 dipendenti con stipendio annuo di 30.000 euro e 1 dirigente con stipendio di 300.000 euro. La media degli stipendi è:

$$\bar{x} = \frac{9 \cdot 30.000 + 300.000}{10} = \frac{270.000 + 300.000}{10} = \frac{570.000}{10} = 57.000 \text{ euro}$$

Ma 57.000 euro non rappresenta nessuno: il 90% dei dipendenti guadagna circa la metà della

media, e il dirigente guadagna più di cinque volte la media. La **mediana** (30.000 euro, il valore che divide la distribuzione a metà) sarebbe in questo caso un indicatore molto più informativo.

Per questo motivo, nella pratica, accanto alla media si calcolano sempre altri indicatori:

- La **mediana**: il valore che divide la distribuzione a metà (il 50% dei dati sta sopra, il 50% sotto). È robusta rispetto agli outlier.
- La **varianza** (che vedremo nelle prossime lezioni): misura la dispersione dei dati attorno alla media. Se la varianza è alta, la media da sola è poco informativa.

Quote

"Se uno mette la testa nel forno e i piedi nel congelatore, in media sta bene. Ecco perché la media da sola non basta: bisogna sempre guardare anche quanto i dati si disperdono attorno ad essa."

Punti chiave della lezione

- Il **valore atteso** $E[X] = \sum_k a_k P_X(a_k)$ è il baricentro della distribuzione e il limite della media campionaria per la legge dei grandi numeri.
- **Bernoulli** $\mathrm{Ber}(p)$: l'esperimento più semplice (successo/fallimento), con media $E[X] = p$.
- **Binomiale** $\mathrm{Bin}(n, p)$: somma di n Bernoulli indipendenti, PMF $= \binom{n}{k} p^k (1-p)^{n-k}$, media $= np$.
- **Uniforme** discreta: tutti i valori equiprobabili, media = media aritmetica dell'alfabeto.
- **Poisson** $\mathrm{Poi}(\lambda)$: distribuzione degli eventi rari, PMF $= \frac{\lambda^k}{k!} e^{-\lambda}$, media $= \lambda$. Si applica a code, traffico, reti.
- **Geometrica** $\mathrm{Geo}(p)$: tempo al primo successo, PMF $= (1-p)^{k-1} p$, media $= 1/p$. Unica distribuzione discreta con assenza di memoria.
- Il **teorema di Bayes** permette di aggiornare la probabilità a priori di un'ipotesi dopo aver osservato dei dati, ottenendo la probabilità a posteriori.
- La **PMF condizionata** restringe lo spazio dei campioni e ridistribuisce le probabilità.
- La media è sensibile agli **outlier**: nella pratica va sempre affiancata da mediana e varianza.

Prossimi argomenti

- [ ] Varianza e deviazione standard
- [ ] Momenti di ordine superiore
- [ ] Variabili aleatorie continue: densità di probabilità

- [ ] Distribuzione Gaussiana (normale)
- [ ] Funzioni di variabili aleatorie

#MSI #variabili-aleatorie #valore-atteso #Bernoulli #binomiale #uniforme #Poisson #geometrica #Bayes #PMF-condizionata #outlier

00 - Obsidian Notes/2° Anno/2° Semestre/Metodi Statistici dell' Informazione/Lezione 4.md

MSI — Lezione 4: Funzioni di Variabili Aleatorie, Varianza e Esercizi

---

Argomenti trattati

- Ripasso variabili notevoli: Binomiale, Uniforme, Poissoniana, Geometrica
- PMF condizionata: ripasso e generalizzazione
- Media condizionale e legge della probabilità totale per le medie
- Funzioni di variabili aleatorie: $Y = g(X)$
  - Caso biiettivo: reflagging dell'alfabeto
  - Caso molti-a-uno: collasso delle probabilità
- Teorema fondamentale del calcolo della media: $E[g(X)] = \sum_x g(x) p_X(x)$
- Valore quadratico medio (RMS) e valore efficace
- Varianza e deviazione standard
- Relazione varianza-valore quadratico medio
- Esercizi: dado truccato (3 dadi), vaccinazione (Binomiale), carte napoletane (non-geometrica)

Ripasso: Variabili Notevoli

Variabile	**Alfabeto**	**PMF** $p_X(k)$	**Media** $E[X]$
Binomiale $B(n, p)$	$\{0, \dots, n\}$	$\binom{n}{k} p^k (1-p)^{n-k}$	np
Uniforme su m valori	$\{x_1, \dots, x_m\}$	$1/m$	media aritmetica
Poissoniana $P(\lambda)$	N_0	$\lambda^k e^{-\lambda}/k!$	λ
Geometrica $G(p)$	$\{1, 2, 3, \dots\}$	$(1-p)^{k-1} p$	$1/p$

PMF Condizionata: Ripasso e Media Condizionale

PMF condizionata a un evento

Data una condizione C con $P(C) > 0$:

$$p_{X|C}(k) = \frac{P(X = k, C)}{P(C)} = \begin{cases} \frac{p_X(k)}{P(C)} & \text{se } k \in C \\ 0 & \text{altrimenti} \end{cases}$$

Questa è ancora una PMF valida. Applicazione in data analysis: **potatura degli outlier** (si escludono valori anomali imponendo una maschera di ammissibilità sul dominio).

Media condizionale e scomposizione della media

Dato un evento C, la **media condizionale** di X dato C è:

$$E[X \mid C] = \sum_{x \in \mathcal{X}} x \cdot p_{X|C}(x)$$

Data una partizione $\{E_1, E_2, \dots, E_m\}$ di Ω (eventi disgiunti la cui unione è Ω), la media totale si decompone come:

$$\boxed{E[X] = \sum_{i=1}^{m} P(E_i) \cdot E[X \mid E_i]}$$

Derivazione: si applica la legge della probabilità totale alla PMF di X, moltiplicando per x e sommando su tutti gli x.

Esempio con Binomiale $B(16, 1/3)$

Partizione: $E_1 = \{X \leq 4\}, E_2 = \{X > 4\}$.

$$E[X] = P(X \leq 4) \cdot E[X \mid X \leq 4] + P(X > 4) \cdot E[X \mid X > 4]$$

Funzioni di Variabili Aleatorie: $Y = g(X)$

Se X è una variabile aleatoria e g è una funzione definita sull'alfabeto di X, allora $Y = g(X)$ è anch'essa una variabile aleatoria.

Caso 1: Corrispondenza biiettiva ($|Y| = |X|$)

Se g è una biiezione (ogni valore di X mappa in un valore distinto di Y), allora:

$$p_Y(g(x_i)) = p_X(x_i)$$

Si tratta di un semplice **reflagging dell'alfabeto**: le probabilità sono invariate, cambiano solo le etichette dei valori.

$Y = 4X$, **con** $X \in \{-2, -1, 1, 2\}$ **e** $p_X = \{1/8, 1/4, 1/4, 3/8\}$

L'alfabeto di Y è $\{-8, -4, 4, 8\}$ con le stesse probabilità.

Caso 2: Corrispondenza molti-a-uno ($|Y| < |X|$)

Più valori di X collassano in uno stesso valore di Y. Le probabilità corrispondenti si sommano:

$$p_Y(y_k) = \sum_{\{x:g(x)=y_k\}} p_X(x)$$

$Y = |X|$, con $X \in \{-2, -1, 1, 2\}$

$Y \in \{1, 2\}$.
$p_Y(1) = p_X(-1) + p_X(1) = 1/4 + 1/4 = 1/2$
$p_Y(2) = p_X(-2) + p_X(2) = 1/8 + 3/8 = 1/2$
Media: $E[Y] = 1 \cdot 1/2 + 2 \cdot 1/2 = 3/2$

Teorema Fondamentale del Calcolo della Media

Teorema

Data una variabile aleatoria X con PMF p_X e una funzione g, la media di $Y = g(X)$ è:

$$\boxed{E[g(X)] = \sum_{x \in X} g(x) \cdot p_X(x)}$$

indipendentemente dal fatto che g sia biiettiva o molti-a-uno.

Questo teorema è fondamentale perché permette di calcolare $E[g(X)]$ **senza costruire esplicitamente la PMF di** Y: si lavora direttamente con la PMF di X.

Dimostrazione (caso molti-a-uno): i valori che collassano nello stesso punto di Y hanno tutti lo stesso $g(x)$; la somma su x è quindi equivalente alla somma su y (le probabilità si sommano automaticamente).

Valore Quadratico Medio (RMS)

Definizione

Il **valore quadratico medio** di X è:

$$E[X^2] = \sum_{x \in X} x^2 \cdot p_X(x)$$

Il **valore efficace** (root mean square) è:

$$x_{rms} = \sqrt{E[X^2]}$$

Terminologia RMS

Il termine inglese "root mean square" indica che si prende la **radice** del valor medio del **quadrato**. La notazione $x_{rms}^2 = E[X^2]$ (il quadrato del valore efficace = valore quadratico medio) può essere fonte di confusione.

Corrente alternata e valore efficace

La corrente sinusoidale ha **media nulla** (le semionde positive e negative si cancellano). La corrente efficace $I_{rms} = I_0/\sqrt{2}$ è quella che determina la potenza dissipata: $P = I_{rms}^2 \cdot R$. Una presa con corrente media zero può essere letale se il valore efficace è diverso da zero.

Machine Learning: minimizzazione dell'errore quadratico medio

L'errore quadratico medio (MSE) è la funzione costo standard nel ML:

$$MSE = E[(X - \hat{X})^2]$$

Vantaggi: è **convessa** (forma a coppa con un unico minimo globale), derivabile e trattabile analiticamente. I problemi di ottimizzazione convessa convergono a soluzioni ottimali globali, a differenza di quelli concavi che hanno massimi unici ma sono usati quando si massimizza una figura di merito.

Varianza e Deviazione Standard

Definizione

La **variabile centrata** $X - \mu_X$ ha media nulla per costruzione. La sua "dimensione" è misurata dalla **varianza**:

$$\sigma_X^2 = E[(X - \mu_X)^2] = \sum_x (x - \mu_X)^2 \cdot p_X(x) \geq 0$$

La **deviazione standard** è $\sigma_X = \sqrt{\sigma_X^2}$.

Relazione con il valore quadratico medio

$$\boxed{\sigma_X^2 = E[X^2] - \mu_X^2}$$

Dimostrazione:

$$E[(X-\mu_X)^2] = E[X^2 - 2\mu_X X + \mu_X^2] = E[X^2] - 2\mu_X^2 + \mu_X^2 = E[X^2] - \mu_X^2$$

Interpretazione fisica: media e varianza come coppia

La coppia (μ_X, σ_X) caratterizza globalmente la variabile aleatoria:

- $\sigma_X \ll \mu_X$: la variabile è concentrata intorno alla media $\rightarrow$ la media è un buon predittore
- $\sigma_X \gg \mu_X$: la variabile è dispersa $\rightarrow$ la media non descrive bene il comportamento tipico

Il rapporto μ_X / σ_X (inverso del coefficiente di variazione) misura il "segnale rispetto al rumore" della variabile aleatoria.

Confronto

Sia X una variabile con media 100€ e deviazione standard 1 centesimo: praticamente deterministica, la media descrive la situazione quasi perfettamente. Se invece \sigma_X = 40€: alta aleatorietà, la situazione economica "istantanea" può essere molto diversa dalla media.

Esercizi Svolti

Esercizio 1: Tre Dadi — Probabilità di Ottenere 12

Setup: urna con 3 dadi: D_0 (onesto), D_1 ($P(1) = u$, altri equiprobabili), D_6 ($P(6) = u$, altri equiprobabili). Si estraggono **2 dadi** e si lanciano.

Per D_1: $P(i \neq 1) = (1-u)/5$. Per D_6: $P(i \neq 6) = (1-u)/5$.

Le coppie estratte (D_0D_1, D_0D_6, D_1D_6) sono equiprobabili con prob. $1/3$ ciascuna. Per la legge della probabilità totale:

$$P(12) = \frac{1}{3}\left[\frac{1}{6}\cdot\frac{1-u}{5} + \frac{1}{6}\cdot u + \frac{1-u}{5}\cdot u\right] = \frac{1+10u-6u^2}{90}$$

Domanda 2: $P(12) = 2/36 = 1/18 \rightarrow$ risolve $6u^2 - 10u + 4 = 0 \rightarrow u_1 = 1, u_2 = 2/3$.

Domanda 3: massimizzare $P(12)$. La funzione è concava, il massimo è in $u^* = 10/12 = 5/6$, con $P(12)_{max} \approx 0{,}0584$.

Esercizio 2: Vaccinazione — Variabile Binomiale $B(10, 0{,}9)$

10 bambini vaccinati, vaccino efficace nel 90% dei casi, indipendentemente. X = numero di bambini immunizzati.

a) Tutti immunizzati:

$$P(X = 10) = 0{,}9^{10} \approx 0{,}349$$

b) Almeno 8 immunizzati:

$$P(X \geq 8) = \binom{10}{8}(0{,}9)^8(0{,}1)^2 + \binom{10}{9}(0{,}9)^9(0{,}1) + (0{,}9)^{10}$$

c) Numero medio: $E[X] = 10 \cdot 0{,}9 = 9$.

Esercizio 3: Carte Napoletane — Distribuzione Non-Standard

Setup: mazzo da 40 carte napoletane (10 denari + 30 altre). Due giocatori estraggono **senza reinserire**. Vince chi per primo estrae un denaro. X = numero di estrazioni.

Alfabeto: $X = \{1, 2, \dots, 31\}$.

> ⚠ **Non è una geometrica!**
>
> La geometrica richiede prove indipendenti. Qui le estrazioni sono **dipendenti**: ogni carta estratta riduce il mazzo e cambia le probabilità per le estrazioni successive.

Calcolo di $P(X = 4)$ con la probabilità composta:

$$P(X = 4) = \frac{30}{40} \cdot \frac{29}{39} \cdot \frac{28}{38} \cdot \frac{10}{37}$$

Chi vince il primo giocatore? Vince se X è dispari (estrae alle posizioni 1, 3, 5, ...):

$$P(\text{vince il } 1° \text{ giocatore}) = \sum_{\substack{i \text{ dispari} \\ 1 \leq i \leq 31}} p_X(i)$$

00 - Obsidian Notes/2° Anno/2° Semestre/Metodi Statistici dell' Informazione/Lezione 5.md

MSI — Lezione 5: Varianza, Disuguaglianza di Chebyshev e Convergenza della Frequenza

Docente: Prof. Marco Lops | **Corso:** Metodi Statistici per l'Informazione | **CFU:** 6 | **Data:** 19/03/2026

Argomenti trattati

- Varianza come misura dell'aleatorietà: interpretazione fisica e geometrica
- Disuguaglianza di Markov e disuguaglianza di Chebyshev

- Relazione varianza–media: quando la media è un buon indicatore
- Proprietà algebriche di media e varianza (linearità, covarianza per scala, invarianza per traslazione)
- Giustificazione matematica della definizione frequentistica di probabilità
- Convergenza in media quadratica e in probabilità della frequenza di successo
- Legge dei grandi numeri: versione forte e debole
- Esercizio: strategia di gioco con puntata costante (geometrica) e martingala
- Annuncio: prossima lezione su coppie di variabili aleatorie

Varianza come Misura dell'Aleatorietà

Interpretazione

La media statistica μ_X è il baricentro della distribuzione. La **varianza** σ_X^2 misura quanto i valori di X si discostano mediamente da quel baricentro.

Definizione: Varianza e Deviazione Standard

Data una variabile aleatoria X con media μ_X, si definisce:

$$\sigma_X^2 = E[(X - \mu_X)^2] = \sum_{x \in \mathcal{X}} (x - \mu_X)^2 \cdot p_X(x)$$

La **deviazione standard** è $\sigma_X = \sqrt{\sigma_X^2}$. Per costruzione, $\sigma_X^2 \geq 0$.

La coppia (μ_X, σ_X) caratterizza globalmente una variabile aleatoria:

- Se $\sigma_X \ll \mu_X$: la variabile è **poco aleatoria**, concentrata intorno alla media. La media è un buon indicatore.
- Se σ_X è comparabile o superiore a μ_X: la variabile è **molto aleatoria**. Osservare valori molto lontani dalla media è probabile. La media da sola non descrive bene il comportamento tipico.

Esempio con deviazione standard 1€ vs 10€

Se il professore ha mediamente 100€ in tasca:

- Con \sigma_X = 1€: con probabilità 99% trovo tra 90 e 110€. La media è quasi deterministica.
- Con \sigma_X = 10€: con probabilità 90% trovo tra 90 e 110€. Alta incertezza.

La quantità rilevante è il **rapporto** μ_X / σ_X (inverso del coefficiente di variazione): più è grande, meno è aleatoria la variabile.

Disuguaglianza di Chebyshev

Disuguaglianza di Markov (prerequisito)

Per ogni variabile aleatoria **non negativa** Y e ogni $\delta > 0$:

$$P(Y \geq \delta) \leq \frac{E[Y]}{\delta}$$

Disuguaglianza di Chebyshev

Applicando la disuguaglianza di Markov alla variabile non negativa $Y = (X - \mu_X)^2$ con $\delta = (k\sigma_X)^2$:

Disuguaglianza di Chebyshev

Per ogni variabile aleatoria X di media μ_X e deviazione standard σ_X, e per ogni $k > 0$:

$$P(|X - \mu_X| \geq k\sigma_X) \leq \frac{1}{k^2}$$

Equivalentemente:

$$P(|X - \mu_X| < k\sigma_X) \geq 1 - \frac{1}{k^2}$$

Interpretazione: la probabilità di trovare X a una distanza superiore a k deviazioni standard dalla media è al più $1/k^2$, indipendentemente dalla forma specifica della distribuzione.

Applicazione numerica

Con $k = 10$: $P(|X - \mu_X| \geq 10\sigma_X) \leq 1\%$. Qualunque sia la distribuzione di X, osservare un valore a più di 10 deviazioni standard dalla media ha probabilità inferiore all'1%.

Proprietà Algebriche di Media e Varianza

Linearità della media

Per costanti reali a e b:

$$E[aX + b] = a \cdot E[X] + b$$

Dimostrazione: b è deterministica (non aleatoria), quindi esce fuori dall'operatore E. Anche a è deterministica e fattorizza:

$$E[aX + b] = E[aX] + E[b] = a\,E[X] + b$$

Comportamento della varianza

$$\sigma^2_{aX+b} = a^2\sigma^2_X$$

Due proprietà distinte:

1. **Invarianza per traslazione:** la varianza di $aX + b$ è uguale a quella di aX. Un termine additivo b sposta la distribuzione ma non la allarga né la restringe.
2. **Covarianza quadratica per scala:** un fattore moltiplicativo a scala la deviazione standard di $|a|$ e la varianza di a^2.

Dimostrazione:

$$\sigma^2_{aX+b} = E[(aX + b - (a\mu_X + b))^2] = E[(a(X - \mu_X))^2] = a^2E[(X - \mu_X)^2] = a^2\sigma^2_X$$

⚠ **Conseguenza importante**

Se $\sigma^2_X = 0$, la variabile aleatoria è quasi certamente uguale alla sua media: per la disuguaglianza di Chebyshev, per ogni $\varepsilon > 0$, $P(|X - \mu_X| > \varepsilon) \to 0$.

Giustificazione Matematica della Probabilità Frequentistica

La frequenza di successo come variabile aleatoria

Il professore mostra rigorosamente perché la definizione frequentistica di probabilità è matematicamente fondata. Si effettuano n prove indipendenti di un esperimento e si conta quante volte l'evento A si verifica.

La frequenza di successo è essa stessa una variabile aleatoria:

$$F_n(A) = \frac{N_A(\omega)}{n}$$

dove $N_A(\omega)$ è il numero di occorrenze di A in n prove. Ogni volta che si ripete il blocco di n prove, N_A può assumere un valore diverso.

N_A è un conteggio Binomiale:

Se le prove sono indipendenti, $N_A \sim B(n, P(A))$, perché contiamo il numero di successi (verificarsi di A) in n prove indipendenti, ciascuna con probabilità $P(A)$.

Di conseguenza:

$$E[N_A] = n \cdot P(A) \qquad \Rightarrow \qquad E[F_n(A)] = \frac{E[N_A]}{n} = P(A)$$

$$\mathrm{Var}(N_A) = n \cdot P(A) \cdot (1 - P(A)) \qquad \Rightarrow \qquad \mathrm{Var}(F_n(A)) = \frac{P(A)(1 - P(A))}{n}$$

Convergenza al crescere di n

$$\lim_{n \to \infty} \mathrm{Var}(F_n(A)) = \lim_{n \to \infty} \frac{P(A)(1 - P(A))}{n} = 0$$

Quando la varianza tende a zero, la variabile aleatoria si concentra attorno alla sua media. Quindi $F_n(A) \to P(A)$ in due sensi precisi:

Legge dei Grandi Numeri (forme)

Convergenza in media quadratica: $E[(F_n(A) - P(A))^2] \to 0$ quando $n \to \infty$, perché coincide con la varianza di $F_n(A)$.

Convergenza in probabilità (da Chebyshev): per ogni $\varepsilon > 0$:

$$P(|F_n(A) - P(A)| > \varepsilon) \leq \frac{\mathrm{Var}(F_n(A))}{\varepsilon^2} = \frac{P(A)(1 - P(A))}{n\varepsilon^2} \to 0$$

Convergenza con probabilità 1 (Legge forte dei grandi numeri, non dimostrata): l'evento che $F_n(A) \to P(A)$ ha probabilità esattamente 1.

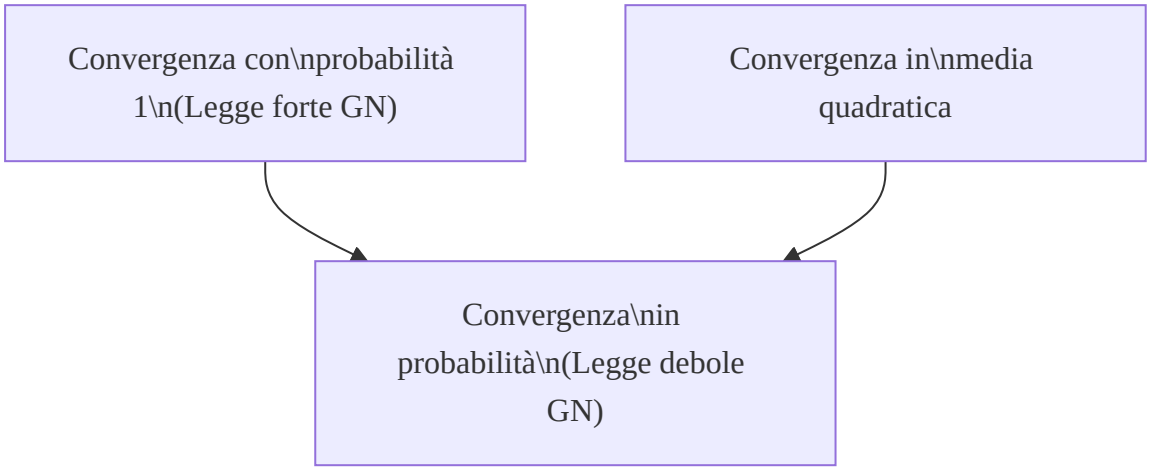

Le frecce indicano implicazioni. Convergenza con prob. 1 e convergenza in media quadratica sono entrambe **forti**, ma non si implicano a vicenda. Entrambe implicano la convergenza in probabilità (la più debole).

Quote

"La probabilità è definita come il limite della frequenza di successo. Questo ha senso matematico rigoroso: la frequenza converge alla probabilità in media quadratica e in probabilità. La nostra definizione era corretta fin dall'inizio."

Nota sul problema circolare

La definizione frequentistica richiede che le prove siano **indipendenti** — ma l'indipendenza è essa stessa un concetto probabilistico. L'approccio formale (assiomi di Kolmogorov) risolve questo problema: si definisce prima la probabilità assiomaticamente, poi si dimostra che la frequenza converge a essa.

> **Quote**
>
> "Il professore Conte me lo contesta sempre: per definire la probabilità usi la frequenza, ma per dire che è una frequenza hai bisogno dell'indipendenza, che è un concetto probabilistico. È il cane che si morde la coda. In realtà non serve strettamente l'indipendenza: basta un'asintotica indipendenza."

Esercizio: Strategie di Gioco al Casinò

Setup

Un giocatore ha una somma S e adotta diverse strategie in un gioco dove la probabilità di vincita è a e, in caso di vittoria, riceve b volte la posta puntata.

Strategia A: Punta costante (1€ per volta)

Variabile aleatoria: X = numero di puntate effettuate.

Alfabeto: $X = \{1, 2, \dots, S\}$.

PMF:

- Per $k < S$: $P(X = k) = (1 - a)^{k-1} \cdot a$ (vince alla k-esima puntata dopo $k - 1$ fallimenti)
- Per $k = S$: il giocatore fa l'ultima puntata comunque, sia che vinca che perda. Quindi $P(X = S) = (1 - a)^{S-1}$ (equivalente a: perde le prime $S - 1$ puntate, poi gioca la S-esima indipendentemente dall'esito).

> **Semplificazione per $k = S$**
>
> Non importa se l'ultima puntata viene vinta o persa: il giocatore si alza in entrambi i casi. Quindi l'evento $\{X = S\}$ coincide con "perde le prime $S - 1$ puntate", con probabilità $(1 - a)^{S-1}$.

Questa distribuzione è **quasi geometrica** (la coda è troncata a S).

Guadagno: Se vince alla k-esima puntata, il guadagno è $b - k$ (riceve b euro, ne ha spesi k). Se $X = S$ senza vincere l'ultima, il guadagno è $-S$.

Strategia B: Martingala (raddoppio dopo ogni perdita)

Alla k-esima puntata si punta 2^{k-1} euro. La somma totale puntata fino alla puntata k-esima è:

$$\sum_{i=1}^{k} 2^{i-1} = 2^k - 1$$

Il numero massimo di puntate intere prima di esaurire la somma S è:

$$x_{max} = \lfloor \log_2(S + 1) \rfloor$$

Guadagno se vince alla k**-esima puntata:**

$$g(k) = b \cdot 2^{k-1} - (2^k - 1) = (b - 2) \cdot 2^{k-1} + 1$$

Per la roulette ($b = 36$, $a = 18/37$): $g(k) = 34 \cdot 2^{k-1} + 1$.

⚠ Paradosso della martingala

Se il limite di puntata $S \to \infty$ (patrimonio infinito, nessun limite), la martingala garantisce di vincere con probabilità 1 — ed è per questo che i casinò impongono un **limite massimo di puntata**. Con un qualunque limite finito S, il guadagno medio è negativo per il giocatore (il banco ha sempre un vantaggio statistico).

Quote

"Il guadagno medio per $S \to \infty$ diverge. Ma attenzione: fare il limite di S al denominatore non è lo stesso che calcolare il guadagno con S infinito. La convergenza è in probabilità, non puntuale. Questo è un esempio di convergenza in probabilità che non implica nulla sul limite dei valori attesi."

Punti chiave della lezione

- La **varianza** misura l'aleatorietà: σ_X^2 piccolo significa variabile concentrata intorno alla media. La coppia (μ_X, σ_X) caratterizza globalmente X.
- La **disuguaglianza di Chebyshev** quantifica quanto raramente una variabile si discosta dalla media: $P(|X - \mu_X| \geq k\sigma_X) \leq 1/k^2$.
- **Media** è lineare: $E[aX + b] = aE[X] + b$. **Varianza** è invariante per traslazione e covariante per scala: $Var(aX + b) = a^2 Var(X)$.

- La **frequenza di successo** $F_n(A)$ è una variabile aleatoria con $E[F_n(A)] = P(A)$ e $Var(F_n(A)) = P(A)(1 - P(A))/n \to 0$. Quindi $F_n(A) \to P(A)$ in media quadratica e in probabilità (legge dei grandi numeri).
- La convergenza in media quadratica e quella con probabilità 1 sono entrambe forti e implicano quella in probabilità, ma non si implicano a vicenda.

Prossimi argomenti

- [ ] Coppie di variabili aleatorie (variabili aleatorie congiunte)
- [ ] PMF congiunta, marginale e condizionale
- [ ] Indipendenza tra variabili aleatorie
- [ ] Covarianza e correlazione

#MSI #varianza #deviazione-standard #Chebyshev #convergenza #frequenza #martingala #legge-grandi-numeri

00 - Obsidian Notes/2° Anno/2° Semestre/Metodi Statistici dell' Informazione/Lezione 2.md

MSI --- Lezione 2: Teoria Assiomatica della Probabilita, Bayes e Variabili Aleatorie

Docente: Prof. Marco Lops | **Corso:** Metodi Statistici per l'Informazione | **CFU:** 6

Argomenti trattati

- Riepilogo dell'analisi combinatoria (k-uple ordinate, non ordinate, con/senza ripetizione, coefficiente binomiale)
- Riepilogo della definizione frequentistica e delle proprietà derivate (complementare, unione, differenza)
- Riepilogo della probabilità condizionata e della frequenza condizionale
- Legge della probabilità composta e legge di Bayes (approccio frequentistico)
- Legge della probabilità totale (partizioni di Ω)
- Limiti dell'approccio frequentistico e necessità della teoria formale
- Algebra e σ-algebra di eventi: definizione e proprietà di chiusura
- Spazio di probabilità (Ω, E, P) e assiomi di Kolmogorov
- Derivazione rigorosa delle proprietà della probabilità dagli assiomi
- Indipendenza stocastica: definizione, proprietà dei complementari, indipendenza di n eventi
- Indipendenza a coppie vs. indipendenza congiunta: controesempio del bit di parità
- Esercizio: probabilità con n eventi indipendenti (nessuno, almeno uno, esattamente uno)

- La probabilità condizionata come legge di probabilità (verifica degli assiomi)
- Esercizio: bussolotto con dado onesto e dado truccato (applicazione di Bayes)
- Introduzione alle variabili aleatorie discrete e alla PMF
- Cenno al valore atteso

Riepilogo: Analisi Combinatoria

Il professore apre la lezione richiamando i risultati fondamentali dell'analisi combinatoria trattati nelle lezioni precedenti. La motivazione originale era quella di calcolare la probabilità di un evento sotto l'ipotesi che tutti gli eventi elementari siano equiprobabili, ovvero "equivalenti": in tal caso la probabilità si calcola come rapporto tra il numero di casi favorevoli e il numero di casi possibili, e il problema si riduce a **saper contare** gli elementi di un insieme.

Dato un insieme di n elementi:

- Il numero di k-**uple ordinate di elementi distinti** (disposizioni semplici) e:

$$D_{n,k} = \frac{n!}{(n-k)!}$$

- Il numero di k-**uple ordinate con ripetizione** e:

$$n^k$$

- Il numero di k-**uple non ordinate** (combinazioni semplici) si ottiene dividendo le disposizioni per il numero di permutazioni di k elementi su k posti, cioe $k!$:

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$

dove $\binom{n}{k}$ e il **coefficiente binomiale**.

Questo coefficiente conta anche il numero di **sequenze binarie** di lunghezza n con esattamente k uni (e $n-k$ zeri).

> **Quote**
>
> "Aritmetica deriva dal greco *arithmos*, che vuol dire numero. Quindi questi esercizi numerologici, ho detto si, va bene, ma spesso gli eventi elementari non sono equiprobabili."

Riepilogo: Proprietà dalla Definizione Frequentistica

Ricordando che la probabilità di un evento A e definita come il limite della frequenza di successo:

$$P(A) = \lim_{n \to \infty} f_n(A) = \lim_{n \to \infty} \frac{N_A}{n}$$

dove N_A e il numero di volte in cui l'evento A si verifica su n prove, si ricavano le seguenti proprietà come conseguenze dirette delle operazioni tra insiemi.

Evento complementare

Se A si verifica N_A volte su n prove, il suo complementare A^c contiene tutti e soli gli elementi di Ω che non sono presenti in A, e si verifica $n - N_A$ volte:

$$f_n(A^c) = \frac{n - N_A}{n} = 1 - f_n(A) \qquad \Longrightarrow \qquad P(A^c) = 1 - P(A)$$

Unione di eventi (subadditività)

Se A e B sono due eventi contenuti in Ω, l'evento $A \cup B$ contiene tutti e soli gli elementi che appartengono ad A, oppure a B, oppure a entrambi. Il numero di volte in cui si verifica $A \cup B$ su n prove e $N_A + N_B - N_{A \cap B}$ (si sottrae l'intersezione per non contarla due volte):

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Se A e B sono **eventi incompatibili** ($A \cap B = \emptyset$ non possono mai verificarsi insieme):

$$P(A \cup B) = P(A) + P(B)$$

La probabilità come misura

Il professore offre un'interpretazione geometrica: la probabilità e un modo per misurare le "dimensioni" di un evento. L'area di $A \cup B$ e la somma delle aree se i due insiemi sono disgiunti; se non lo sono, bisogna sottrarre l'area dell'intersezione. La probabilità si comporta esattamente come una misura di area.

Differenza di eventi

L'evento $A \setminus B$ contiene tutti e soli gli elementi di A che non appartengono a B. Il numero di volte in cui si verifica $A \setminus B$ e $N_A - N_{A \cap B}$:

$$P(A \setminus B) = P(A) - P(A \cap B)$$

Riepilogo: Probabilità Condizionata e Frequenza Condizionale

Il professore richiama il concetto fondamentale di **frequenza condizionale**.

La frequenza condizionale dell'evento A dato che si e verificato B si costruisce **restringendo l'analisi** ai soli elementi che soddisfano la condizione B: nell'ambito di questi elementi, si contano quanti soddisfano anche la condizione A. Questi elementi soddisfano dunque sia A che B.

$$f_n(A \mid B) = \frac{N_{A \cap B}}{N_B} = \frac{N_{A \cap B}/n}{N_B/n} = \frac{f_n(A \cap B)}{f_n(B)}$$

Passando al limite:

Definizione: Probabilità condizionata

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}, \qquad P(B) > 0$$

La probabilità che si verifichi A, dato che si e verificato B, e il rapporto tra la probabilità che si verifichino entrambi e la probabilità di B.

$P(B)$ deve essere diverso da zero

La definizione di probabilità condizionata perde significato se $P(B) = 0$, perche si avrebbe una divisione per zero.

Scambiando A e B:

$$P(B \mid A) = \frac{P(A \cap B)}{P(A)}$$

Notando che $B \cap A = A \cap B$ (l'intersezione e commutativa), si ha:

$$P(A \cap B) = P(A) \cdot P(B \mid A) = P(B) \cdot P(A \mid B)$$

Definizione: Legge della probabilità composta

$$P(A \cap B) = P(A) \cdot P(B \mid A) = P(B) \cdot P(A \mid B)$$

La probabilità dell'intersezione di due eventi si puo esprimere sia come $P(A)$ per la condizionale $P(B \mid A)$, sia come $P(B)$ per la condizionale $P(A \mid B)$.

Legge di Bayes

Uguagliando le due espressioni della probabilità composta si ottiene una legge fondamentale:

Definizione: Legge di Bayes

$$P(B \mid A) = \frac{P(A \mid B) \cdot P(B)}{P(A)}$$

Se si conoscono le probabilità marginali $P(A)$ e $P(B)$ e la condizionale $P(A \mid B)$, si puo ricavare la condizionale "inversa" $P(B \mid A)$.

Quote

"Da questa legge ha preso nome tutta la statistica bayesiana, non so se l'avete mai sentita. In generale tutte le materie che si fondano sulla probabilità devono conoscere la statistica bayesiana."

Legge della Probabilità Totale

Definizione: Partizione

Si definisce **partizione** di Ω una collezione di m sottoinsiemi $\{E_1, E_2, \dots, E_m\}$ tali che:

1. siano a due a due disgiunti: $E_i \cap E_j = \emptyset$ per $i \neq j$;
2. la loro unione sia l'intero spazio: $\bigcup_{i=1}^{m} E_i = \Omega$.

Esempio concreto: i lastroni dell'aula

I lastroni sul pavimento di un'aula sono una partizione della stanza: la loro unione copre tutta la stanza e due lastroni diversi non si sovrappongono (hanno intersezione nulla).

Derivazione. Dato un qualunque evento A:

$$A = A \cap \Omega = A \cap \left(\bigcup_{i=1}^{m} E_i \right) = \bigcup_{i=1}^{m} (A \cap E_i)$$

dove si e usata la proprietà distributiva dell'intersezione rispetto all'unione. Gli insiemi $A \cap E_i$ e $A \cap E_j$ (con $i \neq j$) sono **disgiunti**: $A \cap E_i$ contiene tutti e soli gli elementi che appartengono sia ad A che ad E_i, mentre $A \cap E_j$ contiene quelli che appartengono sia ad A che ad E_j; ma E_i e E_j non hanno elementi comuni perche formano una partizione. Quindi:

$$P(A) = \sum_{i=1}^{m} P(A \cap E_i)$$

Usando la definizione di probabilità condizionata, $P(A \cap E_i) = P(A \mid E_i) \cdot P(E_i)$:

Definizione: Legge della probabilità totale

$$P(A) = \sum_{i=1}^{m} P(A \mid E_i) \cdot P(E_i)$$

La probabilità di un evento A si puo scomporre condizionando rispetto a una partizione dello spazio dei campioni.

Quote

"Questa legge, ragazzi, e importantissima. Si usa in tutti i calcoli probabilistici, in quasi tutti, perche a volte devo calcolare la probabilità di un evento ed e difficile, pero se mi metto in certe condizioni la devo scomporre in calcoli piu semplici. La useremo, la vedremo, ve la farò vedere negli esercizi."

Limiti dell'Approccio Frequentistico

Tutte le proprietà ricavate finora --- complementare, unione, differenza, probabilità condizionata, legge di Bayes, legge della probabilità totale --- derivano dalla definizione frequentistica (limite della frequenza di successo) e sono conseguenze delle proprietà delle operazioni tra insiemi.

Tuttavia questa impostazione presenta due problemi fondamentali:

1. **Convergenza non specificata:** non si e detto in che senso la frequenza di successo converge a un valore stabile; le prove devono essere indipendenti, ma l'indipendenza e essa stessa un concetto probabilistico (circolarità).
2. **Generalità non garantita:** non c'e a priori nessuna garanzia che le proprietà trovate sotto certe ipotesi valgano in generale.

Quote

"Io vi ho promesso che vi avrei definito in modo piu rigoroso la probabilità. Tutto questo zoppica dal punto di vista non solo matematico, ma concettuale."

Il professore spiega perche ha comunque usato l'approccio frequentistico: in quella cornice tutte le proprietà sono **conseguenze immediate** della teoria degli insiemi. Nell'approccio formale che segue, le stesse proprietà diventano **teoremi da dimostrare**.

Teoria Formale: Algebra di Eventi

Algebra

Dato uno spazio dei campioni Ω, consideriamo una collezione E di sottoinsiemi di Ω.

Definizione: Algebra

Una collezione E di sottoinsiemi di Ω si chiama **algebra** se soddisfa due proprietà:

1. **Chiusura rispetto all'unione:** se $A_i \in E$ e $A_j \in E$, allora $A_i \cup A_j \in E$;
2. **Chiusura rispetto alla complementazione:** se $A_i \in E$, allora $A_i^c \in E$.

Chiusura rispetto all'intersezione (dimostrazione via De Morgan)

Il professore chiede alla classe se l'algebra contiene anche l'intersezione di due suoi elementi, e guida la dimostrazione usando le **leggi di De Morgan**.

La legge di De Morgan afferma:

$$(A \cup B)^c = A^c \cap B^c$$

Complementando entrambi i membri:

$$A \cap B = (A^c \cup B^c)^c$$

Allora, se $A \in E$ e $B \in E$:

1. $A^c \in E$ e $B^c \in E$ (chiusura per complementazione);
2. $A^c \cup B^c \in E$ (chiusura per unione);
3. $(A^c \cup B^c)^c \in E$ (chiusura per complementazione).

Quindi $A \cap B \in E$. L'algebra e **chiusa anche rispetto all'intersezione**.

Chiusura rispetto alla differenza

Analogamente, $A \setminus B = A \cap B^c$: poiche $B^c \in E$ (chiusura per complementazione) e l'intersezione e chiusa, si ha $A \setminus B \in E$.

Tutte le operazioni insiemistiche restano nell'algebra

Unione, intersezione, complementazione e differenza di elementi dell'algebra producono sempre elementi dell'algebra. Questo garantisce che la funzione di probabilità possa essere calcolata su qualunque combinazione di eventi: si resta sempre nel dominio di definizione.

La piu piccola algebra contenente un evento

Esempio: dado e evento "risultato pari"

Sia $\Omega = \{1, 2, 3, 4, 5, 6\}$ e $A = \{2, 4, 6\}$ l'evento "risultato pari". La piu piccola algebra che contiene A e:

$$E_{min} = \{\emptyset, \Omega, A, A^c\}$$

Costruzione passo per passo:

- se c'e A, ci deve essere il suo complemento $A^c = \{1, 3, 5\}$;
- se ci sono A e A^c, la loro unione $A \cup A^c = \Omega$ deve appartenere;
- se c'e Ω, il suo complemento $\emptyset$deve appartenere.

L'insieme delle parti 2^Ω e anch'esso un'algebra, ma e molto piu grande del necessario. Piu piccola di questi quattro elementi non e possibile.

Quote

"Non vi fate mai spaventare dai paroloni della matematica."

σ-Algebra

Definizione: σ-algebra

Un'algebra E si chiama **σ-algebra** se un'**unione numerabile** di suoi elementi e ancora un elemento dell'algebra:

$$A_1, A_2, A_3, \ldots \in E \quad \Longrightarrow \quad \bigcup_{i=1}^{\infty} A_i \in E$$

Algebra vs. σ-algebra

Un'algebra garantisce la chiusura per unioni **finite**. Una σ-algebra estende questa garanzia a unioni **numerabili** (infinite ma contabili). La distinzione e rilevante quando lo spazio dei campioni e numerabile.

Perche serve la σ-algebra

Siamo sull'autostrada e contiamo le macchine. Gli eventi elementari sono "non passa nessuna macchina", "passa una macchina", "passano due macchine", eccetera, fino potenzialmente a infinito. Per ogni insieme di questi eventi devo poter fare l'unione, anche all'infinito. Se Ω e

finito, la σ-algebra non aggiunge nulla rispetto all'algebra, perche le unioni finite sono gia sufficienti; la σ-algebra diventa necessaria quando Ω e numerabile.

Quote

"Sigma perche? Forse sommatoria, no? Simbolo della somma."

Spazio di Probabilità e Assiomi di Kolmogorov

A questo punto si dispone di uno spazio dei campioni Ω e di una σ-algebra E dei sottoinsiemi di Ω.

Definizione: Legge di probabilità (Kolmogorov)

Dato uno spazio dei campioni Ω e una σ-algebra E, si definisce **legge di probabilità** una funzione

$$P : E \to [0, 1]$$

che soddisfa i seguenti **assiomi di Kolmogorov** ("tre assiomi e mezzo"):

Assioma 1 --- Non negatività:

$$P(A) \geq 0 \quad \forall A \in E$$

Assioma 2 --- Normalizzazione:

$$P(\Omega) = 1$$

Assioma 3 --- Additività (o subadditività):
Se A e B sono eventi disgiunti ($A \cap B = \emptyset$):

$$P(A \cup B) = P(A) + P(B)$$

Assioma $3\frac{1}{2}$ --- σ-additività (estensione numerabile):
Se $\{A_i\}_{i=1}^{\infty}$ e una successione di eventi a due a due disgiunti:

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

La terna (Ω, E, P) prende il nome di **spazio di probabilità**.

Perche la struttura della σ-algebra e necessaria

La σ-algebra garantisce che tutte le operazioni insiemistiche (unione, intersezione, complementazione, differenza) restino nel dominio di definizione della funzione P. Senza questa struttura, non si potrebbe essere certi di poter calcolare P su combinazioni arbitrarie di eventi. Come dice il professore: "i matematici pensano: io resto nel dominio di definizione dell'algebra."

Quote

"Vedete che noi abbiamo fatto tutto questo ambaradan. Dice, ma e tutta questa cosa complicata? Tu metti le tue prove, fatti la frequenza di successo... Tutto quello che abbiamo ricavato, qua non c'e niente. Io ti faccio vedere che tutto quello che tu hai ricavato prima, usando quella definizione, se volete, un po' farlocca di probabilità, io te lo ricavo come unica conseguenza degli assiomi di Kolmogorov."

Derivazione delle Proprietà dagli Assiomi

Il professore mostra come le proprietà ricavate in modo "facile" dalla definizione frequentistica si dimostrino ora rigorosamente a partire dai **soli** assiomi di Kolmogorov.

Probabilità di $A \setminus B$

Si parte dall'identità insiemistica:

$$A = A \cap \Omega = A \cap (B \cup B^c) = (A \cap B) \cup (A \cap B^c)$$

dove si e usata la proprietà distributiva dell'intersezione rispetto all'unione. Ora si osserva che:

- $(A \cap B)$ contiene tutti e soli gli elementi che appartengono sia ad A che a B;
- $(A \cap B^c)$ contiene tutti e soli gli elementi che appartengono ad A ma **non** a B.

Questi due insiemi sono **disgiunti**. Per l'assioma 3 (σ-additività):

$$P(A) = P(A \cap B) + P(A \cap B^c)$$

Ma $A \cap B^c = A \setminus B$, quindi:

$$\boxed{P(A \setminus B) = P(A) - P(A \cap B)}$$

Osservazione

E la stessa formula trovata prima con la definizione frequentistica, ma ora e dimostrata rigorosamente a partire dagli assiomi.

Probabilità di $A \cup B$

Si scrive:

$$A \cup B = A \cup (B \cap A^c)$$

dove A e $B \cap A^c$ (gli elementi di B che non appartengono ad A) sono **disgiunti**. Quindi per l'assioma 3:

$$P(A \cup B) = P(A) + P(B \cap A^c)$$

Ma dalla proprietà appena dimostrata, $P(B \cap A^c) = P(B \setminus A) = P(B) - P(A \cap B)$ (si invertono i ruoli di A e B nella formula precedente):

$$\boxed{P(A \cup B) = P(A) + P(B) - P(A \cap B)}$$

Probabilità dell'evento complementare

L'evento A e il suo complementare A^c soddisfano $A \cup A^c = \Omega$ e sono incompatibili ($A \cap A^c = \emptyset$. Per l'assioma 3 (additività) e l'assioma 2 (normalizzazione):

$$P(A) + P(A^c) = P(A \cup A^c) = P(\Omega) = 1$$

$$\boxed{P(A^c) = 1 - P(A)}$$

Probabilità dell'evento impossibile

L'insieme vuoto $\emptyset$e il complemento di Ω:

$$P(\emptyset) = P(\Omega^c) = 1 - P(\Omega) = 1 - 1 = 0$$

Terminologia

L'insieme vuoto $\emptyset$si chiama **evento impossibile**; lo spazio dei campioni Ω si chiama **evento certo**.

Quote

"Riprendo il giro per dirvi quanto e pesante questo. Abbiamo trovato le cose prima, le abbiamo trovate in modo facile. Ora dimostrarle diventa un giochino, perche gia sappiamo il risultato che dobbiamo tirare."

Indipendenza Stocastica

Definizione: Indipendenza stocastica

Due eventi $A, B \in E$ si dicono **statisticamente indipendenti** se:

$$P(A \cap B) = P(A) \cdot P(B)$$

Quote

"La nozione di indipendenza e fondamentale e moltissima statistica inferenziale si fonda su ipotesi di indipendenza, perche senza indipendenza una serie di convergenze [non valgono]. Voi avete dei grandi database, giocate quei file Excel per ricavarvi una serie di parametri globali. E ci sono delle ipotesi alla base: ipotesi di ergodicità, che a loro volta indicano ipotesi di indipendenza, per lo meno tra campioni sufficientemente lontani. Se no, la statistica descrittiva vale solo per quel campione di dati. Non e generalizzabile."

Indipendenza dei complementari

Teorema: Se A e B sono statisticamente indipendenti, allora anche A^c e B^c sono statisticamente indipendenti.

Dimostrazione. Per le leggi di De Morgan:

$$A^c \cap B^c = (A \cup B)^c$$

Quindi:

$$P(A^c \cap B^c) = P((A \cup B)^c) = 1 - P(A \cup B)$$

Sostituendo la formula dell'unione:

$$= 1 - P(A) - P(B) + P(A \cap B)$$

Poiche A e B sono indipendenti, $P(A \cap B) = P(A) \cdot P(B)$:

$$= 1 - P(A) - P(B) + P(A) \cdot P(B)$$

Raccogliendo:

$$= 1 - P(A) - P(B)(1 - P(A)) = (1 - P(A))(1 - P(B)) = P(A^c) \cdot P(B^c)$$

$$\boxed{P(A^c \cap B^c) = P(A^c) \cdot P(B^c) \quad \checkmark}$$

Indipendenza di n eventi

Definizione: Indipendenza di n eventi

Tre eventi A, B e C si dicono **indipendenti** se lo sono **a 2 a 2** e **a 3 a 3**:

$$P(A \cap B) = P(A) \cdot P(B), \quad P(A \cap C) = P(A) \cdot P(C), \quad P(B \cap C) = P(B) \cdot P(C)$$

$$P(A \cap B \cap C) = P(A) \cdot P(B) \cdot P(C)$$

In generale, una n-upla di eventi $A_1, A_2, \dots, A_n$ e una n**-upla indipendente** se per ogni sottoinsieme $\{i_1, i_2, \dots, i_k\} \subseteq \{1, \dots, n\}$:

$$P(A_{i_1} \cap A_{i_2} \cap \cdots \cap A_{i_k}) = P(A_{i_1}) \cdot P(A_{i_2}) \cdots P(A_{i_k})$$

L'indipendenza di ordine n implica quella di ordine inferiore (da $n-1$ fino a 2), **ma non vale il viceversa**.

⚠ Indipendenza a coppie $\not\Rightarrow$ indipendenza congiunta

L'indipendenza a coppie **non** implica l'indipendenza della terna (o della n-upla). Un controesempio classico e il **bit di parità**.

Controesempio: il bit di parità

Il bit di parità

Siano X_1 e X_2 due bit equiprobabili e indipendenti, ciascuno con valore 0 o 1 con probabilità $\frac{1}{2}$. Si definisce il **bit di parità**:

$$X_3 = X_1 \oplus X_2$$

dove $\oplus$ denota la **somma modulo 2** (operazione XOR): $X_3 = 0$ se X_1 e X_2 sono uguali, $X_3 = 1$ se sono diversi, in modo che il numero di uni nella terna (X_1, X_2, X_3) sia sempre pari.

Risultato:

- X_1 e X_2 sono **indipendenti** (per ipotesi);
- X_1 e X_3 sono **indipendenti**;
- X_2 e X_3 sono **indipendenti**;
- ma la terna (X_1, X_2, X_3) **non** e indipendente.

Perche? Se si conoscono sia X_1 che X_2, il valore di X_3 e **completamente determinato** ($X_3 = X_1 \oplus X_2$). La probabilità non si puo fattorizzare: $P(X_1 = x_1, X_2 = x_2, X_3 = x_3) \neq P(X_1 = x_1) \cdot P(X_2 = x_2) \cdot P(X_3 = x_3)$. Ma se si conosce **uno solo** dei due bit, non si puo dedurre nulla sul terzo.

Esercizio: n Eventi Indipendenti

Siano $A_1, A_2, \dots, A_n$ eventi indipendenti, con $P(A_i) = p_i$. Si calcolino:

1. Probabilità che non se ne verifichi nessuno

L'evento "non si verifica nessuno" equivale a: non si verifica A_1, **e** non si verifica A_2, **e** ... **e** non si verifica A_n, cioe $A_1^c \cap A_2^c \cap \cdots \cap A_n^c$.

Poiche gli A_i sono indipendenti, abbiamo dimostrato che anche i loro complementari sono indipendenti. Quindi la probabilità dell'intersezione e il prodotto:

$$\boxed{P\left(\bigcap_{i=1}^{n} A_i^c\right) = \prod_{i=1}^{n} (1 - p_i)}$$

2. Probabilità che se ne verifichi almeno uno

L'evento "almeno uno" e il **complementare** dell'evento "nessuno": se ne verifica almeno uno se non e vero che non se ne verifica nessuno.

$$\boxed{P\left(\bigcup_{i=1}^{n} A_i\right) = 1 - \prod_{i=1}^{n} (1 - p_i)}$$

3. Probabilità che se ne verifichi esattamente uno (non importa quale)

L'evento "esattamente uno" si traduce come: **o** si verifica A_1 ma non $A_2, A_3, \ldots, A_n$; **oppure** non si verifica A_1 ma si verifica A_2 e non $A_3, \ldots, A_n$; **oppure** ... **oppure** non si verificano $A_1, \ldots, A_{n-1}$ ma si verifica A_n.

Formalmente:

$$(A_1 \cap A_2^c \cap \cdots \cap A_n^c) \cup (A_1^c \cap A_2 \cap A_3^c \cap \cdots \cap A_n^c) \cup \cdots \cup (A_1^c \cap \cdots \cap A_{n-1}^c \cap A_n)$$

Questi n eventi sono **disgiunti** (nel primo c'e A_1, nel secondo c'e A_2 ma non A_1, ecc.), quindi per la σ-additività e l'indipendenza:

$$\boxed{P(\text{esattamente uno}) = \sum_{i=1}^{n} p_i \prod_{\substack{j=1 \\ j \neq i}}^{n} (1 - p_j)}$$

> **Quote**
>
> "E solo logica, ragazzi, pero vi dico anche che questa logica non la dovete dimenticare, perche poi quando andiamo sulle variabili aleatorie e un po' piu numerica la cosa, pero dovete sempre ricordarvi questa logica. Dovete formulare opportunamente le proposizioni."

La Probabilità Condizionata come Legge di Probabilità

Un risultato importante: **fissato** B **con** $P(B) > 0$, la funzione $P(\cdot \mid B)$ soddisfa gli assiomi di Kolmogorov ed e quindi una legge di probabilità a tutti gli effetti.

Verifica dei tre assiomi:

Assioma 1 (Non negatività): $P(A \mid B) = \frac{P(A \cap B)}{P(B)} \geq 0$, poiche rapporto di due quantità non negative.

Assioma 2 (Normalizzazione):

$$P(\Omega \mid B) = \frac{P(\Omega \cap B)}{P(B)} = \frac{P(B)}{P(B)} = 1 \quad \checkmark$$

Assioma 3 (σ-additività): Siano A e C eventi disgiunti ($A \cap C = \emptyset$):

$$P(A \cup C \mid B) = \frac{P((A \cup C) \cap B)}{P(B)} = \frac{P((A \cap B) \cup (C \cap B))}{P(B)}$$

Ma se $A \cap C = \emptyset$ allora $(A \cap B)$ e $(C \cap B)$ sono disgiunti: $A \cap B$ contiene tutti e soli gli elementi che appartengono a B e ad A, $C \cap B$ contiene quelli che appartengono a B e a C, ma A e C non hanno elementi comuni. Quindi:

$$= \frac{P(A \cap B) + P(C \cap B)}{P(B)} = \frac{P(A \cap B)}{P(B)} + \frac{P(C \cap B)}{P(B)} = P(A \mid B) + P(C \mid B) \quad \checkmark$$

Dunque $P(\cdot \mid B)$ e una legge di probabilità.

Conseguenza per l'indipendenza

Se A e B sono indipendenti:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} = \frac{P(A) \cdot P(B)}{P(B)} = P(A)$$

Il verificarsi di B **non influisce minimamente** sulla probabilità di A: la probabilità condizionata coincide con quella incondizionata.

Piove a Napoli, Portici e Kathmandu

Sia A = "piove a Napoli", B = "piove a Portici", C = "piove a Kathmandu".

- $P(A \mid B) \neq P(A)$: se piove a Portici, e piu probabile che piova anche a Napoli (eventi **dipendenti**).
- $P(A \mid C) \approx P(A)$: sapere che piove a Kathmandu non da informazione utile sulla pioggia a Napoli (eventi approssimativamente **indipendenti**).

La probabilità a priori $P(A)$ si calcola guardando i record storici: quante volte ha piovuto a Napoli il 10 marzo, diviso il numero totale di anni registrati.

⚠ Spazio di probabilità e modellazione

Tutti gli spazi di probabilità sono **matematicamente equivalenti**. Per il lancio di una moneta:

- $P(\text{testa}) = 1,\ P(\text{croce}) = 0$ e legittimo (moneta con due teste);
- $P(\text{testa}) = P(\text{croce}) = \frac{1}{2}$ e legittimo (moneta onesta).

La scelta della legge di probabilità non e un problema matematico ma di **modellazione**: bisogna scegliere la legge che meglio descrive l'esperimento reale. Se si sbaglia la legge, non si sbaglia matematicamente, ma le predizioni non aderiscono alla realtà. Questo e il compito dell'**inferenza statistica**.

Esercizio: Bussolotto con Dado Onesto e Dado Truccato

Enunciato

Un bussolotto contiene due dadi indistinguibili per colore e peso. Un dado e **onesto**, l'altro e **truccato** in modo che il 6 esca con probabilità $\frac{1}{2}$ e tutti gli altri risultati siano equiprobabili. Si estrae un dado e lo si lancia **due volte**, ottenendo la coppia $(5, 5)$. Qual e la probabilità che il dado estratto sia quello truccato?

Modellazione del dado truccato

Per il **dado onesto** D_O, tutti i risultati sono equiprobabili:

$$P(X = i \mid D_O) = \frac{1}{6}, \quad i = 1, 2, \dots, 6$$

Per il **dado truccato** D_T, la probabilità che esca 6 e $\frac{1}{2}$ e gli altri risultati sono equiprobabili tra loro. Per trovare queste probabilità, si impone l'**assioma di normalizzazione** (la somma di tutte le probabilità deve valere 1):

$$P(\Omega) = P(X = 6) + \sum_{i=1}^{5} P(X = i) = \frac{1}{2} + 5p = 1 \quad \Longrightarrow \quad p = \frac{1}{10}$$

Quindi:

$$P(X = i \mid D_T) = \begin{cases} \frac{1}{2} & \text{se } i = 6 \\ \frac{1}{10} & \text{se } i \neq 6 \end{cases}$$

Impostazione con Bayes

Sia A = "il dado estratto e truccato" e B = "i due lanci danno (5, 5)". Si vuole calcolare $P(A \mid B)$.

Per la **legge di Bayes**:

$$P(A \mid B) = \frac{P(B \mid A) \cdot P(A)}{P(B)}$$

Calcolo di $P(B \mid A)$: probabilità di $(5, 5)$ con il dado truccato

Dato che si e estratto il dado truccato, i due lanci sono **condizionalmente indipendenti** (lo stesso dado viene lanciato due volte):

$$P(5, 5 \mid D_T) = \frac{1}{10} \cdot \frac{1}{10} = \frac{1}{100}$$

Calcolo di $P(B \mid D_O)$: probabilità di $(5, 5)$ con il dado onesto

$$P(5, 5 \mid D_O) = \frac{1}{6} \cdot \frac{1}{6} = \frac{1}{36}$$

Probabilità a priori

I dadi sono indistinguibili, quindi si estraggono con uguale probabilità:

$$P(D_T) = P(D_O) = \frac{1}{2}$$

Calcolo di $P(B)$ con la legge della probabilità totale

La partizione e $\{D_O, D_T\}$ (i due eventi sono mutuamente esclusivi):

$$P(B) = P(5, 5 \mid D_O) \cdot P(D_O) + P(5, 5 \mid D_T) \cdot P(D_T) = \frac{1}{36} \cdot \frac{1}{2} + \frac{1}{100} \cdot \frac{1}{2}$$

$$= \frac{1}{2}\left(\frac{1}{36} + \frac{1}{100}\right) = \frac{1}{2} \cdot \frac{100 + 36}{3600} = \frac{136}{7200} = \frac{17}{900}$$

Risultato

$$\boxed{P(D_T \mid 5, 5) = \frac{\frac{1}{100} \cdot \frac{1}{2}}{\frac{17}{900}} = \frac{\frac{1}{200}}{\frac{17}{900}} = \frac{900}{200 \cdot 17} = \frac{9}{34} \approx 0{,}265}$$

Interpretazione

La probabilità a posteriori che il dado sia truccato ($\approx$ 26,5%) e **minore** della probabilità a priori (50%). Questo ha senso: il 5 esce piu facilmente con il dado onesto ($\frac{1}{6} \approx$ 16,7%) che con il

truccato ($\frac{1}{10} = 10\%$), quindi osservare due 5 rende piu probabile che il dado sia quello onesto. Se fossero usciti due 6, il risultato sarebbe stato opposto.

Variante: reinserimento del dado

Il professore discute una variante proposta da uno studente: dopo il primo lancio si **rimette il dado nel bussolotto**, si mescola e si estrae nuovamente.

In questo caso i due lanci diventano **incondizionalmente indipendenti** (non solo condizionalmente), perche si ripristinano esattamente le stesse condizioni iniziali. La probabilità di ottenere 5 in un singolo lancio si calcola con la legge della probabilità totale:

$$P(X = 5) = P(5 \mid D_T) \cdot P(D_T) + P(5 \mid D_O) \cdot P(D_O) = \frac{1}{10} \cdot \frac{1}{2} + \frac{1}{6} \cdot \frac{1}{2} = \frac{1}{2}\left(\frac{1}{10} + \frac{1}{6}\right) = \frac{1}{2} \cdot \frac{4}{15}$$

E la probabilità della coppia $(5, 5)$ e semplicemente il **quadrato**:

$$P(5, 5) = \left(\frac{2}{15}\right)^2 = \frac{4}{225}$$

⚠ Indipendenza condizionale vs. incondizionale

- **Stesso dado, due lanci:** i lanci sono **condizionalmente indipendenti** dato il tipo di dado (D_T o D_O), ma **non** incondizionalmente indipendenti. Si puo scrivere $P(5, 5 \mid D_T) = P(5 \mid D_T)^2$, ma $P(5, 5) \neq P(5)^2$.
- **Reinserimento del dado:** ogni lancio e un esperimento completamente ripristinato, quindi i lanci sono **incondizionalmente indipendenti** e $P(5, 5) = P(5)^2$.

Introduzione alle Variabili Aleatorie

Motivazione: tre esperimenti, un unico trattamento

Il professore introduce le variabili aleatorie partendo da un'osservazione pratica. Tre esperimenti apparentemente diversi:

1. **Lancio di una moneta:** testa o croce;
2. **Sorgente binaria:** emette 0 o 1;
3. **Lancio di un dado:** risultato pari o dispari.

hanno tutti un esito **binario**. Codificando opportunamente (testa $\to$ 0, croce $\to$ 1; pari $\to$ 0, dispari $\to$ 1), si possono trattare in modo **unificato** attraverso un'applicazione che associa ad ogni esito dello spazio campione un valore numerico.

Definizione: Variabile aleatoria (caso discreto)

Dato uno spazio di probabilità (Ω, E, P) discreto, una **variabile aleatoria** e un'applicazione

$$X : \Omega \to X$$

dove X e un insieme numerico chiamato **alfabeto** della variabile aleatoria. La funzione X associa ad ogni esito $\omega \in \Omega$ un valore numerico $X(\omega) \in X$.

Perche le variabili aleatorie sono utili

Consentono di trattare in modo unificato esperimenti diversi che hanno la stessa struttura probabilistica. Ogni insieme discreto non numerico si puo sempre descrivere attraverso un insieme di numeri interi (ad esempio, puntatori a locazioni di memoria dove sono memorizzate le etichette). Quindi, quando lo spazio dei campioni e discreto, si possono indicizzare gli eventi elementari e la variabile aleatoria diventa semplicemente l'indice che denota quell'evento elementare.

Stringhe binarie di lunghezza k

Le stringhe binarie di lunghezza k sono 2^k. Ciascuna stringa puo essere memorizzata in una locazione di memoria; la variabile aleatoria assume il valore i dove i e il puntatore alla locazione della i-esima configurazione. Si ottiene cosi una variabile aleatoria che assume 2^k possibili valori.

Cenno alla misurabilità

Il professore accenna al fatto che, per essere rigorosi, una variabile aleatoria deve essere un'**applicazione misurabile**: l'anti-immagine di ogni evento concernente X deve essere un elemento della σ-algebra. Questa condizione garantisce che si possa calcolare la probabilità che X assuma certi valori. Tuttavia, per il livello del corso, e sufficiente la definizione semplificata.

Quote

"Queste cose le ho studiate perche mi sono servite per la mia ricerca, e manco sono sicuro che mi siano servite veramente perche il mio advisor di dottorato era sadico e mi metteva in mano certi libri. Pero se uno deve fare ricerca in questo campo, e bene che certe cose le faccia."

Evento elementare nello spazio della variabile aleatoria

L'evento elementare diventa $\{X(\omega) = x\}$, cioe l'insieme di tutti gli $\omega \in \Omega$ tali che $X(\omega) = x$:

$$P(X = x) = P(\{\omega \in \Omega : X(\omega) = x\})$$

La probabilità si "trasporta" dallo spazio di probabilità originario al nuovo spazio numerico.

Parità del lancio di un dado onesto

Sia $\Omega = \{1, 2, 3, 4, 5, 6\}$ e si definisca:

$$X(\omega) = \begin{cases} 0 & \text{se } \omega \in \{2, 4, 6\} \text{ (risultato pari)} \\ 1 & \text{se } \omega \in \{1, 3, 5\} \text{ (risultato dispari)} \end{cases}$$

Allora, poiche il dado e onesto e gli eventi $\{2\}, \{4\}, \{6\}$ sono incompatibili:

$$P(X = 0) = P(\{2, 4, 6\}) = \frac{1}{6} + \frac{1}{6} + \frac{1}{6} = \frac{1}{2}$$

$$P(X = 1) = 1 - P(X = 0) = \frac{1}{2}$$

Essendo la variabile binaria, una volta calcolata una probabilità non c'e bisogno di calcolare l'altra.

Doppio lancio di una moneta onesta

$\Omega = \{TT, TC, CT, CC\}$ (dove T = testa, C = croce). Si puo definire una variabile aleatoria X che assume i valori $\{0, 1, 2, 3\}$ (oppure $\{1, 2, 3, 4\}$, la scelta e arbitraria), ciascuno con probabilità $\frac{1}{4}$ per una moneta onesta: $P = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}$.

Probability Mass Function (PMF)

Definizione: PMF (funzione di massa di probabilità)

Data una variabile aleatoria discreta X con alfabeto $X = \{x_1, x_2, \dots, x_m\}$ (dove $m = |X|$ e la cardinalità dell'alfabeto), la **PMF** (Probability Mass Function) e la sequenza:

$$p_X(x_i) = P(X = x_i), \quad i = 1, 2, \dots, m$$

Una sequenza di m numeri e una PMF valida **se e solo se**:

1. $p_X(x_i) \geq 0$ per ogni i (non negatività --- Assioma 1 di Kolmogorov);
2. $\sum_{i=1}^{m} p_X(x_i) = 1$ (normalizzazione --- Assioma 2 di Kolmogorov).

Dalla normalizzazione e dalla non negatività segue automaticamente che $p_X(x_i) \leq 1$ per ogni i (la somma di numeri positivi e 1, quindi ogni singolo numero e al piu 1).

Verifica di una PMF

La sequenza $(\frac{1}{2}, \frac{1}{4}, \frac{1}{8}, \frac{1}{8})$ e una PMF valida?

$$\frac{1}{2} + \frac{1}{4} + \frac{1}{8} + \frac{1}{8} = \frac{4}{8} + \frac{2}{8} + \frac{1}{8} + \frac{1}{8} = \frac{8}{8} = 1 \quad \checkmark$$

Tutti i termini sono non negativi e la somma e 1: **si**, e una PMF valida.

PMF del lancio singolo e del doppio lancio

- **Lancio singolo** di una moneta onesta: la PMF e $(\frac{1}{2}, \frac{1}{2})$, due valori (variabile binaria).
- **Doppio lancio** di una moneta onesta: la PMF e $(\frac{1}{4}, \frac{1}{4}, \frac{1}{4}, \frac{1}{4})$, quattro valori.

Cenno al Valore Atteso (Media)

Il professore anticipa brevemente il concetto di **valore atteso**. Per una variabile aleatoria binaria X con $P(X = 0) = P(X = 1) = \frac{1}{2}$, chiede alla classe: "Qual e la media di questa variabile aleatoria?"

La risposta e $\frac{1}{2}$, e il ragionamento frequentistico che porta a questa risposta e il seguente:

Se si fanno n prove e si osservano le realizzazioni $X(\omega_1), X(\omega_2), \dots, X(\omega_n)$, la **media aritmetica** e:

$$\bar{X}_n = \frac{1}{n} \sum_{k=1}^{n} X(\omega_k) = \frac{1}{n}(0 \cdot n_0 + 1 \cdot n_1) = \frac{n_1}{n}$$

dove n_0 e il numero di volte in cui esce 0 e $n_1 = n - n_0$ e il numero di volte in cui esce 1. Quando $n \to \infty$:

$$\bar{X}_n \xrightarrow{n \to \infty} 0 \cdot P(X = 0) + 1 \cdot P(X = 1) = \frac{1}{2} \overset{\text{def}}{=} E[X]$$

Quote

"Voi avete automaticamente detto, guarda, se io faccio n prove, la meta delle volte mi viene 0, la meta delle volte mi viene 1. Voi ragionate inevitabilmente sulla frequenza di successo."

⚠ Attenzione

Il risultato $E[X] = \frac{1}{2}$ vale perche la variabile e **equiprobabile**. Il fatto che la media aritmetica converga al valore atteso e un risultato profondo che sarà formalizzato nelle lezioni successive.

Punti chiave della lezione

- Le proprietà della probabilità derivate dalla frequenza di successo sono confermate dalla teoria assiomatica, dove diventano **teoremi** dimostrabili dai soli assiomi di Kolmogorov.
- Un'**algebra** e una collezione di sottoinsiemi chiusa rispetto a unione e complementazione; la chiusura rispetto a intersezione e differenza segue dalle leggi di De Morgan.
- Una **σ-algebra** estende la chiusura a unioni numerabili, ed e necessaria quando Ω e infinito numerabile.
- Lo **spazio di probabilità** (Ω, E, P) e il fondamento rigoroso della probabilità: P deve soddisfare non negatività, normalizzazione e σ-additività.
- La **legge della probabilità composta** esprime $P(A \cap B)$ come $P(A) \cdot P(B \mid A)$ o $P(B) \cdot P(A \mid B)$.
- La **legge di Bayes** consente di invertire il condizionamento: da $P(A \mid B)$ a $P(B \mid A)$.
- La **legge della probabilità totale** permette di scomporre $P(A)$ condizionando rispetto a una partizione.
- L'**indipendenza stocastica** e definita da $P(A \cap B) = P(A) \cdot P(B)$; se due eventi sono indipendenti, lo sono anche i loro complementari.
- L'**indipendenza a coppie** non implica l'indipendenza congiunta (controesempio: bit di parità).
- La **probabilità condizionata** $P(\cdot \mid B)$ e essa stessa una legge di probabilità (soddisfa tutti gli assiomi di Kolmogorov).
- Una **variabile aleatoria** e un'applicazione da Ω a un insieme numerico; la **PMF** ne caratterizza completamente la distribuzione nel caso discreto.
- La **media aritmetica** delle osservazioni converge al valore atteso $E[X]$, concetto che sarà formalizzato nelle prossime lezioni.

Prossimi argomenti

- [ ] Ripasso e ulteriori esercizi su probabilità condizionata, Bayes e indipendenza
- [ ] Approfondimento sulle variabili aleatorie discrete
- [ ] Valore atteso e momenti
- [ ] Variabili aleatorie congiunte

#MSI #probabilità #sigma-algebra #assiomi #Kolmogorov #Bayes #probabilità-totale #probabilità-composta #indipendenza #variabili-aleatorie #PMF #partizione

00 - Obsidian Notes/2° Anno/2° Semestre/Metodi Statistici dell' Informazione/Lezione 6.md

Lezione 6: PMF Congiunta, Variabili Aleatorie Multiple e Indipendenza

Corso: Modelli Statistici e Probabilità

Argomenti trattati

- Riepilogo: caratterizzazione di una singola variabile aleatoria
- Coppia di variabili aleatorie: definizione e PMF congiunta
- Proprietà di marginalizzazione
- Indipendenza statistica tra variabili aleatorie
- Estensione a terne e n-uple di variabili aleatorie
- PMF condizionale per coppie
- Esempio: terne di bit (sorgente senza memoria vs. bit di parità)

---

1. Riepilogo: singola variabile aleatoria

Una singola variabile aleatoria discreta X è completamente caratterizzata dalla sua **PMF** (Probability Mass Function) $p_X(x)$, che assegna a ogni valore x dell'alfabeto la probabilità $P(X = x)$.

Dalla PMF si derivano:

- **Media** (valore atteso): $E[X] = \sum_x x \cdot p_X(x)$
- **Teorema fondamentale per il calcolo della media**: $E[g(X)] = \sum_x g(x) \cdot p_X(x)$
- **Momenti**: $E[X^m]$ (momento di ordine m), $E[(X - E[X])^m]$ (momento centrale)
- **Varianza**: $Var(X) = E[(X - E[X])^2] = E[X^2] - (E[X])^2$
- **Disuguaglianza di Chebyshev**: $P(|X - E[X]| \geq k\sigma) \leq \frac{1}{k^2}$, dove σ è la deviazione standard

---

2. Coppia di variabili aleatorie

Motivazione

In molte applicazioni si osservano più grandezze contemporaneamente sullo stesso esperimento. Per esempio, su un database di persone, ogni estrazione casuale restituisce sia l'altezza X che il peso Y: si ha un'**applicazione dallo spazio dei campioni a una coppia ordinata** $(X(\omega), Y(\omega))$.

Definizione: Coppia di variabili aleatorie

Dato uno spazio di probabilità (Ω, F, P), una **coppia di variabili aleatorie** (X, Y) è un'applicazione:

$$\omega \mapsto (X(\omega), Y(\omega)) \in X \times Y$$

dove X e Y sono gli alfabeti (insiemi di valori possibili) di X e Y rispettivamente.

PMF congiunta

Definizione: PMF congiunta

La **PMF congiunta** di (X, Y) è la tabella:

$$p_{XY}(x, y) = P(X = x, Y = y), \quad \forall x \in X, y \in Y$$

Questa tabella ha $|X| \times |Y|$ entrate, tutte non negative, la cui somma è 1:

$$\sum_{x \in X} \sum_{y \in Y} p_{XY}(x, y) = 1$$

Esempio: due variabili binarie

$X_1, X_2 \in \{0, 1\}$. La tabella seguente è una PMF congiunta valida:

	$X_2 = 0$	$X_2 = 1$
$X_1 = 0$	$1/4$	$1/8$
$X_1 = 1$	$1/8$	$1/2$

Verifica: $1/4 + 1/8 + 1/8 + 1/2 = 1$. ✓

---

3. Marginalizzazione

Dalla PMF congiunta si ricavano le PMF delle singole variabili, dette **PMF marginali**:

$$p_X(x) = \sum_{y \in Y} p_{XY}(x, y), \qquad p_Y(y) = \sum_{x \in X} p_{XY}(x, y)$$

Dimostrazione: L'evento $\{X = x\}$ è l'unione disgiunta degli eventi $\{X = x, Y = y\}$ al variare di y. Per l'assioma di additività di Kolmogorov: $P(X = x) = \sum_y P(X = x, Y = y)$.

Asimmetria congiunta ↔ marginali

- Congiunta **implica** marginali: data la PMF congiunta, le marginali sono univocamente determinate (per somma).
- Marginali **non implicano** congiunta: date le due PMF marginali, esistono in generale molte congiunte compatibili con esse.

L'unica eccezione è il caso di indipendenza statistica (vedi §4).

4. Indipendenza statistica

Definizione: Indipendenza statistica

Due variabili aleatorie X e Y sono **statisticamente indipendenti** se e solo se la loro PMF congiunta si fattorizza nel prodotto delle marginali:

$$p_{XY}(x, y) = p_X(x) \cdot p_Y(y), \quad \forall x \in X, y \in Y$$

Equivalentemente: conoscere il valore assunto da X non modifica la distribuzione di probabilità di Y e viceversa.

Altezza e peso: variabili dipendenti

Altezza e peso non sono indipendenti: se so che una persona è alta 1,70 m, la distribuzione del peso condizionata è diversa dalla distribuzione marginale del peso. La probabilità congiunta che una persona sia alta 1,70 m **e** pesi 40 kg non è il prodotto delle probabilità marginali.

Verifica sull'esempio binario

Dalle marginali: $p_{X_1}(0) = 1/4 + 1/8 = 3/8$, $p_{X_2}(0) = 1/4 + 1/8 = 3/8$.

Se fossero indipendenti: $p_{X_1X_2}(0, 0) = 3/8 \cdot 3/8 = 9/64 \neq 1/4$.

Quindi X_1 e X_2 non sono indipendenti in questo esempio.

5. PMF condizionale

Definizione: PMF condizionale

La **PMF condizionale di** X **dato** Y è:

$$p_{X|Y}(x|y) = P(X = x \mid Y = y) = \frac{p_{XY}(x, y)}{p_Y(y)}, \quad \text{per ogni } y \text{ con } p_Y(y) > 0$$

Proprietà: Per ogni y fissato, $\sum_{x \in \mathcal{X}} p_{X|Y}(x|y) = 1$ (è una legge di probabilità). La somma su tutti i valori di y non è necessariamente 1.

⚠ Organizzazione della tabella condizionale

Nella tabella $p_{X|Y}(x|y)$: la **somma per colonne** (condizionamento fisso) fa 1. La **somma per righe** (condizionamento varia) non fa 1.

PMF condizionale sull'esempio binario

$p_{X_2}(0) = 3/8$, $p_{X_2}(1) = 5/8$.

	$X_2 = 0$	$X_2 = 1$
$p_{X_1 | X_2}(0 \cdot)$		
$p_{X_1 | X_2}(1 \cdot)$		

Colonne: $2/3 + 1/3 = 1$ ✓, $1/5 + 4/5 = 1$ ✓. Righe: $2/3 + 1/5 = 13/15 \neq 1$.

Relazione con l'indipendenza: Se X e Y sono indipendenti, allora $p_{X|Y}(x|y) = p_X(x)$: conoscere Y non modifica la distribuzione di X.

6. Estensione a n-uple di variabili aleatorie

Il caso di due variabili si generalizza naturalmente.

Definizione: PMF congiunta di ordine n

Date n variabili aleatorie $X_1, X_2, \dots, X_n$ con alfabeti $\mathcal{X}_1, \dots, \mathcal{X}_n$, la PMF congiunta è:

$$p_{X_1 \cdots X_n}(x_1, \dots, x_n) = P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n)$$

È una tabella di $|\mathcal{X}_1| \times \cdots \times |\mathcal{X}_n|$ numeri non negativi che si sommano a 1.

Marginalizzazione gerarchica: Una PMF di ordine n implica tutte le PMF di ordine inferiore. Sommando su tutti i valori di X_k, si ottiene la PMF congiunta delle restanti $n - 1$ variabili.

La gerarchia va solo verso il basso

La conoscenza di ordine n implica la conoscenza di ordine $n-1$, $n-2$, ..., fino a 1. Non vale il contrario: le marginali di ordine inferiore non determinano quella di ordine superiore (salvo indipendenza).

7. Esempio: terne di bit

Due leggi di probabilità per terne binarie

Si considerano tre variabili aleatorie binarie $X_1, X_2, X_3 \in \{0, 1\}$, con $p \in (0, 1)$.

Prima legge (sorgente senza memoria):

$$p_{X_1X_2X_3}(x_1, x_2, x_3) = p^k(1-p)^{3-k}$$

dove k è il numero di 1 nella terna. In questa legge i tre bit sono **indipendenti**: la probabilità di ogni terna è il prodotto delle probabilità dei singoli bit (p per 1, $1-p$ per 0).

Seconda legge (bit di parità):
Le terne con numero dispari di 1 hanno probabilità 0. Le terne con numero pari di 1 hanno probabilità $p^k(1-p)^{2-k}$ (per $k = 0, 2$).

In questa seconda legge, X_3 è il **bit di parità** dei primi due: è deterministicamente uguale a $X_1 \oplus X_2$. I bit X_1 e X_2 sono indipendenti, ma X_3 è dipendente dagli altri due.

Entrambe le leggi hanno le stesse marginali: $p_{X_i}(0) = 1-p$, $p_{X_i}(1) = p$ per $i = 1, 2, 3$. Eppure modellano fenomeni radicalmente diversi.

Questo esempio mostra concretamente che scegliere una legge di probabilità congiunta significa **modellare un fenomeno fisico** specifico. Leggi diverse con le stesse marginali corrispondono a fenomeni diversi.

8. Regola della catena e marginalizzazione come media

Regola della catena

Per tre variabili aleatorie:

$$p_{XYZ}(x, y, z) = p_Z(z) \cdot p_{Y|Z}(y|z) \cdot p_{X|YZ}(x|y, z)$$

e analogamente per ogni permutazione degli indici. La regola si generalizza a n variabili.

Marginalizzazione come media statistica

Si può riscrivere la marginalizzazione come:

$$p_X(x) = \sum_{y \in Y} p_{X|Y}(x|y) \cdot p_Y(y) = E_Y[p_{X|Y}(x|Y)]$$

Cioè, la PMF marginale di X è la **media rispetto a** Y della PMF condizionale di X dato Y. Questo punto di vista ha applicazioni importanti nella teoria delle code e nei processi di Poisson (da approfondire).

Punti chiave della lezione

- Una coppia di variabili aleatorie è caratterizzata dalla PMF congiunta: una tabella di $|X| \times |Y|$ numeri non negativi che sommano a 1.
- Dalla congiunta si ricavano le marginali per somma (marginalizzazione). Il viceversa non vale in generale.
- Due variabili sono indipendenti se e solo se la congiunta si fattorizza nel prodotto delle marginali.
- La PMF condizionale $p_{X|Y}(x|y)$ è una legge di probabilità per Y fisso, non per tutte le coppie (x, y).
- Una PMF di ordine n implica tutte le PMF di ordine inferiore; una caratterizzazione di ordine superiore implica quelle di ordine inferiore.

Prossimi argomenti

- [ ] Esercizi sulla PMF congiunta (urna con reinserimento/senza)
- [ ] Canale binario simmetrico: probabilità di errore e legge di Bayes
- [ ] Entropia di una variabile aleatoria e concetto di informazione
- [ ] Catene di Markov e indipendenza condizionale

#MSP #PMF-congiunta #marginalizzazione #indipendenza #variabili-multiple #probabilita

00 - Obsidian Notes/2° Anno/2° Semestre/Metodi Statistici dell' Informazione/Lezione 7.md

Lezione 7: Canale Binario Simmetrico, Entropia e Esercizi su PMF Congiunta

Corso: Modelli Statistici e Probabilità

Argomenti trattati

- Canale binario simmetrico: modello, probabilità di errore, legge di Bayes
- Caso peggiore del canale: $\varepsilon = 1/2$

- Introduzione all'entropia e al concetto di informazione (Claude Shannon)
- PMF condizionale e proprietà di marginalizzazione come media
- Regola della catena per tre variabili aleatorie
- Indipendenza condizionale e catene di Markov (cenni)
- Esercizi: urna con due estrazioni, dado onesto e dado truccato

---

1. Canale binario simmetrico (BSC)

Modello

Un **canale di comunicazione** trasferisce un bit X (input) a una destinazione come bit Y (output). Il canale introduce errori con probabilità ε: con probabilità $1 - \varepsilon$ il bit è ricevuto correttamente, con probabilità ε è invertito.

Il canale è detto **simmetrico** perché il comportamento è identico per $X = 0$ e $X = 1$:

$$p_{Y|X}(0|0) = p_{Y|X}(1|1) = 1 - \varepsilon$$

$$p_{Y|X}(1|0) = p_{Y|X}(0|1) = \varepsilon$$

```
    1-ε
0 ──────────→ 0
│    ε  ↗
└──────────
    ε  ↗
1 ──────────→ 1
    1-ε
```

Probabilità di errore

Sia $P(X = 1) = p$, quindi $P(X = 0) = 1 - p$.

Per la legge della probabilità totale:

$$P(\text{errore}) = P(Y \neq X) = P(Y \neq X|X = 0) \cdot P(X = 0) + P(Y \neq X|X = 1) \cdot P(X = 1)$$

$$= \varepsilon(1 - p) + \varepsilon p = \varepsilon$$

Risultato: probabilità di errore nel BSC

In un canale binario simmetrico, la probabilità di errore è esattamente ε, indipendentemente dalla distribuzione dell'input. Il parametro ε è la **frazione di bit trasferiti incorrettamente**.

Inferenza: qual è il bit trasmesso?

Data $Y = 0$, qual è la probabilità che $X = 0$? (Legge di Bayes)

$$P(X = 0|Y = 0) = \frac{P(Y = 0|X = 0) \cdot P(X = 0)}{P(Y = 0)}$$

Il denominatore si calcola con la legge della probabilità totale:

$$P(Y = 0) = P(Y = 0|X = 0) \cdot P(X = 0) + P(Y = 0|X = 1) \cdot P(X = 1) = (1 - \varepsilon)(1 - p) + \varepsilon p$$

Quindi:

$$P(X = 0|Y = 0) = \frac{(1 - \varepsilon)(1 - p)}{(1 - \varepsilon)(1 - p) + \varepsilon p}$$

Il caso peggiore: $\varepsilon = 1/2$

Potrebbe sembrare che il caso peggiore sia $\varepsilon = 1$ (tutti i bit invertiti). Ma se $\varepsilon = 1$, il canale è ancora determinisitco: basta invertire il bit ricevuto.

Il caso peggiore è quando **osservare l'uscita non dà informazioni sull'ingresso**, cioè quando la probabilità a posteriori è uguale a quella a priori:

$$P(X = 0|Y = 0) = P(X = 0)$$

Questo accade quando $\varepsilon = 1/2$: il canale produce rumore puro, e Y è completamente indipendente da X.

Definizione: caso peggiore del BSC

Il caso peggiore per il canale binario simmetrico è $\varepsilon = 1/2$: osservare l'uscita non fornisce alcuna informazione sull'ingresso.

---

2. Entropia e informazione (introduzione)

Misura dell'informazione

L'informazione ricevuta quando si osserva un evento A di probabilità $P(A)$ deve soddisfare tre proprietà di senso comune:

1. **Non negativa**: $I(A) \geq 0$ (non si mente).
2. **Decrescente nella probabilità**: più raro l'evento, più informazione porta.
3. **Additiva per eventi indipendenti**: $I(A \cap B) = I(A) + I(B)$ se $A \perp B$.

L'unica funzione che soddisfa tutte e tre è:

$$I(A) = \log_2 \frac{1}{P(A)} = -\log_2 P(A)$$

La base 2 fa sì che l'unità sia il **bit** (unità di misura dell'informazione).

Casi limite

- Evento certo ($P(A) = 1$): $I(A) = \log_2 1 = 0$ (nessuna informazione: "il Sole sorgerà domani").
- Evento impossibile ($P(A) = 0$): $I(A) \to \infty$ (informazione infinita: "il Sole non sorgerà domani").

Entropia di una variabile aleatoria

Dato che la quantità di informazione $I(X = x) = \log_2 \frac{1}{p_X(x)}$ è essa stessa una variabile aleatoria, si definisce l'**entropia** come la sua media statistica:

Definizione: Entropia

L'entropia di una variabile aleatoria discreta X con PMF p_X è:

$$H(X) = E\left[\log_2 \frac{1}{p_X(X)}\right] = \sum_{x \in \mathcal{X}} p_X(x) \log_2 \frac{1}{p_X(x)}$$

Si misura in **bit**.

Entropia di una variabile Bernoulliana

Per $X \in \{0, 1\}$ con $P(X = 1) = p$:

$$H(X) = p \log_2 \frac{1}{p} + (1 - p) \log_2 \frac{1}{1 - p}$$

Proprietà: $0 \leq H(X) \leq 1$, con $H(X) = 1$ se e solo se $p = 1/2$.

Implicazione per i file compressi

Una variabile Bernoulliana porta al più 1 bit di informazione, e esattamente 1 bit solo quando $p = 1/2$ (i due valori sono equiprobabili). Un file compresso idealmente è una sequenza binaria in cui 0 e 1 sono equiprobabili e statisticamente indipendenti: questa è la condizione di massima complessità informazionale.

Entropia di una variabile quaternaria uniforme

Per $X \in \{1, 2, 3, 4\}$ con $p_X(x) = 1/4$ per ogni x:

$$H(X) = 4 \cdot \frac{1}{4} \log_2 4 = \log_2 4 = 2 \text{ bit}$$

Una variabile quaternaria equiprobabile porta 2 bit di informazione, coerentemente con il fatto che 4 valori si codificano con 2 bit binari.

> **Quote**
>
> "Una variabile bistabile trasporta una quantità di informazione che è al più un bit."

3. PMF condizionale e marginalizzazione come media

Ricapitolo

La PMF condizionale di X dato Y è:

$$p_{X|Y}(x|y) = \frac{p_{XY}(x, y)}{p_Y(y)}$$

Per ogni y fissato, è una legge di probabilità su X.

Marginalizzazione come media

Riscrivendo la proprietà di marginalizzazione:

$$p_X(x) = \sum_y p_{XY}(x, y) = \sum_y p_{X|Y}(x|y) \cdot p_Y(y) = E_Y[p_{X|Y}(x|Y)]$$

Cioè: **la PMF marginale di X è la media (rispetto a Y) della PMF condizionale di X dato Y.** Questo offre un modo alternativo di calcolare le marginali, utile quando la struttura condizionale è più facile da specificare rispetto a quella congiunta.

4. Regola della catena

Per tre variabili aleatorie X, Y, Z:

$$p_{XYZ}(x, y, z) = p_Z(z) \cdot p_{Y|Z}(y|z) \cdot p_{X|YZ}(x|y, z)$$

e tutte le permutazioni degli indici sono valide.

> **Uso nell'esercizio del dado**
>
> Nell'esercizio con dado onesto e dado truccato si è usata la legge della catena:

$$P(X_1 = 6, X_2 = 6|\text{onesto}) = P(X_1 = 6|\text{onesto}) \cdot P(X_2 = 6|X_1 = 6, \text{onesto})$$

Dove il secondo fattore vale $1/6$ (stesso dado, $X_1 = 6$ è pari $\rightarrow$ non si cambia dado).

5. Indipendenza condizionale e catene di Markov (cenni)

Definizione: Indipendenza condizionale

X_1 e X_3 sono **condizionalmente indipendenti dato** X_2 se:

$$p_{X_1X_3|X_2}(x_1, x_3|x_2) = p_{X_1|X_2}(x_1|x_2) \cdot p_{X_3|X_2}(x_3|x_2)$$

Questo è diverso dall'indipendenza (marginale): X_1 e X_3 possono essere dipendenti, ma diventano indipendenti una volta noto X_2.

Mosse del re su una scacchiera

La posizione del re alla mossa 1 (X_1) e alla mossa 3 (X_3) sono dipendenti: se il re è in un angolo al tempo 1, non può essere lontano al tempo 3. Tuttavia, nota la posizione al tempo 2 (X_2), la posizione al tempo 3 dipende solo da X_2 e non più da X_1. Quindi X_1 e X_3 sono condizionalmente indipendenti dato X_2.

Quando vale questa proprietà, la terna (X_1, X_2, X_3) è detta **catena di Markov**. Questa struttura è alla base della teoria delle code e dei processi stocastici in generale.

6. Esercizio: urna con due estrazioni senza reinserimento

Setup: urna con 6 palline — 1 marcata "1", 2 marcate "2", 3 marcate "3". Due estrazioni senza reinserimento. X_1 = risultato prima estrazione, X_2 = risultato seconda estrazione.

PMF marginale di X_1

$$p_{X_1}(1) = \frac{1}{6}, \quad p_{X_1}(2) = \frac{2}{6} = \frac{1}{3}, \quad p_{X_1}(3) = \frac{3}{6} = \frac{1}{2}$$

PMF congiunta

Si usa la regola della probabilità composta: $p_{X_1X_2}(x_1, x_2) = p_{X_1}(x_1) \cdot p_{X_2|X_1}(x_2|x_1)$.

Le probabilità condizionali $p_{X_2|X_1}(x_2|x_1)$ si calcolano ricordando che si lavora **senza reinserimento**: estratta x_1, rimangono 5 palline.

	$X_2 = 1$	$X_2 = 2$	$X_2 = 3$
$X_1 = 1$	0	$\frac{1}{6} \cdot \frac{2}{5} = \frac{1}{15}$	$\frac{1}{6} \cdot \frac{3}{5} = \frac{1}{10}$
$X_1 = 2$	$\frac{1}{3} \cdot \frac{1}{5} = \frac{1}{15}$	$\frac{1}{3} \cdot \frac{1}{5} = \frac{1}{15}$	$\frac{1}{3} \cdot \frac{3}{5} = \frac{1}{5}$
$X_1 = 3$	$\frac{1}{2} \cdot \frac{1}{5} = \frac{1}{10}$	$\frac{1}{2} \cdot \frac{2}{5} = \frac{1}{5}$	$\frac{1}{2} \cdot \frac{2}{5} = \frac{1}{5}$

Verifica della somma

$$0 + \frac{1}{15} + \frac{1}{10} + \frac{1}{15} + \frac{1}{15} + \frac{1}{5} + \frac{1}{10} + \frac{1}{5} + \frac{1}{5} = 1 \checkmark$$

PMF condizionale $p_{X_2|X_1}$

Organizzata per righe (condizionamento = valore di X_1):

	$X_2 = 1$	$X_2 = 2$	$X_2 = 3$	**Somma**
$X_1 = 1$	0	$2/5$	$3/5$	$1 \checkmark$
$X_1 = 2$	$1/5$	$1/5$	$3/5$	$1 \checkmark$
$X_1 = 3$	$1/5$	$2/5$	$2/5$	$1 \checkmark$

Attenzione alla costruzione della tabella condizionale

Il condizionamento è X_1: le righe sommano a 1, le colonne no. Non confondere le righe con le colonne quando si costruisce la tabella.

7. Esercizio: dado onesto e dado truccato

Setup: bussolotto con un dado onesto e uno truccato ($P(6|\text{truccato}) = 1/2$, $P(i|\text{truccato}) = 1/10$ per $i \neq 6$). Si estrae un dado casualmente (prob. $1/2$ ciascuno), si lancia, se il risultato è pari si rilancia lo stesso dado, se dispari si cambia dado.

Distribuzione del dado truccato

$P(6|\text{truccato}) = 5 \cdot P(i|\text{truccato}) = 5p$. Normalizzazione: $5p + 5p = 1 \Rightarrow p = 1/10$.

$$P(i|\text{truccato}) = \begin{cases} 1/2 & i = 6 \\ 1/10 & i \in \{1, 2, 3, 4, 5\} \end{cases}$$

Calcolo di $P(X_1 = 6, X_2 = 6)$

Per la legge della probabilità totale (condizionando sul dado estratto):

$$P(X_1 = 6, X_2 = 6) = \frac{1}{2} P(X_1 = 6, X_2 = 6 | \text{onesto}) + \frac{1}{2} P(X_1 = 6, X_2 = 6 | \text{truccato})$$

- Dado onesto: $P(X_1 = 6|\text{onesto}) = 1/6$. Dato $X_1 = 6$ (pari), si rilancia lo stesso dado: $P(X_2 = 6|X_1 = 6, \text{onesto}) = 1/6$. Contributo: $1/6 \cdot 1/6 = 1/36$.
- Dado truccato: $P(X_1 = 6|\text{truccato}) = 1/2$. Dato $X_1 = 6$ (pari), si rilancia lo stesso dado: $P(X_2 = 6|X_1 = 6, \text{truccato}) = 1/2$. Contributo: $1/2 \cdot 1/2 = 1/4$.

$$P(6, 6) = \frac{1}{2} \cdot \frac{1}{36} + \frac{1}{2} \cdot \frac{1}{4} = \frac{1}{72} + \frac{1}{8} = \frac{1+9}{72} = \frac{10}{72} = \frac{5}{36}$$

Calcolo di $P(X_1 = 6, X_2 = 5)$

- Dado onesto: $P(X_1 = 6|\text{onesto}) = 1/6$. Dato $X_1 = 6$ (pari), si rilancia lo stesso dado: $P(X_2 = 5|X_1 = 6, \text{onesto}) = 1/6$. Contributo: $1/36$.
- Dado truccato: $P(X_1 = 6|\text{truccato}) = 1/2$. Dato $X_1 = 6$ (pari), si rilancia il dado truccato: $P(X_2 = 5|X_1 = 6, \text{truccato}) = 1/10$. Contributo: $1/2 \cdot 1/10 = 1/20$.

$$P(6, 5) = \frac{1}{2} \cdot \frac{1}{36} + \frac{1}{2} \cdot \frac{1}{20} = \frac{1}{72} + \frac{1}{40}$$

Confronto: $P(6, 5)$ vs. $P(5, 6)$

Asimmetria della coppia $(6, 5)$ vs $(5, 6)$

Per il calcolo di $P(X_1 = 5, X_2 = 6)$: dato $X_1 = 5$ (dispari), si **cambia dado**. Quindi, se il primo dado era onesto, il secondo è truccato (e viceversa). Questo cambia radicalmente le probabilità:

- Dado onesto primo: $P(X_1 = 5|\text{onesto}) = 1/6$. Dato $X_1 = 5$ (dispari), si usa il dado truccato: $P(X_2 = 6|\text{truccato}) = 1/2$. Contributo: $1/6 \cdot 1/2 = 1/12$.
- Dado truccato primo: $P(X_1 = 5|\text{truccato}) = 1/10$. Dato $X_1 = 5$ (dispari), si usa il dado onesto: $P(X_2 = 6|\text{onesto}) = 1/6$. Contributo: $1/10 \cdot 1/6 = 1/60$.

$$P(5, 6) = \frac{1}{2} \cdot \frac{1}{12} + \frac{1}{2} \cdot \frac{1}{60} \neq P(6, 5)$$

La PMF congiunta **non è simmetrica**: $P(6, 5) \neq P(5, 6)$. La regola "pari $\rightarrow$ stesso dado, dispari $\rightarrow$ cambia dado" rompe la simmetria.

Punti chiave della lezione

- Nel canale binario simmetrico la probabilità di errore è ε indipendentemente dall'input; il caso peggiore è $\varepsilon = 1/2$ (l'uscita non dà informazioni sull'ingresso).
- L'entropia $H(X) = E[\log_2(1/p_X(X))]$ misura la quantità media di informazione in bit; per una variabile Bernoulliana vale al più 1 bit, raggiunto con $p = 1/2$.
- La PMF marginale è la media della PMF condizionale rispetto alla variabile condizionante.
- L'indipendenza condizionale (e le catene di Markov) è un concetto distinto dall'indipendenza marginale.
- Negli esercizi probabilistici complessi, condizionare su un evento ausiliario (legge della probabilità totale) e applicare la regola della catena sistematicamente porta alla soluzione.

Prossimi argomenti

- [ ] Esercizio 3 della raccolta (da svolgere autonomamente)
- [ ] Approfondimento sulla teoria dell'informazione e sulla compressione
- [ ] Processi di Poisson e catene di Markov
- [ ] Nota: prossima lezione martedì (auguri di Pasqua)

#MSP #canale-binario #entropia #informazione #PMF-condizionale #Bayes #esercizi