

Calcolo combinatorio	k: $ A^{\{k\}} = n(n-1)(n-k+1)$ k: $ A_{\{k\}} = n^k$: $n! = A = 2^n$		
Probabilità totale in una PMF	$p_X(x) = \sum_{m=1}^{ M } (E_m) p_{\{X E_m\}}(x), \{i=1\}^m E_i = (E_i E_j = , i j \{1,...,m\})$		
Probabilità Condizionata / Legge di Bayes	$p_X(x)p_{\{Y X\}}(y x) = p_{\{X,Y\}}(x,y) = p_Y(y)p_{\{X Y\}}(x y) p_{\{X Y\}}(x y) =$		
Variabili indipendenti	$p_{\{Y X\}}(y x) = p_Y(y) p_{\{X Y\}}(x y) = p_X(x) f_{\{X,Y\}}(x,y) = f_X(x)f_Y(y) F_{\{X,Y\}}(x,y)=F_X(x)F_Y(y)$		
Regola della Catena	$p_{\{X,Y,Z\}}(x,y,z) = p_X(x)p_{\{Y X\}}(y x)p_{\{Z X,Y\}}(z x,y) p_{\{i=1\}}^n p_{\{X_i X_{\{i-1\}},X_1\}}(x_i x_{\{i-1\}},x_1)$		
Linearità della Media	$[aX + bY] = a[X] + b[Y] = \sum_i a_i [X_i]$		
Media Condizionata (1 var)	$[X] = \sum_{m=1}^{ M } (E_m) [X E_m] p_{\{X E_m\}}(x) = \sum_{m=1}^{ M } (E_m)[X E_m]$		
Media Condizionata (2 var) / Teorema della media condizionata	$[g(X,Y)] = \sum_y p_Y(y) \sum_x g(x,y)p_{\{X Y\}}(x y) =$		
Media di funzioni	$[g(X)] = \sum_x g(x)p_X(x)$		
Quantità importanti (1 var)	$X_{\{rms\}}^2 = [X^2] = \sum_x x^2 p_X(x) X^2 = X_{\{rms\}}^2 - X^2$		
Quantità importanti (2 var)	$R_{\{X,Y\}} = [XY] COV[X,Y] = [(X-X)(Y-Y)] = R_{\{X,Y\}} - X_Y COV(X,Y)=\{X,Y\}_XY, p_{\{X,Y\}}=p_Xp_Y COV=0$		
Combinazione lineare (2 var)	$Z = aX+bY+c, Z^2 = a^2X^2+b^2Y^2+2ab, COV(X,Y)$		
Disuguaglianza di Chebyshev	$X>0, \{ X-X k_X \} -$		
PMF/pdf Congiunta $\Rightarrow$ marginali	$p_X(x) = \sum_y p_{\{X,Y\}}(x,y) f_X(x) = \sum_y f_{\{X,Y\}}(x,y), dy$		
Funzione gen. Momenti $M_X(s)$	$M_X(s)=e^{\{sX\}} M_X(0)=1 M_X(s) \{s=0\}=[X_r] M_{\{X_n\}}(s)M_X(s) X_nX$		
Nome	PMF	2	Proprietà
Uniforme discreta $X=\{0,,M-1\}$	$p(k)=$	$= 2=$	
Bernoulli $X=\{0,1\}$	$p(k)=$	$=p^2=p(1-p)$	$I=, I_n=$
Binomiale $XB(n,p)$	$p(k)=(1-p)^{\{n-k\}}p_k$	$=np^2=np(1-p)$	
Poisson $XP()$	$p(k)=, >0$	$=2=$	

Nome	PDF	2	CDF
Uniforme continua $X \sim U(a,b)$	$f(x) = \frac{1}{b-a}$	$= \frac{1}{b-a}$	$F(x) = \frac{x-a}{b-a}$
Esponenziale $X \sim \text{Exp}(\lambda)$	$f(x) = \lambda e^{-\lambda x} u(x)$	$= \lambda$	$F(x) = (1 - e^{-\lambda x}) u(x)$
Laplaciana $X \sim \text{Lap}(\mu, \sigma)$	$f(x) = \frac{1}{2\sigma} e^{-\frac{ x-\mu }{\sigma}}$	$= \frac{1}{2\sigma}$	$F(x) = \frac{1}{2} \left(1 + e^{-\frac{ x-\mu }{\sigma}} \right)$
Cauchy $X \sim \text{Cauchy}(\mu, \sigma)$	$f(x) = \frac{1}{\pi \sigma} \frac{1}{1 + \left(\frac{x-\mu}{\sigma}\right)^2}$	$= \frac{1}{\pi \sigma}$	$F(x) = \frac{1}{\pi} \left(\arctan\left(\frac{x-\mu}{\sigma}\right) + \frac{\pi}{2} \right)$
Gaussiana $Y = g(X)$, g continua e iniettiva (invertibile) crescente	$f_X(x) = \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	$F_X(x) = \frac{1}{\sigma \sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{(t-\mu)^2}{2\sigma^2}} dt$	$(Xx) = Q^{-1}(x)$, $Q(x) = \int_{-\infty}^x f_X(t) dt$
decescente	$f_Y(y) = \frac{1}{\sigma_Y \sqrt{2\pi}} e^{-\frac{(y-\mu_Y)^2}{2\sigma_Y^2}}$	$F_Y(y) = \frac{1}{\sigma_Y \sqrt{2\pi}} \int_{-\infty}^y e^{-\frac{(t-\mu_Y)^2}{2\sigma_Y^2}} dt$	$F_Y(y) = 1 - F_X(g^{-1}(y))$
non invertibile (somma su tutte le preimmagini $x_i(y)$)	$f_Y(y) = \sum_i f_X(x_i(y))$	$f_Y(y) = \sum_i f_X(x_i(y))$	—

Matrice di covarianza $\mathbf{K}_X$: $\mathbf{K}_X := \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu}_X)(\mathbf{X} - \boldsymbol{\mu}_X)^T]$ — caso generale
 n -dim: $\mathbf{K}_X = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu}_X)(\mathbf{X} - \boldsymbol{\mu}_X)^T]$, matrice $n \times n$ simmetrica, con $\sigma_{X_i}^2$
 $\sup > 2$ in diagonale e $\text{COV}(X_i, X_j)$ fuori diagonale.

Proprietà della matrice di covarianza $\mathbf{K}_X$: $|\mathbf{K}_X| = \sigma_1^2 \sigma_2^2 (1 - \rho_{1,2}^2) \geq 0$. Se $\rho_{1,2} = \pm 1$: $|\mathbf{K}_X| = 0$.
 $\begin{pmatrix} \sigma_1^2 & \sigma_1 \sigma_2 \rho_{1,2} \\ \sigma_1 \sigma_2 \rho_{1,2} & \sigma_2^2 \end{pmatrix}$ — caso
 M -dim: $\mathbf{K}_X = \frac{1}{M} \sum_{i=1}^M (\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^T$ (definita non negativa).

pdf congiunta Gaussiana: $f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{M/2} |\Sigma|^{1/2}} \exp\left[-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu})\right]$ — caso
 M -dim: $f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{M/2} |\Sigma|^{1/2}} \exp\left[-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu})\right]$.

Chiusura Gaussiana per trasformazioni lineari: $\mathbf{X} \sim N(\boldsymbol{\mu}_X, \mathbf{K}_X) \Rightarrow \mathbf{Z} = \mathbf{A}\mathbf{X} + \mathbf{b} \sim N(\mathbf{A}\boldsymbol{\mu}_X + \mathbf{b}, \mathbf{A}\mathbf{K}_X\mathbf{A}^T)$. Incorrelazione $\Rightarrow$ indipendenza solo per variabili congiuntamente Gaussiane. Incorrelazione (matrice di covarianza diagonale) $\Rightarrow$ indipendenza statistica per vettori/processi Gaussiani.

Derivata del Prodotto	$[f(x)g(x)]' = f'(x)g(x) + f(x)g'(x)$	
Derivata del Rapporto	$=$	
Regola della Catena	$f[g(x)]' = f'[g(x)]g'(x)$	
Integrazione generale	$\int f[g(x)]g'(x)dx = F[g(x)] + c$	
Integrazione per parti	$\int f(x)g(x)dx = F(x)g(x) - \int F(x)g'(x)dx$	
Funzione Gamma	$\Gamma(n) = \int_0^{\infty} t^{n-1} e^{-t} dt = (n-1)! \quad n \in \mathbb{N}$	
Somme dei primi n numeri	$\sum_{i=1}^n i = \frac{n(n+1)}{2}$	
Serie geometrica	$\sum_{i=0}^{\infty} p^i = \frac{1}{1-p} \quad (p < 1)$	
Funzione	Derivata	Integrale
x^n	nx^{n-1}	$\frac{x^n}{n} + c, n \neq 0$
e^x	e^x	$e^x + c$
a^x	$a^x \ln a$	$\frac{a^x}{\ln a} + c$
$\ln(x)$	$\frac{1}{x}$	$\ln x + c$
$\frac{1}{x}$	$-\frac{1}{x^2}$	$-\ln x + c$
	-	$\int \frac{1}{x} dx = \ln x + c$

pdf e CDF di Esponenziale, Laplaciana e Cauchy
pdf e CDF di Esponenziale, Laplaciana e Cauchy

Media e Autocorrelazione	$E[X(t)] = \mu_X$ $R_X(t_1, t_2) = E[X(t_1)X(t_2)]$
Stazionarietà stretta (ordine M)	$\{X(t_1), \dots, X(t_M)\} \stackrel{d}{=} \{X(t_1+h), \dots, X(t_M+h)\}$
Stazionarietà in Senso Lato (SSL)	$E[X(t)] = \mu_X$ $R_X(t_1, t_2) = R_X(t_2 - t_1)$
Matrice di covarianza (processo SSL)	$C_X(t_1, t_2) = R_X(t_1, t_2) - \mu_X^2$
Processo Gaussiano	
Tipi di convergenza (dalla più debole alla più forte)	Convergenza puntuale: $\lim_{n \rightarrow \infty} F_n(x) = F(x)$ Convergenza in distribuzione: $\lim_{n \rightarrow \infty} F_n(x) = F(x)$
Bias/unbias	$E[(X_n - \mu)^2] = \sigma^2$

unbias/corretto asintotico	$E[\hat{\theta}_n] = \theta$	
Consistenza in probabilità	$P(\hat{\theta}_n - \theta > \epsilon) \rightarrow 0, \epsilon > 0$	
Consistenza in media quadratica	$E[\hat{\theta}_n - \theta]^2 \rightarrow 0, E[(\hat{\theta}_n - \theta)^2] (= \text{Var}(\hat{\theta}_n))$	
Consistenza forte	$\hat{\theta}_n \rightarrow \theta$	
Informazione di Fisher	$I_n = -E[\frac{\partial^2 \log L(\theta)}{\partial \theta^2}]$	
Limite di Cramér-Rao	$\text{Var}[\hat{\theta}_n] \geq \frac{1}{I_n}$	
Tipo inf	Cose note	Regola decisione/Stimatore
Decisione Bayesiana	$\hat{\theta}_n = \arg \min_{\theta} \sum_{j=1}^M C_{ij} P_{ij}(\theta)$	$D(\hat{\theta}_n) = \{X_n = x_n, H_i\} > \{X_n = x_n, H_j\} \text{ ji}$ — 2 ipotesi: $L(x_n) =$
Neyman-Pearson	$\hat{\theta}_n = \{L(x_n) > \tau\} = \{L(x_n) > \tau\}$	$L(x_n) = \tau, : \{L(x_n) > \tau\} =$
Stima Bayesiana parametro continuo	$f_{\theta X}(x_n) = p_{\theta}(x_n) f_{X \theta}(x_n)$ $p_{\theta}(x_n) = \int p_{\theta}(x_n) d\theta$ $= [C((X_n) - \theta)]_{\theta=x_n}$	$\{opt\}(x_n) = C((x_n) - \theta) f_{\theta X}(x_n)$ $C(x) = x^2 \{mmse\}(x_n) = [X^n = x_n]$ $C(x) = (x/\{map\}(x_n) = f_{\theta X}(x_n)$
Non Bayes (ML)	—	$\{ML\}(x_n) = (f_{\theta X}(x_n)) \{f_{\theta X}(x_n)\}$ $\{f_{\theta X}(x_n)\} = 0$
Bernoulli (stima frequenza)	$w(x_n) =$	$\{ML\}(x_n) = I_n(0) = \text{CRB} =$
Stimatore LMMSE (lineare)	$(X_n) = TX_n + b, \{LMMSE\} = \{1\}, b\{LMMSE\} = [1] - T[X_n] (= \text{COV}(X_n), = [(X_n - [X_n])(- [1])])$	
Algoritmo del gradiente	$\{n+1\} = \{n\} - \{n\} \cdot \{n\}, <<$	
Stimatore ai Minimi Quadrati (LS)	$\{LS\} = (T)^{-1} T p_n$	
Formula di Sherman-Morrison	$(+T)^{-1} = \{1\} -$	
LS esponenzialmente pesato (adattivo)	$= \{1\}_i w^{\{p-i\}} n(i)(i), w < 1$	
LMS generale (con intercetta, dati centrati)	$\{LMS\} = (0_0^T)^{-1} 0_0, b\{LMS\} = -1 p p^T T \{LMS\}, 0 = -p^T$	

NOTA: Se in uno stimatore Bayesiano $C(\cdot) \geq 0$ è convessa e pari, e $f_{\theta|X} > 0$ è simmetrica rispetto a $E[\theta|X < \sup > n = x < \sup > n]$, allora tutti gli stimatori che ottimizzano $C(\cdot)$ coincidono: $\hat{\theta}_{mmse}(X < \sup > n) = \hat{\theta}_{map}(X^n)$.

NOTA: l'applicazione di una funzione monotona crescente (es. il logaritmo naturale) a entrambi i lati di un test/disequazione non ne altera il verso né l'ottimalità (consente il passaggio a log-verosimiglianza).